基于多尺度状态空间模型和自适应频域滤波的医学图像分割

摘　要

医学图像分割是现代精准医疗与计算机辅助诊断中的关键技术，其精度直接影响临床诊疗决策。然而，医学图像中普遍存在的目标尺度多样性以及边界模糊、信息丢失等问题，严重制约了现有分割方法的性能。针对上述挑战，本文提出了SAF-Mamba 模型，该模型结合多尺度视觉状态空间（Multi-Scale Visual State Space, MSVSS）模块与自适应滤波器模块（Adaptive Filter Block, AFB），分别应对尺度变化与边界细化两大核心难题。MSVSS 模块通过并行多尺度深度卷积分支、通道整合与校准机制，有效捕获不同尺度目标的特征表示；AFB 模块则利用自适应滤波器生成器（AF Generator）在频域中动态调制特征，增强边界细节的保留。在 ACDC 心脏磁共振数据集上，本文方法取得了 92.21% 的 Dice 相似系数（Dice Similarity Coefficient, DSC）和 1.05 mm 的 95% 豪斯多夫距离（95% Hausdorff Distance, HD95）；在 M&Ms 多中心、多厂商心脏分割数据集上，取得了 88.43% 的 DSC 和 12.14 mm 的 HD95，均优于基于卷积神经网络（Convolutional Neural Network, CNN）、Transformer 及 Mamba 的现有方法，验证了本文方法的有效性与泛化能力。

关键词：医学图像分割；Mamba；状态空间模型；多尺度特征；自适应频域滤波

Medical Image Segmentation Based on Multi-Scale Mamba and Adaptive Frequency Filtering

ABSTRACT

Medical image segmentation is a key technology in modern precision medicine and computer-aided diagnosis, and its accuracy directly affects clinical decision-making. However, the widespread problems of target scale diversity, boundary blurring, and information loss in medical images seriously restrict the performance of existing segmentation methods. To address these challenges, this thesis proposes the SAF-Mamba model, which combines the Multi-Scale Visual State Space (MSVSS) module and the Adaptive Filter Block (AFB) to tackle the two core problems of scale variation and boundary refinement. The MSVSS module effectively captures feature representations of targets at different scales through parallel multi-scale depth-wise convolution branches, channel integration, and calibration mechanisms. The AFB module uses an Adaptive Filter Generator to dynamically modulate features in the frequency domain, enhancing the preservation of boundary details. On the ACDC cardiac MRI dataset, the proposed method achieves a Dice Similarity Coefficient (DSC) of 92.21% and a 95% Hausdorff Distance (HD95) of 1.05 mm. On the M&Ms multi-center, multi-vendor cardiac segmentation dataset, it achieves 88.43% DSC and 12.14 mm HD95, outperforming existing CNN-based, Transformer-based, and Mamba-based methods, validating the effectiveness and generalization capability of the proposed approach.

Key words: Medical image segmentation; Mamba; State space model; Multi-scale features; Adaptive frequency filtering

目录

摘　要 I
ABSTRACT II
第一章　绪论 1
1.1　研究背景及意义 1
1.2　国内外研究现状 2
1.2.1　基于传统方法的医学图像分割技术 3
1.2.2　基于深度学习的医学图像分割技术 4
1.3　研究目标及内容 5
1.4　本文的组织结构 6
第二章　相关理论与技术基础 7
2.1　卷积神经网络基础 7
2.2　状态空间模型理论 9
2.2.1　结构化状态空间模型 9
2.2.2　Mamba 模型与选择性机制 10
2.2.3　视觉状态空间模块 11
2.3　频域图像分析理论 12
2.3.1　二维离散傅里叶变换的频域表征 12
2.3.2　频域滤波器设计与空间细节恢复 12
2.4　本章小结 12
第三章　基于自适应频域滤波的医学图像分割 13
3.1　自适应频域滤波模块 14
3.1.1　总体设计思路 14
3.1.2　特征频域映射 15
3.1.3　频域特征调制 16
3.2　自适应滤波器生成器 16
3.3　基于自适应频域滤波的医学图像分割网络 18
3.4　实验与分析 19
3.4.1　实验数据 19
3.4.2　评价指标 21
3.4.3　实验设置 22
3.4.4　实验结果与分析 23
3.5　本章小结 29

第四章　基于多尺度状态空间模型的医学图像分割 30
4.1　尺度变化挑战与多尺度感知策略 30
4.2　多尺度视觉状态空间模块 30
4.2.1　并行多尺度深度卷积分支 30
4.2.2　通道整合与特征校准机制 31
4.2.3　基于共享参数的视觉状态空间建模 31
4.3　基于多尺度状态空间模型的医学图像分割框架 31
4.4　实验与分析 33
4.4.1　实验数据与预处理 33
4.4.2　评价指标 33
4.4.3　实验设置 33
4.4.4　对比实验 33
4.4.5　分割结果的可视化分析 35
4.5　本章小结 35
第四章　基于自适应频域滤波的医学图像分割 36
5.1　下采样过程中的高频信息丢失问题 36
5.2　自适应滤波器模块 36
5.2.1　自适应滤波器生成器 37
5.2.2　频域调制与特征重构 37
5.3　实验与分析 38
5.3.1　实验设置 38
5.3.2　对比实验 38
5.3.3　消融实验 39
5.3.4　自适应滤波器基的频域可视化分析 39
5.3.5　基于皮肤病灶分割的泛化能力验证 40
5.4　本章小结 40
第五章　总结与展望 41
6.1　工作总结 41
6.2　未来展望 41
6.3　本章小结 42
参考文献 42
致谢 45

第一章　绪论

本章首先阐述医学图像分割的研究背景及意义，接着对国内外研究现状进行系统性梳理，并介绍本文的研究目标与主要内容，最后概述全文的组织结构。

1.1 研究背景及意义

国务院办公厅印发的《“十四五”国民健康规划》明确指出：“要把保障人民健康放在优先发展的战略位置，全面推进健康中国建设是实现中华民族伟大复兴的重要基础”[1]。随着国家对国民健康事业的高度重视以及人民健康意识的持续提升，医学影像技术作为现代医学的重要组成部分，正迎来前所未有的发展机遇。以磁共振成像（Magnetic Resonance Imaging, MRI）、计算机断层扫描（Computed Tomography, CT）、X 射线（X-ray）以及超声（Ultrasound, US）为代表的高端成像设备，如图 1.1 中呈现的不同医学影像技术所示，它们使得医生能够以非侵入式、直观且高清晰度的方式探查人体内部复杂的解剖结构与潜在病灶。这不仅显著提高了疾病诊断的准确性，也为各类重大疾病的提早甄别与干预争取了极为宝贵的治疗时间 [2]。

然而，随着高分辨率医疗设备的加速普及，医学影像数据呈现出爆炸式增长。传统的人工分析方法依赖资深放射科医师进行人工阅片与影像判读，逐渐暴露出分析效率受限、精度易受主观经验与视觉疲劳干扰等问题 [3]。特别是面对复杂多变且对比度较低的软组织图像时，专家人工评估的可靠性和一致性面临着巨大挑战。随着计算机技术的不断进步，早期基于图像处理与数学模型的计算机辅助诊断方法开始进入医学影像分析领域，在一定程度上缓解了人工阅片的压力。然而，这类方法依赖手工设计的特征与规则，面对结构复杂、变异多端的真实临床数据，泛化能力有限。近年来，深度学习凭借其自动特征学习能力，逐渐成为医学影像智能化分析的主流技术路线，推动了图像分割精度与自动化程度的大幅提升。

自动医学图像分割是医学图像分析中一个关键的研究领域。其主要目标在于利用计算机视觉技术，从复杂的扫描背景中识别并剥离出感兴趣区域，如：解剖结构、特定脏器或病理组织等，从而为后续的体积测量、病理性质分析及三维重建等奠定像素级的基础。作为现代精准医疗与计算机辅助诊断的核心环节，其临床应用价值主要体现在以下三个维度：

精准诊断：自动图像分割能够帮助医生从混杂的解剖背景中定量提取出器官与病变区域。通过精确测量病灶在三维或二维空间的体积、形态和拓扑结构，能够大幅提升病理判断分期的客观性与可靠性。治疗规划：在放射治疗或外科手术

干预的筹备阶段，术前精确描绘的病变靶区能够为医疗机器人或放疗系统提供三维“导航图”。这要求算法不仅能在摧毁恶性组织的同时最大程度避开周围正常脏器以减少副作用，更直接关系到患者的生存质量。术后监测：通过对患者随访周期的海量影像进行连续自动化分割，医生能够高频度、定量化追踪病灶的变化轨迹（如复发、缩小或向周围组织浸润）。这对于动态调整化疗靶向方案及客观评估预后疗效具有高度的科学依据价值。尽管深层人工神经网络在自动化医学图像分割领域取得了突破性进展，但在真实世界高度复杂的临床场景中，当前主流的视觉预测算法依然面临着两大长期悬而未决的共性学术难题：

第一，目标尺度多样性挑战。人体的形态解剖学结构极其复杂，即便得到自同一成像设备、身处同一张医学切片中，不同解剖部位或病灶的物理尺寸也常常存在跨越数量级的悬殊差异。例如，在心脏磁共振图像中，左右心室腔的广阔区域与纤薄微小的心肌壁形成了强烈的尺度对比；而在皮肤显微图像中，早期细小溃疡与晚期弥散性红斑也常常共处于同一视野。现有的多种深层网络模型在特征提取阶段，往往受限于单一且固定的感受野，缺乏显式的跨尺度融合感知机制。这直接导致算法在微小靶区极易发生结构性漏分或像素断裂，而在大面积靶区则易受到局部杂讯干扰从而丢失整体的拓扑连贯性。

第二，边界高频信息丢失与组织粘连挑战。受限于软组织相近的物理射线吸收率或磁共振弛豫时间，加之受限于成像设备的固有热噪声与伪相分辨率，医学影像中许多关键器官或病灶的边缘往往呈现出严重模糊甚至与毗邻组织大面积粘连的表象。更为致命的是，目前主流的图像深度学习模型，为了提取全局高阶语义特征同时压缩空间计算量，普遍采用逐层池化或带有步幅的大核卷积来进行特征下采样。这一信号降频过程，会以不可逆的方式物理级抹除并抛弃蕴藏着图像纹理及其边缘几何形状的高频有效特征。当网络在解码重建阶段试图仅凭残留的低频语义来还原受损的高频空间信息时，往往心有余而力不足。最终输出的预测掩码在边缘处不够紧密贴合真实解剖结构，伴随着令人难以接受的锯齿和粗糙过平滑伪影，这在容错率极低的临床应用场景中是无法接受的。

综上所述，针对医学图像分割任务中长久存在的目标尺度多样性与边界高频特征丢失这两大顽固痛点，探索并设计一种同时兼顾大感受野多尺度捕捉能力以及具备频域自适应高频边界增强约束的新型网络框架，具有十分重要的前沿理论探索价值和迫切的临床落地需求。

1.2 国内外研究现状

医学图像分割技术的发展经历了从传统算法到深度学习方法的演进。本节对相关技术进行系统性梳理，为后文提出的方法奠定研究坐标。

1.2.1 基于传统方法的医学图像分割技术

传统分割技术在很长一段时间内一直是医学图像分析的基础，这些方法主要依赖于预定义的规则和图像强度。传统方法的优势在于其较高的计算效率与可解释性，但在处理包含高噪声、剧烈强度变化或边界模糊的复杂医学图像时，其性能往往会受到限制。根据现有文献的分类，传统医学图像分割方法主要可分为以下五大类：

阈值分割技术 (Thresholding Techniques) 的核心是将灰度图像转换为二值图像，通过设定阈值将像素划分为目标前景或背景。阈值分割主要分为全局阈值法和局部阈值法两种。全局阈值法使用单一、恒定的阈值，适用于前景与背景灰度分布差异明显的图像，经典算法包括通过最大化类间方差来寻找最佳阈值的 Otsu 法、迭代阈值法、最小误差阈值法（Kittler-Illingworth 法）以及基于熵的阈值法。然而，全局阈值法对于由阴影或定向光照等因素导致的光照不均的复杂场景效果不佳，这种情况下可以采用局部阈值法。局部算法通过分析每个像素局部邻域内的统计特征，如亮度、对比度等，来动态分配阈值，代表性方法包括 Niblack 算法、在低纹理背景下对 Niblack 法进行了改进的 Sauvola 算法以及利用局部对比度区分高低对比度区域的 Bernsen 算法。

基于边缘的分割 (Edge-Based Segmentation) 方法也是一种直观的方式。边缘是两个同质区域之间的边界，表现为图像亮度的局部变化。基于边缘的分割通常包括图像预处理、边缘检测、非极大值抑制、阈值化以及后处理等步骤。该方法广泛使用一阶或二阶微分算子来提取边缘的梯度或曲率信息。常见的一阶微分算子包括 Roberts 算子、Prewitt 算子、Sobel 算子和 Canny 算子。其中，Roberts 算子计算简单、速度快，但对噪声极为敏感；Prewitt 和 Sobel 算子对邻域像素进行差分，具有较好的噪声抑制能力；Canny 算子则通过多阶段处理实现了高精度的边缘定位和出色的噪声抑制，但计算复杂度较高。二阶微分算子对图像细节敏感，通常结合高斯平滑来缓解噪声的干扰，用来实现更精确的边缘定位。

基于区域的分割方法 (Region-Based Segmentation) 主要依赖于像素在颜色、亮度、纹理间的相似性以及空间邻近性，将图像划分为具有相似属性的多个区域。其中最主要的算法有种子区域生长法（Seeded Region Growing, SRG）和分裂合并法（Split and Merge）。

聚类分割 (Clustering-Based Segmentation) 旨在将具有相似特征的像素归入同一簇中，使位于同一簇内的元素相似度最大化，不同簇之间的差异性最大化。聚类方法可划分为层次聚类（Hierarchical Clustering）和划分聚类（Partitional Clustering）。层次聚类通过构建自底向上的凝聚型或自顶向下的分裂型树状图（树状结构）来完成聚类。但层次聚类采用贪心策略，一旦分配便无法纠正，且不优化任何目标

函数，较高的时间复杂度在处理高维医学图像时面临极大挑战。划分聚类则通过优化目标函数来最小化簇内相似度。常见的划分聚类算法包括软聚类（如模糊 C 均值聚类，FCM）和硬聚类（如 K 均值算法）。划分聚类能够迭代提升聚类质量，但对初始条件、噪声以及异常值较为敏感。

基于图的分割方法 (Graph-Based Segmentation) 将图像映射为图结构，其中顶点代表图像像素或区域，边代表相邻顶点间的关系，边的权重用于量化顶点间的某种属性或相似度,。图像分割即转化为图的划分问题。主要的技术包括最小生成树（MST，如 Kruskal 和 Prim 算法）和图割法（Graph Cuts）。在图割法中，图像被转换为包含源节点和汇节点的 s-t 图，并通过 n-links（邻域像素间）和 t-links（终端节点间）来评估像素归属，具体衍生出最小割、归一化割（Ncut）等多种代价函数优化策略,,。此外，该领域还包括马尔可夫随机场（MRF，通过最大后验概率估计进行像素标记并融入局部先验信息）以及最短路径方法（如 Dijkstra 或 Bellman-Ford 算法）。

综上所述，传统医学图像分割技术通过明确的数学模型与规则，为疾病诊断和治疗规划提供了重要的早期解决方案。然而，面对现代医学成像中普遍存在的噪声干扰、边界模糊以及复杂的个体异质性，传统方法难以应对。这一局限性也为后续基于深度学习的自动化特征提取技术的崛起提供了明确的驱动力。

1.2.2 基于深度学习的医学图像分割技术

深度学习直接从数据中学习到重要的结构和其内在联系的特征，并使用端到端的方式将结果进行呈现，因为更快的处理速度和更高的分割精度而成为了目前的主流方法。其在语义分割领域的突破是由于全卷积网络（Fully Convolutional Networks, FCN）的提出。卷积神经网络（CNN）由于在网络末端使用全连接层进行图像级分类而导致空间信息的丢失，针对这一问题 FCN 开创性地移除了全连接层，使网络能够接收任意尺寸的图像并输出像素级别的密集预测，解决了语义分割的核心问题。在 FCN 的基础上，Ronneberger 等人于 2015 年提出的专门针对医学图像的 U-Net 模型确立了医学图像分割中经典的编码器-解码器（Encoder-Decoder）范式。U-Net 引入了跳跃连接（Skip Connections），它将编码器中包含丰富空间定位信息的浅层特征，直接与解码器中包含高级语义信息的深层特征进行拼接融合。这种设计有效弥补了下采样过程中的空间信息丢失，使得模型在有限的医学标注数据上也能实现精准的边缘定位和目标分割。

随着医学图像任务复杂度的增加，在 U-Net 的基础上衍生出了两大主流改进方向，即基于 CNN 的改进模型与基于 Transformer 的模型。UNet++ 在 U-Net 的基础上引入了嵌套的 U 型结构和密集跳跃连接，允许网络在不同的深度和尺度上聚

合特征，从而有效缩小了编码器和解码器之间的语义鸿沟。此外，为了让模型更加关注病灶区域，Attention U-Net 在跳跃连接中引入了注意力门，使网络能够隐式地抑制无关的背景区域，同时突出显示与分割任务高度相关的感兴趣区域。尽管这些 CNN 变体性能优异，但由于卷积操作固有的感受野受限问题，它们难以对图像中的长距离像素建立依赖关系和全局上下文建模。为了克服 CNN 感受野的局限性，具有全局建模能力的 Transformer 被引入医学视觉领域。TransUNet 构建了 CNN 与 Transformer 的混合编码器，这种设计既保留了 CNN 的局部纹理感知力，又弥补了长距离建模的不足。随后提出的 Swin-Unet 则构建了首个纯 Transformer 的 U 型架构，摒弃了卷积操作，使用具有层次化结构的 Swin Transformer 作为主干，并通过移位窗口机制在局部窗口内计算自注意力，在捕获全局特征的同时降低了传统 Transformer 的计算复杂度。尽管 Transformer 在全局建模上具有显著优势，但其模型中核心的自注意力机制的计算复杂度会随着图像空间分辨率呈平方级增长。这导致其在处理高分辨率或 3D 医学图像时面临极高的计算开销和内存消耗瓶颈。

为了解决 CNN 局部感受野受限以及 Transformer 计算复杂度过高的问题，状态空间模型（State Space Models, SSMs），特别是最新的 Mamba 架构，正作为一种新兴的序列建模方法在视觉任务中受到广泛关注。Mamba 模型在结构化状态空间模型（Structured State Space Model, S4）的基础上引入了输入依赖的动态选择机制（Selection Mechanism）和硬件感知（Hardware-aware）的并行扫描算法，实现了线性复杂度的长序列建模。VMamba 将 Mamba 扩展至视觉任务，提出视觉状态空间（Visual State Space, VSS）模块，通过多方向扫描策略缓解一维序列与二维图像之间的方向敏感性。在医学图像分割领域，器官或病灶往往跨越极大的空间范围，Mamba 的出现完美契合了医学图像对高分辨率和全局上下文的双重需求。Mamba-UNet 将 VSS 模块嵌入 U-Net 架构，在医学图像分割任务上展现出优异性能。Mamba 为解决复杂医学图像分割提供了一个极具前景的新型基座架构，本研究在 Mamba-Unet 的基础上开展了进一步的探索。

1.3 研究目标及内容

针对医学图像分割中的尺度变化与边界模糊两大挑战，本文的研究目标是设计一个基于状态空间模型的高效、通用分割框架，并完成以下研究内容：

（1）设计多尺度视觉状态空间（MSVSS）模块，通过并行多尺度深度卷积分支、通道整合与校准机制，捕获不同尺度目标的特征表示，增强模型对尺度变化的敏感性。

（2）构建自适应滤波器模块（AFB），利用快速傅里叶变换（Fast Fourier Trans-

form, FFT）将特征映射至频域，通过自适应滤波器生成器动态调制频率分量，增强边界细节并抑制噪声，最后经逆傅里叶变换（Inverse FFT, IFFT）重构空间特征。

（3）将 MSVSS 与 AFB 集成于 U 型编码器-解码器架构，形成完整的 SAF-Mamba 网络，在编码器各阶段嵌入 MSVSS 模块，在跳跃连接中引入 AFB 模块。

（4）在 ACDC、M&Ms 等公开心脏分割数据集上进行实验，通过对比实验、消融实验与可视化分析，验证方法的有效性与泛化能力。

1.4 本文的组织结构

本文共分为五章，各章内容安排如下：

第一章为绪论，阐述医学图像分割的研究背景、意义及国内外研究现状，并明确研究目标与内容。

第二章介绍相关理论与技术基础，包括卷积神经网络、状态空间模型与频域图像分析理论，为后续方法章节提供理论铺垫。

第三章介绍基于自适应频域滤波的图像特征提取方法，重点阐述自适应频域滤波模块（AFB）的设计原理与细节。

第四章详细阐述基于多尺度状态空间模型的医学图像分割方法，包括多尺度视觉状态空间（MSVSS）模块的设计与完整 SAF-Mamba 架构，并综合验证其性能。

第五章对全文工作进行总结，并展望未来研究方向。

第二章　相关理论与技术基础

本章为后续方法章节中出现的所有关键技术概念提供详尽的理论铺垫，包括卷积神经网络基础、状态空间模型理论以及频域图像分析理论。

2.1 卷积神经网络基础

卷积神经网络（Convolutional Neural Networks, CNNs）是计算机视觉领域，尤其是语义分割任务中的核心基石。从生物学视角来看，CNN 的构建受自然视觉感受机制的启发，特别是 Hubel 和 Wiesel 对动物视觉皮层接收区光线检测功能的研究，为模拟人类视觉感知的层级化处理奠定了生物学基础。CNN 的基本结构包括卷积层、池化层、激活函数和损失函数，以及反向传播机制。

（1）卷积层（Convolutional Layer）

卷积操作是神经网络提取特征表征的核心手段，其本质是通过滑动窗口机制与权重共享策略，在输入特征图上实现局部空间特征的函数映射。在医疗影像分割等高精度需求场景下，卷积变体的选择与设计直接影响模型对解剖结构边界的捕获能力。设输入特征图为 $\mathbf{X} \in \mathbb{R}^{H \times W \times C}$，卷积核为 $\mathbf{K} \in \mathbb{R}^{k \times k \times C}$，则卷积操作可表示为：

$$\mathbf{Y}(i,j) = \sum_{m,n} \mathbf{K}(m,n) \cdot \mathbf{X}(i+m, j+n) \tag{2-1}$$

不同尺寸的卷积核对应不同的感受野，$k \times k$ 卷积核的感受野为 $k \times k$ 像素。感受野决定了网络每一层输出特征图上的像素点在原图上映射的区域大小，是理解多尺度特征提取的关键概念。常规卷积依靠局部连接与空间权重共享，能够高效捕获图像中的纹理、边缘等空间特征，实现特征提取的平移不变性。转置卷积（Transposed Convolution）作为实现上采样的关键手段，通过建立一对多的映射关系恢复特征分辨率，然而由于在计算中对输入矩阵进行填零扩大，核函数在滑动过程中往往产生非均匀重叠，导致输出图像出现明显的”棋盘效应”（Checkerboard Effect），在医疗影像中常表现为类间边界的锯齿状伪影，限制了边缘分割精度。空洞卷积（Dilated Convolution）通过引入扩张率（Dilation Rate）扩大感受野，能够在不增加参数负担的前提下捕捉多尺度上下文信息，但过大的扩张率会导致”网格效应”（Gridding Effect），造成局部像素相关性的丢失。可变形卷积（Deformable Convolution）针对标准卷积核固定几何形状的局限，通过学习额外的偏移量（Offset）来动态调整采样位置，对医疗影像中形状极不规则的组织器官或病灶边界展现了更强的建模灵活

性，显著提升了复杂语义边界的拟合能力。深度可分离卷积（Depth-wise Separable Convolution）将标准卷积分解为逐通道卷积与逐点卷积，在保持表达能力的同时显著降低参数量与计算量，被广泛应用于 MobileNet、EfficientNet 等轻量化架构中，亦为本文 MSVSS 模块中并行多尺度深度卷积的设计提供了效率保障。

（2）池化层（Pooling Layer）

池化层作为典型的下采样操作，其战略职能在于压缩特征图的空间维度，在减少参数冗余的同时，维持网络对输入信号在平移与尺度上的鲁棒性。设局部感受野窗口为 $\mathcal{R}_{i,j}$，最大池化与平均池化分别定义为：

$$\mathbf{P}_{\text{max}}(i,j) = \max_{(m,n)\in\mathcal{R}_{i,j}} \mathbf{X}(m,n) \tag{2-2}$$

$$\mathbf{P}_{\text{avg}}(i,j) = \frac{1}{|\mathcal{R}_{i,j}|} \sum_{(m,n)\in\mathcal{R}_{i,j}} \mathbf{X}(m,n) \tag{2-3}$$

最大池化侧重于提取局部区域内最显著的判别性特征，适用于识别高亮或明显的组织特征；平均池化则更倾向于保留整体背景的统计特性，维持语义信息的平滑性。借鉴 Dropout 的正则化思想，混合池化通过随机切换池化策略增强网络的泛化表现；随机池化则基于元素值的大小设定选取概率，确保非显著特征也有贡献权重的可能，有效缓解过拟合现象。池化后的特征需经非线性激活函数（如 ReLU、Softmax 等）转换，以构建复杂的非凸决策边界，最终由损失函数量化模型预测与真实标签之间的偏差。

（3）损失函数（Loss Function）

损失函数作为量化指标，直接定义了模型参数优化的目标空间，指导梯度下降算法的演进方向。均方误差（Mean Squared Error, MSE）通过计算预测值与真实值差值的平方和来衡量偏差，设预测值为 $\hat{y}_i$、真实值为 y_i，其定义为：

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2 \tag{2-4}$$

其数学性质优良，有利于梯度平滑收敛，但平方项的权重分配使其对离群点（Outliers）极度敏感，容易导致训练过程受极端样本干扰。交叉熵损失（Cross Entropy, CE）基于信息论背景，设 p_i 为真实分布、q_i 为预测概率分布，其定义为：

$$\mathcal{L}_{\text{CE}} = -\sum_{i=1}^{C} p_i \log q_i \tag{2-5}$$

CE 衡量了预测概率分布与真实分布之间的 KL 散度，在语义分割等多分类任务中与 Softmax 函数耦合使用时展现出显著的收敛优势，能够有效避免梯度饱和现象，是目前像素级密集预测任务的主导损失函数。

（4）反向传播（Backpropagation）

反向传播算法是神经网络实现自我进化的核心逻辑，其运行基于多元复合函数求导的链式法则。设网络第 l 层的损失梯度为 $\delta^{(l)}$，则链式法则给出：

$$\delta^{(l)} = \frac{\partial \mathcal{L}}{\partial \mathbf{z}^{(l)}} = \left(\mathbf{W}^{(l+1)\top}\delta^{(l+1)}\right) \odot \sigma'\left(\mathbf{z}^{(l)}\right) \tag{2-6}$$

其中 $\mathbf{z}^{(l)}$ 为第 l 层的线性激活值，$\sigma'(\cdot)$ 为激活函数的导数，$\odot$ 表示逐元素乘法。通过逐层计算损失函数对权重和偏置的梯度，权重 $\mathbf{W}^{(l)}$ 按梯度下降规则更新：

$$\mathbf{W}^{(l)} \leftarrow \mathbf{W}^{(l)} - \eta \cdot \frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(l)}} \tag{2-7}$$

其中 η 为学习率。该机制的目标在于通过最小化损失函数，使网络预测值持续逼近真实标签（Ground Truth）。然而，在医疗影像处理实践中，传统编码器-解码器结构在经历多层离散下采样与上采样恢复后，高分辨率边缘信息往往发生不可逆的衰减。这种基于离散网格的局限性，正是本研究引入自适应频域滤波模块（AFB）的动因，以期在频域层面弥补边界高频信息的损失。

2.2 状态空间模型理论

Transformer 凭借自注意力机制实现了强大的全局建模能力，但生成长度为 L 的序列需要约 $\mathcal{O}(L^2)$ 的计算量，在处理高分辨率医学影像的长序列时面临严重的算力瓶颈。循环神经网络（Recurrent Neural Network, RNN）虽以 $\mathcal{O}(L)$ 线性复杂度实现推理，却因隐状态的有限压缩容量而导致长程遗忘，且难以并行训练。状态空间模型（State Space Models, SSMs）结合了两者优点，训练阶段采用卷积并行化加速，推理阶段采用递归表示获得线性复杂度，为长序列特征建模提供了新范式。

2.2.1 结构化状态空间模型

SSM 的核心源于经典控制理论中的线性动力系统。给定连续输入信号 $x(t)$，模型通过 N 维隐含状态 $\mathbf{h}(t)$ 将其映射到输出 $y(t)$，连续时间系统由如下常微分方程

描述：

$$\begin{aligned}\mathbf{h}'(t) &= \mathbf{A}\mathbf{h}(t) + \mathbf{B}x(t) \\ y(t) &= \mathbf{C}\mathbf{h}(t) + \mathbf{D}x(t)\end{aligned} \tag{2-8}$$

其中，$\mathbf{A} \in \mathbb{R}^{N\times N}$ 为状态转移矩阵，**B**、**C**、**D** 为投影参数。由于实际输入为离散序列（如图像像素序列），需引入步长参数 Δ（代表输入分辨率），通过零阶保持（Zero-Order Hold, ZOH）技术将连续系统离散化：

$$\bar{\mathbf{A}} = \exp(\Delta\mathbf{A}), \quad \bar{\mathbf{B}} = (\Delta\mathbf{A})^{-1}(\exp(\Delta\mathbf{A}) - \mathbf{I}) \cdot \Delta\mathbf{B} \tag{2-9}$$

离散化后，系统可在两种表示间切换：在递归表示（Recurrent Representation）下，$\mathbf{h}_k = \bar{\mathbf{A}}\mathbf{h}_{k-1} + \bar{\mathbf{B}}x_k$，$y_k = \mathbf{C}\mathbf{h}_k$，推理复杂度为 $\mathcal{O}(L)$；在卷积表示（Convolutional Representation）下，输出可通过全局卷积核 $\bar{\mathbf{K}} = (\mathbf{C}\bar{\mathbf{B}}, \mathbf{C}\bar{\mathbf{A}}\bar{\mathbf{B}}, \ldots)$ 与输入做并行卷积计算，训练可充分利用 GPU 并行性。这种训练-推理双模态的设计是 SSM 的核心竞争力。S4（Structured State Space for Sequences）模型进一步将 HiPPO（High-order Polynomial Projection Operators）引入 **A** 矩阵的初始化，使隐状态能够以 Legendre 多项式系数的形式压缩历史信息，显著增强对长程依赖的捕捉能力。然而，S4 的参数 **A**、**B**、**C** 对所有时间步保持固定，属于线性时不变（Linear Time Invariant, LTI）系统，无法根据当前输入内容动态调整，难以应对内容感知型任务（如病灶选择性关注）。

2.2.2 Mamba 模型与选择性机制

Mamba 通过引入选择性扫描机制（Selective Scan, S6），将传统 SSM 从线性时不变系统升级为内容感知的动态系统。S4 中参数 **B**、**C**、Δ 对所有输入 token 保持不变，导致模型无法区分重要信息与冗余背景。Mamba 的关键创新在于令这三个参数成为当前输入 x_t 的函数：

$$\mathbf{B}_t = s_B(x_t), \quad \mathbf{C}_t = s_C(x_t), \quad \Delta_t = \text{softplus}(\text{Param} + s_\Delta(x_t)) \tag{2-10}$$

其中 s_B、s_C、s_Δ 均为可学习的线性投影。参数的输入依赖使得较大的 Δ_t 对应更多关注当前 token，而较小的 Δ_t 则倾向于忽略当前输入、更多沿用历史隐状态，从而实现对信息的选择性压缩。由于参数动态化后无法使用固定核的卷积并行，Mamba 采用并行前缀扫描（Parallel Prefix Scan）算法恢复并行性：利用关联律将扫描序列分段并行计算后迭代合并，计算复杂度维持在 $\mathcal{O}(L)$。此外，Mamba 借鉴 FlashAttention 的思路，通过内核融合（Kernel Fusion）将离散化、选择性扫描和 **C**

乘法整合为单一 CUDA 核，使中间状态直接在片上 SRAM 中完成计算，仅在必要时读写 HBM，并在反向传播时通过重计算（Recomputation）重新生成中间状态，而非保存，从而大幅降低显存占用，使 Mamba 的内存效率与 FlashAttention 相当。Mamba 块的结构以线性投影扩展输入维度，接入一维深度卷积增强局部感知后送入选择性 SSM，输出经门控激活和残差连接合并，整体弃用了自注意力机制，在长序列推理吞吐量上可达 Transformer 的数倍。

2.2.3 视觉状态空间模块

Mamba 最初面向一维序列设计，将其扩展至二维视觉特征图需解决序列化策略问题：单方向展平会引入方向敏感性，使模型对特征图不同扫描方向产生不一致响应。VMamba 提出的视觉状态空间（Visual State Space, VSS）模块通过交叉扫描（Cross-Scan, CS）策略加以解决：将二维特征图 $\mathbf{X} \in \mathbb{R}^{H \times W \times C}$ 分别沿水平正向、水平反向、垂直正向、垂直反向四个方向展平为独立的一维序列，各自经过独立 SSM 处理后再融合还原，确保每个空间位置均具备四个方向的全局感受野：

$$\mathbf{Y}_{\text{SS2D}} = \sum_{k=1}^{4} \text{Merge}(\text{SSM}_k(s_k(\mathbf{X}))) \tag{2-11}$$

VSS 模块在此交叉扫描核心之外，还集成了层归一化（Layer Normalization）、深度卷积（Depth-wise Convolution）与双路径门控流，形成完整的特征提取单元。Mamba-UNet 将纯 VSS 块嵌入对称式 U 型编码器-解码器架构：编码器通过层级化的 Patch Merging 依次将空间分辨率减半、通道数翻倍，配合连续 VSS 块提取深层语义特征；解码器采用 Patch Expanding 逐步恢复分辨率，并通过跳跃连接引入编码器对应阶段的浅层高分辨率特征，设第 i 阶段编码器输出为 $\mathbf{E}_i$、解码器上采样输出为 $\mathbf{D}_i$，其融合过程可表示为：

$$\tilde{\mathbf{D}}_i = \text{VSS}(\text{Concat}[\mathbf{E}_i,\, \mathbf{D}_i]) \tag{2-12}$$

VSS 模块在保持线性复杂度 $\mathcal{O}(L)$ 的同时，有效建模图像的全局上下文，为医学图像分割提供了兼顾效率与精度的新型特征提取范式。本文提出的 SAF-Mamba 在 Mamba-UNet 的 U 型 VSS 架构基础上，进一步于编码器各阶段引入多尺度视觉状态空间（MSVSS）模块、在跳跃连接中引入自适应频域滤波（AFB）模块，以期同时增强多尺度感知与边界细化能力。

2.3 频域图像分析理论

频域分析为理解图像特征提供了另一视角。空间域中的边缘、纹理等细节对应频域中的高频分量，而整体轮廓与平滑区域对应低频分量。在编码器-解码器结构中，下采样操作会衰减高频信息，导致边界模糊。通过在频域中对特征进行选择性增强，可有效弥补这一不足，为本文 AFB 模块的设计提供理论依据。

2.3.1 二维离散傅里叶变换的频域表征

傅里叶变换将信号从空间域映射至频率域，揭示信号的频率组成。对于二维离散信号，二维离散傅里叶变换（2D Discrete Fourier Transform, DFT）定义为：

$$F(u,v)=\sum_{h=0}^{H-1}\sum_{w=0}^{W-1}f(h,w)\cdot e^{-j2\pi\left(\frac{hu}{H}+\frac{wv}{W}\right)} \tag{2-13}$$

其中 $f(h,w)$ 为空间域像素值，$F(u,v)$ 为频域复数值。图像中高频分量对应边缘、纹理等细节信息，低频分量对应整体轮廓与平滑区域。下采样、池化等操作会衰减高频信息，导致边界模糊。

2.3.2 频域滤波器设计与空间细节恢复

高通滤波器增强高频、抑制低频，可突出边缘与细节；低通滤波器则相反，可平滑噪声但削弱细节；带通滤波器保留特定频段。传统滤波器参数固定，难以适应不同图像内容。本文提出的 AFB 通过自适应滤波器生成器，根据输入特征动态生成滤波器参数，实现高通、低通或带通的自适应切换，以更好地保留边界细节。

2.4 本章小结

本章介绍了卷积神经网络的基本原理与编码器-解码器结构，阐述了状态空间模型从 S4 到 Mamba 的发展脉络及 VSS 模块的视觉扩展方式，并概述了傅里叶变换与频域滤波的理论基础。这些技术将共同支撑本文提出的自适应频域滤波（AFB）模块与多尺度视觉状态空间（MSVSS）模块的设计与实现。下一章将在此基础上，详细阐述自适应频域滤波模块的设计思想及其应用架构。

第三章　基于自适应频域滤波的医学图像分割

心脏作为人体循环系统的核心器官，具有周期性收缩与舒张的动态非刚性形变特性。在该动态特性的影响下，临床采集的心脏磁共振（Cardiac Magnetic Resonance, CMR）图像会受到运动伪影及局部容积效应的干扰，从而导致心肌、心室及周围组织之间的解剖边界出现不同程度的模糊。此外，不同切片位置所对应的心脏结构差异进一步增加了分割任务的复杂性。如图3-1所示，以 ACDC 数据集中某患者舒张末期（End-Diastole, ED）的短轴序列为例，从心底至心尖的连续切片中可以观察到：左心室（Left Ventricle, LV）、右心室（Right Ventricle, RV）及心肌（Myocardium, MYO）之间的边界对比度逐渐降低。尤其在心脏外周结构复杂区域，由于组织密度相似性较高以及动态位移的影响，真实解剖边界与背景区域易发生混淆，从而显著增加分割难度。

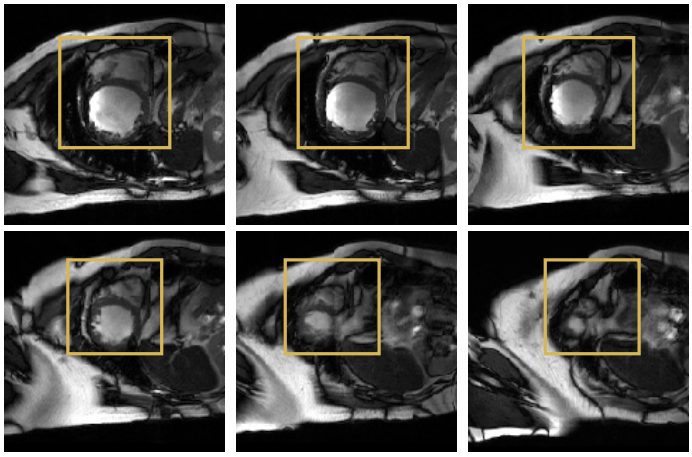

图 3-1　ACDC 数据集中沿短轴从心底向心尖的连续切片

Fig3-1　Continuous slices from base to apex along the short axis in ACDC dataset

医学图像分割任务中广泛采用的 U 型网络结构，在编码器阶段通过多次池化与下采样操作以扩大感受野，但这一过程往往伴随着空间细节信息的不可逆损失。一方面，浅层网络中所包含的关键边缘与形状信息逐渐衰减；另一方面，深层语义特征在逐级压缩过程中可能出现表达不足。这种信息损失在复杂边界区域尤为明显，易导致分割结果出现过度平滑现象，从而降低心脏子结构边界定位的精度。

针对上述问题，本章从频域分析视角开展研究。研究表明，图像的高频分量对边缘等细节信息更为敏感，低频分量主要承载全局结构与语义信息。基于此，本文提出一种基于跳跃连接（Skip Connections）的自适应滤波模块（Adaptive Filter

Block, AFB），旨在缓解编码器中细粒度特征与语义特征的流失问题。考虑到不同编码阶段特征分布存在显著差异，模块遵循数据依赖（Data-dependent）机制，能够根据输入特征的统计特性自适应地生成不同类型的频域滤波器，实现对特征的动态调制。

3.1 自适应频域滤波模块

3.1.1 总体设计思路

与图像分类任务不同，心脏结构的精确分割不仅依赖全局上下文信息的建模，还高度依赖局部纹理与边缘细节的精细刻画。频域表示能够同时刻画图像的全局与局部特征，因此本章基于频域分析设计自适应滤波模块，在保证对数线性（log-linear）计算复杂度以减轻网络的计算负担的前提下，通过引入自适应滤波器生成机制，实现对频域特征的动态调制。具体而言，该模块通过“数据依赖”思想构建自适应滤波器生成器（Adaptive Filter Generator, AFG），从输入特征中学习得到动态权重，并对一组预定义的滤波器基进行加权组合，从而生成具有高通、低通或带通特性的频域滤波器。该机制能够根据输入数据分布自适应地增强高频边界信息或低频语义信息，在复杂成像条件下有效提升分割性能。

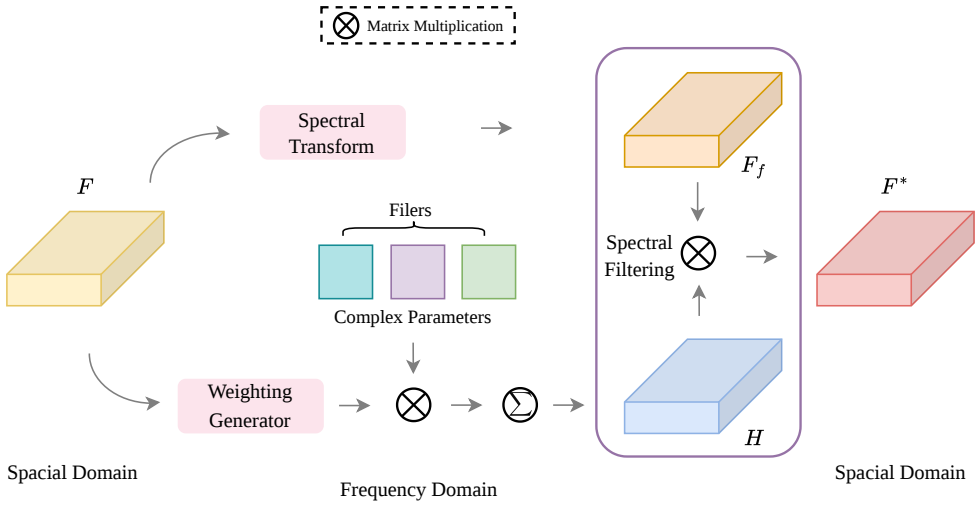

图 3-2　自适应滤波模块结构

Fig3-2　Schematic diagram of the structure of the adaptive filter block

自适应滤波模块如图3-2所示，主要包括频域变换、自适应滤波器生成以及频

域调制三个核心步骤。对于输入特征 $\mathbf{F} \in \mathbb{R}^{H\times W\times C}$，首先通过二维快速傅里叶变换（FFT）获得其频域表示 $\mathbf{F}f$。同时，自适应滤波器生成器基于输入特征学习得到权重系数 α，对滤波器基 $\mathcal{M}i$ 进行加权组合，生成动态滤波器 $\mathbf{H}$。接下来通过逐元素乘法操作 $\odot$ 对频域特征进行调制，实现对不同频率成分的选择性增强。基于跳跃连接的频域调制机制使得模块能够在不同编码阶段针对性地保留浅层高频边缘信息与深层低频语义信息，从而提升整体分割性能。

3.1.2 特征频域映射

自适应频域滤波模块（AFB）的设计基于卷积定理（Convolution Theorem），即频域中的逐点乘法等价于空间域中的循环卷积运算。该模块的具体结构和特征映射过程如图3-3所示，这一频域性质使得模型能够在具备全局感受野的频域空间中，以较低计算复杂度实现长距离特征交互。模块整体前向传播过程定义如下：

$$\mathrm{AFB}(\mathbf{X}i) = \mathrm{MLP}\left(\mathcal{F}^{-1}\left(\mathbf{F}c(\mathbf{X}i) \odot \mathcal{F}(L(\mathbf{X}i))\right)\right) + \mathbf{X}_i \tag{3-1}$$

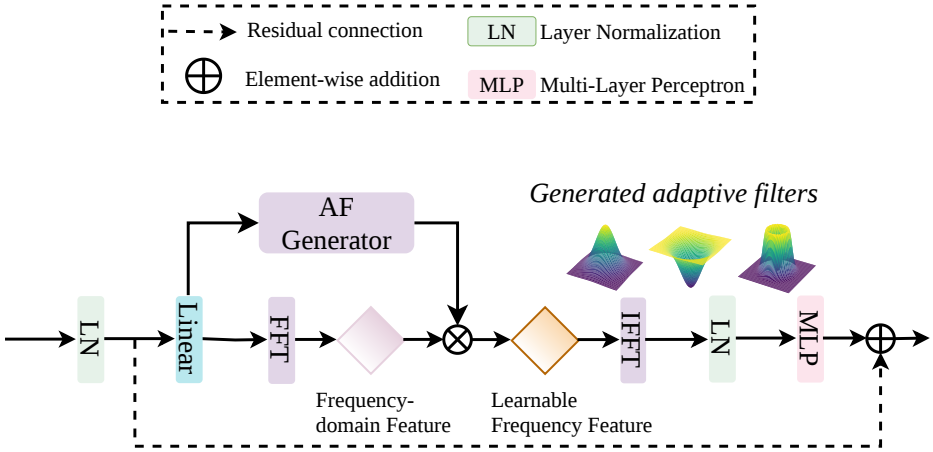

图 3-3 自适应频域滤波模块（AFB）结构与特征映射过程

Fig3-3 Structure and feature mapping process of the Adaptive Filter Block (AFB)

其中，$L(\cdot)$ 表示包括归一化与线性投影在内的预处理操作，$\mathbf{F}c(\mathbf{X}i)$ 为由自适应滤波器生成器动态生成的频域滤波器，$\mathcal{F}$ 与 $\mathcal{F}^{-1}$ 分别表示傅里叶变换及其逆变换，$\odot$ 表示逐元素乘法。重建后的空间特征通过多层感知机（MLP）进行通道融合，并通过残差连接输出。

为提升频域变换的稳定性，对于编码器第 i 阶段输出特征 $\mathbf{X}i$，首先采用层归一化（Layer Normalization）进行标准化处理。随后，通过线性投影将通道维度扩展至 $2C$，得到 $\hat{\mathbf{X}}i$。考虑到空间域大核卷积计算复杂度较高，本文采用二维快速傅里叶变换（2D FFT）将特征映射至频域，其计算复杂度为 $\mathcal{O}(HW\log(HW))$，从而实现对全局信息的高效建模。这种高效的全局信息建模在心智图像分割应用中，能够有效捕捉大脑活动的全局空间关联特性，为从复杂脑信号中准确提取有用的表征提供了强大的支持。

3.1.3 频域特征调制

生成的动态滤波器 $\mathbf{F}c$ 用于对频域特征进行逐元素调制，以抑制冗余信息并增强关键结构响应。随后，通过逆傅里叶变换将特征映射回空间域：

$$A(\hat{\mathbf{X}}i) = \mathcal{F}^{-1}\left(\mathcal{F}(\hat{\mathbf{X}}i) \odot \mathbf{F}c\right) \tag{3-2}$$

在空间域重建后，引入多层感知机以增强通道间的信息交互能力。最终，通过残差连接将输出特征与原始输入 $\mathbf{X}_i$ 相加，得到 refined 特征表示。该设计不仅有助于缓解梯度消失问题，还能够有效保留原始细节信息。对于心智图象分割应用而言，这种频域调制后联合空间通道交互及残差保留的综合机制，不仅能够精准抑制信号中的冗余混叠成分，更有效映射出心智图象的精细内容结构与空间拓扑边缘，极大地提高了由脑电/核磁等多模态数据重建出的视觉目标的保真度和分辨率。

3.2 自适应滤波器生成器

为克服传统频域方法中静态滤波器对不同输入图像特征适应性不足的问题，本文根据数据依赖（data-dependent）思想，设计了自适应滤波器生成器，其内部网络结构细节如图3-4所示。首先，在复数空间内定义了一组可学习的参数集合作为滤波器基（Filter Basis）$\mathbb{M} = \{\mathcal{M}_1, ..., \mathcal{M}_i, ..., \mathcal{M}_N\}$，其中每个基底 $\mathcal{M}_i \in \mathbb{C}^{H\times\lceil\frac{W}{2}\rceil}$ 初始化为随机的复数张量。

随后，网络通过全局平均池化（Global Average Pooling）提取输入特征的全局信息，并通过多层感知机（MLP）和 Softmax 激活函数实现通道间的信息交互，通过生成的权重向量 a 对滤波器基进行线性组合，得到动态滤波器：

$$a = MLP(\frac{\sum_{h=1}^{H}\sum_{w=1}^{W} X_{i,h,w}}{HW}) \tag{3-3}$$

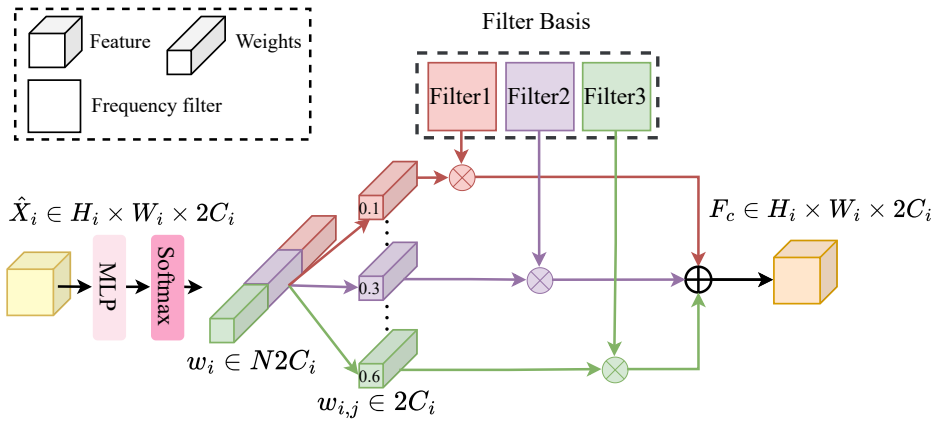

图 3-4 自适应滤波器生成器（AF Generator）详细结构

Fig3-4 Detailed structure of the Adaptive Filter Generator

其中 $a \in \mathbb{R}^{N2C}$ 为生成的权重向量。沿基底的维度 N 对多层感知机输出的原始实数值权重 $\alpha_{c,i}$ 进行 Softmax 归一化处理，计算得出归一化后的组合系数 $\hat{\alpha}_{c,i}$，具体公式如下：

$$\hat{\alpha}_{c,i} = \frac{e^{\alpha_{c,i}}}{\sum_{n=1}^{N} e^{\alpha_{c,n}}} \tag{3-4}$$

其中，$\alpha_{c,i}$ 表示作用于第 c 个通道组的第 i 个权重分量。该归一化步骤将离散的权重转化为和为 1 的概率分布形式，即 $\sum_{i=1}^{N} \hat{\alpha}_{c,i} = 1$ 且 $\hat{\alpha}_{c,i} \in (0,1)$）。不仅有效避免了网络训练过程中可能出现的梯度爆炸问题，还为后续的特征调制赋予了合理的非负值。利用计算出的归一化系数 $\hat{\alpha}_{c,i}$ 对预定义的复数参数滤波器基 $\mathbb{M}$ 进行加权求和，最终得到作用于特定通道组的自适应频域滤波器 $F_c \in \mathbb{C}^{H \times \lceil \frac{W}{2} \rceil \times 2C}$，计算公式如下：

$$F_c = \sum_{i=1}^{N} \hat{\alpha}_{c,i} \mathcal{M}_i \tag{3-5}$$

根据当前特征进行权重生成的方法实现频域滤波器从静态参数到动态生成的转变。根据当前输入的心脏图像（如不同患者、不同心动周期的形变特征）的特定数据分布，通过数据驱动的方式，对基底进行线性叠加实时合成出最适合当前特征的频域调制滤波器。本文将滤波器基的基底数 N 设置为 3，N 值过大会导致计算冗余并出现不同基底间的同质化现象；若 $N = 1$，则自适应滤波器会退化为参数固定的静态滤波器，失去数据驱动带来的自适应能力。

3.3 基于自适应频域滤波的医学图像分割网络

本章提出了基于自适应频域滤波的医学图像分割网络（Adaptive Filtering Mamba for Cardiac Image Segmentation, AF-Mamba），如图3-5所示，该网络通过整合多尺度状态空间特征提取、多阶段自适应频域滤波和渐进式层次化解码，实现高效且精准的心脏图像定位与分割。编码网络负责初步提取心脏图像的多尺度局部纹理与全局长距离依赖特征，自适应频域滤波模块（AFB）用于动态调制和提纯不同层级特征中的高低频细节，借助带有跳跃连接的对称式解码结构实现从粗到细的多尺度特征融合与医学图像重构。整个网络的解析流程如下：

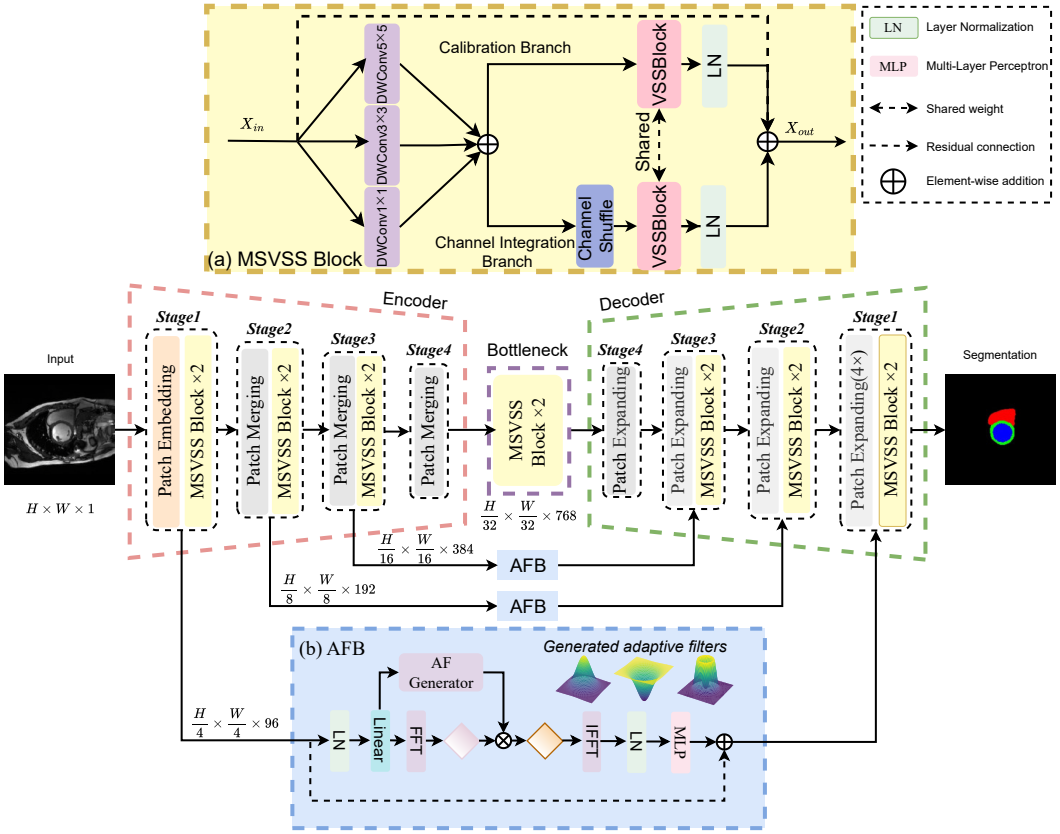

图 3-5　AF-Mamba 模型框架图

Fig3-5　Schematic diagram of the overall architecture of AF-Mamba

（1）输入二维灰度心脏图像 $I \in \mathbb{R}^{H \times W \times 1}$ 通过图像块嵌入（Patch Embedding）被划分为数量为 $\frac{H}{4} \times \frac{W}{4}$ 的非重叠块，并线性投影至 96 维高维特征空间。随后，这些特征在四个编码阶段中经由多个多尺度视觉状态空间模块（MSVSS Blocks）进行特征提取，且通过图像块合并层（Patch Merging）降低特征图空间分辨率并翻倍

通道维度，建立由浅入深的多尺度层次化特征表示。

（2）在编码器跨层特征传递的过程中，为了弥合高分辨率空间特征与低分辨率语义信息之间的“语义鸿沟”，前三个阶段输出的特征被送入自适应频域滤波模块（AFB）进行特征重标定与提纯。结合心脏图像的外周结构特点，该模块自适应构建不同的频域调制模式：在浅层阶段生成高通（High-pass）滤波器提取锐利边缘，在深层阶段生成低通（Low-pass）滤波器强化全局定位信息，有效抑制由于直接拼接带来的结构性背景噪声，得到多尺度增强后的特征表示，捕获心脏目标的精准边界依赖关系。

（3）在连续的解码与恢复阶段中，基于前述自适应特征滤波增强后的特征输出，模型依次通过图像块扩展层（Patch Expanding）对解码路径特征图进行上采样，并通过跳跃连接（Skip Connections）将其与对应的提纯特征进行拼接融合。通过渐进式的上采样重构逐步细化目标边界位置，最终在解码层末端执行四倍上采样操作，输出与原始输入尺寸完全匹配的高精度心脏图像分割掩码和预测结果。

3.4 实验与分析

3.4.1 实验数据

本文采用 ACDC 数据集和 M&Ms 数据集进行实验。ACDC (Automated Cardiac Diagnosis Challenge) 数据集来自 MICCAI 2017 的心脏自动分割挑战赛。

(1) ACDC 数据集

该数据集是为了实现对心脏动态磁共振成像（cine-MRI）中舒张末期（ED）和收缩末期（ES）的左心室（LV）、右心室（RV）以及心肌（Myo）的像素级分割。高精度的分割结果可以准确量化射血分数（EF）、心肌厚度、每搏输出量（SV）等关键生理参数，从而为心血管疾病的临床评估与治疗提供可靠依据。该数据集由法国第戎大学医院（University Hospital of Dijon）在常规临床检查中利用 1.5 T 和 3.0 T 两种不同磁场强度的西门子 MRI 扫描仪获得。成像过程采用稳态自由进动（SSFP）序列，沿短轴方向获取从心底到心尖的连续切片，单张切片的厚度为 5 mm 或 10 mm，空间分辨率在 1.37 至 1.68 mm^2/pixel 之间。为了完整反映心脏在收缩与舒张过程中的动态非刚性形变，每个心动周期包含了 28 到 40 帧连续的图像序列。该数据集共包含 150 名不同受试者的 4D NIfTI 格式数据，为全面评估分割模型在不同心脏病理结构下的泛化能力，包含下面五组不同的心脏病理情况：

- 健康对照组 (NOR)：受试者心脏结构正常，各项生理指标及心室形态均处于健康状态。

- 心肌梗死组 (MINF)：患者存在既往心肌梗死病史，临床表现为左心室射血分数低于 40%，且伴有多个局部心肌节段的收缩异常。
- 扩张型心肌病组 (DCM)：此类患者的左心室发生显著扩张，舒张期左心室容积指数超过 100 mL/m^2，同时伴随左心室射血分数下降至 40% 以下。
- 肥厚型心肌病组 (HCM)：主要病理特征为心室壁的异常增厚，在舒张期内存在多个厚度大于 15 mm 的心肌节段，且左心室质量指数高于 110 g/m^2，但其射血分数通常保持在正常水平。
- 右心室异常组 (ARV)：患者的病理特征主要集中于右心，表现为右心室腔容积指数异常增加（大于 110 mL/m^2）或右心室射血分数降低至 40% 以下。

150 例数据划分为包含 100 例患者的训练集与 50 例患者的测试集，训练集中每类 20 例，测试集中每类 10 例，以保证上述五组类型在训练与测试阶段比例均衡。标注任务由 2 名分别具有 10 年与 20 年的专家手工进行，两者均先独立完成，随后进行交叉检查，如出现不一致的情况，专家进行讨论并达成一致后进行修正。标签映射规则为：0 代表背景，1 代表右心室，2 代表心肌，3 代表左心室。本文的实验设置将训练集中的 100 例 3D MRI 数据沿短轴切分为 1400 张 2D 图像切片。按照 80% 和 20% 的比例进一步划分为模型训练集与验证集。

(2) M&Ms 数据集

为进一步验证 AF-Mamba 模型在多中心、多设备、多病理条件下的泛化能力，本文在 M&Ms (Multi-Centre, Multi-Vendor and Multi-Disease Cardiac Segmentation) 挑战赛数据集进行了实验。为了还原真实临床场景中数据分布的多样性，CMR 影像由位于西班牙、德国和加拿大三个国家的不同临床中心采集，采集使用的扫描设备来自四家磁共振扫描仪制造商，分别为西门子（Siemens）、通用电气（General Electric）、飞利浦（Philips）以及佳能（Canon）。

该数据集包含 375 例受试者的 CMR 影像，病理分布涵盖了肥厚型心肌病（HCM）患者、扩张型心肌病（DCM）患者以及健康对照组。训练集中包含 150 例数据，分别来自两家不同 MRI 设备供应商（每家 75 张），以及来自第三家供应商的 25 张未标注图像。测试集包含 200 例受试者数据。其中 100 例与训练集中的两家供应商相同（各 50 例），50 例来自训练集中仅提供未标注数据的第三家供应商，其余 50 例则是在训练阶段未出现过的第四家供应商。测试集中包含未知设备的数据，能够严苛地评估模型在域偏移（Domain Shift）情况下的鲁棒性。

M&Ms 数据集按照 ACDC MICCAI 2017 挑战赛的规范进行数据标注，标注区域包括左心室（LV）、左室心肌（MYO）以及右心室（RV），对应的像素级标签与 ACDC 数据集一致。专家在标注过程中遵循了以下解剖学规则：首先保证左心

室与右心室的腔体完整覆盖，乳头肌明确包含在心腔范围内，并且在左心室基底部分，不能进行任何心肌轮廓的插值操作。最后，从解剖学逻辑上确保右心室在舒张末期（ED）的表面积大于收缩末期（ES），进行轮廓标注时避开肺动脉区域。

3.4.2 评价指标

在深度学习中，为了定量评估模型的性能，需要建立与任务特性匹配的评价体系。在医学图像分割任务中评估一个模型的性能涉及包括参数量、运算量、推理时间和准确率等在内的多个维度，考虑到医学图像分割的现实应用场景，准确率是首要考虑因素，本节选取了医学图像分割领域普遍使用且最具代表性的两项评价指标 Dice 相似系数 (Dice Similarity Coefficient) 和 95HD(95% Hausdorff distance) 对分割结果进行评价。为了验证所提出的模型在准确性和性能之间能取得良好的平衡，本文还采用了每秒十亿次浮点运算 (Giga Floating Point Operations Per Second, GFLOPS) 来衡量模型的推理速度。

Dice 相似系数是一种度量两个集合相似度的空间重叠指标，在医学影像分割任务中主要用于计算模型预测出的分割区域与真实区域（Ground Truth）之间的空间重叠程度。其取值范围为 $[0,1]$，数值越接近 1，表示预测结果与真实标签的重叠度越高，即模型的分割性能越好；反之则分割效果越差。其数学定义如下：

$$DSC(P,G)=\frac{2|P\cap G|}{|P|+|G|} \tag{3-6}$$

其中，P 表示模型预测为目标的像素点集合，G 表示真实标签中目标的像素点集合。$|P\cap G|$ 表示预测集合与真实集合交集中的像素数量，而 $|P|$ 和 $|G|$ 分别代表预测集合和真实集合的像素总数。从混淆矩阵（Confusion Matrix）的角度来看，基于像素级的分类结果，该公式也可等效表示为：

$$DSC=\frac{2TP}{2TP+FP+FN} \tag{3-7}$$

其中，TP（True Positive）为真正例，即模型正确预测为心脏解剖结构（如左心室、右心室或心肌）的像素数；FP（False Positive）为假正例，即背景被模型误判为目标的像素数；FN（False Negative）为假反例，即目标被模型漏判为背景的像素数。在心脏图像分割中，DSC 能够直观且有效地反映模型对各心脏子结构整体区域的分割精度。

尽管 Dice 系数能够全局地评估区域重叠度，但其对局部边界的微小误差不够敏感，不能暴露出模型对心脏外周复杂形态的分割缺陷。为了评估分割边界的能

力，本文引入了豪斯多夫距离（Hausdorff Distance, HD）。HD 用于度量预测边界与真实解剖边界之间的最大不匹配程度。对于预测边界点集 P_b 和真实边界点集 G_b，传统的 HD 定义为：

$$HD(P_b, G_b) = \max\left\{\sup_{p\in P_b}\inf_{g\in G_b} d(p,g), \sup_{g\in G_b}\inf_{p\in P_b} d(p,g)\right\} \tag{3-8}$$

其中，$d(p,g)$ 表示预测边界点 p 与真实边界点 g 之间的欧几里得距离。sup 和 inf 分别代表上确界和下确界。然而，传统的 HD 指标取的是距离的最大值，这导致其对图像中的孤立噪点和极端异常预测值极其敏感。为增强评估指标在临床应用中的鲁棒性，本文采用 95% 豪斯多夫距离（95HD）。95HD 通过计算边界点最短距离的第 95 百分位数来替代最大值，从而有效排除了 5% 的极端离群点对整体评价的干扰。其计算公式如下：

$$95HD(P_b, G_b) = \max\left\{K^{95th}_{p\in P_b}\min_{g\in G_b} d(p,g), K^{95th}_{g\in G_b}\min_{p\in P_b} d(p,g)\right\} \tag{3-9}$$

其中，K^{95th} 表示取集合中数值排序后的第 95 个百分位值。95HD 的单位通常为毫米（mm）或像素（pixel）。该数值越小，表明模型预测的分割边界与真实心脏子结构边界的贴合度越高，进一步验证了本文提出的自适应频域滤波模块在缓解局部容积效应、捕获精细边缘特征方面的有效性。

3.4.3 实验设置

本文所有的网络搭建、模型训练及验证评估实验都基于 PyTorch 2.1.1 深度学习框架，硬件使用的是单张具有 24GB 显存的 NVIDIA GeForce RTX 3090 图形处理器。AF-Mamba 采用随机梯度下降（Stochastic Gradient Descent, SGD）优化器来更新网络参数。其初始学习率（Learning Rate）设定为 0.01，动量参数（Momentum）设定为 0.9，并引入了 1×10^{-4} 的权重衰减（Weight Decay）以有效防止模型在训练过程中发生过拟合。在整个训练期间，模型的批处理大小（Batch Size）统一固定为 16。为了兼顾像素级别的分类准确性与全局解剖结构边界的完整性，本文在所有实验中均采用交叉熵损失（Cross-Entropy Loss）与 Dice 损失（Dice Loss）的混合加权损失函数来计算网络预测输出与真实标签之间的误差。二者的权重分配均设置为 0.5，该混合损失函数的具体数学表达如下：

$$Loss = 0.5\times L_{CE} + 0.5\times L_{Dice} \tag{3-10}$$

其中，L_{CE} 代表交叉熵损失，用于优化像素级的类别归属；L_{Dice} 代表 Dice 损失，用于优化预测区域与真实掩码之间的空间重叠度。

对于 ACDC 数据集，本文遵循文献 [12] 中概述的方法进行标准化的数据清洗与预处理。结合该数据集的数据规模与收敛特性，模型在此数据集上的默认最大训练迭代次数（Iterations）设置为 15,000 次。为适配本文提出的 AF-Mamba 网络结构的空间维度要求，输入网络的二维切片图像尺寸被统一调整为 224×224 像素。

对于多中心的 M&Ms 数据集，本文则采用文献 [13] 描述的预处理方案，将图像的面内像素间距（In-plane spacing）统一重采样至 1.2×1.2 mm，同时保持沿 Z 轴的层间距不变，以此消除不同扫描设备带来的物理空间尺度差异。在该数据集的训练过程中，默认最大训练迭代次数设置为 10,000 次，输入网络的二维切片图像尺寸被统一调整为 256×256 像素。

3.4.4 实验结果与分析

(1) 核心组件有效性消融实验

为了评估所提模型中不同组件的有效性，本文在 ACDC 数据集上进行了一系列核心架构的消融实验。当既不使用频域滤波模块（Frequency-domain Filtering, FF），也不使用自适应滤波器生成器（Adaptive Filter Generator, AFG）时，模型退化为基础的 Mamba-UNet 架构。如表3-1所示，仅引入静态频域滤波模块（即将滤波器参数固定为静态可学习张量）能够使模型网络在频域中捕获心脏的全局特征，平均分割性能得到初步提升。而完整集成频域滤波模块与自适应滤波器生成器的配置（即 AF-Mamba）则通过随输入特征动态演变的调制机制达到了最高的性能：其 DSC 为 91.95%，HD95 为 1.09 mm。这充分证明了频域特征过滤机制和自适应动态权重捕捉策略相互结合在重建高频组织结构边缘等复杂医学表征方面具有决定性的优势。

表 3-1 在 ACDC 数据集上对各个核心组件的消融实验结果

Table3-1 The results of ablation studies conducted on ACDC dataset

Methods	频域滤波模块 (FF Module)	自适应滤波器生成器 (AF Generator)	DSC(%)↑	HD95(mm)↓
AF-Mamba(ours)	✗	✗	90.97	1.81
	✓	✗	91.35	1.45
	✓	✓	91.95	1.09

值得注意的是，在表3-1的设计中，自适应滤波器生成器作为一个产生动态频域权重信号以决定不同频率通道相对抑制或增强强度的辅助模块，其物理意义与数学操作完全依赖于其主干网络中的频域滤波操作本身。因此，在没有应用频域特征变换或基础的同模滤波器相乘机制的前提下，模型逻辑上无法独立地去执行自适应生成器的单一参数调节；这就解释了为何实验缺少“剔除频域滤波模块而单独保留生成器”这种消融组合。这种组件内部具备强烈的逻辑依赖或是操作寄生关系的架构设计模式，不仅深植于本文的频域特征控制方案，在计算机视觉领域的许多经典注意力模型以及动态权值推理骨干结构中同样广泛普及。例如，在多通道注意力重标定的代表性工作之一，挤压-激励网络（SENet，Squeeze-and-Excitation Networks）架构中，用于计算和生成可学习通道权重的“激励（Excitation）”操作，必然建立在“挤压（Squeeze）”操作从多层输入张量中抽取提取的全局空间描述信息向量之上；脱离了“挤压”算子的前提约束，激励逻辑及参数推导分支便失去了信息基础且无法正常运转；再如，在具有深远影响的动态卷积（Dynamic Convolution）中，利用输入特征在并行通道上的方差矩阵和聚合标量对当前帧的动态内核权值进行推断并加权输出的可学习网络映射路由组件，也必然需要寄生并依附于原版最基础的局部算子和特征离散卷积的物理实现过程才能发挥最终响应计算功能。本文引入设计自适应滤波器生成器模块同以上经典范式类似，必须以多频域内不同特征维度的复平面空间矩阵操作为基座前提，二者不可分割共同构建形成了整体有效的动态滤波系统。

(2) 滤波器基底维度 N 消融实验

为了探究自适应频域滤波（AFB）模块中滤波器基底维度 N 对最终分割性能的影响，本节在 ACDC 数据集上进行了消融实验。在自适应滤波器生成器中，基底维度 N 决定了滤波器参数空间的广度与动态表达能力。实验设计中将 N 的取值分别设置为 1、2、3、4 和 5，并记录模型在测试集上的平均 Dice 相似系数（DSC），以评估不同配置下的特征提取效果。

实验结果表明，当基底维度 N 为 1 时，模型的平均 DSC 为 89.50% 是实验中的最低数值。N 取值过小，自适应滤波器会退化为静态参数滤波器，完全丧失针对不同输入特征进行动态调制的灵活性，导致模型无法有效处理复杂多变的频域模式。随着 N 值的逐步增加，滤波器基底的表征能力得到强化，模型的平均 DSC 呈现出显著的上升趋势，并在 N 取 3 时达到了 91.95% 的峰值性能。这一结果有力地验证了利用多个随机初始化的复数参数进行动态线性耦合，能够大幅提升网络对心脏不同解剖结构高低频特征的捕捉与重建精度。然而，当 N 进一步增加至 4 和 5 时，平均 DSC 指标并未随之继续提升，反而出现了轻微的衰退现象。从模型优化的深层角度考量，过大的 N 值不仅引入了不必要的庞大计算负担，更会导致滤波器基底内部产生严重的参数冗余；在医学图像数据集规模相对有限的情况

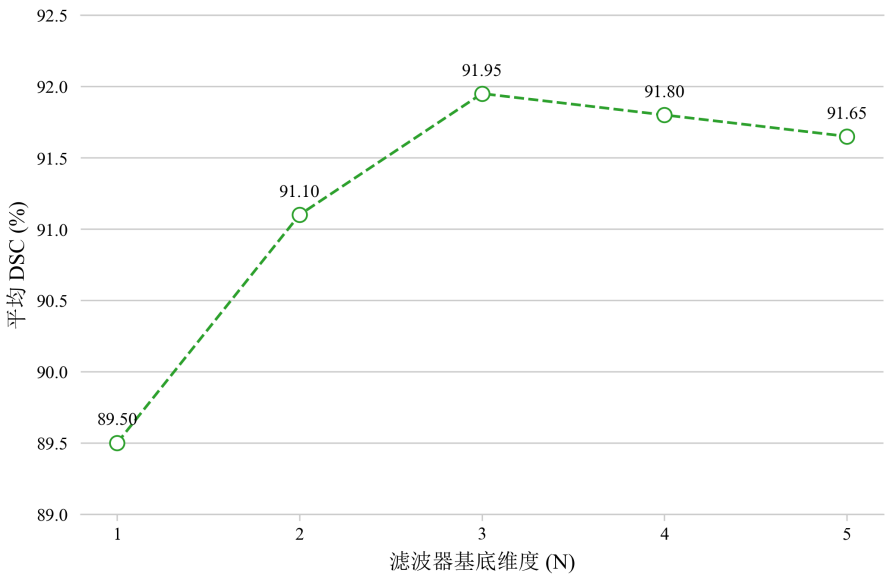

图 3-6 滤波器基底维度 N 对 ACDC 数据集分割性能的消融实验结果

Fig3-6 Ablation study results of filter basis dimension N on ACDC dataset

下，这种冗余极易增加模型过拟合的风险，从而损害网络在未知数据上的泛化能力。因此，综合权衡模型的分割精度、参数规模以及计算效率，本文在最终的网络结构设计中将滤波器基底维度 N 设置为 3。

(2) 对比实验

为了全面评估本文所提方法的分割性能，本节在 ACDC 和 M&Ms 两个公开且具代表性的数据集上，将本文方法（注：此时仅包含自适应频域滤波模块）与九种当前先进的（State-of-the-Art, SOTA）医学图像分割网络进行了客观的定量对比。对比基线方法涵盖了三大主流架构：基于纯卷积神经网络（CNN）的方法（如 U-Net）、基于视觉 Transformer 的方法（如 Swin-Unet、TransUNet、HiFormer、TransCASCADE、PVT-CASCADE）以及近期涌现的基于状态空间模型（Mamba）的方法（如 Swin-UMamba、UU-mamba、Mamba-UNet）。

表 3-2 展示了不同方法在 ACDC 数据集上的定量分割结果。总体而言，本文方法取得了 91.95% 的平均 Dice 相似系数（DSC）以及 1.09 mm 的 95% 豪斯多夫距离（HD95），在各项综合指标上均展现出了显著的竞争力。与经典的 U-Net（88.55%）相比，本文方法的平均 DSC 提升了 3.4%。传统卷积神经网络受限于局部感受野，难以充分捕获心脏整体的结构上下文，而本文引入的自适应频域滤波（AFB）能够在频域空间对全局特征进行高效调制，有效突破了局部卷积的物理限制。此外，相较于 Swin-Unet 和 TransUNet 等基于 Transformer 的主流网络，本文

方法不仅在区域重叠度上实现了超越，在衡量边界分割质量的 HD95 指标上同样大幅领先。这表明，尽管视觉 Transformer 具备长距离依赖的建模能力，但在特征聚合过程中往往会平滑掉高频的边缘细节；本文的自适应频域滤波机制则能够有针对性地保留并增强特征图中的高频边缘信息，从而显著降低预测边界与真实解剖结构之间的误差。

表 3-2　本章提出的 AF-Mamba 在 ACDC 数据集上与其他方法的对比

Table3-2　Comparison of AF-Mamba proposed in this chapter with other methods on ACDC dataset

Methods	DSC(%)↑				HD95(mm)↓
	RV	MYO	LV	Avg	
U-Net[1]	85.01	86.35	94.29	88.55	2.39
Swin-Unet[2]	85.62	84.49	94.03	88.05	2.08
TransUNet[16]	86.87	84.22	94.12	88.40	1.65
HiFormer[17]	90.51	89.27	95.68	91.82	1.12
TransCASCADE[18]	89.07	88.90	94.45	90.81	1.29
PVT-CASCADE[18]	90.15	**89.97**	95.05	91.72	1.16
Swin-UMamba[19]	85.12	83.73	93.81	87.55	2.47
UU-mamba[20]	90.23	89.43	95.60	91.75	1.20
Mamba-UNet[14]	90.25	88.39	94.27	90.97	1.81
AF-Mamba(ours)	**90.62**	89.15	**96.08**	**91.95**	**1.09**

在针对特定心脏子结构的局部特征提取中，本文方法在右心室（RV）和左心室（LV）的分割任务上分别取得了 90.62% 和 96.08% 的优异成绩。由于右心室具有形状极不规则、心动周期内形变剧烈且管壁较薄等解剖学特点，其分割一直是心脏图像处理中的难点。本文方法在 RV 分割上领先于表现优异的 PVT-CASCADE 和 Mamba-UNet，充分证明了频域滤波在处理动态、复杂边缘特征时具有较高的特征响应灵敏度。然而，在心肌（MYO）的分割指标上（89.15%），本文方法未能超越 PVT-CASCADE。从医学图像的物理特性分析，心肌呈现环状拓扑结构，不仅与周围组织的灰度对比度极低，且在数据集中存在显著的类间像素数量不平衡问题。当前模型仅依靠单一尺度的自适应频域滤波，在缺乏多尺度空间上下文信息深度融合的情况下，较难完整建立心肌内外壁的宏观空间拓扑关系。这一实验现象也为后续章节引入多尺度状态空间模块以进一步增强模型的空间感知与拓扑重建能力提供了切实的实验依据。

为进一步验证模型在复杂真实临床环境下的泛化性能，本文在 M&Ms 数据集上进行了对比实验。与单一中心的 ACDC 数据集不同，M&Ms 数据集包含由多个不同临床中心、使用不同厂商（Vendor A、B、C、D）的磁共振扫描仪采集的影像。

由于不同厂商设备的磁场强度、线圈配置以及成像协议存在显著差异，导致图像在信噪比、对比度分布和伪影模式上呈现出严重的非均匀性，即存在明显的域偏移（Domain Shift）问题。受此多中心域偏移的负面影响，表 3-3 显示所有参评方法的整体分割指标较 ACDC 数据集均出现了不同程度的下滑。

表 3-3 本章提出的 AF-Mamba 在 M&Ms 数据集上与其他方法的对比

Table3-3 Comparison of AF-Mamba proposed in this chapter with other methods on M&Ms dataset

Methods	DSC(%)↑					HD95(mm)↓
	A	B	C	D	Avg	
U-Net[1]	87.65	84.80	82.69	83.79	84.73	15.85
Swin-Unet[2]	86.27	84.52	83.11	84.95	84.71	13.66
TransUNet[16]	87.69	85.82	84.25	85.53	85.82	13.30
HiFormer[17]	87.90	83.94	83.25	83.86	84.74	12.78
TransCASCADE[18]	85.92	84.23	82.93	84.43	84.38	13.91
PVT-CASCADE[18]	88.71	87.12	85.36	87.81	87.25	12.60
Swin-UMamba[19]	87.88	86.15	83.67	85.28	85.75	13.29
UU-mamba[20]	88.15	86.90	85.22	86.79	86.77	13.09
Mamba-UNet[14]	88.32	86.48	83.11	86.98	86.22	14.05
AF-Mamba(ours)	88.65	**88.21**	**86.12**	**88.86**	**87.96**	**12.38**

尽管面临严峻的跨域挑战，本文方法依然实现了最高的平均 DSC（87.96%）和最低的平均 HD95（12.38 mm）。具体到各个厂商子集，本文方法在四个不同设备厂商的数据上均保持了高度稳定且最优的分割性能。这种强大的跨域泛化能力，从深层网络机制上可以归因于本文设计的自适应频域滤波模块。该模块通过在频域空间对复杂的图像特征进行解耦，能够自适应地识别并抑制代表设备特异性噪声和成像伪影的高频干扰成分，同时高保真地提取代表心脏核心解剖结构的低频和关键频段信息。因此，模型在训练过程中不会过度拟合于某一特定设备的灰度分布规律，而是学习到了更具本质性和域不变性（Domain-invariant）的心脏解剖特征表示，从而有效克服了多中心、多设备带来的图像异质性挑战。

(3) 分割结果可视化

(4) 滤波器可视化

AF-Mamba 模型中的滤波器可视化如图3-8所示，图像的中心像素严格对应零频（即图像的直流分量或整体灰度均值），随着像素点距中心空间距离的逐渐增加，其所代表的频率成分由低频向高频平滑过渡。滤波器在特定频点位置的幅度值直接决定了该对应频率分量在特征图中的保留强度。因此，本文通过计算滤波器的幅度谱并将其映射为热力图，以定性地描述和探讨模型的频率响应特性。如

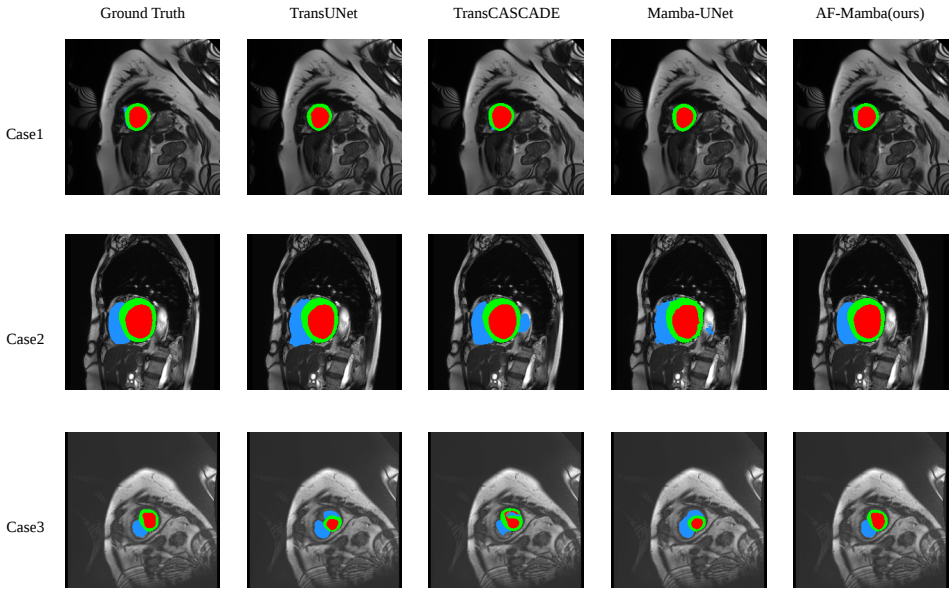

图 3-7　分割结果可视化

Fig3-7　Visualization of segmentation results

图3-8所示，模型在不同网络深度学习到的滤波器组呈现出了极其显著的形态差异，且在同一阶段内的三个独立滤波器基底（对应基底维度 $N = 3$）也展现出了截然不同的频率聚焦模式。在第一阶段（stage1）中，滤波器的能量分布相对宽泛且幅度较高，这表明在网络的浅层，模型倾向于保留较大范围的低频宏观结构信息与部分中高频基础纹理，以构建完备的初始特征空间。随着特征提取的深入，在第二阶段（stage2）中，滤波器的响应区域开始明显收缩并呈现出特定的几何结构分布（如十字形聚焦或菱形轮廓），这意味着网络开始对特定空间方向和特定频段的心脏结构边缘特征进行强烈的选择性增强与背景抑制。而到了第三阶段（stage3），滤波器的频率选择特性演变得更为苛刻和抽象。从可视化结果中可以清晰地观察到，此时模型不仅生成了仅保留中心极小区域的严格低通滤波器，还自适应地演化出了沿特定坐标轴延伸的锐利高通滤波器，甚至出现了类似于环状的带通滤波响应。综上所述，在多个网络阶段的特征演进过程中，本文清晰地观察到了高通、低通以及带通等多种经典信号处理滤波特性的自适应涌现。这种多样化且随网络深度动态演变的频率响应模式，不仅避免了传统手工设计滤波器在应对复杂医学影像时的局限性，更充分彰显了本文所设计的自适应频域滤波机制在处理由于多中心、多设备导致的心脏图像复杂变异时，所具备的高度灵活性与强大的特征解耦能力。

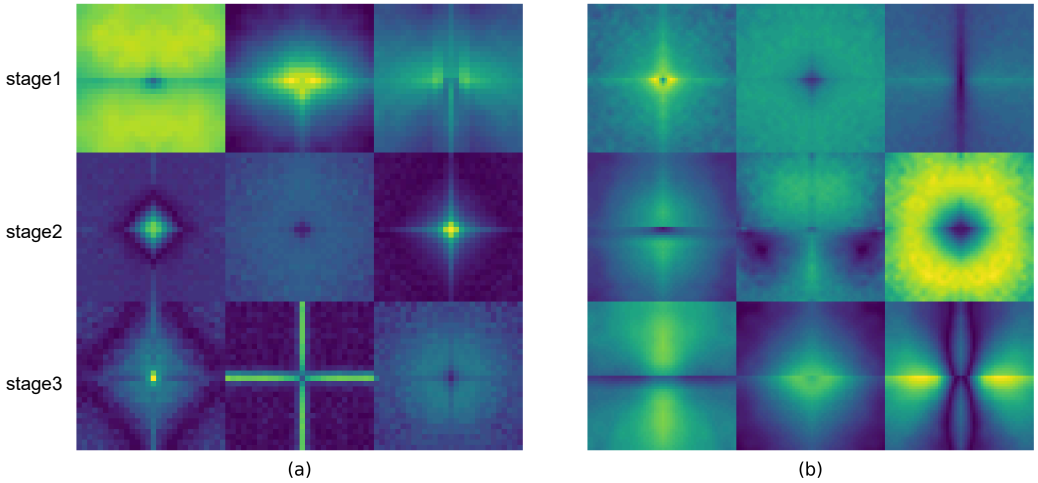

图 3-8 滤波器组频谱可视化

Fig3-8 Visualization of the spectrum of filter banks

3.5 本章小结

本章围绕频域建模方法，系统研究了自适应频域滤波在医学图像分割中的应用，并提出了自适应滤波模块（AFB）。通过引入数据驱动的动态滤波机制，模型能够在频域空间中有效融合全局语义与局部细节信息，从而提升复杂边界区域的分割精度。下一章将在此基础上进一步引入多尺度状态空间建模方法，构建完整的心脏图像分割框架。

第四章　基于多尺度状态空间模型的医学图像分割

如上一章所述，自适应频域滤波（AFB）模块在保留高频细节特征上表现出色。然而，除了边界模糊问题外，医学图像中还广泛存在目标尺度多样性的挑战。本章针对这一问题，详细阐述多尺度视觉状态空间（MSVSS）模块的设计思想与实现细节，并介绍集成了 MSVSS 与 AFB 的最终模型——SAF-Mamba 网络的综合性能验证。

4.1 尺度变化挑战与多尺度感知策略

医学图像中目标尺度变化多样，如心脏影像中左心室、右心室与心肌的尺寸差异显著，小结构易被忽略而大结构需充分上下文。现有多尺度策略包括图像金字塔、空洞卷积、特征金字塔网络（Feature Pyramid Network, FPN）等。图像金字塔通过多尺度输入捕获不同尺度信息，但计算开销随尺度数量线性增长。空洞卷积在保持分辨率的同时扩大感受野，但存在网格效应与信息相关性丢失等问题。FPN 通过自上而下与自下而上的路径融合多尺度特征，在目标检测与分割中应用广泛。受不同卷积核尺寸对应不同感受野的启发，本文采用并行多尺度深度卷积策略，以较低成本捕获多尺度上下文，并结合 VSS 模块进行长距离依赖建模，在计算效率与表征能力之间取得平衡。

4.2 多尺度视觉状态空间模块

4.2.1 并行多尺度深度卷积分支

MSVSS 模块的设计遵循“多尺度提取—通道整合—长程建模”的流程。设输入特征为 $\mathbf{X}_{in} \in \mathbb{R}^{H\times W\times C}$，MSVSS 模块首先通过并行深度卷积提取多尺度特征：

$$\mathbf{Y} = \mathrm{DWConv}_{ks}(\mathbf{X}_{in}) \tag{4-1}$$

其中 $\mathrm{DWConv}_{ks}(\cdot)$ 表示核尺寸为 ks 的深度可分离卷积，$\mathcal{KS} = \{1\times 1, 3\times 3, 5\times 5\}$。$1\times 1$ 卷积保留局部细节，3×3 与 5×5 卷积分别提供中等与较大感受野，三者并行提取后沿通道维度拼接，形成多尺度特征表示。

4.2.2 通道整合与特征校准机制

多尺度特征拼接后，通过通道混洗（Channel Shuffle）操作促进跨通道信息流动，打破通道间的隔离。通道整合分支将混洗后的特征输入共享 VSS 模块，捕获通道间依赖；校准分支将原始多尺度特征直接输入同一共享 VSS 模块，对整合过程中可能被忽略的特征进行 refinement。两分支共享 VSS 权重，在保证表达能力的同时降低参数量。输出可表示为：

$$\begin{aligned}\mathbf{Y}_1 &= \mathrm{VSS}_{\text{shared}}(\text{Channel Shuffle}(\mathbf{Y}))\\ \mathbf{Y}_2 &= \mathrm{VSS}_{\text{shared}}(\mathbf{Y})\end{aligned} \tag{4-2}$$

4.2.3 基于共享参数的视觉状态空间建模

两分支共享 VSS 模块，使多尺度特征在融合后统一进行长距离依赖建模。最终输出通过两分支结果与残差连接求和得到：

$$\mathbf{X}_{out} = \mathbf{Y}_1 + \mathbf{Y}_2 + \mathbf{X}_{in} \tag{4-3}$$

该设计在增强多尺度感知能力的同时，保持了计算效率与特征表达的完整性。

4.3 基于多尺度状态空间模型的医学图像分割框架

SAF-Mamba 采用 U 型层次结构，编码器包含四个阶段，整体架构如图4-1所示。输入图像 $I \in \mathbb{R}^{H\times W\times 1}$ 经块嵌入（Patch Embedding）划分为 $\frac{H}{4}\times\frac{W}{4}$ 个非重叠块，线性投影至 96 维。各阶段由多个 MSVSS 块组成，阶段间通过块合并（Patch Merging）层将空间尺寸减半、通道数加倍，形成层次化表征。解码器通过块扩展（Patch Expanding）上采样特征，并与前三个阶段编码器经 AFB 处理后的跳跃连接特征拼接，最后经 4 倍上采样得到与输入同尺寸的分割掩码。SA-Mamba 为仅集成 MSVSS、未引入 AFB 的版本，用于消融实验验证多尺度模块的有效性；完整 SAF-Mamba 则在此架构基础上，在跳跃连接中引入了第三章提出的 AFB 模块。

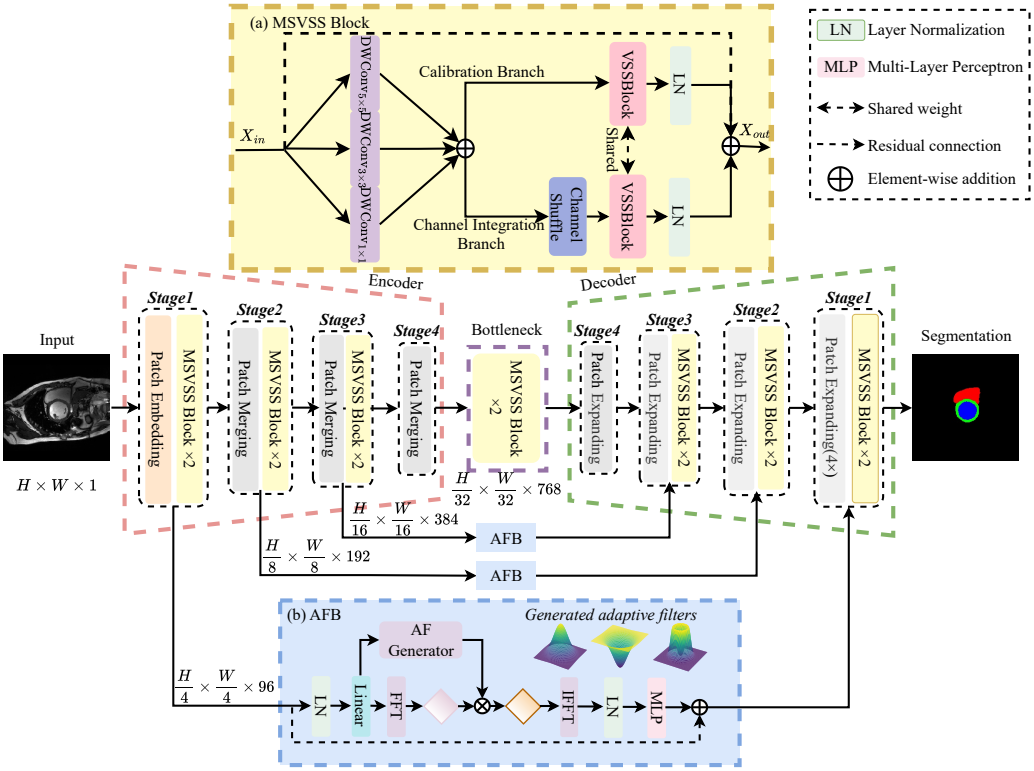

图 4-1　SAF-Mamba 整体架构与 MSVSS、AFB 模块示意图

Fig4-1　Schematic diagram of SAF-Mamba overall architecture and MSVSS, AFB modules

4.4 实验与分析

4.4.1 实验数据与预处理

实验在 ACDC 与 M&Ms 两个心脏分割数据集上进行。ACDC 包含 100 名患者的 200 例标注心脏 MRI 扫描，标注右心室（RV）、心肌（MYO）和左心室（LV），按 70 例训练、10 例验证、20 例测试划分，共 1930 张训练切片。M&Ms 包含来自四个厂商（Siemens、Philips、GE、Canon）的 375 名患者、7334 张标注切片，训练集为 150 例标注扫描，厂商 C 的 25 例未标注扫描被排除，测试集为每厂商 50 例共 200 例。数据预处理遵循 Mamba-UNet 与 UTNet 的设置，ACDC 输入尺寸为 224×224，M&Ms 为 256×256，采用归一化及常规数据增强。

4.4.2 评价指标

采用 Dice 相似系数（DSC）与 95% 豪斯多夫距离（HD95）作为主要评价指标。DSC 衡量预测与真实分割的重叠程度，取值范围 $[0, 1]$，越高越好；HD95 衡量边界误差，单位为毫米，越低越好。

4.4.3 实验设置

实验在单张 16GB NVIDIA RTX 3090 GPU 上进行，使用 PyTorch 2.1.1。ACDC 训练 15000 次迭代，M&Ms 训练 10000 次迭代，批大小为 16。优化器为 SGD，学习率 0.01，动量 0.9。损失函数为交叉熵与 Dice 损失的组合。

4.4.4 对比实验

表4-1与表4-2分别展示了引入多尺度感知模块的初步网络模型 SA-Mamba 在 ACDC 与 M&Ms 上的对比结果。SA-Mamba 在 ACDC 上取得了 91.25% 的平均 DSC 与 1.47 mm 的 HD95，在 RV 与 MYO 分割精度上已有显著提升。在 M&Ms 上取得平均 DSC 87.35% 与 HD95 12.86 mm，展现出比基础 Mamba-UNet 更好的适应能力，初步验证了 MSVSS 模块在应对多尺度挑战时的有效性。完整模型（SAF-Mamba）的综合对比将在本章末的小节集中展示。

表 4-1　ACDC 数据集 SA-Mamba 对比实验初步结果

Table4-1　Preliminary comparison results of SA-Mamba on ACDC dataset

方法	DSC(%)↑				HD95(mm)↓
	RV	MYO	LV	Avg	
U-Net	85.01	86.35	94.29	88.55	2.39
TransUNet	86.87	84.22	94.12	88.40	1.65
Mamba-UNet	90.25	88.39	94.27	90.97	1.81
SA-Mamba(本文)	**90.54**	**88.75**	**94.46**	**91.25**	**1.47**

表 4-2　M&Ms 数据集 SA-Mamba 对比实验初步结果

Table4-2　Preliminary comparison results of SA-Mamba on M&Ms dataset

方法	DSC(%)↑					HD95(mm)↓
	A	B	C	D	Avg	
U-Net	87.65	84.80	82.69	83.79	84.73	15.85
TransUNet	87.69	85.82	84.25	85.53	85.82	13.30
Mamba-UNet	88.32	86.48	83.11	86.98	86.22	14.05
SA-Mamba(本文)	**88.85**	**87.12**	**84.55**	**88.88**	**87.35**	**12.86**

4.4.5 分割结果的可视化分析

定性可视化表明，得益于多尺度特征的整合，SA-Mamba 在处理不同大小心腔结构时相较于基线模型展现出明显优势。与 Mamba-UNet 相比，引入 MSVSS 后的 SA-Mamba 在右心室等小尺度靶区的分割上表现更为稳定，初步缓解了尺度极差带来的漏分现象。然而，受限于单纯的空间域特征提取，在心肌与左心室交界等极其模糊的区域，其边界平滑度仍存在瑕疵。这些遗留的边界问题，将由完整加入第三章 AFB 模块后的 SAF-Mamba 彻底解决，相关深层次对比可视化见后文分析。

4.5 本章小结

本章介绍了 MSVSS 模块的设计思想与实现细节，包括并行多尺度深度卷积分支、通道整合与校准机制以及共享 VSS 的特征提取。基于 MSVSS 构建的 SA-Mamba 网络在 ACDC 与 M&Ms 数据集上取得了优于现有方法的性能，验证了多尺度感知策略对心脏分割中尺度变化挑战的有效应对能力。

第四章　基于自适应频域滤波的医学图像分割

虽然第四章提出的多尺度视觉状态空间（MSVSS）模块通过空间维度的特征聚合，有效捕捉了不同尺度目标的上下文信息，缓解了器官尺度多样性的问题；然而，在编码器的逐层下采样（池化或步进卷积）过程中，图像的高频细节（如边界轮廓、微小组织结构）势必会发生严重衰减。单靠空间维度的特征提取难以从根本上挽回这些已经丢失的高频信息。

基于这一严峻的挑战，本章从频率域视角出发，引入自适应频域滤波模块（AFB），通过在频域进行有区分度的特征增强，找回并细化丢失的边界。本章将详细阐述 AFB 的设计原理，并通过消融实验及与现有先进方法的综合对比，全面验证完整模型 SAF-Mamba 的最终性能。

5.1 下采样过程中的高频信息丢失问题

在编码器-解码器结构中，下采样操作在降低空间分辨率的同时，会衰减高频分量。根据傅里叶分析，高频对应边缘、纹理等细节，低频对应整体轮廓与平滑区域。高频信息的丢失导致解码器恢复的边界模糊、定位不准，影响分割精度。因此，在跳跃连接中对编码器特征进行频域增强，有助于在融合到解码器时保留更多边界细节，提升边界贴合度与平滑度。

5.2 自适应滤波器模块

AFB 对跳跃连接中的编码器特征进行自适应频域滤波。设空间特征 $\mathbf{X}_i \in \mathbb{R}^{H\times W\times C}$，经层归一化（Layer Normalization, LN）与线性层投影至 $\hat{\mathbf{X}}_i \in \mathbb{R}^{H\times W\times 2C}$，再经 2D FFT 变换至频域。根据先验工作，2D DFT 可将空间信号分解为频率分量；为加速计算，采用 2D FFT 实现。自适应滤波器由 AF Generator 根据输入特征动态生成，在频域中与特征逐元素相乘，增强有效频率、抑制噪声，最后经 IFFT 重构至空间域：

$$A(\hat{\mathbf{X}}_i) = \mathcal{F}^{-1}\left(\mathcal{F}(\hat{\mathbf{X}}_i) \odot \mathbf{F}_c\right) \tag{5-1}$$

其中 $\odot$ 表示逐元素乘法，$\mathcal{F}(\cdot)$ 与 $\mathcal{F}^{-1}(\cdot)$ 分别为 2D FFT 与 IFFT，$\mathbf{F}_c$ 为 AF Generator 生成的滤波器，根据输入特性调制频谱。经 MLP 建模跨通道依赖并精炼特征后，通过残差融合得到最终输出 $\mathbf{X}_i^{out} \in \mathbb{R}^{H\times W\times C}$，恢复空间细节。

5.2.1 自适应滤波器生成器

AF Generator 是 AFB 的核心组件，其作用是根据输入特征的内容动态生成滤波器参数，使滤波行为随输入自适应变化。与固定高通、低通或带通滤波器不同，AF Generator 生成的滤波器可根据不同区域、不同阶段的需求，呈现高通（增强边界）、低通（平滑噪声）或带通（保留特定频段）等多样化模式。这种自适应性使得 AFB 能够在不增加大量参数的前提下，灵活应对医学图像中边界与噪声的复杂分布。

AF Generator 通过 MLP 与 Softmax 归一化产生通道级权重，对滤波器基 $\mathbb{M} = \{\mathcal{M}_1, \ldots, \mathcal{M}_N\}$ 进行线性组合，其中每个 $\mathcal{M}_i \in \mathbb{C}^{H \times \lceil W/2 \rceil}$ 为随机初始化的复参数。由于各频谱通道对应不同频率响应，采用逐通道滤波。权重计算为：

$$\mathbf{a} = \text{Softmax}\left(\text{MLP}\left(\frac{\sum_{h=1}^{H}\sum_{w=1}^{W}\mathbf{X}_{:,h,w}}{HW}\right)\right) \tag{5-2}$$

$$\mathbf{a} = (\alpha_1, \ldots, \alpha_{N \cdot 2C})^\top \tag{5-3}$$

自适应滤波器由下式生成：

$$\mathbf{F}_c = \sum_{i=1}^{N} \frac{e^{\alpha_{c,i}}}{\sum_{n=1}^{N} e^{\alpha_{c,n}}} \mathcal{M}_i \tag{5-4}$$

其中 $\alpha_{c,i}$ 为第 c 组 α 的第 i 个元素，α 被划分为 N 段，每段长度 $2C$。本文设置 $N = 3$。N 过大增加计算成本，N 过小（如 $N = 1$）则滤波器退化为固定形式，失去自适应性。

5.2.2 频域调制与特征重构

生成的滤波器 $\mathbf{F}_c$ 在频域中与 $\mathcal{F}(\hat{\mathbf{X}}_i)$ 逐元素相乘，实现对特定频率（尤其是高频细节）的自适应增强。根据输入内容，滤波器可呈现高通、低通或带通特性，在边界区域往往呈现高通特性以增强边缘。经 IFFT 将调制后的频谱重构回空间域，得到增强后的特征，再经 MLP 与残差融合，输出最终特征供解码器使用。

5.3 实验与分析

5.3.1 实验设置

本章实验与第四章共享数据、评价指标及大部分超参数设置。消融实验中，基线为 Mamba-UNet（即无 MSVSS、无 AFB），逐步添加 MSVSS、AFB 或两者，以验证各模块贡献。

5.3.2 对比实验

为验证完整 SAF-Mamba 模型在心脏图像分割任务上的优异性能，本节展示其与现有各类先进网络在 ACDC 与 M&Ms 数据集上的全面对比结果。如表5-1与表5-2所示，得益于频域 AFB 模块与空间域 MSVSS 模块的强强联合，完整版 SAF-Mamba 在 ACDC 上取得最高平均 DSC（92.21%）与最低 HD95（1.05 mm），显著优于单纯的 Swin-Unet、HiFormer 以及基础版本的 Mamba-UNet 等对比方法。在 M&Ms 跨厂商数据集上，SAF-Mamba 同样取得最佳评价指标，充分验证了模型强大的鲁棒性与广泛的泛化潜力。

表 5-1　ACDC 数据集 SAF-Mamba 综合对比实验结果

Table5-1　Comprehensive comparison results of SAF-Mamba on ACDC dataset

方法	DSC(%)↑				HD95(mm)↓
	RV	MYO	LV	Avg	
U-Net	85.01	86.35	94.29	88.55	2.39
Swin-Unet	85.62	84.49	94.03	88.05	2.08
TransUNet	86.87	84.22	94.12	88.40	1.65
HiFormer	90.51	89.27	95.68	91.82	1.12
TransCASCADE	89.07	88.90	94.45	90.81	1.29
PVT-CASCADE	90.15	89.97	95.05	91.72	1.16
Swin-UMamba	85.12	83.73	93.81	87.55	2.47
UU-mamba	90.23	89.43	95.60	91.75	1.20
Mamba-UNet	90.25	88.39	94.27	90.97	1.81
SAF-Mamba(本文)	**90.87**	**89.42**	**96.34**	**92.21**	**1.05**

表 5-2 M&Ms 数据集 SAF-Mamba 综合对比实验结果

Table5-2 Comprehensive comparison results of SAF-Mamba on M&Ms dataset

方法	DSC(%)↑					HD95(mm)↓
	A	B	C	D	Avg	
U-Net	87.65	84.80	82.69	83.79	84.73	15.85
Swin-Unet	86.27	84.52	83.11	84.95	84.71	13.66
TransUNet	87.69	85.82	84.25	85.53	85.82	13.30
HiFormer	87.90	83.94	83.25	83.86	84.74	12.78
TransCASCADE	85.92	84.23	82.93	84.43	84.38	13.91
PVT-CASCADE	88.71	87.12	85.36	87.81	87.25	12.60
Swin-UMamba	87.88	86.15	83.67	85.28	85.75	13.29
UU-mamba	88.15	86.90	85.22	86.79	86.77	13.09
Mamba-UNet	88.32	86.48	83.11	86.98	86.22	14.05
SAF-Mamba(本文)	**89.16**	**88.79**	**86.83**	**88.92**	**88.43**	**12.14**

5.3.3 消融实验

表5-3展示了在 ACDC 上的消融结果。移除 MSVSS 或 AFB 均导致性能下降，表明二者具有互补作用。同时集成两者时，SAF-Mamba 取得最高 DSC（92.21%）与最低 HD95（1.05 mm），验证了 MSVSS 与 AFB 联合使用的有效性。

表 5-3 ACDC 数据集消融实验结果

Table5-3 Ablation study results on ACDC dataset

方法	MSVSS	AFB	DSC(%)↑	HD95(mm)↓
SAF-Mamba(本文)	×	×	90.97	1.81
	✓	×	91.25	1.47
	×	✓	91.54	1.42
	✓	✓	92.21	1.05

5.3.4 自适应滤波器基的频域可视化分析

将不同病例或不同区域的图像块输入 AF Generator，对生成的滤波器参数进行可视化，可直观展示滤波器如何根据输入内容自适应调整。实验表明，学习到的滤波器在不同阶段呈现多样化的高通、低通与带通模式，验证了 AFB 的自适应

频域调制能力。

除 DSC 与 HD95 外，可引入针对边界的评价指标如平均对称表面距离（Average Symmetric Surface Distance, ASSD）进行补充评估。通过放大分割结果的边界区域进行可视化对比，可定性展示加入 AFB 后边界的贴合度与平滑度改善。HD95 的显著降低（从 1.81 mm 至 1.05 mm）也定量印证了 AFB 对边界精度的提升。

5.3.5 基于皮肤病灶分割的泛化能力验证

为验证 SAF-Mamba 对不同模态、不同任务的泛化能力，可在 ISIC2017 等皮肤病灶分割数据集上进行实验，将完整 SAF-Mamba 与任务相关 SOTA 方法对比。该部分可根据实际实验进度补充表格与图示。

5.4 本章小结

本章介绍了 AFB 模块的设计思想与实现细节，包括 FFT/IFFT 的频域变换、AF Generator 的自适应滤波器生成以及频域调制与特征重构流程。消融实验与可视化分析表明，AFB 能有效增强边界细节；结合 MSVSS，完整集成的 SAF-Mamba 模型在心脏分割任务上具备良好的综合性能与泛化能力。

第五章　总结与展望

6.1 工作总结

本文针对医学图像分割中的尺度变化与边界模糊两大共性挑战，提出了基于多尺度状态空间模型和自适应频率滤波的 SAF-Mamba 模型，主要工作可总结如下：

（1）设计了多尺度视觉状态空间（MSVSS）模块，通过并行多尺度深度卷积分支、通道整合与校准机制，有效捕获不同尺度目标的特征表示，增强模型对尺度变化的敏感性。MSVSS 模块与共享 VSS 的联合设计在保证多尺度感知能力的同时，兼顾了计算效率。

（2）构建了自适应滤波器模块（AFB），利用 FFT 将编码器跳跃连接特征映射至频域，通过 AF Generator 根据输入内容动态生成滤波器参数，在频域中调制频率分量以增强边界细节，最后经 IFFT 重构空间特征。AFB 能够自适应呈现高通、低通或带通特性，有效缓解下采样过程中的高频信息丢失。

（3）将 MSVSS 与 AFB 集成于 U 型编码器-解码器架构，形成完整的 SAF-Mamba 网络。在 ACDC 与 M&Ms 心脏分割数据集上，SAF-Mamba 取得了优于 CNN、Transformer 及 Mamba 类现有方法的性能，验证了方法的有效性与高泛化能力。

（4）提出核心理论范式：本研究打破了现有视觉状态空间模型高度依赖空间域特征提取的局限，为 Mamba 架构在密集预测任务中实现“空间大感受野统筹”与“高频精准边界保留”的协同处理提供了一种全新范式。这一理论视角的补充，显著提升了模型表现，更为医学图像分割领域的创新提供了具有更强鲁棒性与泛化能力的网络设计思路。

6.2 未来展望

基于本文研究的发现与局限性，未来可从以下方向开展进一步工作：

（1）**模型轻量化**：当前 SAF-Mamba 在精度上表现优异，但模型规模与计算开销对临床部署（如移动端、嵌入式设备）仍有一定限制。未来可探索知识蒸馏、模型剪枝、量化等技术，在保持性能的同时降低计算与存储开销，便于在资源受限场景下的实际应用。

（2）**向 3D/4D 扩展**：本文方法基于 2D 切片，而医学影像常以 3D 体积或 4D 动态序列形式存在。将 MSVSS 与 AFB 扩展至 3D 乃至 4D 数据，可更充分利用空

间与时间上下文，处理 CT、MRI 体积数据及心脏动态序列等更复杂的医学数据。

（3）**与 SAM 及大模型方向的结合**：Segment Anything Model（SAM）等基础模型在零样本与少样本分割上展现出强大能力，其提示式（Prompt-based）分割范式与医学图像分割的交互式标注需求高度契合；视觉大模型（Vision Large Language Model, VLLM）在理解与推理方面具有独特优势，可提供高层语义先验。未来可探索将 SAF-Mamba 与 SAM 或大模型相结合，如利用 SAM 的提示机制增强边界定位，或借助大模型的语义理解能力提升复杂场景下的分割一致性，形成“小模型 + 大模型”的协同框架，以应对标注数据稀缺与长尾类别等实际挑战。

6.3 本章小结

本章对全文研究工作进行了系统总结，梳理了 SAF-Mamba 模型在医学图像分割中的三项核心贡献：多尺度视觉状态空间模块的设计、自适应频域滤波模块的构建，以及二者在完整网络框架中的协同集成。同时，从模型轻量化、三维扩展以及与基础大模型结合三个维度对未来研究方向进行了展望，以期为后续工作提供参考与借鉴。

参考文献

参考文献

[1] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015. Springer, 2015: 234-241.

[2] Cao H, Wang Y, Chen J, et al. Swin-unet: Unet-like pure transformer for medical image segmentation[C]//European Conference on Computer Vision. Springer, 2022: 205-218.

[3] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2021.

[4] Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[J]. arXiv preprint arXiv:2312.00752, 2023.

[5] Gu A, Goel K, Ré C. Efficiently modeling long sequences with structured state spaces[J]. arXiv preprint arXiv:2111.00396, 2022.

[6] Liu Y, Tian Y, Zhao Y, et al. VMamba: Visual state space model[J]. arXiv preprint arXiv:2401.10166, 2024.

[7] Ma M, Xia C, Xie C, et al. Boosting broader receptive fields for salient object detection[J]. IEEE Transactions on Image Processing, 2023, 32: 1026-1038.

[8] Rahman M M, Munir M, Marculescu R. EMCAD: Efficient multi-scale convolutional attention decoding for medical image segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 11769-11779.

[9] Zhang X, Zhou X, Lin M, et al. Shufflenet: An extremely efficient convolutional neural network for mobile devices[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 6848-6856.

[10] Tatsunami Y, Taki M. FFT-based dynamic token mixer for vision[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(14): 15328-15336.

[11] Chang A, Zeng J, Huang R, et al. EM-Net: Efficient channel and frequency learning with Mamba for 3D medical image segmentation[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, 2024: 266-275.

[12] Bernard O, Lalande A, Zotti C, et al. Deep learning techniques for automatic MRI cardiac multi-structures segmentation and diagnosis: Is the problem solved?[J]. IEEE Transactions on Medical Imaging, 2018, 37(11): 2514-2525.

[13] Campello V M, Gkontra P, Izquierdo C, et al. Multi-centre, multi-vendor and multi-disease cardiac segmentation: The M&Ms challenge[J]. IEEE Transactions on Medical Imaging, 2021, 40(12): 3543-3554.

[14] Wang Z, Zheng J-Q, Zhang Y, et al. Mamba-UNet: UNet-like pure visual Mamba for medical image segmentation[J]. arXiv preprint arXiv:2402.05079, 2024.

[15] Gao Y, Zhou M, Metaxas D N. UTNet: A hybrid transformer architecture for medical image segmentation[C]//Medical Image Computing and Computer Assisted Intervention–MICCAI 2021. Springer, 2021: 61-71.

[16] Chen J, Lu Y, Yu Q, et al. TransUNet: Transformers make strong encoders for medical image segmentation[J]. arXiv preprint arXiv:2102.04306, 2021.

[17] Heidari M, Kazerouni A, Soltany M, et al. HiFormer: Hierarchical multi-scale representations using transformers for medical image segmentation[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2023: 6202-6212.

[18] Rahman M M, Marculescu R. Medical image segmentation via cascaded attention

decoding[C]//2023 IEEE/CVF Winter Conference on Applications of Computer Vision. IEEE, 2023: 6211-6220.

[19] Liu J, Yang H, Zhou H-Y, et al. Swin-UMamba: Mamba-based UNet with ImageNet-based pretraining[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, 2024: 615-625.

[20] Tsai T Y, Lin L, Hu S, et al. UU-Mamba: Uncertainty-aware U-Mamba for cardiac image segmentation[J]. arXiv preprint arXiv:2405.17496, 2024.

致谢

本论文的完成离不开导师的悉心指导和实验室同门的无私帮助。

首先，衷心感谢导师在选题、方法设计、实验分析与论文撰写全过程中的指导与支持。导师严谨的治学态度与渊博的专业知识使我受益良多。

其次，感谢实验室同门在学术交流与技术讨论中给予的启发与帮助，感谢他们在实验环境与代码实现上的支持。

最后，感谢家人一直以来的理解与鼓励，他们的支持是我完成学业的坚强后盾。