学校代码： 10255
学　　号： 2222715
中图分类法： TP391

学术学位硕士学位论文

基于量化自注意力和空间离散建模的服装关键点检测

学 位 申 请 人：陆然
指　导　教　师：王绍宇副教授
一　级　学　科：软件工程
研　究　方　向：服装关键点检测
所　在　学　院：计算机科学与技术学院

提　交　日　期：2025 年 4 月

University Code: 10255

Student ID: 2222715

CLC Index: TP391

ACADEMIC MASTER DISSERTATION

CLOTHING KEYPOINT DETECTION BASED ON QUANTIZED SELF-ATTENTION AND SPATIAL DISCRETIZATION MODELING

Candidate: Ran Lu

Supervisor: Assoc. Prof. Shaoyu Wang

Major: Software Engineering

Research Direction: Clothing Keypoint Detection

Affiliation: School of Computer Science and Technology

Date of Submit: Apr, 2025

东华大学

学位论文原创性声明

本人郑重声明：我恪守学术道德，崇尚严谨学风。所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已明确注明和引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品及成果的内容。论文为本人亲自撰写，我对所写的内容负责，并完全意识到本声明的法律结果由本人承担。

学位论文作者签名：陆然

日期：2025 年 5 月 20 日

东华大学

学位论文版权使用授权书

学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅或借阅。本人授权东华大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

保　密 □，在　　年解密后适用本版权书。

本学位论文属于

不保密 ☑。

导师签名：王绍宇　　学位论文作者签名：陆然

日期：2025 年 5 月 20 日

硕士学位论文答辩委员会名单

姓名	职称	单位	备注
夏小玲	教授	东华大学	主席
丁宏锴	高级工程师	亚太计算机信息系统有限公司	委员
石秀金	副教授	东华大学	委员
吴国文	副教授	东华大学	委员
于守健	副教授	东华大学	委员
张红	高级实验师	东华大学	秘书

答 辩 人：陆然

答辩地点：1 号学院楼 259 室

答辩日期：2025 年 5 月 20 日

基于量化自注意力和空间离散建模的服装关键点检测

摘 要

服装关键点检测是计算机视觉领域中的重要研究内容，它在虚拟试衣、智能制造和服装个性化推荐等领域具有重要应用价值。通过精准定位服装图像中具有结构意义的特定点（如领口、袖口和腰线），可有效提升服装检索、服装推荐和虚拟试衣的精度。受服装非刚性形变、多样性和遮挡等固有挑战影响，现有基于热图和基于回归的方法由于空间结构建模能力不足和位置表示精度受限，在复杂场景中仍面临检测精度不足和全局结构一致性难以保障等问题。

本文针对当前服装关键点检测算法中缺乏全局信息建模、在高分辨率下计算成本较高等问题，提出了基于量化自注意力和空间离散建模的服装关键点检测算法。研究内容主要包括：

（1）针对服装关键点检测中特征表示能力不足的问题，提出了量化自注意力模块（Quantized self-Attention Module, QAM），通过结合向量量化和自注意力机制，有效增强了模型捕获服装结构全局上下文信息的能力。该模块通过向量量化将连续特征投影到离散码本空间，将原始连续自注意力计算转换为基于码本的稀疏查询，实现了特征的结构化表示，在保留关键信息的同时减少了对细微特征的过拟合，避免了形变和复杂背景对预测的干扰，提升了模型在不同场景下的泛化能力。

（2）针对传统回归方法难以建模关键点间复杂关系的问题，提出了基于 QAM 的多阶段回归框架，通过将关键点坐标嵌入至特征空间，利用 QAM 建模关键点之间的相互依赖关系，并设计了多阶段级联回归结构，实现递进式特征增强与坐标细化，完成由粗到细的高效回归过程。此外，还结合残差对数似然估计实现坐标的逐步精确定位和不确定性估计，提高了服装关键点检测在复杂场下的精度和可靠性。

（3）针对热图方法计算开销大、回归方法精度有限的问题，提出了空间离散（Spatial Discretization, SD）建模，将关键点定位任务从连续回归问题转换为分类任务，在水平与垂直两个维度上对图像空间进行离散化编码，通过可学习的空间划分机制自适应调整空间划分策略，结合残差对数似然估计提供不确定性建模，在保持高计算效率的同时实现了精确定位和不确定性估计的双重目标。

本文在 DeepFashion2 数据集上对长裤、裙子、长袖外套和吊带四类服装进行了全面验证实验，结果表明，本方法在各项评估指标上均取得了较好效果。其中，

基于量化自注意力的服装关键点检测网络的计算复杂度为 1.5 GFLOPs，推理速度达 572 FPS，在四种服装类别上取得了和基于热图方法相当的结果；而引入空间离散建模后，在上述四种服装类别上的 AUC 分别达到了 0.65、0.66、0.51 和 0.55，均超越了现有方法，且 GFLOPs 和 FPS 分别为 1.9 和 473。实验证明本文的方法有效解决了服装关键点检测中的全局结构建模不足和空间精度受限等关键问题，同时保持了较高的计算效率。

关键词：轻量级网络；服装关键点检测；量化自注意力；空间离散建模

CLOTHING KEYPOINT DETECTION BASED ON QUANTIZED SELF-ATTENTION AND SPATIAL DISCRETIZATION MODELING

ABSTRACT

Clothing keypoint detection is a fundamental task in the field of computer vision with significant applications in virtual try-on, intelligent manufacturing, and personalized recommendations. Through precise localization of structurally meaningful points on clothing images (such as necklines, cuffs, and waistlines), the accuracy of clothing retrieval, recommendation, and virtual try-on can be significantly enhanced. Due to inherent challenges including non-rigid deformation, diversity in clothing styles, and occlusion, existing methods based on heatmaps and regression suffer from insufficient spatial structure modeling capacity and limited positional representation precision, resulting in inadequate detection accuracy and difficulties in maintaining global structural consistency in complex scenarios.

This paper presents a clothing keypoint detection algorithm based on quantized self-attention and spatial discretization modeling, addressing key issues in current algorithms, including the insufficient global information modeling and high computational costs at high resolutions. The contributions of this research are as follows:

(1) To address the inadequate feature representation in clothing keypoint detection, we propose a Quantized self-Attention Module (QAM), which effectively enhances the model's ability to capture global contextual information of clothing structures by combining vector quantization with self-attention mechanisms. This module projects continuous features into a discrete codebook space, transforming traditional continuous self-attention computation into codebook-based sparse queries. This structured representation preserves critical information while reducing overfitting to minor features, mitigating interference from deformations and complex backgrounds, and improving model generalization across diverse scenarios.

(2) To overcome the limitations of traditional regression methods in modeling the complex relationships between keypoints, we develop a multi-stage regression framework based on QAM. The framework embeds keypoint coordinates into the feature space and utilizes QAM to model the interdependencies between keypoints. The multi-stage cascading regression structure enables progressive feature enhancement and coordinate refinement, resulting in a coarse-to-fine regression process. Additionally, by incorporating residual log-likelihood estimation, the framework achieves gradual precise localization and uncertainty estimation, enhancing both accuracy and reliability of clothing keypoint detection in complex scenarios.

(3) To address the high computational costs of heatmap methods and limited precision of regression approaches, we propose Spatial Discretization (SD) modeling, which transforms the keypoint localization task from a continuous regression problem to a classification problem. This

approach discretizes the image space along both horizontal and vertical dimensions, employing a learnable spatial partition mechanism to adaptively adjust the discretization strategy. Combined with residual log-likelihood estimation, SD provides reliable uncertainty modeling while maintaining computational efficiency, enabling both precise localization and uncertainty estimation.

Experimental validation on the DeepFashion2 dataset across four clothing categories (trousers, skirts, long-sleeved outerwear, and slings) demonstrate the effectiveness of the proposed method. The quantized self-attention-based keypoint detection network achieves 1.5 GFLOPs computational complexity with 572 FPS inference speed, delivering results comparable to heatmap-based methods across all four clothing categories. With the integration of spatial discretization modeling, our approach achieves AUC scores of 0.65, 0.66, 0.51, and 0.55 for the four categories respectively, surpassing existing methods while maintaining efficient computation at 1.9 GFLOPs and 473 FPS. These experimental results confirm that our method effectively addresses the key challenges of insufficient global structure modeling and limited spatial precision in clothing keypoint detection while maintaining high computational efficiency.

Ran Lu

Supervised by: Shaoyu Wang

KEY WORDS: Lightweight Network， Clothing Keypoint Detection， Quantized Self-Attention, Spatial Discretization Modeling

目录

摘 要 ····· I
ABSTRACT ····· III
第一章 绪论 ····· 1
1.1 研究背景及意义 ····· 1
1.2 研究现状 ····· 3
1.2.1 关键点检测研究现状 ····· 3
1.2.2 服装关键点检测研究现状 ····· 6
1.3 研究内容 ····· 8
1.4 文章组织结构 ····· 8
第二章 关键点检测与深度学习 ····· 10
2.1 关键点检测的任务特性及技术需求 ····· 10
2.2 卷积神经网络的结构 ····· 12
2.2.1 VGG ····· 13
2.2.2 ResNet ····· 14
2.2.3 HRNet ····· 15
2.2.4 RepViT ····· 16
2.3 基于 Transformer 的关键点检测 ····· 17
2.3.1 Transformer 的结构 ····· 18
2.3.2 Vision Transformer ····· 18
2.3.3 Pyramid Vision Transformer ····· 20
2.3.4 TokenPose ····· 21
2.4 本章小节 ····· 22
第三章 基于量化自注意力的服装关键点检测 ····· 23
3.1 量化自注意力模块的设计 ····· 23
3.1.1 服装特征的量化表示 ····· 25
3.1.2 服装特征码本更新策略 ····· 26
3.2 多阶段渐进细化策略 ····· 28
3.2.1 初始关键点回归 ····· 28
3.2.2 关键点嵌入与量化自注意力的结构感知 ····· 28
3.2.3 坐标细化与不确定性估计 ····· 29

3.3 基于多阶段量化自注意力的服装关键点检测网络 …… 30
3.4 实验与分析 …… 31
3.4.1 实验数据集 …… 31
3.4.2 数据预处理 …… 32
3.4.3 实验基础设置说明 …… 33
3.4.4 评价指标 …… 35
3.4.5 实验结果分析 …… 36
3.5 本章小节 …… 40
第四章 基于空间离散建模的服装关键点检测 …… 42
4.1 基于空间离散建模的服装关键点检测框架 …… 42
4.1.1 框架整体设计 …… 42
4.1.2 传统关键点检测范式与空间离散建模的对比 …… 43
4.1.3 QAM 在不同网络框架中的作用 …… 44
4.2 空间离散建模结构设计 …… 44
4.2.1 空间离散建模的基本原理 …… 44
4.2.2 高斯平滑策略 …… 45
4.3 空间离散建模策略 …… 45
4.3.1 空间离散建模的基本形式 …… 45
4.3.2 空间划分策略 …… 46
4.3.3 概率散度度量与损失函数 …… 48
4.4 位置编码的设计 …… 49
4.5 实验与分析 …… 51
4.5.1 消融实验 …… 51
4.5.2 对比实验 …… 52
4.5.3 可视化结果分析 …… 54
4.6 本章小结 …… 55
第五章 总结与展望 …… 56
5.1 工作总结 …… 56
5.2 课题展望 …… 57
参 考 文 献 …… 58
作者简历及在学期间所获得的学术成果 …… 64
致 谢 …… 66

图录

图1-1 服装关键点示意图 1
图2-1 DeepFashion2中不同类别服装关键点的数量（来源于文献[41]） 10
图2-2 VGG结构示意图（来源于文献[47]） 13
图2-3 ResNet中的残差单元（来源于文献[17]） 15
图2-4 HRNet结构示意图（来源于文献[18]） 16
图2-5 MobileNet Block与RepViT Block结构示意图（来源于文献[48]） 17
图2-6 ViT结构示意图（来源于文献[54]） 19
图2-7 PVT结构示意图（来源于文献[55]） 20
图2-8 TokenPose结构示意图（来源于文献[28]） 21
图3-1 同一件服装在不同场景下的关键点分布 23
图3-2 量化自注意力模块 24
图3-3 MQA-Net结构示意图 30
图3-4 DeepFashion2数据集示例 31
图3-5不同码本大小对性能的影响 36
图3-6 MQA-Net在DeepFashion2上的可视化结果 40
图4-1 LSD-Net的网络结构 43
图4-2 三种不同的空间划分策略 46
图4-3 不同空间划分策略对关键点坐标解码精度的影响 48
图4-4 显式位置编码示意图 50
图4-5 LSD-Net在DeepFashion2上的可视化结果 54

表录

表3-1 实验环境的配置.....33
表3-2 骨干网络的参数配置.....34
表3-3 不同细化阶段数对性能的影响.....37
表3-4 本章提出的MQA-Net与其他方法的对比.....38
表4-1 QAM在不同网络框架中的作用.....44
表4-2 QAM和SD对模型性能的影响.....51
表4-3 不同空间划分策略对模型性能的影响.....52
表4-4 本章提出的LSD-Net与其他方法的对比.....52

第一章 绪论

1.1 研究背景及意义

服装不仅是人类生活的基本需求之一，不仅有基本的御寒和保护的功能，还承载着文化、社会和经济等多重价值。服装行业是创造美好时尚生活的基础性消费品产业和民生产业，也是体现技术进步、社会文化发展和时代变迁的创新型产业。现代社会中，服装更是成为个性表达的重要载体，人们通过不同的搭配展示自我，特定的服饰甚至可以传达民族传统、地域文化及宗教信仰。

在电子商务的快速发展下，服装产业的数字化和智能化进程显著加快，智能技术的应用成为行业发展的重要驱动力。据国家统计局公布数据显示，2023 年网络零售分品类交易额占比中，服装鞋帽、针织纺品是第一大品类，占实物商品网络销售额的 22.0%，但其在 2024 年的增速相较于 2023 年明显放缓[1]，表明传统的线上销售模式已逐渐接近饱和。在此背景下，提升线上购物体验成为行业进一步发展的关键。消费者期望有更加智能化、个性化的购物方式以弥补现有方式的局限性。因此，计算机视觉技术在服装产业中的应用愈发重要，从服装检索[2]、推荐系统[3]到虚拟试衣[4]等技术的不断优化，正在为消费者提供更便捷的购物体验。

图 1-1 服装关键点示意图
Fig 1-1 Schematic diagram of clothing keypoints

在计算机视觉技术的诸多下游技术中，服装关键点检测一直是服装分析领域的基础性研究方向之一，长期以来收到广泛关注，如图 1-1 所示，其主要任务是

识别并定位服装的关键部位，如袖口、领口、腰线、裤脚等。这一任务的核心在于通过计算机视觉技术精确建模服装的结构特征，从而实现在复杂服装形态、剧烈形变及严重遮挡情况下的稳健关键点识别。通过对关键点的快速准确检测，可以在虚拟试衣中确保虚拟服装与人体的匹配度，提升试穿效果的真实性。

对于关键点检测领域而言，目前主流的工作更多是针对人体姿态估计的，服装关键点检测与人体姿态估计在方法论上具有一定的相似性，均涉及对图像中目标对象的关键点进行识别与定位，然而，二者在任务目标和挑战方面存在显著差异，服装具有更复杂的视觉特征，会受到非刚性形变、遮挡、纹理等多因素的影响，具体技术挑战包括：（1）服装通常由柔性材料制成，其形态受穿着者的个人因素影响较大，同一款长裤可能在不同的姿态下产生褶皱和拉伸，导致其形态完全不同，甚至在相同姿态下，由于穿着者体型的不同，关键点位置也会发生显著变化；（2）服装图像在拍摄过程中往往会受到不同程度的遮挡，如层叠穿着的上衣与裙子、背包与上衣的交叠部分以及长发可能会遮挡衣领和肩部等，这些遮挡问题不仅影响关键点的准确定位，还可能导致模型在训练过程中产生错误的监督信号；（3）由于服装图像的拍摄角度和距离不同，多样的光照条件可能会导致服装关键点的高亮或阴影，从而对检测结果带来影响，服装在图像中表现的尺寸也会因拍摄距离的不同发生变化；（4）服装图像往往会受到纹理相似性与复杂背景的干扰，某些印花服装上的图案可能与关键点的形态类似，从而误导关键点检测，复杂的拍摄背景也可能和服装颜色相似，导致模型难以区分目标区域。为了解决上述挑战同时更好地拟合服装的使用场景以及刻画服装轮廓，服装图像数据集会包含多种服装类别、以及多样的拍摄场景，较新的数据集往往还会有更加密集的关键点标注，为服装关键点检测任务提供了高质量的数据支持。

尽管服装关键点检测任务面临诸多挑战，但服装本身的一些特性也为该任务提供了新的研究视角：服装的关键点都有明确且层次化的语义信息，Yu 等人[5]提出使用布局图来表示服装关键点，构建了一个包含根节点、身体部位节点（如上半身、下半身）、粗略服装部位节点（如衣领、袖子）以及具体关键节点（如左衣领、有衣领）的层次化布局图，通过图卷积操作来进行学习和推理，使得预测结

果有了更加合理的结构表示；服装图像中的颜色和纹理也是非常重要的特征，颜色可以提供局部一致性约束，而纹理提供的细粒度信息有助于区分服装的不同区域，Chen 等人[6]提出了双重注意力特征增强模块，不仅考虑到了服装图像中的多尺度特征，还设计了通道注意力选择模块，通过建模通道之间的相互依赖的关系，强调与任务相关的通道特征（如颜色、纹理），从而提高特征的有效性；服装关键点之间有较强的依赖关系以及对称性，比如领口、肩膀、袖子之间的连接就有类似与人体解剖结构的运动学关系，此外，服装的左右两侧通常具有对称性，Wang 等人[7]依赖上述关系，定义了对应的服装语法，并使用双向卷积递归神经网络模拟消息传递过程，从而能够有效地处理服装语法中的复杂关系，并生成更符合人体解剖结构和对称性的关键点位置。

上述的方法都利用到了服装图像的一些特性来进行关键点检测工作，但无论是利用了颜色、纹理还是服装的结构信息，它们都是在强大骨干网络的基础上进一步提升预测准确率，充分依赖于多尺度骨干网络学习到的充足局部和全局特征。因此，通过合理的建模方式来学习的充足的语义和结构信息来提复转关键点检测精度是十分有必要的。

1.2 研究现状

1.2.1 关键点检测研究现状

关键点检测作为计算机视觉领域的核心任务之一，其研究方法经历了从传统计算机视觉技术到深度学习模型的演变。在早期研究中，关键点检测主要依赖手工设计的特征，并结合传统机器学习方法进行关键点定位。例如，尺度不变的特征变换（Scale-Invariant Feature Transform, SIFT）[8]算法用于提取和匹配图像特征，构建不同尺度下的高斯金字塔，并使用高斯差分（Difference of Gaussians, DoG）[9]来检测关键点。此外，方向梯度直方图（Histogram of Oriented Gradients, HOG）[10]也被用作人体关键点的特征描述符，并结合图示结构模型（Pictorial Structures Model, PSM）[11]，利用 HOG 特征来匹配不同部位的潜在位置。这些方法虽然在

特定场景下表现良好，但由于依赖于手工设计特征，对复杂环境、视角变化和遮挡等情况的适应性较弱，泛化性能有限。

随着计算机硬件的发展，深度学习技术也取得了长足进步，关键点检测技术的核心也从手工设计的特征描述符转向卷积神经网络（Convolutional Neural Networks, CNN）。2014 年，Toshev 和 Szegedy[12]在提出了 DeepPose，首次引入 CNN 来完成人体姿态估计。DeepPose 将关键点检测视为回归问题，并采用级联策略优化关键点的预测，之后基于 CNN 的端到端的关键点检测方法也逐渐成为主流。Sun 等人[13]采用了重参数化的姿态表示，用基于骨骼的表示来代替之前用关节表示姿态的方法，通过预测骨骼长度、计算相对关节的位置来重建人体姿态。然而，基于回归的方法由于直接回归关键点坐标，缺乏空间约束，且受限于网络深度限制，对复杂背景和遮挡的建模能力有限。

为了克服基于回归方法的局限性，研究人员开始将研究重点转向基于热图的方法。在这类方法中，神经网络不再直接预测关键点的坐标，而是通过 CNN 生成每个关键点的热图，代表性工作包括：Newell 等人[14]提出了堆叠沙漏网络（Stacked Hourglass Network），采用对称的编码-解码结构，逐层提取全局和局部特征，通过多尺度特征融合，增强了局部关键点与全局背景之间的关联；Wei 等人[15]提出了卷积姿态机（Convolutional Pose Machines, CPM），在初始阶段粗略预测关键点热图，之后的级联阶段通过细化热图，提高定位精度，并采用长短程依赖建模，提升了对复杂姿态的适应性；Xiao 等人[16]提出了简单基线模型（Simple Baseline, SBL），采用 ResNet[17]作为骨干网络，借助其跳跃连接的模型结构，解决了深度网络训练中的梯度消失问题，使得更深层的网络可以稳定训练，并在骨干网络之后添加反卷积层以恢复高分辨率特征，再通过热图预测关键点位置，该方法验证了深度网络配合简单的后处理也能实现高精度关键点检测，成为许多后续方法的基础。

尽管上述方法在关键点检测上取得了成功，但它们在特征提取过程中都存在分辨率下降的问题，为了缓解这一问题，Sun 等人[18]提出了 HRNet（High-Resolution Network）。HRNet 与传统的 CNN 结构不同，在整个网络过程中始终维持高分辨率

的特征表示，避免特征下采样带来的信息损失，并且将高低分辨率的特征统合，以提高关键点预测的精度。在 HRNet 的基础上，Yu 等人[19]将 ShuffleNet[20]中高效的 shuffle 块应用到其中，构建了更高效的高分辨率网络。Kan 等人[21]引入了自校正和自适应推理方法来解决网络预测的泛化挑战，解决了网络无法表征预测误差的问题。Wang 等人[22]将 HigherHRNet[23]进行逐步缩减，渐进式地抛弃网络中的一些模块和分支，得到一个接近于但分支地结构，为轻量级关键点检测模型提供了一个新思路。

近年来，Transformer[24]结构在计算机视觉任务中的应用迅速增长，并被引入关键点检测任务中，以提升模型的全局建模能力。Li 等人[25]提出了 PRTR（Pose Regression Transformer），探索了 Transformer 在关键点检测任务中的应用，该方法结合 CNN 进行特征提取，并利用 Transformer 进行全局建模，以提升关键点检测的鲁棒性。PRTR 证明了 Transformer 结构可以有效增强关键点检测任务中的全局依赖建模能力。Ding 等人[26]提出的 HR-NAS 将 Transformer 结构嵌入了 CNN 中，并针对像关键点检测这样的密集预测任务，提出了一种高效的细粒度 NAS[27]方法，有效地探索搜索空间，找到关键点检测任务下的最佳架构。Li 等人[28]提出的 TokenPose 进一步将人体关键点表示为一组可学习的 tokens，并利用 Transformer 编码器捕捉关键点之间的全局关系，这种方法在保持较高精度的同时，计算复杂度较传统 CNN 方法更低。Xu 等人[29]提出的 ViTPose 完全弃用了 CNN，采用纯视觉 Transformer（Vision Transformer, ViT）架构，结合高效的位置编码机制，以增强空间信息的保持能力，同时结合轻量级解码器便可在 MS COCO[30]数据集上达到 SOTA 性能，展现了 Transformer 在关键点检测任务中的强大潜力。Ding 等人[31]针对图像中多实例的情况，利用 Transformer 建立实例内部表征的关系来学习实例的全局表征，最后通过实例级别的特征来预测关键点位置。

此外，图神经网络（Graph Neural Networks, GNNs）在关键点检测任务中也逐渐受到关注。与传统的 CNN 或 Transformer 方法不同，GNN 可以直接建模关键点之间的拓扑结构关系，从而更有效地捕捉空间依赖性。Luo 等人[32]提出了 Graph-PCNN，采用图卷积网络（Graph Convolutional Networks, GCN）[33]建模关键点间

的结构信息，并结合 CNN 提取局部特征，以增强关键点检测的鲁棒性。

尽管 CNN 和 Transformer 方法在关键点检测领域取得了重大突破，但仍存在一些挑战：首先，高精度的 CNN 和 Transformer 模型通常需要庞大的计算机资源，导致其实际应用场景有限；其次，当面临遮挡、极端姿态或复杂背景等情况时，模型的预测性能会下降，出现关键点定位偏差等问题。

1.2.2 服装关键点检测研究现状

服装关键点检测类似于人体姿态估计，当前大多数研究都遵循单人姿态估计的基本方案。在早期研究中，服装关键点检测方法主要依赖于基于图像特征的传统计算机视觉技术。例如，一些方法尝试利用几何先验信息或基于服装轮廓的形状约束来辅助关键点定位。然而，由于服装材料的非刚性形变、褶皱、遮挡以及不同款式间的巨大外观差异，这些基于手工规则的方法在复杂场景下难以保证鲁棒性和泛化能力。

随着深度学习的发展，基于 CNN 的服装关键点检测方法逐渐成为主流。例如，Liu 等人[34]提出了 FashionNet，首次将深度神经网络引入到服装关键点检测任务上。FashionNet 通过联合预测服装属性和服装关键点来学习更加鲁棒的服装特征。同时，该研究还公开了 DeepFashion 数据集，该数据集包含超过 80 万张图像，并提供了丰富的标注信息，包括服装关键点、不同场景下的服装对应关系，以及材质、纹理等多个属性。这一数据集的发布为后续的服装关键点检测研究提供了坚实的数据基础。此外，Liu 等人[35]还提出了深度时尚对齐（Deep Fashion Alignment, DFA）框架，该框架通过级联网络逐步提升关键点定位精度，解决服装形变和遮挡问题，还额外输出关键点的可见性状态，以增强模型鲁棒性，除此之外，研究者还发布了专为服装关键点检测任务的设计的数据集 Fashion Landmark Dataset，该数据集从 DeepFashion 数据集中筛选了姿态和尺度变化较大的图像子集，定义了 8 个服装上的功能性关键点，相较于 DeepFashion 进一步扩展了关键点数量和标注规模。Yan 等人[36]提出了深度关键点网络（Deep LAndmark Network, DLAN），该

网络包含用于处理尺度差异的选择性膨胀卷积以及用于处理背景干扰的分层循环空间转换，通过端到端的方式实现边界框于关键点的联合检测与迭代训练。

除了上述早期的基于回归的服装关键点检测网络，目前主流的服装关键点检测网络多采用基于热图的范式。例如，Hu 等人[37]提出了一种基于 CNN 的序列预测框架，该框架能够学习服装关键点之间的空间结构关系，从而减少服装摆放方式和人体姿态对服装关键点的影响。Li 等人[38]设计了非局部空间感知（Spatial-Aware Non-Local, SANL）模块，该模块可以有效融合空间和语义信息，并捕捉全局依赖性，利用该模块搭建的特征金字塔骨干网络结合逐步细化的特征图，显著提高了关键点的定位精度。Huang 等人[39]通过精心设计的卷积层来获取关键点位置的初始概率图，并结合关键点之间的相对位置和方向信息来建模关键点之间的依赖关系。同时，该研究还提出了一个包含超过 14 万张上半身服装图像的数据集，每张图像均标注了十个关键点，为服装关键点检测任务提供了更加丰富的数据支持。Wang 等人[40]提出利用方向感知空间注意力（Direction-aware Spatial Attention Module, DSAM）模块，将方向信息嵌入空间注意力，以捕捉全局上下文信息。在此基础上，研究者还基于 DSAM 构建了空间注意力模块（Spatial Attention ResBlock, SARB），并利用该模块设计了用于特征提取的残差网络，该网络通过自上而下的特征细化和多尺度特征聚合，进一步提升了关键点检测的精度和鲁棒性。

2019 年，Ge 等人[41]公开了 DeepFashion2 数据集，相较于 DeepFashion，DeepFashion2 提供了更加密集的关键点标注以及更精细的服装分类信息。基于此数据集，谢志峰等人[42]借鉴了深度可分离卷积的思想，设计了空间特征引导注意力模块，强化了不同特征通道之间的信息交互。此外，还采用了 Lin[43]提出的分组和微调训练策略以及 Huang 等人[44]提出的无偏数据处理方式，在降低计算量的同时，提高了关键点检测的准确率。Sidnev 等人[45]提出了 DeepMark++，通过语义关键点分组策略，降低了训练时的内存占用，并联合中心重评分、平滑热图响应、融合粗定位与精细定位结果以及抑制离群预测等后处理操作，在不增加计算负担的情况下，提升了关键点检测精度。

1.3 研究内容

本文围绕服装关键点检测任务，针对现有方法在全局依赖关系建模、计算复杂度以及检测头对高分辨率特征图的依赖性等方面的不足，展开以下研究：

（1）针对传统方法对服装关键点全局依赖关系捕获能力不足的问题，设计一种量化自注意力模块（QAM），用于增强模型对服装结构全局上下文信息的捕获能力，通过向量量化将连续特征投影到离散特征空间，将原始连续自注意力计算转换为基于码本的稀疏查询，降低自注意力的计算复杂度。

（2）针对传统回归方法难以建模关键点间复杂关系的局限性，提出了基于QAM的多阶段回归框架，通过迭代细化关键点预测并建模关键点间的相互依赖提升了检测精度。

（3）针对传统空间表示方法的不足，提出一种基于可学习空间离散建模的检测范式，通过动态调整空间划分实现精度资源的自适应分配，使其更符合服装关键点不均匀分布的特点，并结合残差对数似然估计实现可靠的不确定性建模，在保持计算效率的同时提升检测精度。

1.4 文章组织结构

本文的结构安排如下：

第一章：绪论。本章首先介绍了服装关键点检测的具体任务及其研究背景，接着对现有的关键点检测方法进行了介绍，同时归纳总结了服装关键点检测任务相较于其他关键点检测任务存在的难点，并介绍了本文的研究内容，最后归纳整理了本文的研究内容和组织架构。

第二章：服装关键点检测与深度学习。本章主要调研了深度学习方法在关键点检测上的主要应用。本章首先对关键点检测任务进行简要描述，回顾了用于服装关键点检测的经典网络结构（VGG、ResNet、HRNet、RepViT）以及注意力机制，并对这些模型结构的优缺点进行了分析。

第三章：基于量化自注意力的服装关键点检测。本章针对传统直接回归方法

在服装关键点检测任务中难以有效建模关键点间全局依赖关系的局限性，提出了一种基于量化自注意力增强的多阶段回归框架，将关键点坐标嵌入至特征空间，并通过多轮迭代处理捕获关键点间的长距离依赖关系。介绍了实验环境的配置和具体实施细节，最后通过对比实验、消融实验以及可视化结果进行分析，验证了提出的方法在复杂场景下的有效性。

第四章：基于空间离散建模的服装关键点检测。本章针对传统热图方法计算开销大、直接回归方法精度受限的问题，提出了一种基于可学习空间离散建模的服装关键点检测框架，将坐标预测问题转化为离散空间中的概率分布预测。设计了可学习的空间离散化机制，通过动态调整坐标区间的划分，使模型能够自适应地将精度资源分配给关键区域，最后通过实验结果证明该方法的有有效性，并可视化展示模型在 DeepFashion2 上的关键点检测结果。

第五章：总结与展望。本章对论文的研究内容及成果进行了整理与总结，分析了本文所提出方法的优势和不足，并对后续研究方向进行了展望。

第二章　关键点检测与深度学习

本章首先围绕关键点检测任务的特性与技术需求展开讨论，并介绍了基于 CNN 和 Transformer 的主流深度学习模型，分析其在关键点检测任务中的应用与改进策略。

2.1 关键点检测的任务特性及技术需求

关键点检测是计算机视觉中的一个核心任务，其核心目标是从输入图像中精确定位具有特定语义的稀疏点状目标，该任务广泛应用于人体姿态估计、面部关键点检测、手部关键点检测以及物体关键点检测等多个领域。关键点检测具有独特的任务特性和技术需求，主要体现在关键点的稀疏性、目标形态的多变性以及关键点间的结构化约束三方面。

首先，关键点检测任务通常涉及有限数量的目标点。例如，在服装关键点检测中，如图 2-1 所示，典型的关键点数量通常介于 8 到 37 个，而人体姿态估计中的关节点数量一般不超过 30 个。这种稀疏性使得关键点检测不同与目标检测或全局密集预测任务，后者的输出通常是连续的区域或者密集的像素分布。由于关键点仅占图像中的极少数像素，模型必须具备从全局信息中有效提取关键点特征的能力，以避免背景噪声的干扰。

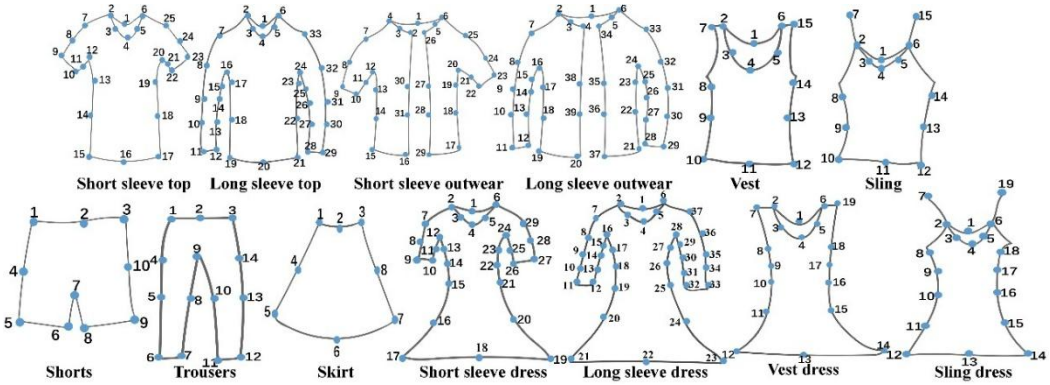

图 2-1 DeepFashion2 中不同类别服装关键点的数量（来源于文献[41]）

Fig 2-1 The number of annotated keypoints per clothing category in the DeepFashion2 dataset (Origin from [41])

其次，关键点检测任务面临显著的形态变化挑战，尤其是在涉及非刚性目标时。例如，服装的形态会受到穿着者姿态、布料材质、光照条件、摄像角度等因素的影响，使得同一件衣服在不同状态下可能呈现出完全不同的轮廓形态和褶皱分布。这种形变不仅影响关键点的绝对坐标，还可能改变关键点之间的相对几何关系，导致模型难以依赖固定的模式进行预测。为了应对这一挑战，模型需要具备高鲁棒性的特征表示能力，能够学习不同形态下的关键点分布模式，并结合上下文信息进行推理。

最后，关键点检测的输出具有明确的结构化特征，各个关键点之间并非独立存在，而是通过特定的空间关系相互关联。例如，在人体姿态估计中，关节点对应于人体结构的关键部位，手肘必须与肩膀和手腕形成合理的连接关系，而服装关键点通常沿服装轮廓排列，遵循一定的拓扑关系。这种结构化分布使得关键点之间的相对位置存在较强约束，即使在部分关键点不可见的情况下，仍可通过整体结构推测其合理位置。因此，模型不仅需要具备局部精准定位关键点的能力，还需要具备全局上下文建模能力，能够学习关键点之间的空间依赖关系，以确保关键点间的空间一致性和拓扑约束的满足。

针对上述任务特性，关键点检测算法需要满足多方面的技术要求。在特征提取方面，模型需要具备保持高分辨率特征的能力。传统卷积网络通过逐层下采样来扩大感受野的涉及思路在关键点检测任务中存在明显局限，下采样操作会导致关键点的空间细节信息丢失严重。为解决这一问题，当前的主流方法主要采用两种技术路线：其一是利用转置卷积等操作对特征图进行上采样以恢复空间细节；其二是通过多尺度特征融合架构来维持高分辨率的特征表示。

在几何形变建模方面，关键点检测算法需要具备处理非线性几何变换的能力。由于目标的关键点分布可能会因为目标本身的特性发生复杂变化，传统的卷积操作难以适应这种形变特性。为此，研究者们提出了多种解决方案，包括可变性卷积这种能够自适应调整采样点的卷积操作以及在数据层面通过几何增强策略来提升模型对形变的鲁棒性。

在关系推理方面，关键点检测算法需要具备处理全局依赖关系的能力。当关

键点受到遮挡时，仅依靠局部视觉信息往往难以做出准确判断，此时需要模型能够利用上下文信息进行推理。例如，基于自注意力机制的 Transformer 架构能够有效建模长程依赖关系，图神经网络可以显式编码关键点之间的拓扑约束。这些方法都突破了传统卷积操作的局部感受野的限制，使模型能够整合更大范围的上下文信息。

基于深度学习的关键点检测技术已经形成了相对完整的技术体系，当前的主流方法可以分为三类：基于卷积神经网络的方法主要依靠精心设计的网络架构来维持高分辨率特征表示；基于注意力机制的方法通过在 CNN 中嵌入通道或空间注意力模块来动态调整特征响应；基于 Transformer 的方法依赖自注意力机制来建模全局依赖关系。这些方法各有优势，卷积方法在局部特征提取上效率较高，注意力机制能够有效处理特征选择问题，而 Transformer 则在长程依赖建模方面表现突出。在实际应用中，这些方法并非相互排斥，而是常常被组合使用以发挥各自优势。

2.2 卷积神经网络的结构

卷积神经网络作为深度学习在计算机视觉领域的核心架构，其设计灵感源自生物视觉皮层的感受野机制。CNN 是一种前馈神经网络，通过卷积层对输入数据进行特征提取，并逐层学习图像中的空间层次特征，能够高效处理图像数据，捕捉局部空间信息，且在多层次上逐步学习更复杂的特征表示。

CNN 的基本构成包括卷积层、池化层、全连接层等，其中卷积层是其核心组成部分。卷积层通过卷积核与输入图像进行卷积运算，提取局部区域的特征。这些卷积核通常包含较少的参数，并且通过共享权重机制减少模型的计算量。每个卷积核通过滑动窗口的方式对图像进行卷积操作，得到的特征图代表了图像在该局部区域的特征。

卷积操作之后，池化层通常用于下采样特征图，减少特征图的尺寸，同时保留重要的空间信息。最常见的池化方法包括最大池化和平均池化，其中最大池化

通过选择局部区域内的最大值来进行降维，从而保持图像中的最显著特征；而平均池化计算池化窗口内所有像素值的均值，保留整体信息的平滑特征，但可能会导致特征细节的丢失。

在卷积和池化层之后，通常会连接一个或多个全连接层，用于整合前面层提取的特征并进行最终的决策输出。全连接层通过将所有节点与前一层的所有节点连接来完成复杂的非线性变换，最终输出分类或回归结果。

尽管卷积神经网络在计算机视觉任务中取得了显著的成功，但不同的 CNN 结构在设计上具有各自的特点，并针对不同的任务需求进行了优化。早期的 CNN 主要依赖较浅的网络结构，但随着网络深度的增加，模型的特征表达能力显著提升，然而也引入了梯度消失、计算开销较大等问题。为了克服这些挑战，研究者们提出了不同的 CNN 结构，如 VGG[46]通过堆叠小卷积核加深网络、ResNet 通过残差连接缓解梯度消失问题、HRNet 通过多分支结构保持高分辨率特征、RepViT 通过整合轻量级视觉 Transformer 的高效架构设计，增强了标准轻量 CNN。

2.2.1 VGG

Simonyan 和 Zisserman[46]于 2014 年提出的 VGG 网络是一个典型的深层卷积神经网络，具有多层结构，其核心贡献在于验证了小卷积核深度堆叠的有效性，为后续深度网络设计奠定了结构范式，VGG 的网络结构如图 2-2 所示。

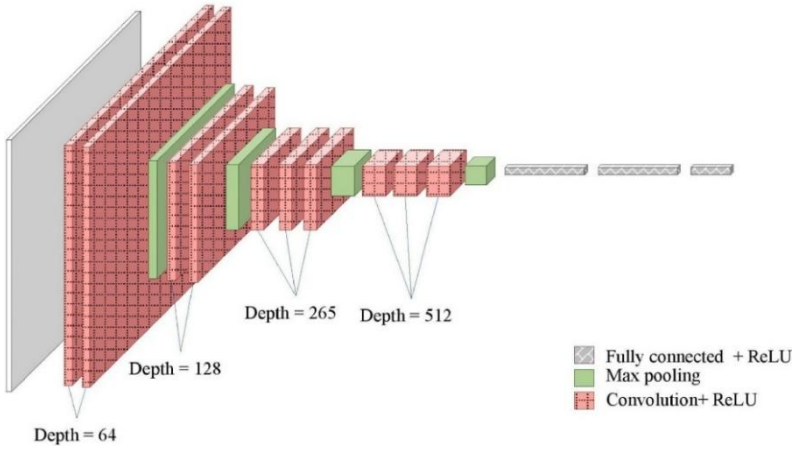

图 2-2 VGG 结构示意图（来源于文献[47]）
Fig 2-2 Structure of VGG (Origin from [47])

VGG 网络在整个架构中使用多个 3×3 的小卷积核代替较大尺寸的卷积核来增加网络的深度，这样做的好处是在保持计算量可控的同时，提高模型的非线性表达能力，并通过不断叠加卷积层和池化层，逐步加深网络，从而提取更复杂的特征。VGG 虽然是为分类任务设计的，但是在关键点检测任务中，VGG 可以作为特征提取网络，将输入图像转化为高维特征表示，既可以用于生成关键点的热力图，也可以直接回归得到关键点坐标。

尽管 VGG 结构简单，但由于其多层的池化层会导致分辨率下降，在细粒度关键点检测上，细节信息可能丢失，同时在网络堆叠过深的时候会出现梯度消失问题，导致网络的训练难度增大。

2.2.2 ResNet

He 等人[17]于 2016 年提出了 ResNet，通过跳跃连接解决了深度网络的梯度消失问题。ResNet 的核心在于残差块的设计，其前向传播过程可表述为：

$$y = \mathcal{F}(x, \{W_i\}) + x \tag{2-1}$$

其中，$\mathcal{F}(x, \{W_i\})$ 表示由权重参数 $\{W_i\}$ 定义的残差变换函数，x为输入特征，y为输出特征。该设计在数学上实现了原始特征与非线性变换特征的逐元素加和，这种结构在反向传播过程中可表示为：

$$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial y} \cdot \left(\frac{\partial \mathcal{F}}{\partial x} + I \right) \tag{2-2}$$

其中 I 为单位矩阵，确保即使当 $\partial \mathcal{F} / \partial x$ 趋近于 0 时，梯度仍能通过恒等路径有效传播，缓解深度神经网络的退化问题。

针对深层网络的优化需求，研究者进一步提出了 Bottleneck 的改进方案，如图 2-3 所示，当网络深度较小时，直接通过 a)中的 3×3 卷积提取特征，而网络深度较大时，则通过 b)中 1×1 卷积实现特征维度的先降后升，在减少计算量的同时，保持模型表达能力。

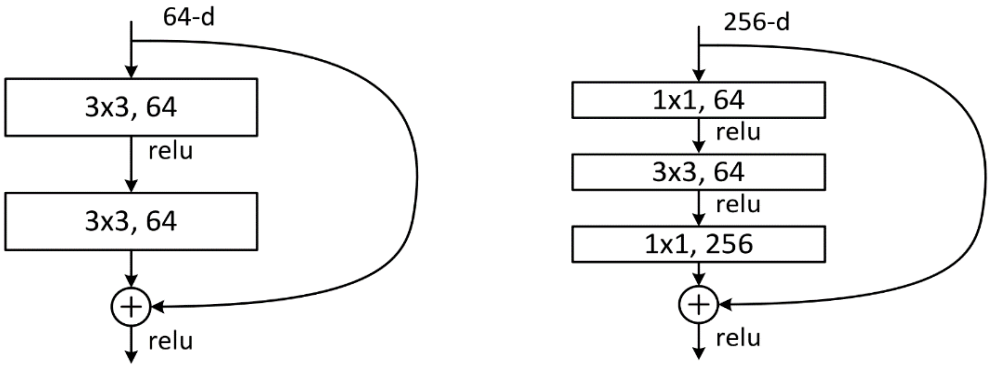

a) 应用于浅层网络的残差单元
a) Residual units for shallow networks

b) 应用于深层网络的残差单元
b) Residual Units for Deep Networks

图 2-3 ResNet 中的残差单元（来源于文献[17]）
Fig 2-3 Residual units in ResNet (Origin from [17])

2.2.3 HRNet

对于关键点检测这类需要高分辨率信息的任务，多次下采样操作会导致特征图的分辨率下降，从而影响细节识别能力。与 VGG 和 ResNet 依赖逐层下采样来减少计算量的方式不同，HRNet（High-Resolution Network）采用多尺度分支并行计算的策略，在整个特征提取过程中始终保留高分辨率信息，以更好地捕捉精细结构和局部细节，其网络结构如图 2-4 所示。

HRNet 的核心设计在于保持多尺度特征表示并进行高效的信息融合。具体来说，该网络在特征提取过程中维护四个不同分辨率的分支，分别对应于输入图像尺寸的 1/4、1/8、1/16 和 1/32。这些分支并行计算，并通过多次双向信息交换进行特征融合，使得低分辨率特征可以整合高分辨率信息，从而增强全局感受野，同时保留局部细节，提高关键点定位的精准度。

在 HRNet 中，上采样操作采用 1×1 卷积层和批量归一化进行通道调整，并最终通过最邻近插值恢复到目标尺寸。下采样操作采用步长为 2、卷积核大小为 3×3 的卷积层，每当分辨率减少一半，就增加一个这样的卷积层，以逐步降低分辨率并提取深层特征。这种多尺度特征融合机制使得 HRNet 在保持高分辨率特征的同时，能够充分利用不同尺度的信息，提高网络的整体表现，尤其在关键点检测

任务中，能够更好地识别复杂场景中的细粒度结构，如遮挡、姿态变化和细微的关键点位移。

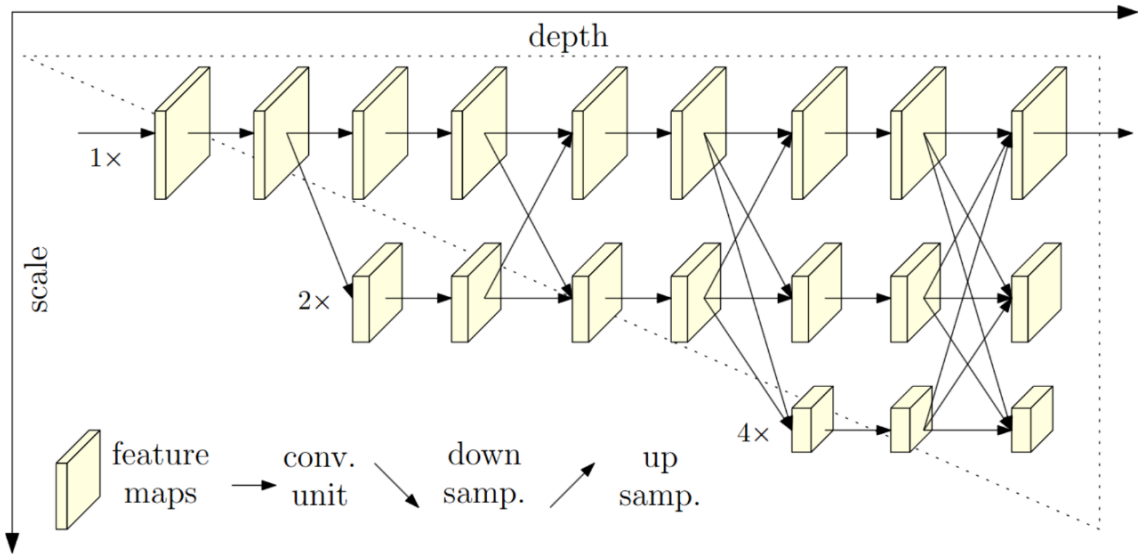

图 2-4 HRNet 结构示意图（来源于文献[18]）
Fig 2-4 Structure of HRNet (Origin from [18])

2.2.4 RepViT

Wang 等人[48]在 MobileNetV3[49]的基础上，借鉴轻量级视觉 Transformer 的设计理念，提出了一种高效的轻量级纯卷积网络——RepViT。该网络针对 MobileNetV3 的耦合式块结构进行了改进，引入了空间维度与通道维度特征交互分离的策略，以提升特征表达能力和计算效率。

如图 2-5 所示，RepViT 将 MobileNetV3 中顺序执行的空间信息融合（3×3 深度可分离卷积[50]）和通道信息融合（1×1 卷积）的操作进行解耦，同样引入可选择的 SE 模块[51]以增强通道注意力机制。此外，RepViT 采用结构重参数化技术[52]，在训练过程中使用多分支结构，增强梯度多样性，帮助模型学习更丰富的特征表示。在推理阶段，这些多分支结构可以通过卷积核融合转化为单一的等效卷积操作，从而消除额外的计算开销。这一策略使得 RepViT 在训练时具备更强的特征学习能力，同时在推理时仍保持轻量级、高效的单路径计算模式。

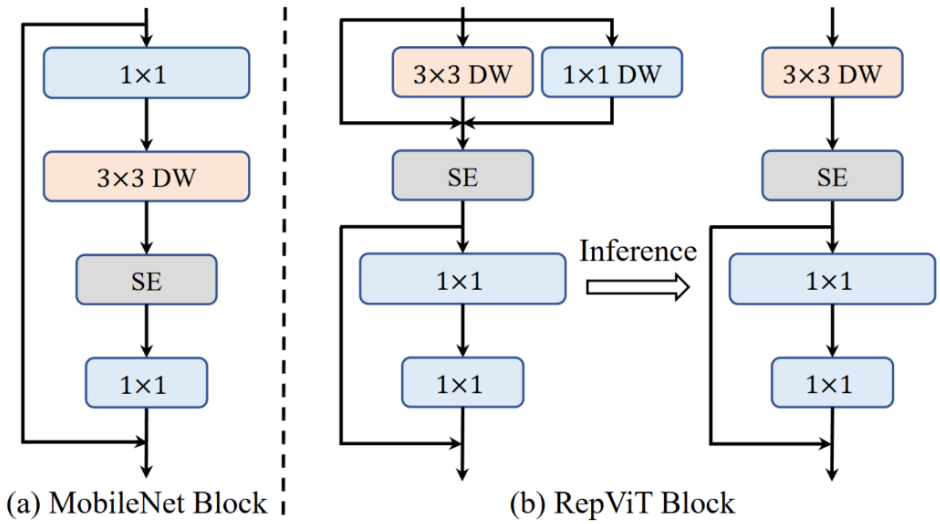

图 2-5 MobileNet Block 与 RepViT Block 结构示意图（来源于文献[48]）
Fig 2-5 Structure of MobileNet Block and RepViT Block (Origin from [48])

此外，RepViT 采用了一种渐进式下采样策略，在网络的 Stem 层连续使用多个 3×3 卷积，以增强初始特征提取的稳定性。这种设计不仅提高了模型对低层次信息的捕捉能力，同时也有助于优化整体网络的感受野分布，使其在轻量化与高效性之间取得更好的平衡。

2.3 基于 Transformer 的关键点检测

在关键点检测任务中，传统的卷积神经网络方法依赖于局部卷积操作和池化操作来提取特征。然而，这些方法在捕捉关键点长距离依赖关系、建模全局信息以及应对复杂形态变化等方面存在一定的局限性。由于 CNN 依赖局部卷积操作，其感受野受限，需要堆叠多个卷积层才能捕捉长距离依赖关系，这增加了模型深度和计算量。此外，池化操作和多层卷积在逐步提取高级语义特征的同时，也会不可避免地造成空间分辨率下降，从而影响关键点的精确定位。

随着计算机视觉任务对全局建模能力的需求不断提高，Transformer 架构逐渐进入视觉领域。相比于 CNN 结构，Transformer 擅长建模长距离依赖关系，能够自适应地捕捉输入序列中的全局上下文信息，这使其成为关键点检测等任务中对

复杂姿态建模的有力工具。

2.3.1 Transformer 的结构

Transformer 最初由 Vaswani 等人[24]提出，其主要由多个堆叠的编码器和解码器模块组成，在计算机视觉任务中则主要使用编码器结构。每个编码器层主要包括两大组成部分：多头自注意力机制（Multi-Head Self-Attention, MHA）和前馈神经网络（Feed-Forward Network, FFN）。在标准的 Transformer 模块中，设第l层的输入为 $X^{(l)} \in \mathbb{R}^{n\times d}$，$n$表示输入序列长度，$d$表示特征维度，多头注意力机制首先将输入分别线性映射为查询（Q_i）、键（K_i）和值（V_i）三个向量表示，接着计算每个注意力头：

$$head_i = Attention(Q_i, K_i, V_i) = softmax\left(\frac{Q_i K_i^\top}{\sqrt{d_k}}\right) V_i \tag{2-3}$$

最终，通过多头并行计算后拼接并投影回原始维度：

$$MultiHead\left(X^{(l)}\right) = Concat(head_i, \dots, head_h) W^O \tag{2-4}$$

FFN 采用两层全连接网络并引入非线性表达提升特征表达能力：

$$FFN(x) = RELU(xW_1 + b_1)W_2 + b_2 \tag{2-5}$$

其中，$W_1 \in \mathbb{R}^{d\times 4d}$ 是第一层的权重矩阵，通常将维度扩展 4 倍，$W_2 \in$ 是第二层的权重矩阵，将扩展的维度降回原来的大小，$b_1 \in \mathbb{R}^{4d}$、$b_2 \in \mathbb{R}^{4d}$ 分别是第一层和第二层的偏置项。

整个 Transformer 编码器层通过自注意力建模全局依赖，通过 FFN 提升表达能力，并通过残差连接和层归一化（LayerNorm）[53]保持训练稳定性。这种架构为如关键点检测的下游视觉任务提供了强大的全局建模框架，使其能够适应多尺度、多形变、遮挡等复杂结构建模场景。

2.3.2 Vision Transformer

Dosovitskiy 等人[54]首次将纯 Transformer 架构引入视觉任务中，提出了 Vision Transformer。如图 2-6 所示，在 ViT 的基本框架中，输入图像 $X \in \mathbb{R}^{C\times H\times W}$ 被划

分为 n 个不重叠的图像块（patches），每个 patch 的尺寸为 $P \times P$，此操作将二维图像转换为一维序列表示，其中 $n = \frac{H \times W}{P^2}$。每个 patch 通过展平处理后，再通过线性映射投影到高维特征空间中，以生成该 patch 的特征表示。为了弥补因图像划分带来的位置信息丢失，引入了位置编码，以确保 Transformer 能够感知各 patch 的相对或绝对位置。最终的输入形式为：

$$z_0 = [x_p^1 E; x_p^1 E; \dots x_p^N E] + E_{pos} \tag{2-6}$$

其中 $x_p^i \in \mathbb{R}^{P^2 \cdot C}$为第 i 个 patch 的展平表示，$E \in \mathbb{R}^{(P^2 C) \times D}$ 是投影矩阵，将每个 patch 映射到固定维度 D 的特征空间中。

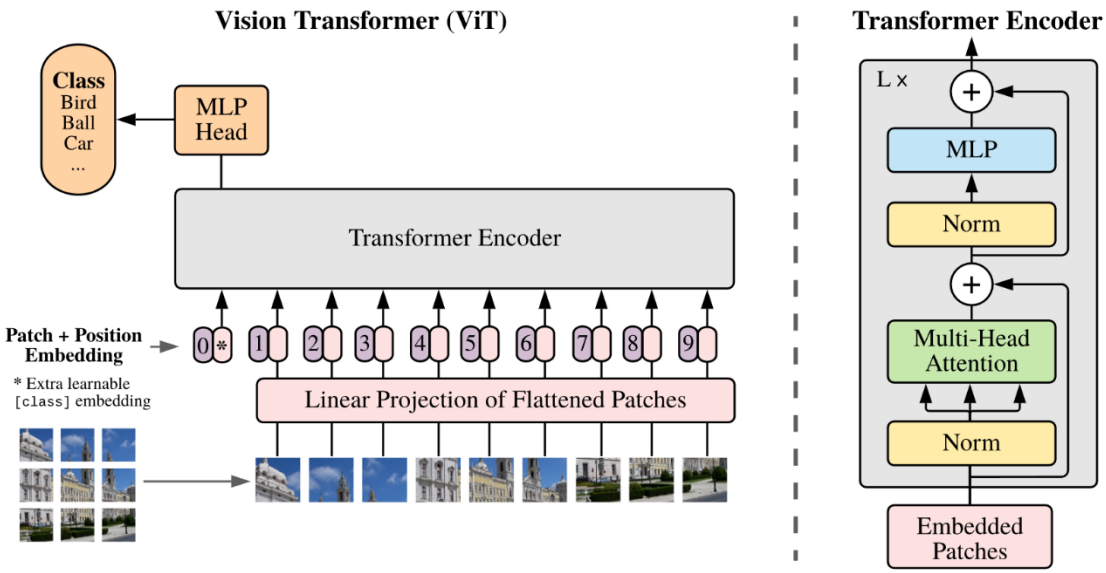

图 2-6 ViT 结构示意图（来源于文献[54]）
Fig 2-6 Structure of ViT (Origin from [54])

ViT 的关键优势在于不依赖 CNN 的结构归纳偏置，直接通过多层 Transformer 进行特征建模，使得其在大规模数据集上具备更强的表征能力。由于 Transformer 架构的全局自注意力机制，ViT 能够直接捕捉图像中的长距离依赖关系，克服了传统卷积神经网络在建模全局上下文方面的局限性。然而，ViT 在关键点检测等细粒度任务中仍面临一些关键挑战：首先，ViT 输入被划分为固定的 patch，导致了局部细节信息的丢失，在需要高精度定位的任务可能成为性能瓶颈；其次，ViT 架构本身缺乏针对局部结构建模的能力，导致其在数据量有限或者低分辨率的场

景中泛化能力较差；最后，Transformer 中的自注意力的计算复杂度为 $O(n^2)$，在高分辨率输入或者长序列建模中，影响了推理速度和效率。

2.3.3 Pyramid Vision Transformer

由于 ViT 中所有 token 都保持相同的尺度，模型难以构建层级特征表示，而传统 CNN 通过逐层下采样就可以提取不同尺度的特征图。针对这一问题，Wang 等人[55]借鉴 CNN 中的金字塔结构，提出了 Pyramid Vision Transformer（PVT），在 Transformer 架构中引入层级特征设计，以增强对多尺度信息的建模能力。

如图 2-7 所示，PVT 采用四个阶段逐步提取不同尺度的特征图，每个阶段都有相似的架构，包括一个 patch embedding 层（用来获取 patch 的展平表示）和 L_i 个 Transformer Encoder 层。在第一个阶段中，输入图像 $X \in \mathbb{R}^{H\times W\times C}$ 经过 patch embedding 层转换为 $\mathbb{R}^{\frac{HW}{4^2}\times C_1}$ 形式的特征表示，并加上位置编码之后输入 Transformer Encoder 层。随后，输出被重塑为 $\mathbb{R}^{\frac{H}{4}\times\frac{W}{4}\times C_1}$ 的特征图。类似地，在后续阶段，通过进一步下采样，PVT 逐步获得相对于输入图像尺寸下采样 8、16、32 倍的层级特征图，从而有效增强多尺度表征能力。

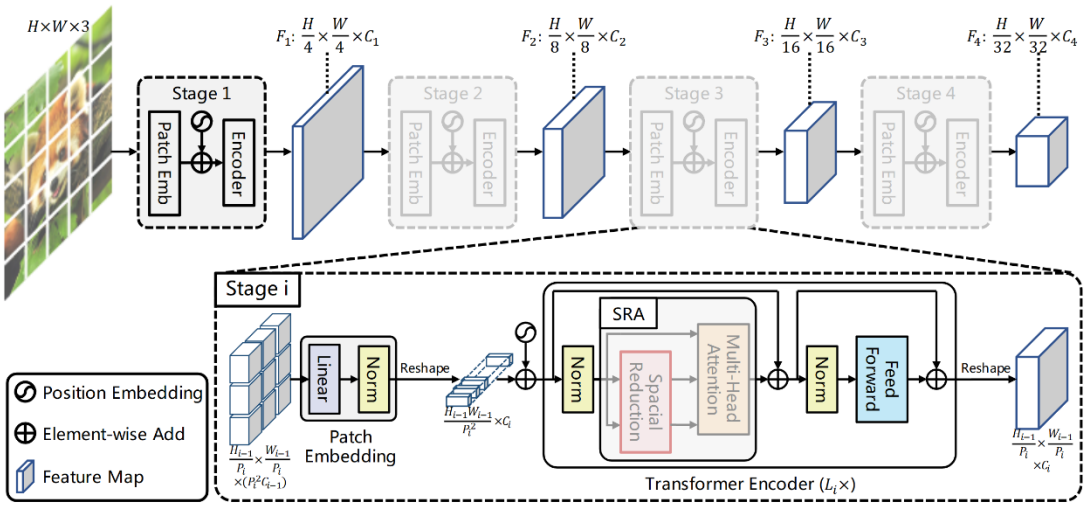

图 2-7 PVT 结构示意图（来源于文献[55]）
Fig 2-7 Structure of PVT (Origin from [55])

此外，为了降低计算复杂度，PVT 在自注意力机制中引入了空间降维注意力

（spatial-reduction attention, SRA）来替换传统的 MHA，即在计算 K，V 时，SRA 首先对其进行平均池化，将其空间维度由 $H \times W$ 降低至固定大小 $P \times P$，从而使计算复杂度从 $O(n^2)$ 降低到 $O(nm)(m < n)$，有效提升了计算效率。

2.3.4 TokenPose

TokenPose 在关键点检测任务中引入了 Transformer 架构，但不同于 PVT 采用的金字塔特征提取方式，其核心关注点在于关键点 Token 的建模。如图 2-8 所示，TokenPose 采用 CNN-Transformer 融合框架，结合 CNN 对图像纹理信息的学习能力与 Transformer 在关键点关系建模方面的优势，以提升关键点检测的精度。

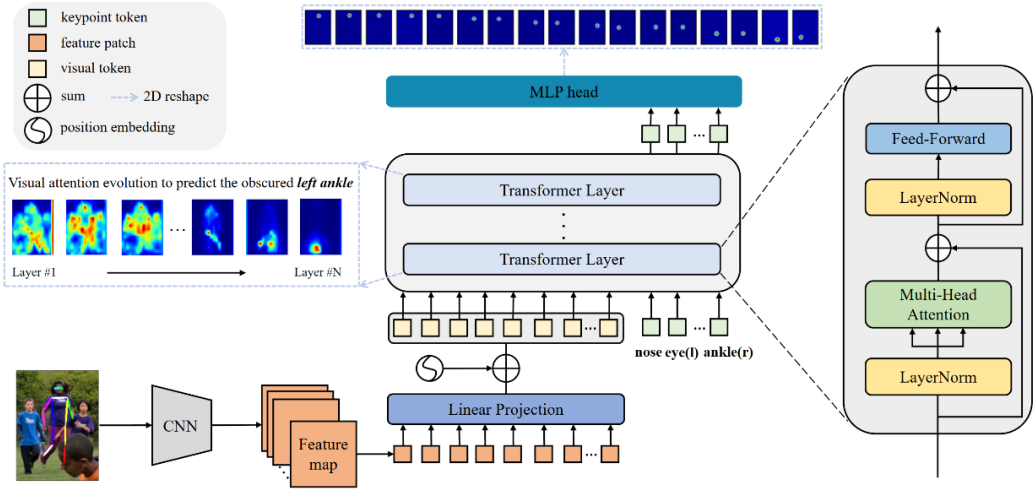

图 2-8 TokenPose 结构示意图（来源于文献[28]）
Fig 2-8 Structure of TokenPose (Origin from [28])

具体而言，输入图像首先经过一个基于 CNN 的骨干网络进行特征提取，以获得高质量的视觉表示。随后，再将特征图拆分为 patch 后并展平为一维向量，经过全连接层投影并加上位置编码之后形成视觉 Tokens。此外，TokenPose 通过随机初始化一组可学习的 d 维向量作为关键点 Tokens，其中每个 Token 对应一个关键点。

在 Transformer 中，这两类 token 共同参与学习，视觉 Tokens 提供丰富的纹理特征，而关键点 Tokens 则用于建模关键点之间的关联性及其相对位置约束。最终，

将关键点 Tokens 的输出通过一个 MLP 映射到 $H \times W$ 维，用于预测关键点热图。

该方法有效融合了 CNN 与 Transformer 的优势，不仅能够利用 CNN 进行细粒度特征提取，还能借助 Transformer 的自注意力机制学习关键点之间的全局依赖关系，从而优化关键点定位流程，提升检测精度。

2.4 本章小节

本章系统回顾了深度学习在关键点检测任务中的应用，重点分析了 CNN 及 Transformer 结构的特性及其在关键点检测中的适用性。首先，介绍了关键点检测的基本任务需求与挑战，然后对 VGG、ResNet、HRNet 和 RepViT 等典型 CNN 结构进行了讨论，分析其在关键点检测任务中的局限性与改进方向。随后，介绍了基于 Transformer 的关键点检测方法，包括 ViT、PVT 和 TokenPose，并对这些模型的创新点及优缺点进行了分析。

第三章 基于量化自注意力的服装关键点检测

由于服装的材质柔软，并且会随人体姿态的改变发生非刚性形变，同一件服装在不同状态下会呈现显著差异化的空间分布。如图 3-1 所示，相同款式的长袖外套由于人体姿态和拍摄角度的不同，关键点位置在图像中表现出较大的偏移（关键点基于数据集标注绘制）。尽管如此，服装关键点之间的相对位置关系及其周围的局部几何特征仍然保持相对稳定的语义约束。

图 3-1 同一件服装在不同场景下的关键点分布
Fig 3-1 Keypoint distribution of the same clothing in different scenes

针对上述特性，受 Transformer-VQ[56]启发，本章提出一种基于多阶段量化自注意力的服装关键点检测网络（Multi-stage Quantized self-Attention Network, MQA-NET），在保持模型轻量化设计的前提下，有效提升关键点定位的鲁棒性。该方法以 RepViT 为主干特征提取网络，并在此基础上引入 Transformer 模块，结合了 CNN 在局部特征表达方面的优势以及 Transformer 在全局关系建模的能力。通过特征量化与离散表示学习压缩特征空间，有效建模关键点间结构依赖关系。

3.1 量化自注意力模块的设计

由于服装容易产生剧烈形变，传统方法难以稳定捕获这些远程关联。现有的全局建模的方法通常都是通过在卷积网络中添加额外精心设计的注意力模块，或者通过使用 Transformer 架构来辅助建模全局依赖关系。尽管这些方法已经在捕获

长距离依赖方面取得了一定的成功，但是它们普遍存在计算复杂度较高以及推理速度较慢等问题，特别是在处理高分辨率服装图像时，标准 Transformer 结构的二次方计算复杂度限制了其实用性，并可能引入过拟合风险。

针对这些挑战，本章提出量化自注意力模块（Quantized self-Attention Module, QAM）。该模块通过在标准自注意力机制的基础上引入向量量化技术，将 Key 向量映射到预定义的离散码本中，从而降低计算复杂度，同时提高关键点预测的稳定性。特别是在面对不同风格、材质和形变的服装时，量化机制能够增强模型的泛化能力。如图 3-2 所示，QAM 的整体结构包括特征映射、向量量化和自注意力计算三个主要部分。输入特征 $F \in \mathbb{R}^{k \times d}$ 为经骨干网络提取并压缩后二维特征图，其首先经过标准化处理，然后通过线性变换生成查询（K）、键（Q）和值（V）三组表示，其中键向量 K 经过量化处理得到量化键向量 $\hat{K}$，与查询向量 Q 计算注意力权重，G 表示门控单元，用来动态调整全局注意力信息对最终特征$F*$的贡献值。

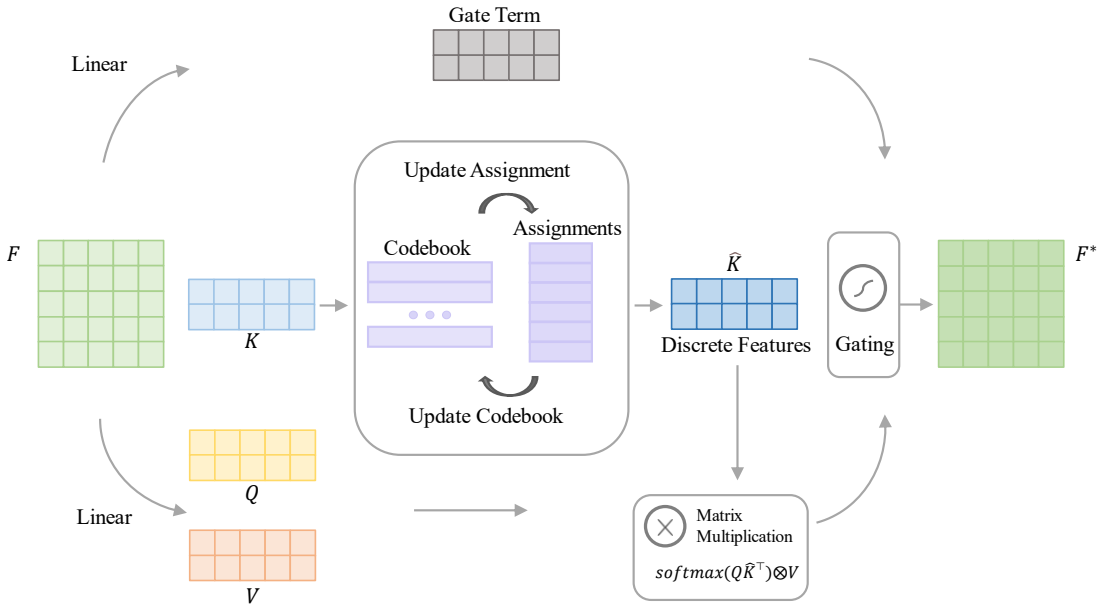

图 3-2 量化自注意力模块
Fig 3-2 Quantized self-attention module

3.1.1 服装特征的量化表示

在传统自注意力机制中，每个 Query 向量需要计算与所有 Key 向量之间的相关性，导致计算复杂度随特征图尺寸成平方级增长。对于高分辨率服装图像而言，这带来了巨大的计算负担。同时，连续的特征表示容易受到服装图像中的光照变化、面料纹理和背景干扰的影响，影响关键点的精确预测。针对以上问题，QAM 引入向量量化机制，对 Key 进行离散化处理，将其限制在固定码本 $C \in \mathbb{R}^{c\times d}$ 中，其中 c 为码本大小，d 为码字维度。这种量化方式使 Key 不再是连续的像素级特征，而是被映射为某个“原型特征”，在服装语境下，这些原型可以理解为特定语义区域的表征，例如领口、袖口等关键区域的特征模式，从而提升模型对不同服装风格和形变的适应能力。具体而言，Key 的量化过程如下：

$$\widehat{K} = VQ(K;C) \in \mathbb{R}^{n\times d_k} \tag{3-1}$$

其中，$VQ(\cdot;C)$为向量量化函数，它将每个 Key 向量映射到码本中最相似的码字，并在反向传播时使用直通梯度估计器（Straight-Through Estimator, STE）维持梯度。基于量化后的 Key，自注意力权重计算如下：

$$W = softmax\left(\frac{Q\widehat{K}^{\top}}{\sqrt{d_k}}\right) \in \mathbb{R}^{n\times n} \tag{3-2}$$

QAM 效率的提升源于其线性时间复杂度的计算机制。具体而言，每个量化后的 Key 可用一个独热矩阵 $\Delta \in \mathbb{R}^{n\times c}$ 表示其在预定义码本 C 中的索引归属，从而量化后的 Key 可以表示为：

$$\widehat{K} = \Delta C \in \mathbb{R}^{n\times d_k} \tag{3-3}$$

将上述表示代入到注意力中，在略去尺度因子后可将输出重构为如下形式：

$$softmax\left(Q\widehat{K}^{\top}\right)V = \frac{exp\left(QC^{\top}\Delta^{\top}\right)V}{exp\left(QC^{\top}\right)\Delta^{\top}1_{n\times 1}} \tag{3-4}$$

上述表达式在与 Value 向量相乘时，通过重排计算顺序，可以将右乘 $\Delta^{\top}$ 其从 $exp(\cdot)$ 中分离计算，此时分子部分的计算可以分为 $QC^{\top} \in \mathbb{R}^{n\times c}$ 以及 $\Delta^{\top}V \in \mathbb{R}^{c\times d_v}$ 两部分，使得输出特征的计算不再依赖于 $n \times n$ 的注意力矩阵，从而将理论复杂度降至了 $O(n)$。

需要指出的是，服装关键点检测任务对局部纹理和边界细节也有较高的依赖性。例如，领口边缘、袖口缝线和褶皱处的细节对于精确定位关键点至关重要。如果全局信息过度主导，可能导致这些局部细节的丢失，进而影响关键点定位精度。为平衡全局与局部特征的贡献，QAM 引入可学习的门控机制，动态调控全局信息在最终特征表达中的贡献程度。具体而言，通过对输入特征 X 进行线性变换并通过 $Sigmoid$ 函数激活，生成一个门控权重矩阵：

$$G = \sigma(XW_G) \in \mathbb{R}^{n \times d_v} \tag{3-5}$$

其中 W_G 为可训练的参数矩阵，$Sigmoid$ 函数确保门控权重落在 $(0,1)$ 区间，从而在每个位置上对全局信息进行加权调节。随后，将门控信号与自注意力部分的结果 WV 逐元素相乘，以实现对不同区域的全局信息适配性控制，最终得到模型的输出：

$$Y = X + (WV \odot G)W_O \tag{3-6}$$

其中 W_O 是输出投影矩阵，$\odot$ 表示逐元素乘法。这种门控机制的引入不仅增强了模型对全局与局部信息的动态感知能力，也有效替代了传统 Transformer 中计算成本较高的前馈网络，从而在保持模型表达力的同时进一步减轻了推理负担。通过这种结构，QAM 能够针对不同区域动态分配信息重心：对于结构性强但需要精确定位的区域（如领口、袖口），门控值倾向于较低，保留更多局部信息；而对于形变大、依赖全局上下文的区域（如腰线、裙摆），门控值倾向于较高，引入更多全局语义信息辅助关键点检测。

3.1.2 服装特征码本更新策略

服装关键点检测任务面临的数据分布具有高度异质性，涵盖多种服饰类别、面料质地、遮挡模式和人体姿态变化。尤其是当不同训练批次间服装样本差异较大的情况下，若采用传统通过基于梯度下降的码本更新策略，往往会出现更新不连续、振荡剧烈等问题，进而导致模型的收敛速度变慢甚至产生聚类效果不稳定的现象。

为了提高 QAM 在训练过程中的稳定性，本节引入指数移动平均（Exponential

Moving Average, EMA）策略，对码本中的每个码字进行平滑更新。设第 t 步训练中，第 i 个码字为 $c_i^{(t)} \in \mathbb{R}^{d_k}$，对于一个 mini-batch 中的所有 Key 向量 $k_j \in \mathbb{R}^{d_k}$，将其根据欧氏距离映射至最近邻的码字，令 $\mathcal{K}_i$ 表示所有被分配到码字 c_i 的 Key 向量的集合：

$$\mathcal{K}_i = \{k_j \in \mathbb{R}^{d_k} | index(k_j) = i\} \tag{3-7}$$

其中 $index(k_j)$ 表示 k_j 被映射到的码字索引，则基于当前 mini-batch 的统计均值表示为：

$$\hat{c}_i^{(t)} = \frac{1}{|\mathcal{K}_i|} \sum_{k_j \in \mathcal{K}_i} k_j \tag{3-8}$$

其中 $|\mathcal{K}_i|$ 表示集合中样本数量，这个平均值反映了当前 batch 中，属于第 i 个码字的特征向量的中心趋势。通过 EMA 实现码字的迭代更新：

$$c_i^{(t+1)} = \alpha \cdot c_i^{(t)} + (1 - \alpha) \cdot \hat{c}_i^{(t)} \tag{3-9}$$

其中 $c_i^{(t)}$ 表示第 t 轮迭代中的码字，$\alpha \in [0,1)$ 是平滑因子，用于控制当前值与历史值之间的权重平衡。在服装关键点检测中，较大的 α 值可有效抑制因服装风格、褶皱、姿态变化等引起的码字波动，从而保持码本的表征稳定性。

EMA 机制的核心优势在于其能够动态平衡短期和长期统计之间的关系。在服装关键点检测任务中，尽管不同样本间的关键点位置各异，但服装各部位具有相对稳定的结构语义关系。例如，不同上衣的领口形状各异，但都具有类似的结构特征以及相同的语义概念，EMA 能够有效聚合这些语义一致区域在多个样本中的平均表征，形成对服装各部位特征的稳定编码，从而缓解因局部遮挡或姿态偏差导致的码字漂移现象。这种平滑的更新机制显著增强了量化空间的全局一致性，为后续注意力权重计算提供更可靠的语义支撑。

此外，为缓解向量量化过程中产生的信息损失，同时保持服装结构特征的完整性，本节还在训练过程中引入了量化误差的正则项。该误差通过计算每个 Key 向量与其最近邻码字之间的欧式距离来度量，其实现方式如下：

$$\mathcal{L}_{commit} = \sum_{i=1}^{n} \left\| k_i - sg(\hat{k}_i) \right\|_2^2 \tag{3-10}$$

其中 $sg(\cdot)$ 表示停止梯度传播操作。该项损失鼓励量化后的特征保持对原始

特征空间的贴合，避免量化过程中丢失关键部位的边缘和纹理特征，确保特征在嵌入空间的语义完整性。

3.2 多阶段渐进细化策略

多阶段渐进细化策略受到人类视觉认知过程的启发：人类在识别服装关键点时，往往先形成整体布局感知，再聚焦细节进行精确定位。本章将关键点定位分解为初步定位和迭代细化两个阶段，通过量化自注意力模块建立关键点间的结构关联，实现从粗到细的渐进优化过程。

3.2.1 初始关键点回归

初始关键点定位阶段负责建立服装关键点的基础位置分布，这一阶段更关注全局形态而非精确坐标。具体而言，通过骨干网络提取的特征图进行全局池化，获取服装的整体表征。设上游骨干网络输出特征的形状为 (B, C, H, W)，全局池化操作将空间维度 (H, W) 压缩得到 X_{pooled}，用于提取服装的整体特征。这种压缩虽然损失了局部空间信息，但能够提供关键点的大致分布，随后通过一个简单的 MLP 网络预测初始坐标：

$$\hat{P}^{(0)} = \sigma\left(W_2 \cdot SiLU\left(W_1 \cdot x_{pooled}\right)\right) \in R^{B\times K\times 2} \tag{3-11}$$

其中 W_1 和 W_2 两个全连接层分别用于将全局向量嵌入到隐藏控件以及预测 K 个关键点坐标，σ 表示 $sigmoid$ 函数，将坐标归一化到 $[0,1]$ 范围，$SiLU$ 为非线性激活函数。这种初步定位虽然精度有限，但为后续细化提供了合理的起点，降低了优化难度。对于服装图像而言，这种全局感知有助于捕获关键点的整体布局。

3.2.2 关键点嵌入与量化自注意力的结构感知

由于二维坐标本身缺乏足够的语义信息，将初始关键点坐标直接用于细化是

不够的。本章利用关键点嵌入层将坐标映射到高维特征空间：

$$E^{(t)} = SiLU\left(W_e \cdot \hat{P}^{(t)}\right) \in R^{B\times K\times D} \tag{3-12}$$

其中，$\hat{P}^{(t)}$ 表示当前阶段的关键点坐标预测，W_e 表示坐标到特征向量的投影矩阵。通过关键点嵌入将二维坐标编码为向量形式，将物理位置转化为语义表示，并且提供足够丰富的特征维度，量化自注意力模块在此基础之上建立关键建立点间的结构化关联：

$$F^{(t)} = QSAM\left(E^{(t)}\right) \tag{3-13}$$

其中，$F^{(t)}$ 表示关键点之间注意力增强后的特征表示，其表征了每个关键点在上下文中的“语义属性”。与传统的自注意力不同，量化机制通过离散的码本表示，创建了更加结构化和稳定的特征关联模式，这对于服装这类高度形变的目标尤为重要。

3.2.3 坐标细化与不确定性估计

基于量化自注意力增强的特征，本节通过两个平行分支进行关键点预测：坐标细化分支和不确定性估计分支。坐标细化分支预测关键点位置的偏移量，实现逐步优化：

$$\Delta P^{(t)} = W_{coord} \cdot SiLU\left(F^{(t)}\right) \tag{3-14}$$

其中 W_{coord} 为可学习的线性变换矩阵，用于将每个关键点的语义特征映射为一个二维向量。同时，不确定性估计分支评估预测的可靠性：

$$\Sigma^{(t)} = \sigma\left(W_\sigma \cdot SiLU\left(F^{(t)}\right)\right) \tag{3-15}$$

其中，W_σ 为可学习的权重矩阵，σ 为 $sigmoid$ 激活函数。不确定性估计不仅提供预测置信度，还在损失计算中作为自适应权重，调节不同关键点的误差惩罚程度。坐标的更新方法如下：

$$\hat{P}^{(t+1)} = Clamp\left(\hat{P}^{(t)} + \Delta P^{(t)}, 0,1\right) \tag{3-16}$$

其中 $Clamp(\cdot,0,1)$ 将结果限制在合法坐标范围 $[0,1]$ 内，避免产生无效坐标

渐进细化策略的核心在于迭代优化过程,每轮迭代都在前一轮结果的基础上

进行改进，每个阶段的 QAM 共享相同的码本结构但不共享参数，这允许不同阶段中能够关注到关键点结构的不同方面。初始阶段更关注整体布局，而后续阶段则逐渐聚焦于精细边界和局部细节。通过这种渐进细化机制，模型能够有效处理服装中的褶皱、形变和部分遮挡等复杂情况，提高关键点定位的精确度和鲁棒性。

3.3 基于多阶段量化自注意力的服装关键点检测网络

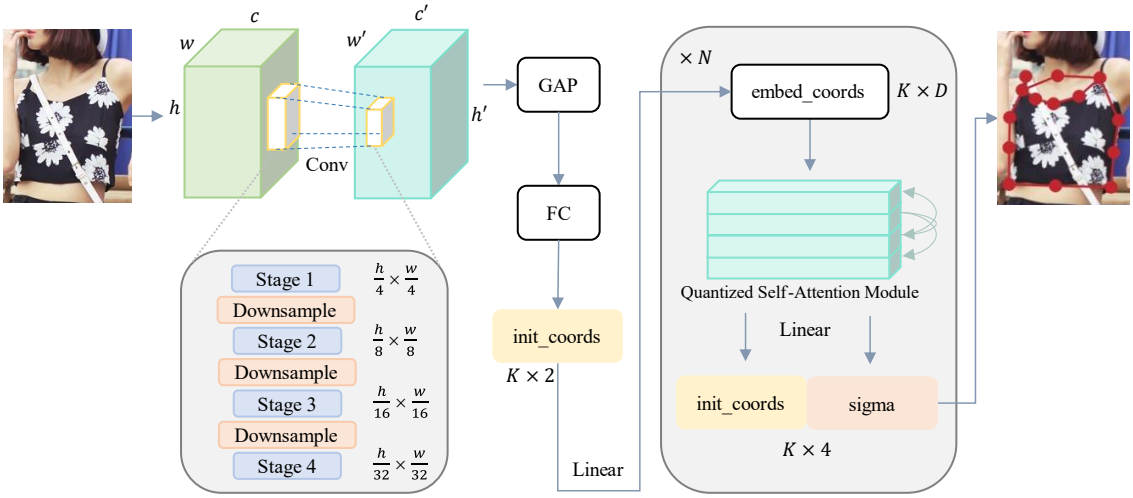

图 3-3 MQA-Net 结构示意图
Fig 3-3 Structure of MQA-Net

本章提出了基于多阶段量化自注意力机制的服装关键点检测网络（Multi-stage Quantized self-Attention Network, MQA-NET），如图 3-3 所示，该网络通过整合卷积特征提取，多阶段量化自注意力和渐进式坐标细化，实现高效的服装关键点定位。骨干网络负责初步提取服装的局部特征，量化自注意力模块用于建模关键点间的结构化关系，借助多阶段细化实现从粗到细的关键点定位。整个网络的解析流程如下：

（1）输入服装图像通过 RepViT 骨干网络提取多尺度特征，深层特征图经全局池化转换为全局特征向量，并通过全连接层预测初始关键点坐标，建立基础定位。

（2）将初始二维坐标嵌入高维特征空间后，使用激活函数增强非线性表达能

力，通过 QAM 将连续特征映射到离散码本，创建结构化的语义表示，得到增强后的特征表示，捕获关键点间的长距离依赖关系。

（3）在多个迭代阶段中，基于量化自注意力增强的特征，模型通过两个平行分支分别预测坐标偏移和不确定性估计，通过残差连接逐步细化关键点位置，最终输出关键点坐标和对应的可靠性评估。

3.4 实验与分析

3.4.1 实验数据集

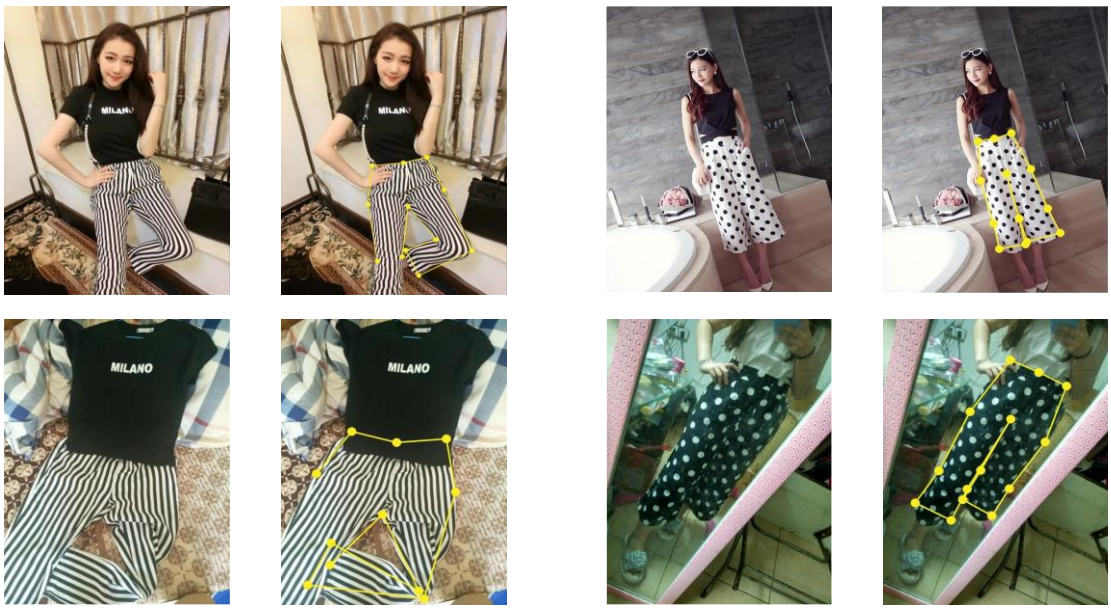

图 3-4 DeepFashion2 数据集示例
Fig 3-4 DeepFashion2 dataset example

本章在 DeepFashion2 数据集上进行实验。DeepFashion2 是一个大规模服装数据集，涵盖来自商家和消费者的 13 种服装类别，总计 49.2 万张服装图像。该数据集为服装关键点检测任务提供了详尽的结构标注与多样化的场景样本，具有广泛的代表性与挑战性。

DeepFashion2 数据集的图像来源主要包括两类：（1）商家图像，拍摄质量较高，背景简洁，光照均匀；（2）消费者图像，来源于真实穿着场景，常伴随姿态变化大、背景复杂、光照不均和关键点遮挡等挑战因素。图 3-4 展示了上述两类图

像的典型示例，第一行和第二行分别对应商家和消费者图像，每张图像配有以下标注信息：服装框、服装类别标签、关键点坐标及其可见性标注、骨架连接结构。

该数据集中对每一类服装定义了特定的关键点结构，例如裙子、长裤、长袖外套等类别均具备不同的关键点数量与位置定义，体现了高度的类别适应性。此外，数据集中不同的样本之间姿态变化幅度较大、拍摄视角丰富且有不同程度的遮挡，是验证服装关键点检测算法性能与泛化能力的理想平台。

本文在实验中选取了四个具有代表类型的类别：裤子（约 50000 个样本）、裙子（约 30000 个样本）、长袖外套（约 14000 个样本）和吊带（约 2000 个样本）。选择这些类别是为了反映不同类别的结构复杂性和数据不平衡性，从而更全面地评估模型对不同服装类型和样本分布的适应性。

3.4.2 数据预处理

在实验过程中，数据预处理在模型训练与推理过程中扮演着至关重要的角色。合理且系统的预处理流程不仅能够显著增强数据的多样性，还能有效缓解过拟合现象，提升模型在不同场景下的泛化能力。本节将详细介绍本实验所采用的图像预处理策略，包括边界框提取与仿射变换、图像增强技术、关键点归一化以及模型输入标准化等步骤。

（1）边界框处理与仿射变换。由于 DeepFashion2 数据集中图像分辨率不统一，且服装目标在图像中的尺度、姿态变化较大，为了确保模型输入的一致性，需对图像中目标服装区域进行裁剪与对齐。首先，根据数据集中提供的边界框信息，计算目标服装区域的中心点与尺度信息，并据此构建仿射变换矩阵。该变换将服装区域映射到统一分辨率（本实验中设定为 256×192），以确保服装区域在模型输入空间中具备统一的空间分布和尺度大小。此外，在执行仿射变换的过程中，图像中的关键点位置也会通过同一变换矩阵进行同步映射，保持关键点与图像之间的空间一致性。

（2）数据增强。在神经网络训练时，数据增强是一种提高模型性能的常见技

术，它可以增加数据的多样性，避免模型对特定场景过拟合。本章中采用了随机水平翻转增强，同时对图像、边界框及关键点进行一致性翻转，帮助模型适应不同的服装方向变化。此外，还通过随机边界框变换，对目标区域进行不同程度的裁剪、缩放、旋转等操作，增加训练数据的多样性，帮助模型更好地学习和泛化。

（3）关键点归一化与可见性编码。实验中通过编码器将关键点坐标映射到归一化空间，使所有坐标值落在 [0,1] 区间内。这种归一化处理有助于模型学习相对位置关系，而非绝对像素位置，提高了模型的尺度不变性。同时，编码器还处理关键点可见性信息，将其转换为权重矩阵，指导模型在训练中对可见、部分可见和不可见关键点采取不同的优化策略。

（4）输入规范化。在数据预处理的最后阶段，为确保模型接收统一的输入分布，图像像素值会进行标准化处理。采用了 ImageNet 预训练模型的标准均值和标准差进行通道归一化，并将 BGR 格式转换为 RGB 格式。这种规范化处理使模型能够充分利用预训练权重中的特征提取能力，加速收敛并提高性能。

3.4.3 实验基础设置说明

（1）实验环境配置

表 3-1 显示了本文使用的实验环境配置。

表 3-1 实验环境的配置

Table 3-1 The configuration of the experimental environment

配置选项	型号或版本
内核	GNU/Linux 5.11.0
操作系统	Ubuntu 20.04.3 LTS
CUDA 版本	CUDA 11.7
编程语言	Python 3.9.16
深度学习框架	PyTorch 2.0.1
处理器	Intel Core i9-11900K
显卡	NVIDIA GeForce RTX 3090 24G

（2）网络模型参数配置

本节使用 RepViT_m1.1 作为骨干网络，由于该骨干结构本身包含较多参数，若从头开始训练将面临较长的收敛时间与较高的计算开销。为加快模型训练过程并提升初期性能表现，本文使用在 ImageNet 上预训练的权重对骨干网络进行初始化，而其他新增模块则采用随机初始化。

本节除去了 RepViT_m1.1 中最后一层分类头，只采用 Patch Embedding、Stage 1、Stage 2、Stage 3、Stage 4 作为骨干网络。使用 k 代表卷积核大小，t 代表中间层通道数相较于输入通道数的倍率，s 代表每个阶段首层的下采样倍率，se 模块在深层网络中交替使用，增强特征表达，$hs=0$ 时使用标准激活，$hs=1$ 时使用 $GeLU$ 激活函数[57]。骨干网络的具体参数配置如表 3-2 所示。

表 3-2 骨干网络的参数配置

Table 3-2 Parameter configuration of the backbone

阶段	输出大小 $(C\times H\times W)$	卷积结构
Patch Embedding	$32\times128\times96$ $64\times64\times48$	$[k=3,s=2,p=1]$ $[k=3,s=2,p=1]$
骨干网络 Stage 1	$64\times64\times48$	$[k=3,t=2,s=1,se=1/0/0，hs=0]\times3$
骨干网络 Stage 2	$128\times32\times24$	$[k=3,t=2,s=2,\mathrm{se}=0,hs=0]$ $[k=3,t=2,s=1,\mathrm{se}=1/0/0,hs=0]\times3$
骨干网络 Stage 3	$256\times16\times12$	$[k=3,t=2,s=2,\mathrm{se}=0,hs=1]$ $[k=3,t=2,s=1,\mathrm{se}=1/0,hs=1]\times13$
骨干网络 Stage 4	$512\times8\times6$	$[k=3,t=2,s=2,\mathrm{se}=0,hs=1]$ $[k=3,t=2,s=1,\mathrm{se}=1/0，hs=1]\times2$

（3）训练细节设置

在训练过程中，采用 AdamW 优化器，初始学习率设定为 5×10^{-4}，并在前 500 次迭代中使用学习率预热（warm-up）机制，以提高训练的稳定性。随后，学习率按照 MultiStepLR 策略，在第 170 和第 200 轮训练时进行衰减，以优化模型在后期训练阶段的收敛效果。

为进一步提升模型的训练稳定性与泛化能力，网络中采用均方根层归一化

（RMSLayerNorm）[59]作为归一化方法。在训练和测试阶段，均基于数据集中提供的真实边界框，以确保模型能够获得准确的目标区域与尺度信息。

在测试阶段，采用翻转测试（flip testing）策略，即对输入图像进行水平翻转，并对两次预测结果取平均值，以利用图像的对称性提高关键点预测的准确度。

（4）损失函数的设计

本章采用残差对数似然估计损失函数同时优化坐标预测和不确定性估计。RLELoss 定义为：

$$\mathcal{L}_{RLE} = log(\sigma) - log(p_{\phi}(\frac{p - p_{gt}}{\sigma})) \tag{3-17}$$

其中 p 表示预测坐标，p_{gt} 表示真实坐标，σ 表示预测的不确定性参数，p_{ϕ} 表示残差分布，具体实现中，残差服从拉普拉斯分布。

在多阶段渐进细化框架中，为确保各阶段有效协同，本章采用综合损失函数，整合多阶段预测的 RLE 损失和量化自注意力的承诺损失：

$$\mathcal{L}_{total} = \lambda_r \sum_{t=1}^{T} w_t \mathcal{L}_{RLE}{}^{(t)} + \lambda_c \mathcal{L}_{commit} \tag{3-18}$$

其中，T 表示细化阶段数，w_t 为第 t 阶段的权重，λ_c 和 λ_r 分别设定为 1.0 和 0.1。

3.4.4 评价指标

在神经网络训练完成之后，为定量评估服装关键点检测模型的性能，需要建立与任务特性匹配的评价体系。在服装关键点检测领域，评估一个模型的性能涉及多个维度，包括参数量、运算量、推理时间和准确率等。为了确保模型在规模和性能之间取得良好的平衡，本文采用了多个评价指标来全面衡量模型的性能。这些指标包括每秒十亿次浮点运算（Giga Floating Point Operations Per Second, GFLOPS）、每秒帧数（Frames Per Second, FPS）、正确关键点百分比（Percentage of Correct Keypoints, PCK）、曲线下面积（Area Under the Curve, AUC）和端点误差（End-Point Error, EPE）。

GFLOPS 和 FPS 是衡量模型计算效率和推理速度的重要指标。GFLOPS 反映

了模型在推理过程中所需的计算量，FPS 则衡量了模型在推理过程中每秒处理的图像帧数。通过这两个指标，可以评估模型的计算负担和推理效率。

PCK 是表示在给定的距离阈值内正确预测的关键点比例，计算公式如下：

$$PCK = \frac{1}{N}\sum_{i=1}^{N} 1\left(\frac{\|\hat{p}_i - p_i\|}{s} < thr\right) \tag{3-19}$$

其中，N 表示关键点数量，$\hat{p}_i$ 和 p_i 分别表示预测和真实关键点位置，s 为归一化因子，通常取目标边界框对角线长度，$1(\cdot)$ 为指示函数，当关键点误差小于阈值 thr 时取 1，否则取 0。

AUC 是衡量 PCK 在 N 个阈值范围内的平均性能，计算公式如下：

$$AUC = \frac{1}{N}\sum_{i=1}^{N} PCK(thr_i) \tag{3-20}$$

EPE 用于衡量模型预测的关键点与真实关键点之间的平均欧氏距离，数值越小代表预测越精准，其计算公式如下：

$$EPE = \frac{1}{N}\sum_{i=1}^{N} v_i \|\hat{p}_i - p_i\| \tag{3-21}$$

其中，v_i 是关键点可见性掩码，值为 1 表示可见，0 表示不可见。

3.4.5 实验结果分析

（1）消融实验

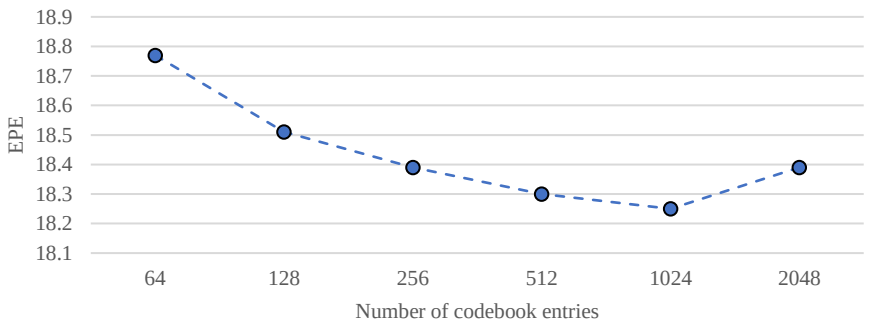

图 3-5 不同码本大小对性能的影响
Fig 3-5 The impact of different codebook sizes

为验证 MQA-NET 核心组件的有效性，本节分别对量化自注意力模块（QAM）

的码本大小和多阶段渐进细化策略的阶段数进行了系统性消融研究。实验采用交叉控制变量法，在评估码本大小影响时固定阶段数为 2；分析阶段数贡献时固定码本大小为 512。

图 3-5 展示了码本大小对长袖外套关键点定位精度的影响（以端点误差 EPE 表示）。随着码本容量从 64 扩增至 1024，EPE 呈单调下降趋势，表明更大的码本能够提供更细致的特征量化能力，从而更有效地建模服装结构中的细节差异。然而，当码本规模进一步扩展至 2048 时，模型性能略有退化，这归因于过大码本导致的量化稀疏性和收敛不稳定性。实验证明该参数在 256-2048 内达到最优性能平衡点，模型对码本大小的变化并不敏感。

基于上述实验，在后续阶段数消融实验中，本章固定码本大小为 512，既确保了表征能力，又保持了计算效率。

表 3-3 不同细化阶段数对性能的影响

Table 3-3 The impact of different numbers of refinement stages

阶段数	PCK@0.05↑	AUC↑	EPE↓
1	0.762	0.49	18.25
2	0.765	0.50	18.16
3	0.769	0.50	18.57
4	0.761	0.49	18.65

表 3-3 展示了不同细化阶段数对 MQA-Net 性能的影响。实验结果表明，随着阶段数从 1 增加到 3，模型性能在 PCK@0.05 和 AUC 上都有小幅提升，且在训练过程中能够更快收敛，这主要归因于多阶段量化特征的渐进细化机制，后续阶段的量化能够更专注于前一阶段未能精确建模的细节区域，但当阶段数增加到 4 时，各项性能指标反而出现下降，此时累积的量化误差会超过额外细化带来的收益，导致性能下降。

考虑到计算效率、模型复杂度与性能之间的平衡，后续在对比实验中都选择使用两阶段设计，这样既能保证较高的关键点定位精度，又能避免过多阶段带来的潜在性能退化。

（2）对比试验

为进一步验证 MQA-Net 的有效性，本节将其与当前主流的关键点检测方法进行对比：包括基于热图且结构简洁的 Simple Baseline (SBL)[16]、以 PVT 为骨干网络的回归模型 PVT[55]、采用坐标分类方法的 SimCC[58]以及轻量级混合结构 RTMPose[63]，其中除 PVT 外的所有方法都采用 RepViT_m1.1 作为骨干网络。

表 3-4 展示了不同方法在多个指标上的对比结果，各方法在服装关键点检测任务上展现出不同的性能与效率权衡。从结果来看，MQA-Net 作为基于回归的方法，在保持竞争性精度的同时，以 1.5 GFLOPs 的计算复杂度实现了 572 FPS 的推理速度，在计算效率方面展现出显著优势。

表 3-4 本章提出的 MQA-Net 与其他方法的对比

Table 3-4 The comparison between the proposed MQA-Net and other methods

Method	GFLOPs	FPS	Category	PCK@0.05↑	AUC↑	EPE↓
Simple Baseline	2.7	144	trousers	0.822	0.63	14.16
			skirt	0.799	0.65	16.17
			long sleeved outwear	**0.772**	**0.51**	18.20
			sling	**0.687**	**0.55**	**20.95**
PVT	3.7	355	trousers	0.806	0.60	16.38
			skirt	0.761	0.61	19.24
			long sleeved outwear	0.733	0.45	21.43
			sling	0.545	0.46	24.91
SimCC	3.5	339	trousers	**0.826**	**0.64**	**13.66**
			skirt	**0.811**	**0.66**	**15.61**
			long sleeved outwear	0.762	0.50	18.33
			sling	0.672	0.54	22.49
RTMPose	1.9	364	trousers	0.822	0.63	13.97
			skirt	0.803	0.65	15.76
			long sleeved outwear	0.764	**0.51**	18.20
			sling	0.665	0.54	22.55
MQA-Net（本章方法）	**1.5**	**572**	trousers	0.814	0.62	16.52
			skirt	0.790	0.64	19.64
			long sleeved outwear	0.765	0.50	**18.16**
			sling	0.628	0.51	21.50

从具体性能看，Simple Baseline 虽然结构简单，但其 FPS 仅 144，计算效率相对较低。得益于热图方法中的密集空间监督，SBL 在各服装类别上均有稳定表现。

PVT 作为基于 Transformer 的回归方法，其完全依赖特征图进行回归的设计限制了捕捉局部细节的能力，且与 MQA-Net 类似，在样本量较少的 sling 类别中表现欠佳。SimCC 通过将定位转化为分类问题实现了相对最优的精度结果，其能在训练样本充分的情况下学习到较好的位置表示，但依赖计算开销较大的上采样层，导致较高的 GFLOPs。RTMPose 则在效率与性能间取得了良好平衡，以 1.9 GFLOPs 实现了 364 FPS 的推理速度，同时保持了接近 SimCC 的检测精度。

MQA-Net 虽然在 PCK 和 AUC 指标上略低于部分方法，但其 EPE 值与竞争方法相当，表明其在关键点位置精确度上具有可比性。更重要的是，MQA-Net 显著降低了计算成本，推理速度提升了 57%以上。这一结果充分证明了量化自注意力机制在降低计算复杂度的同时，有效保持了模型捕获全局结构关系的能力。

（3）可视化结果对比分析

图 3-6 展示了 MQA-Net 在 DeepFashion2 中一些具有挑战性场景下的可视化结果。从裙子类别的样例可观察到，该方法能够准确识别不同风格裙装的结构特征，并在模特多变姿态下保持稳定的预测性能；在吊带类别中，网络成功应对了极端俯视视角和部分区域严重遮挡的复杂情况，体现了其鲁棒性；长裤类别的检测结果表明，本方法能有效适应人体姿态变化带来的服装形变，精确定位裤装各部位关键点；长袖外套样例则验证了网络对具有复杂分割结构和多层次设计的外套类服装的适应能力。这些多样化的检测结果证实了基于量化自注意力的方法在捕获服装全局结构关系方面的优越性，能够有效应对服装关键点检测中的视角变化、姿态多样性和部分遮挡等挑战。

然而，在长裤类别和长袖外套类别中最后一个预测失败案例中，由于长裤图像中衣物折叠以及长袖外套图像中手臂部位存在严重遮挡，相关区域的纹理与结构信息丢失，模型难以有效推断关键点的空间位置，导致出现了明显不合理的关键点预测偏差。尽管 QAM 模块强化了结构建模，但在关键点局部区域的细粒度建模仍存在一定缺失，可能导致特定部位的定位精度下降。

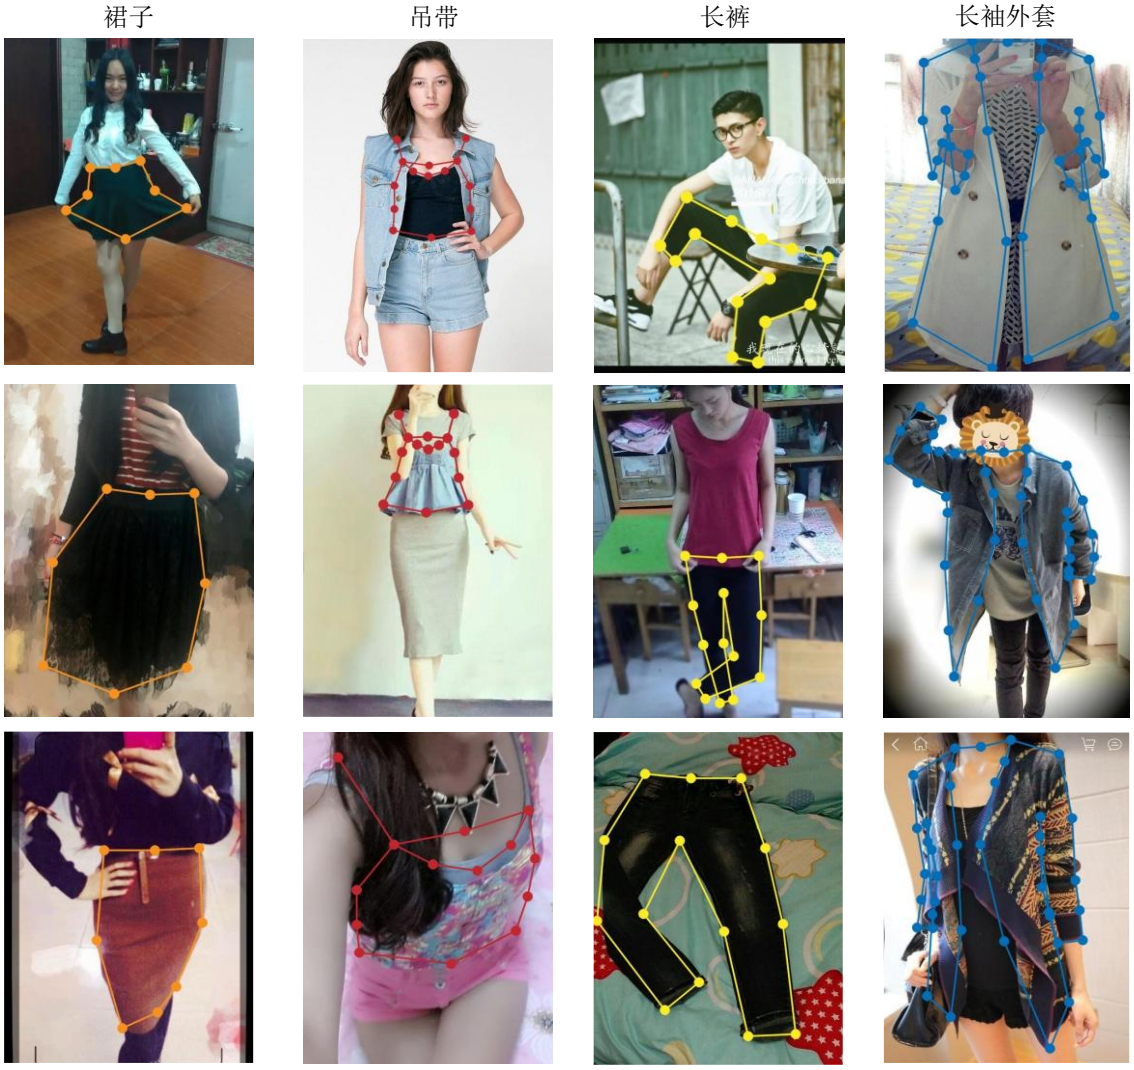

图 3-6 MQA-Net 在 DeepFashion2 上的可视化结果
Fig 3-6 Visualization results of LSD-Net on the DeepFashion2 dataset

3.5 本章小节

本章针对服装关键点检测中服装特征表示困难和全局结构建模不足，提出了基于量化自注意力的服装关键点检测。该方法通过将关键点特征映射至离散码本空间，不仅实现了特征的有效压缩同时保留了关键点之间的结构信息，一方面显著降低了传统自注意力的计算复杂度，另一方面通过离散化增强了模型对图像中各种干扰因素的鲁棒性。引入的多阶段渐进细化策略，通过关键点嵌入、量化自注意力处理以及坐标细化网络的协同作用，有效提高了定位精度。框架整体采用

轻量级设计，结合全局池化和量化机制大幅降低计算负担，在 DeepFashion2 数据集上的实验结果表明，本章提出的方法相比现有方法有更少的计算量和更快的推理速度，同时性能仅略低于计算密集型模型，充分验证了量化自注意力和多阶段渐进细化策略在服装关键点检测任务中的有效性，为资源受限场景下的高效服装关键点检测提供了新思路。

第四章 基于空间离散建模的服装关键点检测

在上一章中，本文提出了基于多阶段量化自注意力的服装关键点检测网络(MQA-NET)，该方法通过回归范式结合量化自注意力机制，有效增强了模型对服装图像中复杂结构与形变的建模能力。然而，深入分析发现，该方法在两个关键方面仍存在局限性：一方面，基于回归的预测范式本质上是坐标推断过程，难以保留关键点位置的完整概率分布信息；另一方面，轻量回归模型中的全局池化操作不可避免地造成了空间信息损失，削弱了对服装局部纹理、边缘结构和区域特征等细节的保留能力。

为克服上述局限性，本章结合坐标分类[58]的思想，提出了一种基于可学习空间离散（Spatial Discretization, SD）建模的服装关键点检测框架——可学习空间离散网络（Learnable Spatial Discretization Network, LSD-Net）。该框架将连续坐标空间划分为离散区间，将定位问题转化为概率分布预测任务，并通过可学习的空间划分机制实现精度资源的自适应分配。与第三章方法相比，本章的技术路线有两个根本性差异：首先，检测范式从直接坐标回归转向空间离散建模，保留了完整的位置概率表示；其次，量化自注意力模块的应用位置发生转变，从处理关键点嵌入特征转向增强原始图像特征，更有效地捕获服装的全局语义信息与空间结构。

本章提出的可学习空间离散建模框架整合了回归方法与热图方法的技术优势，实现了计算效率与定位精度地平衡，更进一步引入了可学习的空间划分机制，该机制能够根据服装关键点在空间维度上表现出的非均匀分布特性，动态调整不同区域的离散化精度。

4.1 基于空间离散建模的服装关键点检测框架

4.1.1 框架整体设计

本章提出的服装关键点检测框架采用编码器-解码器设计范式，如图 4-1 所示。

该框架由三个主要组件构成：

（1）位置感知骨干网络：该网络在 RepViT 的基础上继承了显式坐标编码，增强了对空间位置的感知能力。

（2）量化自注意力模块：QAM 在 LSD-Net 中直接作用于骨干网络提取的图像特征，使模型能够更直接地捕获服装结构的长距离依赖关系。

（3）可学习空间离散建模：独立预测两个方向上的坐标，并根据服装关键点的分布特性，动态调整不同区域的划分精度。

本章网络框架在保持端到端设计的同时，将检测范式从直接坐标回归转变为空间离散建模，更好地保留了关键点位置的概率分布信息。

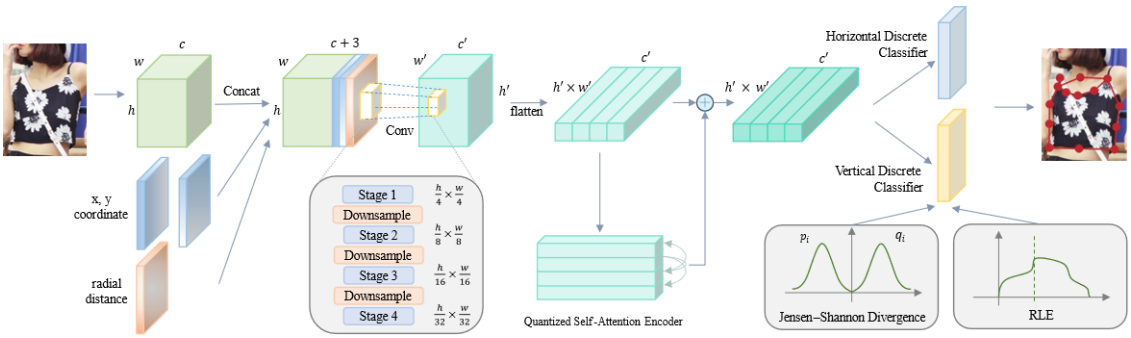

图 4-1 LSD-Net 的网络结构
Fig 4-1 Structure of LSD-Net

4.1.2 传统关键点检测范式与空间离散建模的对比

基于热图的方法为每个关键点生成二维概率分布图，一般通过高斯滤波器表示目标位置，虽然精度较高，但计算和存储开销大，定位精度受限于热图的空间分辨率。

基于回归的方法直接预测关键点的坐标值，结构简单高效，然而，其无法学习到完整的概率分布，且通常存在优化困难，尤其在处理复杂姿态和遮挡情况时性能较差。

空间离散建模方法将坐标轴划分为多个区间（bin），预测关键点在各个区间上的概率分布。这种方法结合了热图的高精度和回归的计算效率，同时引入了更灵

活的精度资源分配机制。

4.1.3 QAM 在不同网络框架中的作用

表 4-1 展示了 QAM 在不同网络框架中的作用差异，两种应用模式的本质区别还是在于 MQA-NET 中 QAM 作用于坐标空间，而 LSD-NET 中 QAM 作用于特征空间，这使得 LSD-Net 在捕捉服装的全局结构与细节特征方面表现得更加出色。

表 4-1 QAM 在不同网络框架中的作用
Table 4-1 The role of QAM in different network frameworks

对比维度	MQA-Net 中的 QAM	LSD-Net 中的 QAM
输入数据类型	关键点坐标嵌入后的特征	2D 特征图展平后的特征
输入形状	$[B, K, hidden_dims]$	$[B, K, hidden_dims]$
应用位置	多阶段迭代的每个阶段中	特征提取之后，坐标预测之前
主要功能	建模关键点之间的空间关系	增强原始特征的表示能力
作用机制	关键点间信息交互，细化坐标预测	通道间信息交互，增强特征表达

4.2 空间离散建模结构设计

4.2.1 空间离散建模的基本原理

空间离散建模是一种将连续坐标表示转化为离散编码的方法，其核心思想是将二维坐标分解为两个独立的一维表示，然后对每个维度进行离散化处理。具体而言，空间离散建模将图像中的每个坐标轴划分为若干个离散区间，并在这些 bin 上进行一维 softmax 分类，最终以加权平均方式回归出连续坐标。虽然空间离散建模与基于热图的方法都是在特征空间上定位响应值最高的位置，但是基于热图的方法为每个关键点生成像素级置信度，模型学习的是每一个关键点的编码，空间离散建模中是学习多个权重向量，每个权重向量代表的是连续空间上的离散采样点的位置，模型学习的内容是关键点的位置编码。这个学习目标在显著降低问题的复杂度同时，也减小了模型规模。

4.2.2 高斯平滑策略

在传统分类任务中，类别之间通常被视为互斥且等距的，但在关键点检测任务中，空间位置具有内在的连续性和相关性，并非除了关键点的标注坐标以外都是错误的预测，距离真实关键点较近的位置应当比远处位置受到更小的惩罚。这种空间相关性在服装关键点检测中尤为重要，因为关键点的标注也可能存在模糊性，服装的变形和遮挡也会导致关键点位置的不确定性。因此在坐标编码过程中采用硬性的独热编码不仅不合理，还可能导致模型过拟合到特定像素，降低泛化能力。

高斯平滑策略通过在真实关键点位置周围创建概率分布，使得空间相关性得到合理建模。对于坐标 (x, y)，其在离散空间中的高斯平滑表示为：

$$P_x(i) = exp(-\frac{(i-i_x)^2}{2{\sigma_x}^2} \cdot Z_x^{-1}), \quad P_y(j) = exp(-\frac{(j-j_y)^2}{2{\sigma_y}^2} \cdot Z_y^{-1}) \tag{4-1}$$

其中，(i_x, j_y) 是关键点在离散空间中的索引，σ_x 和 σ_y 是控制高斯分布宽度的参数，Z_x 和 Z_y 是归一化常数，确保概率和为 1。这种表示方式在关键点周围的位置赋予了较高的概率密度，随着与关键点距离的增加，概率密度平滑地降低。高斯平滑策略还能够自然地过渡到不同地空间离散建模策略中，为关键点检测提供了统一且灵活地建模框架。

4.3 空间离散建模策略

4.3.1 空间离散建模的基本形式

给定图像尺寸 (H, W) 和划分粒度系数 ρ，空间离散建模将 x 和 y 坐标轴分别划分为 $W_d = \rho W$ 和 $H_d = \rho H$ 个 bins。对于任意坐标点 (x, y)，其离散表示为：

$$P(x, y) = P_x(i), P_y(j) \tag{4-2}$$

其中，$P_x(i)$ 和 $P_y(j)$ 分别表示该点在第 i 个 x 轴上的 bin 和第 j 个 y 轴上的 bin 的概率密度，$i \in [0, W_d - 1]$，$j \in [0, H_d - 1]$。

标准化坐标 $(\hat{x},\hat{y})$（范围在[0,1]内）的计算公式为：

$$\hat{x}=\sum_{i=0}^{W_d-1}P_x(i)\cdot b_x(i),\hat{y}=\sum_{j=0}^{H_d-1}P_y(j)\cdot b_y(j) \tag{4-3}$$

其中，$b_x(i)$ 和 $b_y(j)$ 对应 bin 的位置编码值，最终实际像素坐标计算为：

$$(x,y)=(\hat{x}\cdot W,\hat{y}\cdot H) \tag{4-4}$$

空间离散建模的关键在于如何定义 $b_x(i)$ 和 $b_y(j)$。如图 4-2 所示，本章介绍了三种不同的空间划分方式（均匀划分、对数划分、可学习划分），公式中均以 x 方向为代表进行介绍。

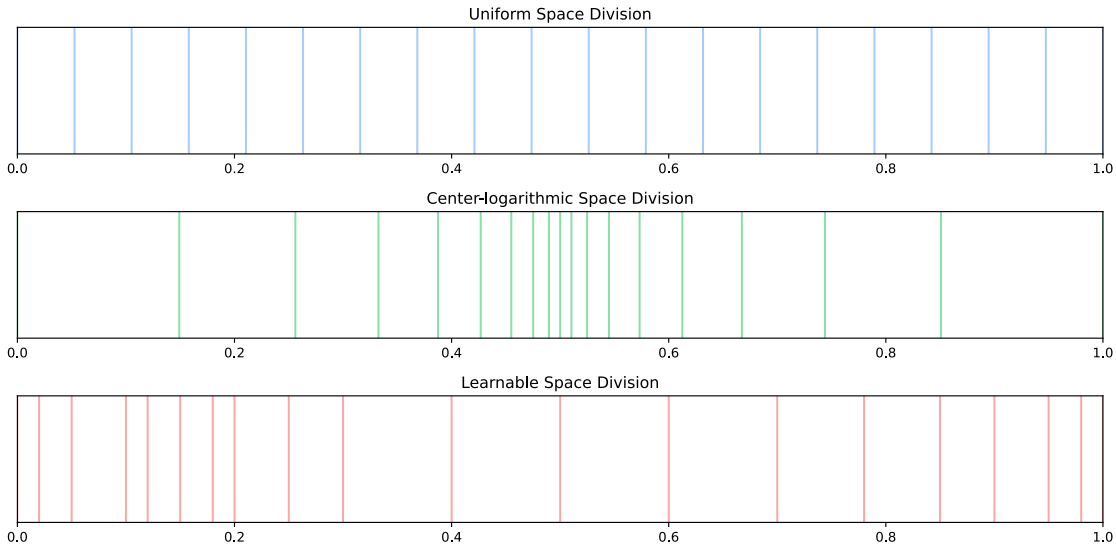

图 4-2 三种不同的空间划分策略
Fig 4-2 Three different space division strategies

4.3.2 空间划分策略

（1）均匀空间划分策略：该策略将坐标空间等分为大小相同的区间，这种方法对整个坐标空间采用相同的精度，不偏向任何特定区域。对于服装关键点检测而言，这意味着图像中的每个关键点都被赋予了相同的精度重要性。该条件下 bin 的位置计算公式为：

$$b_x(i)=\frac{i}{W_d-1} \tag{4-5}$$

均匀划分虽然计算效率较高，但是在处理服装细节部位式精度可能不足。

（2）对数空间划分策略：该策略采用非线性刻度对坐标空间进行划分，为关键点周围的区域提供更精细的划分以提高定位精度。当以图像中心为基准进行对数变换时，bin 位置计算公式为：

$$b_x(i) = 0.5 + sign\left(\frac{i}{(W_d - 1)} - 0.5\right) \cdot \frac{log\left(1 + \alpha \cdot \left|\frac{i}{(W_d - 1)} - 0.5\right|\right)}{\frac{log(1+\alpha)}{2}} \tag{4-6}$$

其中 α 用来控制非线性程度，α 越大，非线性效应越明显。对数离散空间建模在不增加模型参数和复杂度的同时引入了非均匀精度分配，但其架设了中心区域更重要的先验，对形状复杂或不对称的服装可能不是最优分配方式。

（3）可学习空间划分策略：该策略模摒弃了预定义的刻度分布，而是让模型自行学习最优的空间划分方式，这意味着模型可以从数据中发现不同服装类型和区域的重要性模式，并针对各种服装类型优化分配策略。可学习空间离散建模首先定义可学习参数 $w_x(i)$，然后通过以下步骤计算 bin 的位置：首先计算 bin 之间的正值间隔：

$$\delta_x(i) = softplus(w_x(i)) = log(1 + e^{w_x(i)}) \tag{4-7}$$

其次计算累计和，确保 bin 的位置单调性：

$$c_x(i) = \sum_{k=0}^{i} \delta_x(k) \tag{4-8}$$

最后归一化：

$$b_x(i) = \frac{c_x(i)}{c_x(W_d - 1)} \tag{4-9}$$

可学习的空间离散建模能够自适应学习最优的空间精度分配，不依赖人为假设，对不同类型服装和关键点分布具有更强的适应能力。

图 4-3 中比较了三种空间划分策略下的概率解码过程：

第一行展示了一个固定的概率分布，第二行展示了三种不同 bin 位置划分略，第三行展示了各策略下的最终解码坐标，并于真实分布均值（灰色线）进行比较，距离真实分布越近表示此概率分布更接近真实分布。

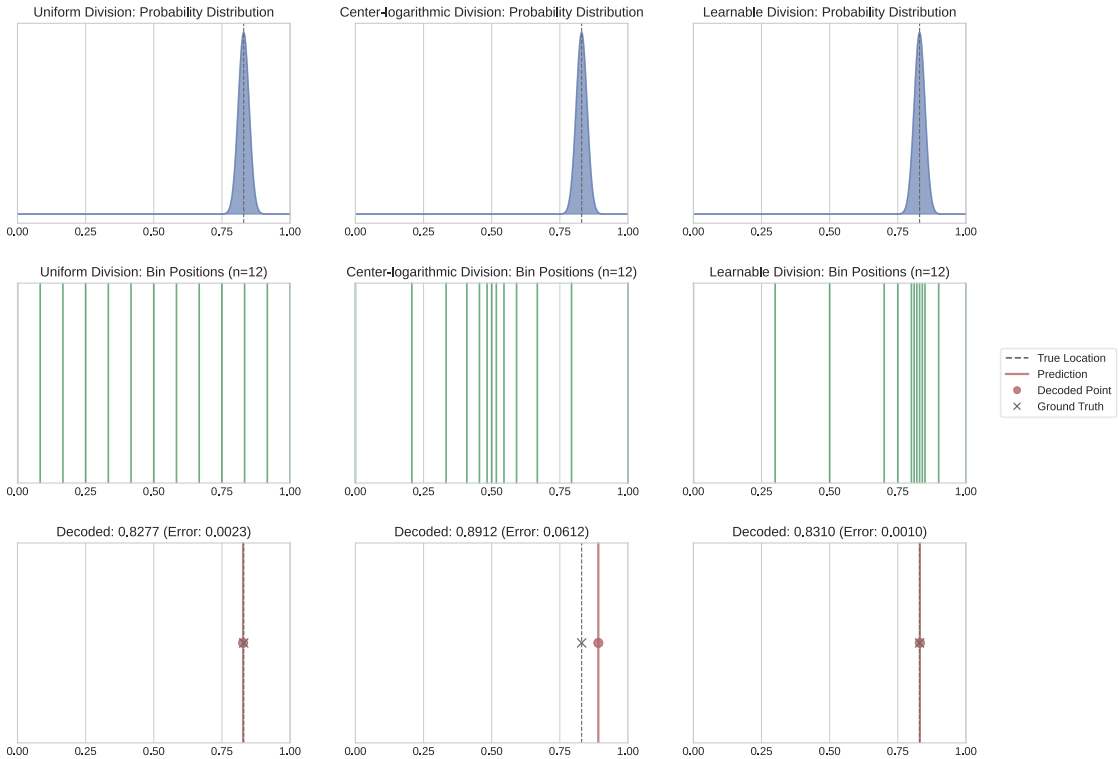

图 4-3 不同空间划分策略对关键点坐标解码精度的影响

Fig 4-3 The impact of different space division strategies on the decoding accuracy of key point coordinates

4.3.3 概率散度度量与损失函数

在空间离散建模中，关键点坐标预测被表示为概率分布而非单点值，计算空间离散建模的损失本质上是衡量预测概率分布与目标概率分布之间的差异程度。在概率论和信息论中，常用的分布相似度度量包括 KL 散度（Kullback-Leibler divergence）[60]和 JS 散度（Jensen-Shannon divergence）[61]。KL 散度的数学定义为：

$$D_{KL}(P||Q) = \sum_i P(i) log \frac{P(i)}{Q(i)} \tag{4-10}$$

其中 P 是目标分布，Q 是预测分布。JS 散度则是 KL 散度的对称变体，定义为：

$$D_{JS}(P||Q) = \frac{1}{2} D_{KL}(P||M) + \frac{1}{2} D_{KL}(Q||M) \tag{4-11}$$

其中 $M = \frac{1}{2}(P + Q)$ 是两个分布的平均。

在服装关键点检测任务中，JS 散度相较于 KL 散度具有明显优势，KL 散度的一个重要缺陷是其不对称性：$D_{KL}(P||Q) \neq D_{KL}(Q||P)$，当预测分布 Q 中某个位置概率接近零而目标 P 分布在该位置有正值时，KL 散度会趋于无限大，导致训练不稳定；当目标关键点位置存在固有不确定性时，模型可能产生多峰或者分散的预测分布。JS 散度通过平均分布 M 作为中介，能更好地容忍这种合理的不稳定性，而不会像 KL 散度那样过度惩罚分布差异。

仅有位置分布的匹配还不足以全面表达关键点预测的不确定性。为此，本章在离散预测值的基础上引入残差对数似然估计（RLE）作为补充，直接建模坐标预测误差的概率分布。

本章提出将 JS 散度和 RLE 损失结合，形成针对服装关键点检测的完整损失函数：

$$\mathcal{L}_{SDM} = \mathcal{L}_{JS} + \mathcal{L}_{RLE} \tag{4-12}$$

其中 $\mathcal{L}_{JS}$ 是基于 JS 散度的位置分布匹配损失，$\mathcal{L}_{RLE}$ 是基于残差对数似然的不确定性建模损失，通过联合损失函数，二者能够提供互补的监督信号，并且能够满足服装关键点检测任务对位置精度和不确定性评估的需求。

4.4 位置编码的设计

在服装关键点检测任务中，许多关键点之间有明显的空间先验性，其空间位置信息对于模型理解服装结构至关重要。标准的自注意力机制由于其无序性，无法直接感知输入特征的空间关系，从而导致在不同服装形态和尺度变化下，模型难以建立稳定的关键点依赖关系，进一步导致在关键点定位时出现偏移，这种情况在数据集规模较小时会更加凸显。而轻量级 CNN 骨干网络由于参数量受限，通常缺乏对图像中绝对空间位置的强建模能力，卷积特征中缺乏位置感知可能导致定位精度下降。

现有的位置编码策略主要包括两类：一类是在特征进入 Transformer 之前添加

静态或可学习的位置编码；另一类是像 RoFormer[62]中引入旋转位置编码，通过对注意力计算中的 Query 和 Key 进行旋转变换，实现相对位置感知，这些方法对输入特征的连续性分布有较强依赖，而 QAM 中的量化操作会破坏特征的连续性和方向性。

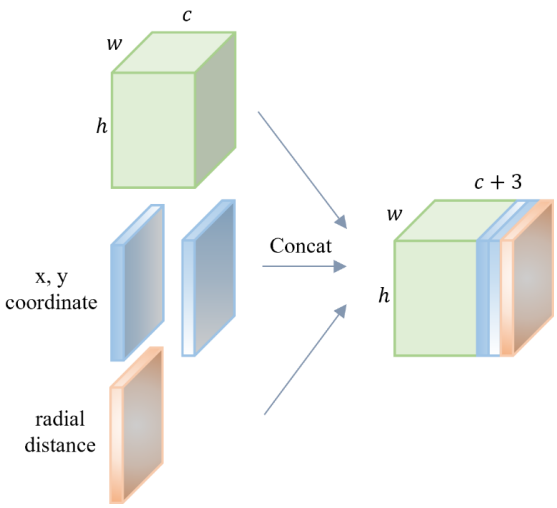

图 4-4 显式位置编码示意图
Fig 4-4 Schematic diagram of explicit position encoding

基于上述分析，本章采用显式编码的方式作为替代方案，在特征图进入骨干网络之前，显式地将空间位置信息直接拼接到输入特征中，以增强模型的空间感知能力。如图 4-4 所示，位置编码分为三部分：每个像素点在图像中归一化后的水平、垂直位置以及每个像素点到图像中心的距离归一化后的值，对于输入特征图 $X \in \mathbb{R}^{C \times H \times W}$ 及其中的位置 (i, j)：

$$X_{norm}(i,j) = \frac{2i}{W-1} - 1 \tag{4-13}$$

$$Y_{norm}(i,j) = \frac{2j}{H-1} - 1 \tag{4-14}$$

$$R_{norm}(i,j) = \sqrt{(X_{norm}(i,j) - 0.5)^2 + (Y_{norm}(i,j) - 0.5)^2} \tag{4-15}$$

此类显式坐标编码具有两个主要优势：首先，它与特征提取过程深度整合，使模型能够在最初阶段就获取位置信息；其次，即使在特征量化过程中部分空间信息被离散化，模型仍能保留足够的位置语义。

4.5 实验与分析

本节采用的实验环境和训练细节除坐标编码方式外与第三章完全相同。在本节实验中，关键点的坐标在编码阶段被转换为一维概率分布形式，并在标签生成过程中引入了高斯平滑策略，以提升监督信号的连续性与稳定性。

4.5.1 消融实验

为了验证 QAM 和 SD 的有效性，本节在相同骨干网络的基础上，采用不同配置模型：（1）基线模型，采用直接回归策略；（2）仅引入 SD，由于移除了 QAM，需要对骨干网络输出特征同应用转置卷积上采样（2）同时整合 QAM 和 SD 的完整模型。

表 4-2 QAM 和 SD 对模型性能的影响
Table 4-2 The impact of QAM and SD

QAM	SD*	SD	GFLOPs	FPS	PCK@0.05↑	AUC↑	EPE↓
			1.7	505	0.812	0.61	14.35
	✓		3.5	339	0.826	0.64	13.66
✓		✓	1.9	473	**0.831**	**0.65**	**12.83**

如表 4-2 所示，SD*表示通过额外上采样层实现的空间离散建模，在长裤类别上的实验结果清晰揭示了各组件的贡献：基线模型虽然具有较低的计算成本（1.7 GFLOPs）和较高的推理速度（505 FPS），但在所有精度指标上表现不佳。仅引入 SD*显著提升了检测精度，但由于上采样层的引入，使计算复杂度增加至 3.5 GFLOPs，推理速度下降至 339 FPS。当同时整合 QAM 和 SD 时，模型不仅在所有精度指标上取得最佳表现（PCK 达到 0.831，AUC 达到 0.65，EPE 降至 12.83），而且保持了较低的计算开销（1.9 GFLOPs）和较高的推理效率（473 FPS）。这一结果凸显了 QAM 和 SD 的协同增效作用：QAM 通过量化自注意力机制在有限计算资源下增强了全局特征表示能力，而 SD 则通过空间坐标离散化机制确保了关键点定位的高精度。

为了进一步验证不同的空间划分策略的效果，本节针对 4.3.2 中提到的三种划

分策略进行比较，其中可学习的划分策略中的初始分布为均匀分布。实验将展示 LSD-Net 在长袖外套类别上的实验结果。

表 4-3 不同空间划分策略对模型性能的影响
Table 4-3 The impact of different spatial division

空间划分策略	PCK@0.05↑	AUC↑	EPE↓
均匀划分	0.759	0.50	18.11
中心对数划分	0.762	0.50	18.15
可学习划分	**0.765**	**0.51**	**17.81**

表 4-3 的实验结果揭示了空间划分策略对检测性能的影响，均匀划分作为基础策略，在三个指标中均为最低，反映出其在面对分布不均的关键点时存在精度不足问题。中心对数划分试图通过更细致的中心区域空间分配改善定位精度，其在 PCK 指标上略优于均匀划分，但其 EPE 值反而略高，表明固定的非均匀分布模式虽能在某些区域提供更细致的划分，却可能在其他区域造成更大的精度损失。这一现象进一步佐证了服装关键点空间分布的复杂多变性，预设的固定划分方案难以满足不同类型服装在不同部位呈现的独特结构特征和分布规律。可学习划分策略在所有评估指标上均取得了最佳表现。这一结果验证了可学习空间离散机制的自适应优势，其能够根据服装关键点的实际分布特性动态调整空间精度资源分配，从而更精确地捕捉关键区域的细微差异。

4.5.2 对比实验

为全面评估 LSD-Net 的性能，本节将其与当前主流的服装关键点检测方法进行对比，包括基于热图的 Simple Baseline (SBL)、基于 Transformer 的 PVT、基于分类的 SimCC、混合结构的 RTMPose 以及上一章提出的 MQA-Net。

表 4-4 本章提出的 LSD-Net 与其他方法的对比
Table 4-4 The comparison between the proposed LSD-Net and other methods

Method	GFLOPs	FPS	Category	PCK@0.05↑	AUC↑	EPE↓
Simple Baseline	2.7	144	trousers	0.822	0.63	14.16
			skirt	0.799	0.65	16.17
			long sleeved outwear	**0.772**	**0.51**	18.20
			sling	0.687	**0.55**	**20.95**

表 4-4（续）

Method	GFLOPs	FPS	Category	PCK@0.05↑	AUC↑	EPE↓
PVT	3.7	355	trousers	0.806	0.60	16.38
			skirt	0.761	0.61	19.24
			long sleeved outwear	0.733	0.45	21.43
			sling	0.545	0.46	24.91
SimCC	3.5	339	trousers	0.826	0.64	13.66
			skirt	**0.811**	**0.66**	15.61
			long sleeved outwear	0.762	0.50	18.33
			sling	0.672	0.54	22.49
RTMPose	1.9	364	trousers	0.822	0.63	13.97
			skirt	0.803	0.65	15.76
			long sleeved outwear	0.764	**0.51**	18.20
			sling	0.665	0.54	22.55
MQA-Net	**1.5**	**572**	trousers	0.814	0.62	16.52
			skirt	0.790	0.64	19.64
			long sleeved outwear	0.765	0.50	18.16
			sling	0.628	0.51	21.50
LSD-Net（本章方法）	1.9	473	trousers	**0.831**	**0.65**	**12.83**
			skirt	0.809	**0.66**	**15.37**
			long sleeved outwear	0.765	**0.51**	**17.81**
			sling	0.663	**0.55**	21.04

表 4-4 的对比结果展示了 LSD-Net 在精度与效率平衡方面的良好性能。LSD-Net 在四类服装上均实现了稳定且领先的检测精度，尤其在 AUC 以及 EPE 指标上的全面优势，充分验证了可学习空间离散建模对不同服装类型特性的适应能力。

与基于热图的 SBL 相比，LSD-Net 在保持相当精度的同时，计算复杂度降低了 30%，推理速度提升了 3.3 倍。虽然 SBL 得益于密集空间监督在小样本类别（如吊带）中表现较好，但其低效的计算特性限制了实际应用场景。

PVT 尽管采用了强大的 Transformer 架构增强全局建模能力，但其 3.7 GFLOPs 的高计算负担和对局部细节捕捉能力的不足，导致在所有指标上均落后于 LSD-Net。SimCC 通过简化的分类方法实现了较好的检测精度，但上采样层带来的高计算复杂度使其效率大幅低于 LSD-Net。

RTMPose 与 LSD-Net 具有相当的计算复杂度（1.9 GFLOPs），但 LSD-Net 在

长裤和裙子类别上的 PCK 和 AUC 指标明显领先，特别是 EPE 指标的全面优势突显了空间离散建模的精确定位能力。与上一章提出的 MQA-Net 相比，LSD-Net 虽然计算量略有增加，但在所有类别上的检测精度均有显著提升，验证了从回归范式转向空间离散建模的技术路线优势。

综合分析表明，LSD-Net 成功实现了计算效率与检测精度的优化平衡，其引入的可学习空间离散建模机制能够有效适应不同服装类型的结构特性，实现了高精度、高效率的服装关键点检测。

4.5.3 可视化结果分析

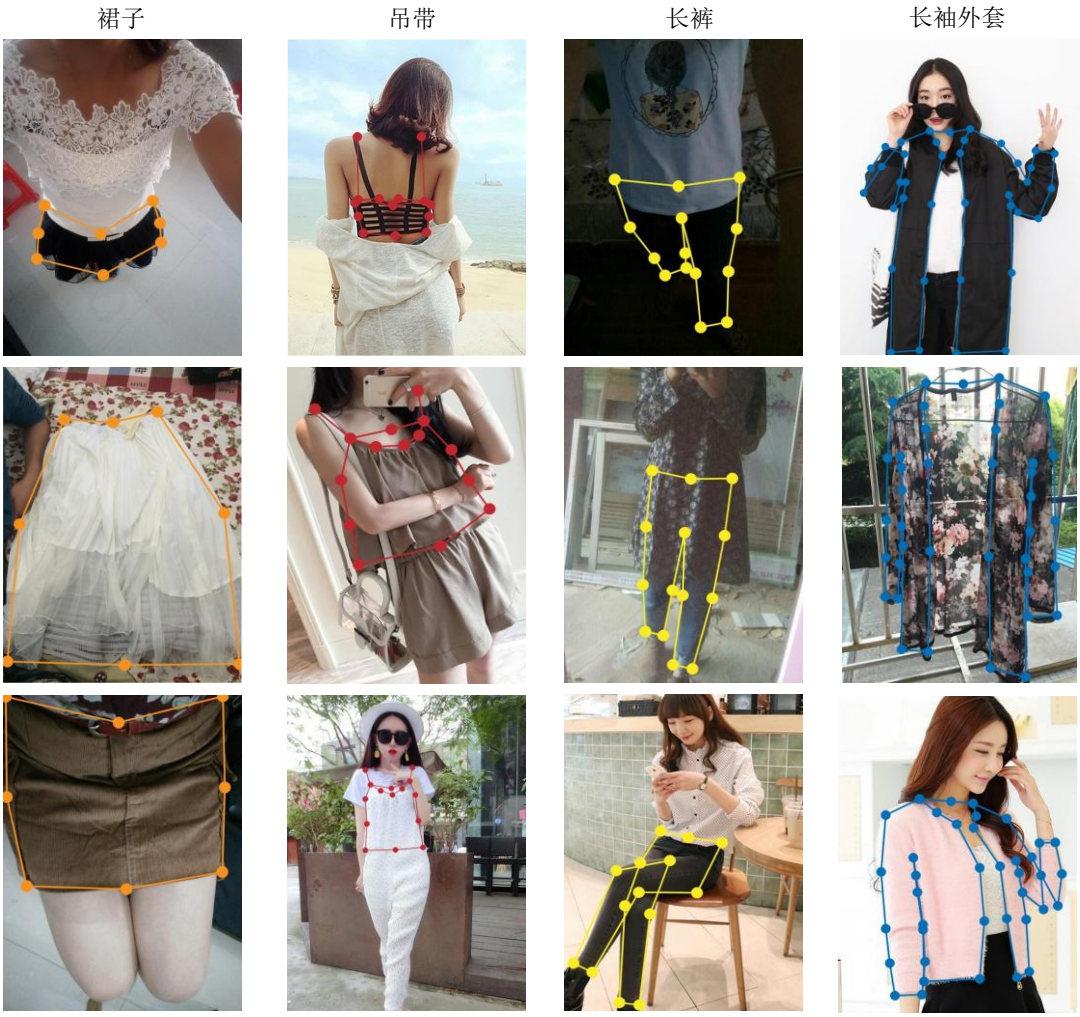

图 4-5 LSD-Net 在 DeepFashion2 上的可视化结果
Fig 4-6 Visualization results of LSD-Net on the DeepFashion2 dataset

本节将 LSD-Net 的关键点检测结果进行了可视化，从四类服装中选取具有代表性的挑战场景进行展示。图 4-5 展示了检测结果，验证了 LSD-NET 在多样化场景下的鲁棒性和适应能力。

图 4-5 中长裤类别的三个样例分别呈现了模型在不同姿态变化、局部遮挡以及背景干扰条件下的准确预测能力；裙子类别中的极端俯视视角样例展示了方法对视角变化的适应性；长袖外套样例不同款式的外套证明了算法能有效处理不同风格和材质引起的形变与褶皱；吊带类别的罕见款式样例则验证了即使在训练数据稀疏的类别上，模型仍保持较高的泛化能力和结构一致性。

这些多样化的检测结果共同证实了基于可学习空间离散建模的检测框架在服装关键点定位任务上的优势，尤其在应对姿态多变性、部分遮挡、视角差异和款式多样性等实际挑战时表现出色。LSD-Net 通过空间自适应离散化和量化自注意力增强的特征表示，成功捕捉了服装的全局结构关系与局部精细特征，为服装关键点检测提供了高效且鲁棒的解决方案。

4.6 本章小结

本章针对传统服装关键点检测方法中热图计算成本高、直接回归精度有限的问题，提出了一种基于可学习空间离散建模的检测框架。该模型的关键在于将连续坐标空间转化为离散表示，并通过可学习方法动态调整空间精度分配，有效平衡精度与效率的关系。针对服装关键点分布不均匀的特点，提出了基于累积 softplus 函数的 bin 位置学习机制，使模型能够自动为细节丰富的区域分配更多精度资源。与第三章不同，本章的 QAM 模块直接应用于原始图像特征，增强特征表示能力。本章在实验部分，通过与热图方法和直接回归方法的对比，验证了本框架在精度、计算效率上的综合优势，并通过消融实验验证了可学习空间离散建模的有效性。

第五章 总结与展望

本文针对现有的服装关键点检测方法中存在的问题，首先在基于回归的方法上设计了量化自注意力模块将关键点特征映射至离散码本，增强全局关系的建模能力，其次，设计了基于空间离散建模的检测框架，并且通过可学习的坐标区间划分机制，使模型能够根据服装关键点分布特性自适应分配精度。最后通过在DeepFashion2 数据集上进行实验证明了本文提出的方法能够有效平衡服装关键点检测模型的检测精度和模型规模。

5.1 工作总结

本文的主要工作内容可总结如下：

（1）针对服装关键点检测中特征表示能力不足的问题，设计了量化自注意力模块（QAM），通过结合向量量化与自注意力机制，有效增强了模型捕获服装结构全局信息的能力。该模块通过离散码本学习结构化特征表示，在保留关键信息的同时减少冗余，使模型能够更好地适应服装的多样性变化，为后续的关键点定位提供可靠基础。实验表明，QAM 不仅提高了模型对多样化服装的适应能力，还为两种不同检测范式提供了统一的特征增强解决方案。

（2）针对传统回归方法难以建模关键点间复杂关系的局限性，提出了基于QAM 的多阶段回归框架（MQA-Net），通过迭代细化关键点预测并建模关键点间的相互依赖提升了检测精度。该框架将关键点坐标嵌入至特征空间，通过多轮QAM 处理实现关键点间信息交互，提高了模型对复杂区域中难点部位的定位能力，增强了模型对复杂场景的适应能力。实验结果表明，MQA-Net 在保持高效计算的同时，实现了接近热图方法的定位精度。

（3）针对热图方法计算开销大、回归方法精度有限的问题，提出了基于可学习空间离散建模的检测框架（LSD-Net），突破了传统检测范式的限制，实现了高精度与高效率的统一。该框架通过可学习位置划分策略自适应分配空间精度资源，

结合残差对数似然估计提供可靠的不确定性估计，在保持高计算效率的同时适应了服装关键点分布不均匀的特性。实验证明，LSD-Net 在四类服装上均达到了领先性能，同时保持了较低的计算复杂度和较高的推理速度。

5.2 课题展望

虽然本文提出的基于量化自注意力模块以及空间离散建模方法能够以轻量网络结构实现较高精度的服装关键点检测，但是依然存在一些不足，需要进一步优化，但仍有多个方向值得进一步探索：

（1）将高精度服装关键点检测模型部署到算力受限的移动设备上具有重要价值，未来研究可着重于模型量化、知识蒸馏和结构优化等技术，以在保持检测精度的同时继续降低计算复杂度和内存占用。

（2）目前的方法多针对特定服装类别进行优化，缺乏跨类别的泛化能力。未来可探索多类别联合训练策略，结合类别自适应模块，实现单一模型对多种服装类型的精确检测。同时，引入迁移学习技术，将在大规模数据集上预训练的模型高效迁移到新服装类别或特定应用场景，降低对大量标注数据的依赖。

（3）服装关键点标注成本高，高质量标注数据稀缺。未来研究可探索自监督学习方法，利用大量无标注服装图像进行预训练，提取更通用的服装特征表示。同时，开发更先进的数据增强技术，如基于生成模型的样本合成、基于物理的服装形变模拟等，丰富训练数据的多样性，进一步提升模型的泛化能力和鲁棒性。

参 考 文 献

[1] 中国服装协会. 2024 年 1-12 月中国服装行业经济运行简报[EB/OL].2025.https://www.cntac.org.cn/zixun/shuju/202502/t20250220_4376583.html.

[2] Huang J, Feris R S, Chen Q, et al. Cross-domain image retrieval with a dual attribute-aware ranking network[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1062-1070.

[3] Lu Z, Hu Y, Jiang Y, et al. Learning binary code for personalized fashion recommendation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 10562-10570.

[4] Zhu L, Yang D, Zhu T, et al. Tryondiffusion: A tale of two unets[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 4606-4615.

[5] Yu W, Liang X, Gong K, et al. Layout-graph reasoning for fashion landmark detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 2937-2945.

[6] Chen M, Qin Y, Qi L, et al. Improving fashion landmark detection by dual attention feature enhancement[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops. 2019: 0-0.

[7] Wang W, Xu Y, Shen J, et al. Attentive fashion grammar network for fashion landmark detection and clothing category classification[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 4271-4280.

[8] Lowe D G. Distinctive image features from scale-invariant keypoints[J]. International journal of computer vision, 2004, 60: 91-110.

[9] Lowe D G. Object recognition from local scale-invariant features[C]//Proceedings of the seventh IEEE international conference on computer vision. Ieee, 1999, 2: 1150-1157.

[10] Dalal N, Triggs B. Histograms of oriented gradients for human detection[C]//2005

IEEE computer society conference on computer vision and pattern recognition (CVPR'05). Ieee, 2005, 1: 886-893.

[11] Fischler M A, Elschlager R A. The representation and matching of pictorial structures[J]. IEEE Transactions on computers, 1973, 100(1): 67-92.

[12] Toshev A, Szegedy C. Deeppose: Human pose estimation via deep neural networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 1653-1660.

[13] Sun X, Shang J, Liang S, et al. Compositional human pose regression[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2602-2611.

[14] Newell A, Yang K, Deng J. Stacked hourglass networks for human pose estimation[C]//Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part VIII 14. Springer International Publishing, 2016: 483-499.

[15] Wei S E, Ramakrishna V, Kanade T, et al. Convolutional pose machines[C]//Proceedings of the IEEE conference on Computer Vision and Pattern Recognition. 2016: 4724-4732.

[16] Xiao B, Wu H, Wei Y. Simple baselines for human pose estimation and tracking[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 466-481.

[17] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.

[18] Sun K, Xiao B, Liu D, et al. Deep high-resolution representation learning for human pose estimation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 5693-5703.

[19] Yu C, Xiao B, Gao C, et al. Lite-hrnet: A lightweight high-resolution network[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 10440-10450.

[20] Zhang X, Zhou X, Lin M, et al. Shufflenet: An extremely efficient convolutional

neural network for mobile devices[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 6848-6856.

[21] Kan Z, Chen S, Zhang C, et al. Self-correctable and adaptable inference for generalizable human pose estimation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 5537-5546.

[22] Wang Y, Li M, Cai H, et al. Lite pose: Efficient architecture design for 2d human pose estimation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 13126-13136.

[23] Cheng B, Xiao B, Wang J, et al. Higherhrnet: Scale-aware representation learning for bottom-up human pose estimation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 5386-5395.

[24] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

[25] Li K, Wang S, Zhang X, et al. Pose recognition with cascade transformers[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 1944-1953.

[26] Ding M, Lian X, Yang L, et al. Hr-nas: Searching efficient high-resolution neural architectures with lightweight transformers[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 2982-2992.

[27] Zoph B, Le Q V. Neural architecture search with reinforcement learning[J]. arXiv preprint arXiv:1611.01578, 2016.

[28] Li Y, Zhang S, Wang Z, et al. Tokenpose: Learning keypoint tokens for human pose estimation[C]//Proceedings of the IEEE/CVF International conference on computer vision. 2021: 11313-11322.

[29] Xu Y, Zhang J, Zhang Q, et al. Vitpose: Simple vision transformer baselines for human pose estimation[J]. Advances in neural information processing systems, 2022, 35: 38571-38584.

[30] Lin T Y, Maire M, Belongie S, et al. Microsoft coco: Common objects in context[C]//Computer vision–ECCV 2014: 13th European conference, zurich, Switzerland, September 6-12, 2014, proceedings, part v 13. Springer International

Publishing, 2014: 740-755.
[31] Ding Y, Deng W, Zheng Y, et al. I^ 2R-Net: intra-and inter-human relation network for multi-person pose estimation[J]. arXiv preprint arXiv:2206.10892, 2022.
[32] Wang J, Long X, Gao Y, et al. Graph-pcnn: Two stage human pose estimation with graph pose refinement[C]//Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XI 16. Springer International Publishing, 2020: 492-508.
[33] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[J]. arXiv preprint arXiv:1609.02907, 2016.
[34] Liu Z, Luo P, Qiu S, et al. Deepfashion: Powering robust clothes recognition and retrieval with rich annotations[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1096-1104.
[35] Liu Z, Yan S, Luo P, et al. Fashion landmark detection in the wild[C]//Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part II 14. Springer International Publishing, 2016: 229-245.
[36] Yan S, Liu Z, Luo P, et al. Unconstrained fashion landmark detection via hierarchical recurrent transformer networks[C]//Proceedings of the 25th ACM international conference on Multimedia. 2017: 172-180.
[37] Hu Y, Xiao L, Wang Y, et al. Fashion pose machine for fashion landmark detection[C]//2018 International Conference on Image and Video Processing, and Artificial Intelligence. SPIE, 2018, 10836: 186-190.
[38] Li Y, Tang S, Ye Y, et al. Spatial-aware non-local attention for fashion landmark detection[C]//2019 IEEE international conference on multimedia and expo (ICME). IEEE, 2019: 820-825.
[39] Huang C Q, Chen J K, Pan Y, et al. Clothing landmark detection using deep networks with prior of key point associations[J]. IEEE transactions on cybernetics, 2018, 49(10): 3744-3754.
[40] Wang R, Feng J, Bu Q. Fashion Landmark Detection via Deep Residual Spatial Attention Network[C]//2021 IEEE 33rd International Conference on Tools with

Artificial Intelligence (ICTAI). IEEE, 2021: 745-752.
[41] Ge Y, Zhang R, Wang X, et al. Deepfashion2: A versatile benchmark for detection, pose estimation, segmentation and re-identification of clothing images[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 5337-5345.
[42] 谢志峰, 周志鹏, 王兆胜, 等. 多尺度空间特征引导的服装关键点检测方法[J]. 计算机辅助设计与图形学学报, 2022, 34(11): 1763-1771.
[43] Lin T H. Aggregation and finetuning for clothes landmark detection[J]. arXiv preprint arXiv:2005.00419, 2020.
[44] Huang J, Zhu Z, Guo F, et al. The devil is in the details: Delving into unbiased data processing for human pose estimation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 5700-5709.
[45] Sidnev A, Krapivin A, Trushkov A, et al. Deepmark++: Real-time clothing detection at the edge[C]//proceedings of the IEEE/CVF winter conference on applications of computer vision. 2021: 2980-2988.
[46] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
[47] Behrad F, Abadeh M S. An overview of deep learning methods for multimodal medical data mining[J]. Expert Systems with Applications, 2022, 200: 117006.
[48] Wang A, Chen H, Lin Z, et al. Repvit: Revisiting mobile cnn from vit perspective[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 15909-15920.
[49] Howard A, Sandler M, Chu G, et al. Searching for mobilenetv3[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 1314-1324.
[50] Chollet F. Xception: Deep learning with depthwise separable convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1251-1258.
[51] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.
[52] Ding X, Zhang X, Ma N, et al. Repvgg: Making vgg-style convnets great

again[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 13733-13742.

[53] Ba J L, Kiros J R, Hinton G E. Layer normalization[J]. arXiv preprint arXiv:1607.06450, 2016.

[54] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.

[55] Wang W, Xie E, Li X, et al. Pyramid vision transformer: A versatile backbone for dense prediction without convolutions[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 568-578.

[56] Lingle L D. Transformer-vq: Linear-time transformers via vector quantization[J]. arXiv preprint arXiv:2309.16354, 2023.

[57] Hendrycks D, Gimpel K. Gaussian error linear units (gelus)[J]. arXiv preprint arXiv:1606.08415, 2016.

[58] Li Y, Yang S, Liu P, et al. Simcc: A simple coordinate classification perspective for human pose estimation[C]//European conference on computer vision. Cham: Springer Nature Switzerland, 2022: 89-106.

[59] Zhang B, Sennrich R. Root mean square layer normalization[J]. Advances in Neural Information Processing Systems, 2019, 32.

[60] Cover T M. Elements of information theory[M]. John Wiley & Sons, 1999.

[61] Lin J. Divergence measures based on the Shannon entropy[J]. IEEE Transactions on Information theory, 1991, 37(1): 145-151.

[62] Su J, Ahmed M, Lu Y, et al. Roformer: Enhanced transformer with rotary position embedding[J]. Neurocomputing, 2024, 568: 127063.

[63] Jiang T, Lu P, Zhang L, et al. Rtmpose: Real-time multi-person pose estimation based on mmpose[J]. arXiv preprint arXiv:2303.07399, 2023.

作者简历及在学期间所获得的学术成果

1. 作者简历

陆然，男，2000 年 1 月 26 日生，于 2022 年 9 月 1 日考入东华大学计算机科学与技术学院软件工程专业，从事服装关键点检测方向研究。经过三年学习，完成学业，撰写了学位论文《基于量化自注意力和空间离散建模的服装关键点检测》。

2. 教育背景

2018 年 9 月~2022 年 6 月， 东华大学，本科，专业：软件工程

2022 年 9 月~2025 年 6 月， 东华大学，硕士研究生，专业：软件工程

3. 在学期间获得的学术成果

[1] Lu R, Wang S, Chen N, et al. QACC-Net: Lightweight Clothing Keypoint Detection with Quantized Self-Attention and Learnable Coordinate Classification[C]//2025 International Conference on Intelligent Computing (ICIC). Singapore: Springer Nature Singapore, 2025: 1-12.（**第一作者**，CCF-C，已录用）

[2] Lu R, Wang S, Chen N, et al. HLPE: A Hybrid Lightweight Model for Efficient and Robust Human Pose Estimation[C]//2025 International Conference on Neural Networks, Information and Communication Engineering (NNICE). IEEE. 2025: 1-4. （**第一作者**，已录用）

[3] Chen N, Wang S, Lu R, et al. PHMamba: Preheating State Space Models with Context-Augmented Features for Medical Image Segmentation[C]//ICASSP 2025-2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2025: 1-5. （第三作者，已发表）

[4] Chen N, Wang S, Lu R, et al. Clothing Parsing Based on Multi-Scale Fusion and Improved Self-Attention Mechanism[J]. Journal of Donghua University (English

Edition), 2023, 40(6). （第三作者，已发表）

[5] Li W, Wang S, Chen N, et al. Uncertainty-Guided Prototype Mixture Model for Skin Lesion Segmentation[C] //2025 International Joint Conference on Neural Networks (IJCNN). IEEE, 2025: 1-8. （第四作者，已录用）

[6] Li W, Wang S, Chen N, et al. EDGRNet: An Error Detection and Guided Refinement Network for Skin Lesion Segmentation[C]//2025 International Joint Conference on Neural Networks (IJCNN). IEEE, 2025: 1-8. （第四作者，已录用）

致　谢

在本论文完成之际，我衷心感谢所有在学业与生活中给予我指导与帮助的人。

首先，忠心感谢我的导师王绍宇老师。在论文选题、研究过程及撰写过程中始终以严谨治学的态度和悉心的指导帮助我不断提升。王老师不仅在学术上给予我宝贵建议，也在科研思维与写作规范方面给予了深入启发，使我受益匪浅。

其次，感谢计算机科学与技术学院为我提供良好的科研平台与学习环境。

最后，感谢我的家人，尤其是父母的理解与支持，使我能够专注于学业，坚定前行。

本论文的完成，凝聚了许多人的心血与帮助。在此，我再次向所有支持和鼓励过我的人表示诚挚的感谢。