学校代码： 10255
学　　号： 2222666
中图分类法： TP183

学术学位硕士学位论文

基于隐式神经表示和预热状态空间模型的语义分割

学 位 申 请 人：陈诺
指　导　教　师：王绍宇副教授
一　级　学　科：计算机科学与技术
研　究　方　向：语义分割
所　在　学　院：计算机科学与技术学院

提　交　日　期：2025 年 5 月

University Code: 10255
Student ID: 2222666
CLC Index: TP183

ACADEMIC MASTER DISSERTATION

SEMANTIC SEGMENTATION BASED ON IMPLICIT NEURAL REPRESENTATION AND PREHEATING STATE SPACE MODEL

Author: Nuo Chen

Supervisor: Assoc. Prof. Shaoyu Wang

First-level Discipline: Computer Science and Technology

Research Field: Semantic Segmentation

College: College of Computer Science and Technology

Date of Submission: May, 2025

东华大学
学位论文原创性声明

本人郑重声明：我恪守学术道德，崇尚严谨学风。所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已明确注明和引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品及成果的内容。论文为本人亲自撰写，我对所写的内容负责，并完全意识到本声明的法律结果由本人承担。

学位论文作者签名：陈诺

日期： 2025 年 5 月 21 日

东华大学
学位论文版权使用授权书

学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅或借阅。本人授权东华大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

保 密 □，在 年解密后适用本版权书。

本学位论文属于

不保密 ☑。

导师签名：王绍宇 学位论文作者签名：陈诺

日期： 2025 年 5 月 21 日

硕士学位论文答辩委员会名单

姓名	职称	单位	备注
夏小玲	教授	东华大学	主席
丁宏锴	高级工程师	亚太计算机信息系统有限公司	委员
石秀金	副教授	东华大学	委员
吴国文	副教授	东华大学	委员
于守健	副教授	东华大学	委员
张红	高级实验师	东华大学	秘书

答 辩 人：陈诺

答辩地点：一号学院楼 259

答辩日期：2025 年 5 月 20 日

基于隐式神经表示和预热状态空间模型的语义分割

摘 要

语义分割作为计算机视觉领域的核心任务之一，旨在对图像中的每个像素进行分类，实现像素级别的密集语义解析。随着深度学习技术的快速发展，基于深度学习方法的语义分割模型在精度和效率上取得了显著突破，已被广泛应用于自动驾驶、场景理解、医学影像分析和遥感地物识别等现实场景。然而，区域边界的分割精度优化和复杂区域的语义一致性等问题仍是当前语义分割技术面临的重要挑战。

本文针对当前语义分割方法中上采样解码过程导致边缘模糊、复杂区域语义一致性差等问题，提出了基于隐式神经表示和预热状态空间模型的改进语义分割算法。研究内容主要包括：

（1）针对上采样解码器在恢复高分辨率特征的过程中会影响类间边界分割精度的问题，将隐式神经表示方法引入到语义分割方法，提出基于查询的解码器。根据语义分割任务的特点，提出语义分割的隐式神经表示范式，通过多尺度特征信息和位置信息进行预测结果的查询，来提高类间边界的分割精度。

（2）针对语义分割这一像素级密集预测任务的要求，对隐式神经表示的输入信息进行进一步强化，提出了隐式神经表示的信息增强模块。该模块通过可变形融合模块完成逐坐标的上下文信息提取来强化特征信息，并生成上下文的注意偏移信号，再通过位置编码模块对注意偏移信号进行编码，生成增强的位置信息。根据强化的特征信息和位置信息，隐式神经表示方法能够用查询的方式完成解码，从而有效改善边缘模糊问题。

（3）为了进一步提高复杂区域的分割效果和语义区域的一致性，引入状态空间模型来利用图像的全局信息，并进一步设计一种预热机制来聚合图像中的类与特征间关系上下文，提出了预热状态空间模型。通过粗分割图对特征进行增强，并将经过粗分割图辅助增强后的特征输入给状态空间模型，来提前建立对关键上下文的关注，从而提高复杂区域的语义一致性。

（4）针对预热机制过程中多次重复输入导致模型对特定信息产生偏好的问题，提出信息补偿模块来恢复原特征图中的语义信息。该模块由局部提取模块、全局提取模块和补偿模块构成，通过提取模块从原特征图中提取对应语义信息，并通

过补偿模块将其聚合至输出特征图，来补偿丢失的部分信息，改善分割精度。

本文在 Cityscapes 数据集和 ADE20K 数据集上进行了广泛的实验，结果表明本方法的分割精度相较于同类型算法在两个数据集上均有一定提升。其中，基于隐式神经表示的语义分割方法在 Cityscapes 数据集上达到了 96.54%的 PA 和 80.76%的 mIoU，在 ADE20K 数据集上达到了 81.03%的 PA 和 44.04%的 mIoU；而在组合了基于预热状态空间模型的语义分割方法后，分割精度进一步提升到了 96.67%的 PA 和 81.79%的 mIoU，以及 81.36%的 PA 和 46.25%的 mIoU。实验证明本文的方法能够有效解决边缘模糊问题，并提高语义区域的一致性，具有较好的实际应用价值。

关键词：语义分割；隐式神经表示；状态空间模型；多尺度融合；上下文聚合

SEMANTIC SEGMENTATION BASED ON IMPLICIT NEURAL REPRESENTATION AND PREHEATING STATE SPACE MODEL

ABSTRACT

As one of the core tasks in computer vision, semantic segmentation aims to assign a semantic label to each pixel in an image, thereby achieving dense, pixel-level understanding. With the rapid development of deep learning techniques, semantic segmentation models have made significant progress in both accuracy and efficiency, and have been widely applied in real-world scenarios such as autonomous driving, scene understanding, medical image analysis, and remote sensing. However, critical challenges remain in current semantic segmentation task, including imprecise delineation of region boundaries and inconsistent semantic predictions in complex areas.

This thesis proposes an improved semantic segmentation algorithm based on Implicit Neural Representation (INR) and preheating State Space Model (SSM) to address issues such as edge blurring caused by upsampling decoding processes and poor semantic consistency in complex regions. The main contributions are as follows:

(1) To mitigate the impact of upsampling decoders on inter-class boundary accuracy during high-resolution feature recovery, this thesis introduces INR into the semantic segmentation and proposes a query-based decoder. By designing a novel INR paradigm tailored for semantic segmentation, the model performs pixel-wise predictions through queries based on multi-scale features and positional encodings, effectively improving boundary precision.

(2) To address the requirements of pixel-wise dense prediction tasks in semantic segmentation, this thesis proposes an information enhancement module for INR to further reinforce input features. The module employs a deformable fusion submodule to perform coordinate-based contextual feature extraction, thereby enhancing feature representations while generating attention offset signals. These signals are subsequently encoded by a position encoding submodule to produce augmented position information. By integrating the refined feature and position information, the INR-based framework achieves decoding through query-driven inference, effectively mitigating edge blurring.

(3) To improve segmentation performance in complex regions and enhance semantic

consistency, this thesis integrates a SSM to capture global context. A preheating mechanism is designed to guide the SSM by injecting class-feature relational context extracted from coarse segmentation maps. This allows the model to establish early focus on critical contextual cues.

(4) To counteract the model's bias toward specific information caused by repeated inputs during the preheating process, this thesis proposes an information compensation module. This module comprises the local extraction submodule, the global extraction submodule, and the compensation submodule. It retrieves semantic information from the original feature maps through corresponding extraction and integrates it into the output features, thereby compensating for lost information and refining segmentation accuracy.

Extensive experiments are conducted on the Cityscapes and ADE20K benchmarks. The proposed INR-based segmentation method achieves 96.54% PA and 80.76% mIoU on Cityscapes, and 81.03% PA and 44.04% mIoU on ADE20K. With the integration of the preheating SSM method, performance further improves to 96.67% PA and 81.79% mIoU on Cityscapes, and 81.36% PA and 46.25% mIoU on ADE20K. These results demonstrate that the proposed method effectively addresses edge blurring and semantic inconsistency, and exhibits strong potential for practical deployment.

Nuo Chen

Supervised by: Shaoyu Wang

KEY WORDS: Semantic segmentation, Implicit neural representation, State space model, Multi-scale fusion, Context aggregation

目录

摘 要 …… **I**
ABSTRACT …… **III**
第一章 绪论 …… **1**
1.1 研究背景及意义 …… 1
1.2 国内外研究现状 …… 2
1.2.1 基于传统方法的语义分割技术 …… 2
1.2.2 基于深度学习方法的语义分割技术 …… 4
1.3 研究目标及内容 …… 6
1.4 文章的组织结构 …… 6
第二章 深度学习与语义分割 …… **8**
2.1 卷积神经网络 …… 8
2.1.1 卷积神经网络的发展变迁 …… 8
2.1.2 卷积神经网络的基本结构 …… 9
2.2 多尺度融合结构 …… 18
2.2.1 并行多分支的多尺度融合 …… 18
2.2.2 金字塔结构的多尺度融合 …… 20
2.2.3 级联结构的多尺度融合 …… 21
2.3 隐式神经表示 …… 22
2.4 状态空间模型 …… 25
2.5 本章小结 …… 27
第三章 基于隐式神经表示的语义分割方法 …… **28**
3.1 多尺度融合的隐式神经表示解码器 …… 28
3.2 隐式神经表示的信息增强模块 …… 30
3.2.1 信息增强模块的框架 …… 30
3.2.2 可变形融合模块 …… 31
3.2.3 小波位置编码模块 …… 33
3.3 基于隐式神经表示的语义分割框架 …… 34
3.4 实验与分析 …… 35

3.4.1 实验数据 35
3.4.2 评价指标 35
3.4.3 实验设置 36
3.4.4 消融实验 37
3.4.5 对比实验 39
3.4.6 实验结果可视化 41
3.5 本章小结 42
第四章 基于预热状态空间模型的语义分割方法 43
4.1 预热状态空间模型 43
4.2 信息补偿模块 45
4.2.1 局部提取模块 46
4.2.2 全局提取模块 47
4.2.3 补偿模块 48
4.3 基于预热状态空间模型的语义分割框架 48
4.4 实验与分析 50
4.4.1 实验设置 50
4.4.2 消融实验 50
4.4.3 对比实验 51
4.4.4 实验结果可视化 52
4.5 本章小结 54
第五章 结论与展望 55
5.1 工作总结 55
5.2 课题展望 56
参 考 文 献 57
作者简历及在学期间所获得的学术成果 65
致 谢 67

图录

图 2-1 常规卷积的计算过程 10
图 2-2 转置卷积的模拟计算过程 10
图 2-3 空洞卷积的计算过程 11
图 2-4 可变形卷积的计算过程 12
图 2-5 最大池化和平均池化的计算过程 12
图 2-6 混合池化的计算过程 13
图 2-7 随机池化的计算过程 14
图 2-8 空间金字塔池化的计算过程 14
图 2-9 Sigmoid 激活函数的图像 15
图 2-10 Tanh 激活函数的图像 16
图 2-11 ReLU 激活函数的图像 16
图 2-12 Inception 模块（来源于文献[42]） 18
图 2-13 PSPNet 的金字塔池化模块（来源于文献[30]） 19
图 2-14 空洞空间金字塔池化模块（来源于文献[51]） 19
图 2-15 特征金字塔网络（来源于文献[52]） 20
图 2-16 路径增强网络（来源于文献[53]） 20
图 2-17 PAN 的特征金字塔增强模块（来源于文献[54]） 21
图 2-18 HRNet 结构（来源于文献[21]） 21
图 2-19 HRFormer 结构（来源于文献[55]） 22
图 2-20 SDF 的示例图像（来源于文献[56]） 23
图 2-21 空间占用概率的示例图像（来源于文献[58]） 24
图 2-22 神经辐射场的示例图像（来源于文献[60]） 24
图 2-23 LIIF 结构（来源于文献[61]） 25

图 2-24 VMamba 模型的框架（来源于文献[67]） 26
图 2-25 Mamba-UNet 模型的框架（来源于文献[68]） 27
图 3-1 上采样解码网络和查询解码网络的对比 28
图 3-2 多尺度融合的隐式神经表示解码器的整体结构 29
图 3-3 信息增强模块的结构 31
图 3-4 基于隐式神经表示的语义分割框架 34
图 3-5 Cityscapes 数据集和 ADE20K 数据集样本示例 35
图 3-6 不同方法在 Cityscapes 数据集上的可视化结果 41
图 3-7 不同方法在 ADE20K 数据集上的可视化结果 41
图 4-1 粗分割辅助特征图的生成流程 44
图 4-2 预热状态空间模型的流程 45
图 4-3 局部提取模块的流程 46
图 4-4 全局提取模块的流程 47
图 4-5 补偿模块的流程 48
图 4-6 基于预热状态空间模型的语义分割框架 49
图 4-7 不同方法在 Cityscapes 数据集上的可视化结果 53
图 4-8 不同方法在 ADE20K 数据集上的可视化结果 53

表录

表 3-1 可变形融合模块和位置编码模块的消融实验 37
表 3-2 不同隐式查询函数结构的比较实验 38
表 3-3 不同小波位置编码核的比较实验 38
表 3-4 与基于 CNN 的方法的对比实验 39
表 3-5 与上采样解码方法的对比实验 39
表 3-6 与隐式神经表示方法的对比实验 40
表 3-7 对边缘分割的对比实验 40
表 4-1 局部补偿模块和全局补偿模块的消融实验 50
表 4-2 不同预热状态空间模型结构的比较实验 51
表 4-3 与其他方法的对比实验 52

第一章　绪论

本章首先对语义分割的研究背景及意义进行了阐述，接着对语义分割的研究现状进行了分析，并介绍了本文的研究内容及研究目标，最后梳理了本文的整体组织结构。

1.1 研究背景及意义

视觉信息是人类感知外界环境的重要因素，这在机器感知领域同样适用。视觉信息可以由各种传感器获得，并通过算法处理得到需要的信息，用于机器与真实世界的交互。随着社会生产和生活智能化进程的不断深入，具身智能正引发社会各界的高度关注，人们对机器视觉传感器的识别精度也提出了更高的要求，这推动了计算机视觉的迅速发展。在现有的计算机视觉方法中，机器学习无疑是目前最有效的方法，而其中深度学习作为机器学习算法中最为热门的一个分支，在各项任务中均有出色的表现。因此，基于深度学习的计算机视觉方法逐渐成为了目前的研究重点。

作为一种应用场景广泛的研究方向，计算机视觉包含了多种任务，如图像分类、目标检测和语义分割等。其中，图像分类将整张图像分类为一个特定标签，目标检测则定位图像中存在的物体并为其分配标签。语义分割与之前的两个任务不同，其目标对象是图像中的每一个像素，即为像素分配标签。这使其拥有更强的图像细节精度要求，需要根据目标像素区域的特性，如颜色、纹理和形状等，将相似的像素区域标注为同一标签，例如服装图像中的上衣和裤子。也正因如此，语义分割的效果将直接影响到后续图像下游任务的精度，如场景理解[1, 2]、医学图像分析[3, 4]、机器感知[5, 6]、视频监控[7, 8]、增强现实[9, 10]和图像压缩[11, 12]等。研究更加精准的语义分割方法成为了科研的一个重要目标。

传统的语义分割研究已经提出了多种算法，包括阈值法[13]、k 均值聚类法[14]、分水岭法[15]、活动轮廓法[16]、图割法[17]、马尔科夫随机场[18]和基于稀疏性的方法[18]等。然而，在过去几年里，随着深度学习技术飞速发展，基于深度学习模型的

语义分割方法逐渐成为主流，在不同方向上均达到了最高的准确率，这使研究的重心逐渐倒向了深度学习研究。当更适用于计算机视觉的卷积神经网络（Convolutional Neural Networks, CNNs）被提出时，基于 CNN 的语义分割方法立即成为了研究的核心，随着全卷积网络（Fully Convolutional Network, FCN）[19]、残差网络（Residual Network, ResNet）[20]和高分辨率网络（High-Resolution Network, HRNet）[21]等模型的提出，语义分割的准度也在飞速进步，逐渐达到了应用的标准。语义分割方法在具备巨大研究价值的同时，也拥有很大的研究空间。

由于语义分割的像素级目标要求，一个合格的语义分割方法应该具备以下能力：（1）将具有相同特征的连续像素区域划分为同一语义标签的能力；（2）区分相邻相似区域为不同语义标签的能力；（3）生成清晰正确的类别边界的能力。这些能力决定了该方法能够区分不同类别物体的特征，排除光线条件、遮挡环境和拍摄角度等因素的影响，理解类别划分的本质要求。根据这些需求，语义分割涌现出了许多相关的研究，来提高深度学习网络对图像中局部和全局信息的利用情况。

尽管语义分割领域具备良好的研究前景，但其固有的特性决定其仍有许多问题亟待解决。研究人员正在努力从各种角度优化语义分割方法，从而得到更加精确的分割结果，提高方法应用的实际表现。综上所述，语义分割任务依然存在改良的空间，具备极大的研究价值，对于生产和生活的智能化具有重要意义。

1.2 国内外研究现状

近年来，随着研究的不断深入，语义分割领域出现了大量效果显著的方法。总体而言，语义分割方法根据原理可以分为两种类型，分别是基于传统方法的语义分割技术和基于深度学习方法的语义分割技术。下面将对这两种技术路线进行详细介绍。

1.2.1 基于传统方法的语义分割技术

早期的传统语义分割方法大多根据图像的特征，如灰度、纹理、空间信息等，

使用阈值、直方图、分水岭等统计方法进行语义区域的划分，这类方法通常是无监督的。

阈值分割法是一类简单而实用的语义分割方法。它将图像中的像素灰度值通过统计方法进行划分，用灰度信息来区分不同的语义标签，然后将像素的灰度值与各阈值进行比较并分类。Ostu[13]首先提出使用灰度直方图的零阶和一阶累积矩来找到最优边界，这成为了阈值分割法的经典方法。范九伦等人[22]提出了在二维灰度直方图上基于二维混合正态分布假设的最小误差阈值法及其快速算法。Sahoo 等人[23]提出通过搜索阈值来实现分割，使得目标与背景的熵之和最大。Wei 等人[24]提出通过选择多方向的分割阈值，在一个方向上进行阈值分割，然后将各个方向的分割结果融合得到最终结果，相比之前的三种方法有效解决了虚假分割的问题，且具备较快的速度。阈值分割法拥有简单的原理，只需要根据信息选择出阈值即可进行分割，但这种方法只考虑到了统计信息，缺少对图像结构的理解，分割质量难以提高。

基于边缘检测的方法也是一种直观的方式。在简单的图像中，不同语义区域之间必然地存在容易分割的边缘，并能以此作为区域划分的依据，这引出了许多边缘相关的算法。最基本的方法是使用一些边缘检测算子，通过像素值变化来寻找图像中物体的边界[25]。Najman 等人[15]提出将分水岭算法应用于二维连续图像，为梯度的极小值赋予一个影响区域，将分水岭定义为影响区域的边界，从而得到分割的边界。Couprie 等人[26]对分水岭算法进行了改进，加入了图切割、随机游走和最短路优化算法，来引入适用于分水岭的最优生成森林算法，进一步拓展了适用范围。边缘检测方法具备精细的分割边界，但无法应对复杂场景的图像环境。

基于聚类的方法，尤其是基于 K-Means 聚类算法的方法同样是一种有效的技术路线。K-Means 聚类算法是一种无监督算法，其将像素看作数据点，并根据像素的特征如 RGB 值和坐标等进行聚类，归为 K 个不同的组，每个组对应图像中的一个语义区域。Mignotte[27]使用了一种简单的基于颜色空间的聚类方法，用类标签的局部直方图作为特征，来预估初始的聚类中心，证明了应用 K-Means 聚类方法来实现语义分割的有效性。Dhanachandra 等人[14]提出用减法聚类算法来生成聚

类的中心，用其来进行 K-Means 算法，并通过中值滤波来去除图像中的多余区域，成为了用 K-Means 聚类算法进行语义分割的一种标准过程。聚类方法十分依赖特征空间，聚类中心的选择决定了分割的质量，这极大地影响了语义分割的稳定性和效果。

基于图割的方法是一种以能量最小化为核心的方法，其将语义分割任务与无向图的最小割任务相结合，并通过计算最大流来得到最小的能量函数值的情况。通过对无向图的分割，图割法既能做到对像素区域整体的划分，又能实现对像素所属类别的分类，是解决像素级视觉问题的又一强大工具。Boykov 等人[17]针对具有各种不连续性光滑约束的能量函数的 NP 难问题，提出了两种用于寻找局部最小值的状态移动方法，然而这种方法受噪声的影响较大，缺乏稳定性。Rother 等人[28]提出的 GrabCut 改进了边界的生成算法，提出一种迭代图割方法来简化交互，一定程度降低了噪声的影响，但只能适用于中等复杂度的用例。基于图割的方法拥有简单且有效的算法基础，但无向图的性质决定了其较大的复杂度，难以处理较多类标签的任务。

基于传统方法的语义分割技术拥有很长的研究历史和丰富的技术路线，但难以处理复杂的图像，大多集中于前后景分割的程度，缺乏实际应用场景。随着深度学习方法被提出，基于传统方法的语义分割技术逐渐被舍弃，拥有更高精度和效率的深度学习方法称为了研究的首选。

1.2.2 基于深度学习方法的语义分割技术

基于传统机器学习的语义分割方法很大程度上依赖于特征的选择，只有针对特定特征进行对应操作才能得到较高的准确率。然而，现实图像拥有的丰富特征使方法无法面面俱到地利用现有信息，这限制了传统方法的性能。同时，传统方法需要人工精细地调整算法初始化和数据预处理等，这会耗费大量的时间。因此，传统的机器学习方法无法满足当下现实图像任务的复杂需求。随着深度学习的发展，越来越多的语义分割任务选择使用神经网络来进行特征学习。人们只需要机械化地设计监督数据，就可以使用泛用的模型，自适应地学习数据内部的联系，

这极大地简化了图像任务的流程。同时，由于目前图形处理器等物理硬件方面的进步，工业界推出了诸多适应深度学习方法的物理架构，来提高算法的效率，这也极大地促进了基于深度学习的语义分割方法的发展。深度学习模型会使用样本进行有监督的训练，从样本中学习到数据的特征，从而应对没见过的数据。这种方法结合了脑科学的思想，将输入到输出的过程转化为神经元的信号传输，让模型具备人脑的分析能力，从而得到高效精确的结果。目前，深度学习方法已经在各领域广泛应用，成为了研究的主流方向。

在早期的研究[29]中，卷积以一种更适合二维图像数据的处理方式，代替了神经元式的线性层来进行特征的学习，从而产生了 CNN 的模型范式。作为里程碑式的模型，FCN[19]将神经网络的全连接层用反卷积替代，从而统一了神经网络的结构，实现了一个只有卷积层的模型。通过反卷积操作，FCN 将图像特征恢复到原图像大小，进行像素级别的预测，实现了语义分割。这种做法使研究人员意识到了用 CNN 进行语义分割的可行性，奠定了后续研究的基础。ResNet[20]是视觉深度学习发展的另一个历史节点，其提出了一种残差结构，来解决 CNN 在加深网络结构时遇到的退化问题。在这之后，各种模型从不同的角度强化语义分割的效果，计算机视觉领域发展迅速。

CNN 的研究方向众多，研究人员试图从不同方面来提高语义分割的效果。PSPNet[30]提出了金字塔型的多尺度结构，从不同大小的特征图中提取不同的信息并融合，来生成最终的结果。DeepLab 系列[31]探讨了用空洞卷积代替池化层来拓展感受野的可行性，并利用空洞卷积实现了下采样和金字塔池化的操作。SENet[32]提出了一种逐通道的注意力机制，为不同通道自适应地加权，来关注更重要的特征，成为了经典的通道注意力方法。DANet[33]则以相似的形式同时执行了空间和通道的注意力操作，以即插即用的方式提高了空间信息和特征信息的效果。随着 CNN 的发展，各种功能的模块逐渐完善，语义分割方法可以从需要的角度提高目标任务的性能。

目前，基于深度学习的语义分割方法已经达到了相当高的精度，在各领域得到了广泛应用。相对于传统方法而言，深度学习方法更符合需求，成为了目前研究

的重点。

1.3 研究目标及内容

语义分割的精度一定程度上决定了视觉应用的效果，在视觉下游任务中起决定性的作用。因此，本文的研究目标是用基于深度学习的方法进行语义分割的研究，针对深度学习模型在语义分割任务上面临的问题，提出相应的改进方案。

自然图像的一个重要特点是语义区域之间的复杂关系。其主要分为前后景物体间的关系和大小物体区域间的关系两类，这考验了模型精确划分出区域之间的边界分割精度的能力。目前的语义分割模型基本上是编码器-解码器结构，通过编码器提取图片中的特征，再用解码器恢复出原图尺寸的预测结果。然而，在特征经过解码器时，一定量的信息会在恢复过程中丢失，从而导致预测结果在区域边缘发生模糊现象。基于这一问题，本文提出了基于隐式神经表示的查询式解码器，通过从已知信息中查询得到预测结果而非恢复的方式来生成更精确的边缘，并结合多尺度融合的编码器结构来综合利用多尺度语义信息。更进一步地，为了使隐式神经表示更好地应用于语义分割中，本文提出了适用于语义分割任务的隐式神经表示解码范式，将输入分为特征信息和位置信息，并使用可变形融合（Deformable Fusion, DF）模块和位置编码（Position Encoding, PE）模块对两种信息进行增强，提高查询输出的效果。此外，为了提升复杂区域的分割效果和语义一致性，本文提出了预热状态空间模型，利用粗分割图得到类与特征间关系信息，来增强模型对特定上下文的关注。为了解决重复输入引发的信息偏好问题，本文设计了一种信息补偿模块，从原特征图中提取相应语义信息并融合至输出中，来缓解其他语义信息的丢失。

1.4 文章的组织结构

本文的内容安排如下：

第一章：绪论。首先阐述了语义分割任务的研究背景以及研究意义，接着对现

有的语义分割方法进行了介绍，包括传统的机器学习分割方法和最近的深度学习分割方法，并介绍了本文的研究目标和研究内容，最后对本文的组织结构进行了整理归纳。

第二章：深度学习与语义分割。主要回顾了计算机视觉任务中经典卷积神经网络的发展变迁，阐述了卷积神经网络的基本结构，并讨论了多尺度融合、隐式神经表示和状态空间模型等相关概念。

第三章：基于隐式神经表示的语义分割。主要介绍了一种使用隐式神经表示作为解码器的语义分割方法，首先阐述了适用于语义分割任务的隐式神经表示结构范式，梳理了该方法的算法流程，然后提出了可变形融合模块和小波位置编码模块进行信息增强，接着介绍了基于隐式神经表示的语义分割整体框架，最后详细介绍了实验的实施细节，通过对消融实验、对比实验和可视化结果进行分析，验证了基于隐式神经表示的语义分割方法的有效性。

第四章：基于预热状态空间模型的语义分割方法。为了提高复杂区域的分割效果和语义区域的一致性，提出了一种基于预热状态空间模型的语义分割方法。首先介绍了根据粗分割图生成类与特征间关系信息的流程，介绍了预热机制这一上下文聚合方法，并设计了信息补偿模块来缓解预热过程中重复输入导致的信息偏好，对局部语义信息和全局语义信息进行提取和补偿，接着介绍了基于预热状态空间模型的语义分割整体框架，最后通过消融实验、对比实验和可视化结果的分析，验证了基于预热状态空间模型的语义分割方法的有效性。

第五章：总结与展望。对本文的研究内容和成果进行了归纳总结，分析了本文提出的方法的优势以及不足，并对未来的工作方向提出了展望。

第二章　深度学习与语义分割

本章对计算机视觉任务中的经典卷积神经网络的发展变迁进行了回顾，对卷积神经网络的基本结构进行了介绍，并对多尺度融合、隐式神经表示和状态空间模型等相关概念进行了讨论。

2.1 卷积神经网络

2.1.1 卷积神经网络的发展变迁

作为目前最著名的深度学习结构之一，神经网络的灵感来源于生物的自然视觉感受机制[34]。20 世纪 60 年代，Hubel 和 Wiesel 对猫的视觉系统进行了广泛的研究，并发现动物的视觉皮层负责接收区光线的检测[35]。受这一发现的启发，Fukushima 在 1980 年提出了 Neocognitron[36]，它被看做是 CNN 的前身。1990 年，LeCun 等人在手写数字识别任务中发表了 CNN 框架的奠基论文反向传播网络[37]，并在后续对其进行了改良[29]。他们提出了一种名为 LeNet-5 的多层神经网络，其中包含卷积层、池化层和全连接层等基础结构，至此 CNN 已经初具雏形。同时，Zhang 等人[38]研究出了具有平移不变性的人工神经网络 SIANN 来识别图像中的字符。然而由于当时缺乏大规模的训练数据和强力的计算能力，他们的网络在复杂的问题上并没有很好的表现，如大规模的图像和视频分类问题。

随着近年来 GPU 性能和网络算法方面的不断发展，人们逐渐克服了训练 CNN 时遇到的各种困难。值得注意的是，Krizhevsky 等人[39]提出了一种经典的 CNN 架构 AlexNet，在图像分类任务中相比以前的方法具有明显的改进，并在当年的 ImageNet 竞赛中取得优胜。他们的 AlexNet 与 LeNet-5 类似，但具备更深的结构。随着 AlexNet 的成功，越来越多的基于 CNN 的研究被提出，网络的深度也逐渐加深，一系列经典网络模型逐渐出现，例如 ZFNet[40]、VGGNet[41]、GoogLeNet[42]和 ResNet[20]等。

尽管目前关于 CNN 架构存在许多不同的变种，但他们核心的组成部分都是

类似的，包括卷积层和池化层等关键组件。卷积层的目的是学习输入的特征表示，每个卷积层基本都由几个卷积核组成。通过用学习后的卷积核对输入的特征图进行卷积，然后再应用激活函数，对输入和输出作函数映射，最终得到新一层的特征图。池化是 CNN 中的另一种重要概念，它通过减少卷积层之间的连接数来降低计算负担，并尽可能维持输入特征图的特征不变。为了综合前面提取的所有特征，在网络的最后将使用全连接层或 1×1 卷积层连接前一层的每个特征图，从而产生全局的语义信息。 通过逐层的计算操作，CNN 一步步地将图像中的深层语义信息抽离出来，从而作出精准的预测。

2.1.2 卷积神经网络的基本结构

CNN 的基本结构包括卷积层、池化层、激活函数和损失函数。一个完整的 CNN 在输入后将经过数轮的卷积层和池化层来得到输出，并在卷积层之间使用激活函数进行输入到输出的映射，在这个过程中通过损失函数来监督网络，据此来更新网络内的参数。

（1） 卷积层

卷积层是 CNN 中最重要的组成部分，其负责学习提取输入的特征。图 2-1 所示为一个步长（stride）为 1，无填充（padding），尺寸（kernel size）为 3×3 的卷积核的卷积过程，卷积核将从输入矩阵的左上角开始逐行扫描，每次移动 1 列，直至完成全部运算后结束。在卷积核移动的过程中，卷积核内的每个值都会与输入矩阵中相覆盖的值逐个相乘并求和，最终获得当前位置的输出值。在这些参数中，步长决定了卷积核在输入矩阵上每次移动的步幅，尺寸决定了每次卷积核提取的输入图像范围。然而，由于卷积核自身尺寸的原因，导致边缘输入值无法像内部输入值一样被充分提取特征，又或是希望输入和输出的尺寸保持一致，因此会对输入的边缘进行填充，通常采用 0 值填充，另外还有边缘复制等方式。

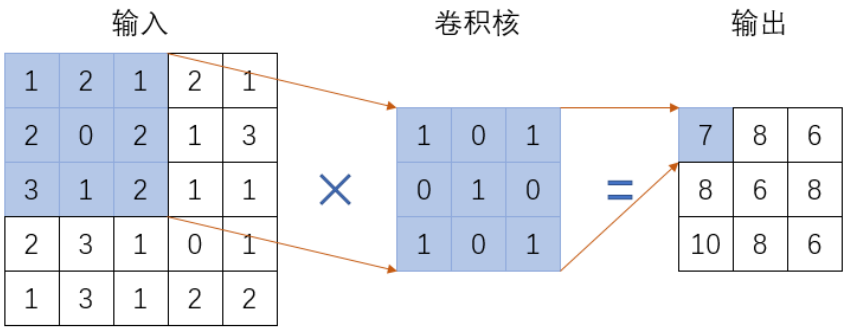

图 2-1 常规卷积的计算过程

Fig 2-1 The computational procedure for regular convolution

随着卷积的进一步研究，许多新型的卷积被运用在了各项任务上。作为上采样的一种可行方式，转置卷积（Transposed Convolution）[40]采用非插值的方式，将上采样过程以网络学习的方式完成，其同常规卷积一样，具有可学习的参数。图 2-2 模拟了一个 3×3 转置卷积的计算思路，其希望与常规卷积相反，建立一个一对多的映射关系，视觉上就像一个反向的卷积过程。然而尽管被称作转置卷积，但其并非通过输入矩阵和卷积核计算输出卷积，而是通过填零扩大输入矩阵，再执行常规卷积的方式来获得上采样结果，因此图 2-2 并不能称为转置卷积的实际计算过程。由于转置卷积同样采用常规卷积，因此也具备对应的步长和填充等参数。另一方面，转置卷积会导致图像中出现棋盘效应等问题，因此也有越来越多的研究针对其进行了改良。

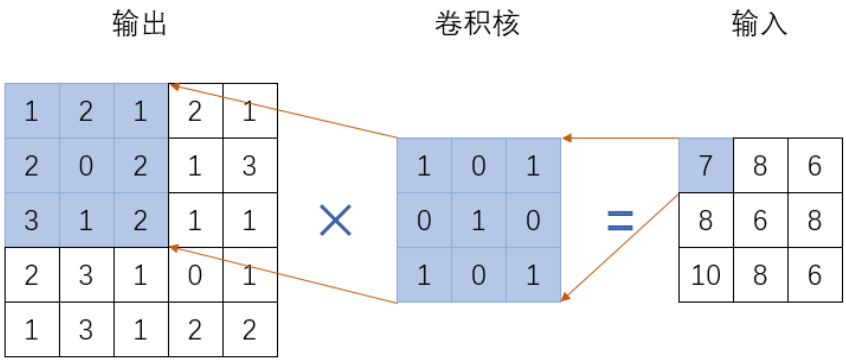

图 2-2 转置卷积的模拟计算过程

Fig 2-2 The simulation of the computational procedure of transposed convolution

感受野是 CNN 中的一个重要概念，其指网络每一层输出的特征图上的像素点在原图上映射的区域大小，目前扩大感受野的一种重要方式就是使用空洞卷积（Dilated Convolution）[43]。图 2-3 展示了一个扩张率为 2，即卷积核中间存在间隙为 1 的空洞的空洞卷积案例。空洞卷积采用扩张的卷积核来在扩大感受野的同时不损失信息，同时还能捕获多尺度上下文信息，是一种简洁而有效的方法。另一方面，空洞卷积能用较小的参数量来实现较大卷积核的感受野效果，在分割效果与资源消耗之间选择了一种折中的路线，减轻了计算负担和资源消耗。然而空洞卷积由于其较大的尺寸和空洞的存在，也拥有例如信息相关性丢失、分割小物体效果差的问题，因此后续同样研究出了多种改良方法。

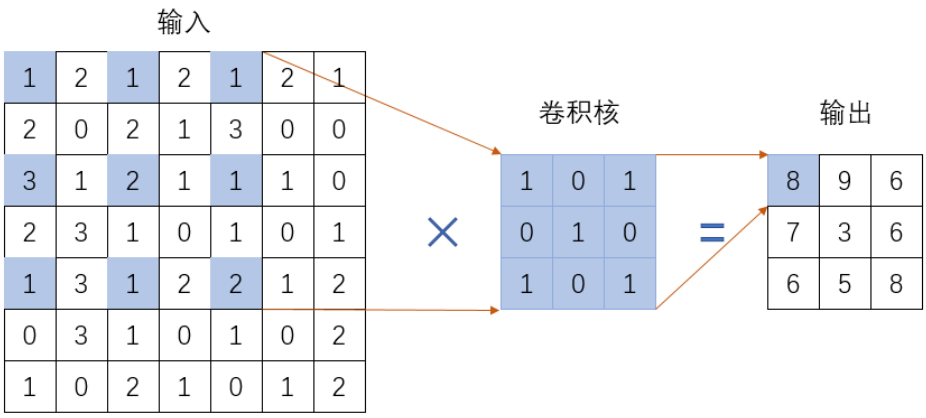

图 2-3 空洞卷积的计算过程

Fig 2-3 The computational procedure for regular convolution

在研究中发现，标准卷积固定的卷积核限制了卷积层对几何形变的提取能力，为了解决这个问题，可变形卷积[44]被提出用于替代标准卷积来实现几何形变特征提取。如图 2-4 所示，可变形卷积将在当前的输入特征图中学习一组代表几何形变的偏移量。在卷积过程中，可变形卷积核会对偏移后的浮点数坐标进行双线性插值后得到的坐标进行卷积运算，从而得到输出结果。这种方式能够有效地增强尺度不变性，提升网络的性能且不会过多增加网络的参数负担。

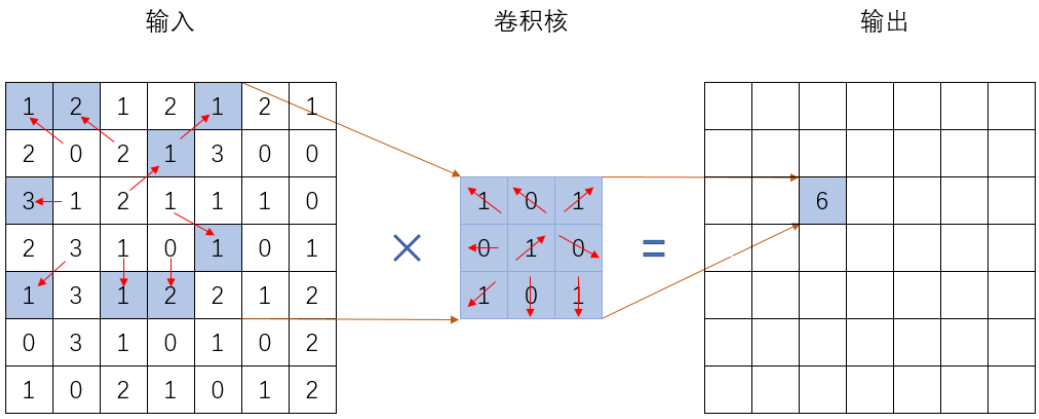

图 2-4 可变形卷积的计算过程

Fig 2-4 The computational procedure for deformable convolution

（2） 池化层

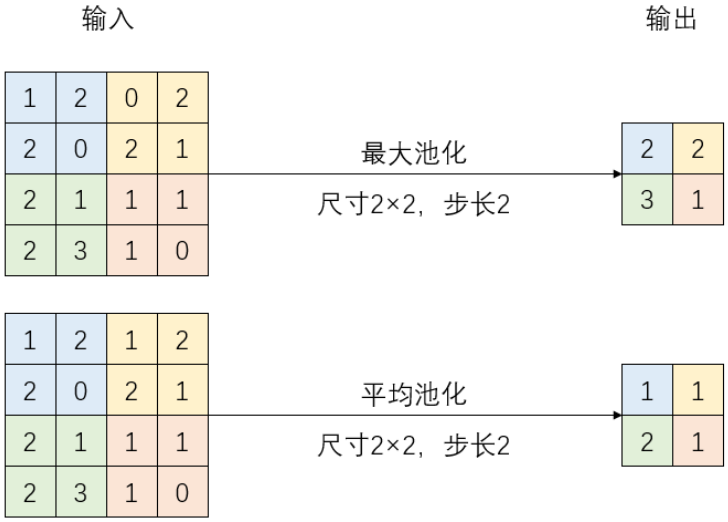

图 2-5 最大池化和平均池化的计算过程

Fig 2-5 The computational procedure for maximum pooling and average pooling

池化层是 CNN 的另一个重要组成部分，它本质上是一种下采样操作。池化层的作用是降低特征图的分辨率，从而减少计算量和参数数量，并实现一定的尺度不变性和空间不变性。根据任务目标的不同，选取的池化层也会不同，但通常都会被置于两个卷积层之间，用于不同卷积阶段间的分辨率调整。常用的池化层有

最大池化、平均池化等，此外还有混合池化[45]、随机池化[46]、空间金字塔池化[47]等优化池化层。以最大池化和平均池化为例，图 2-5 展示了最常用的 2×2 池化层的计算过程。池化层通常具有和卷积层相似的参数和执行逻辑，即以与卷积核相似的形式完成逐行的扫描，且同样具备尺寸和步长等参数，来控制池化操作时的各条件。最大池化将在一个固定的区域中取最大值，而平均池化则取平均值，这使他们输出的结果具备不同的侧重点和特征。不同的池化层将带来不同的效果，因此选择合适的池化层对于卷积神经网络来说十分重要。

混合池化受到 Dropout 层的启发，用随机的池化选择过程替代了固定的池化操作，从而增强了网络的泛化能力，且带来的额外计算开销可忽略不计。如图 2-6 所示，在模型训练过程中，混合池化将随机采用最大池化和平均池化的方法来完成池化工作。这种方式使模型能够同时考虑到不同侧重的特征，但生成效果也会受随机值影响，无法保证效果。

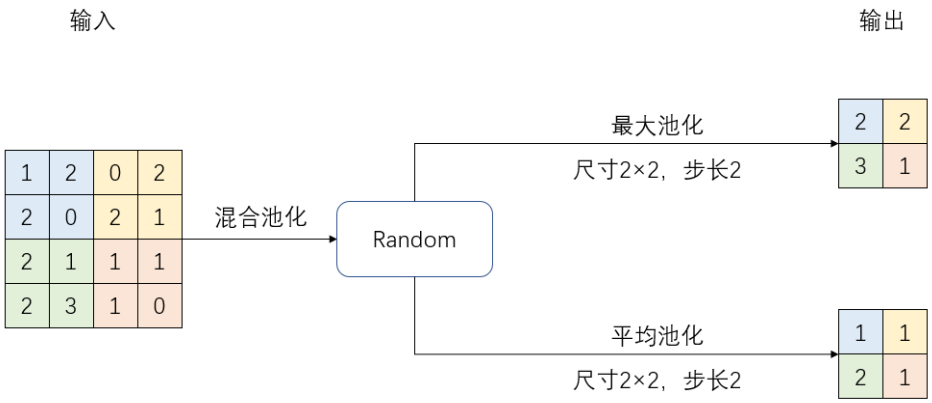

图 2-6 混合池化的计算过程

Fig 2-6 The computational procedure for mixed pooling

随机池化同样是一种受到 Dropout 启发的池化层。随机池化与最大池化相似，差别在于随机池化不像最大池化一样在每一个区域中选取区域的最大值，而是根据每一个元素值的大小作为选取的概率来选取当前区域的池化结果值。如图 2-7 所示，随机池化会将区域中的元素除以该区域的总和，从而得到概率矩阵，再根

据概率随机选中元素，以该元素的原值作为池化的结果。这种方式既使较大值的元素更可能被选中，又保证了每个元素都有被选中的可能，保证了池化的泛化能力。

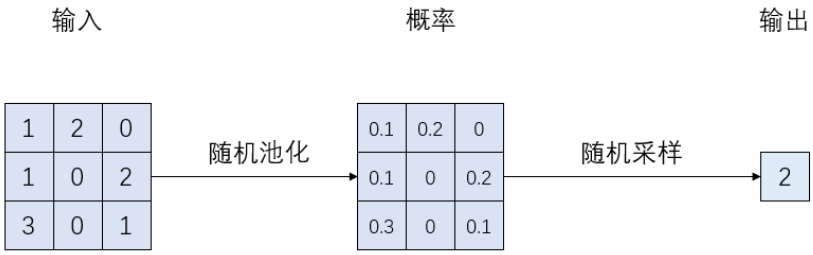

图 2-7 随机池化的计算过程

Fig 2-7 The computational procedure for stochastic pooling

空间金字塔池化旨在为全连接层生成一个固定长度的表征，而不需要通过裁剪和缩放来固定输入尺寸，防止输入图像的扭曲。如图 2-8 所示，空间金字塔池化能通过对特征图进行不同尺度的池化，将输入的特征图汇集到与特征图大小成比例的局部块内，从而产生固定数量的局部块，即全连接层所需要维度的特征向量。采用空间金字塔池化既能避免裁剪和缩放带来的弊端，又能提取不同尺度的空间特征细节信息，提高尺度不变性和防止过拟合。

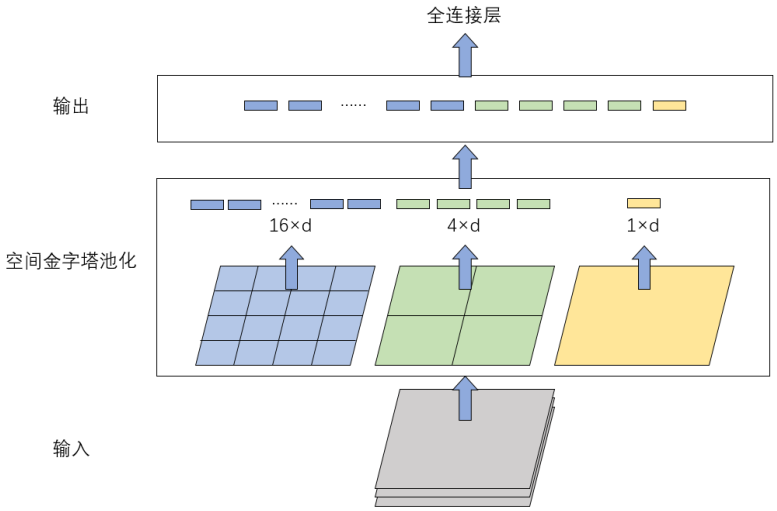

图 2-8 空间金字塔池化的计算过程

Fig 2-8 The computational procedure for spatial pyramid pooling

（3） 激活函数

激活函数使用于神经网络的两层神经元之间，将上层的输出通过某种函数关系转换为下层的输入，这对网络学习非线性特征具有至关重要的作用，适当的激活函数可以显著提高 CNN 对某项任务的性能。

Sigmoid 函数是一种常见的激活函数，它的数学定义如下：

$$Sigmoid(x) = \frac{1}{1 + e^{-x}} \tag{2-1}$$

Sigmoid 函数能把输入的连续值转化为 0 到 1 之间的输出，并且当输入偏小或偏大时，输出将无限接近 0 或 1，即导数将接近 0，函数图像见图 2-9。Sigmoid 函数的特征使其可能导致梯度消失、非 0 均值等问题，因此后续针对这些问题提出了许多改良函数。

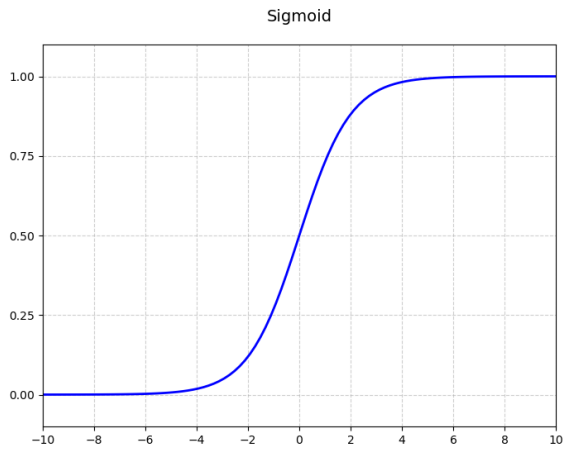

图 2-9 Sigmoid 激活函数的图像

Fig 2-9 The graph of Sigmoid activation function

Tanh 函数是对 Sigmoid 函数的改良，它的数学定义如下：

$$Tanh(x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}} \tag{2-2}$$

Tanh 函数相对于 Sigmoid 函数，最大的差别在于其值域从 0 到 1 变为了-1 到 1，其他性质基本没有变化，函数图像见图 2-10。这一改动解决了 Sigmoid 的非 0 均值问题，提高了收敛速度，然而其他问题仍然没有得到解决。

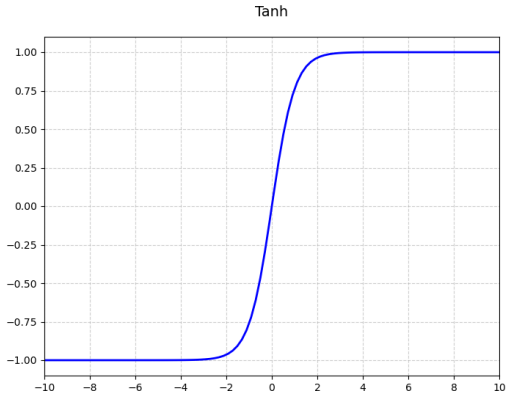

图 2-10 Tanh 激活函数的图像
Fig 2-10 The graph of Tanh activation function

ReLU 函数是一种分段线性函数，它的数学定义如下：

$$ReLU(x) = \max(0, x) \tag{2-3}$$

ReLU 函数采用了简单的最大值操作，在负数部分输出为 0，整数部分则保持输入不变，这使得它的计算速度和收敛速度远远快于 Sigmoid 函数或 Tanh 函数，函数图像见图 2-11。同时，ReLU 函数还有使网络更容易获得稀疏特征，解决梯度消失问题等优点。虽然其仍存在 0 点处不连续以及非 0 均值等问题，但这仍掩盖不了 ReLU 函数的优秀效果。针对这些问题，也存在包括 Leaky ReLU[48]、Parametric ReLU[49]和 ELU[50]在内的多种改良 ReLU 函数对其进行优化。

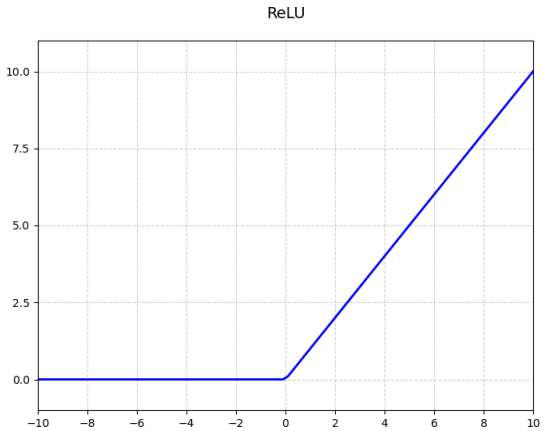

图 2-11 ReLU 激活函数的图像
Fig 2-11 The graph of ReLU activation function

Softmax 函数是在多分类问题中常见的激活函数，它的数学定义如下：

$$Softmax(x_i) = \frac{e^{x_i}}{\sum_{k=1}^{n} e^{x_k}} \tag{2-4}$$

其中n为多分类问题的类别总数，该函数将得到像素属于第i类的概率。Softmax 函数是一种应用于神经网络最后一层的激活函数，其目的是通过归一化，将多分类的输出值转换为在(0,1)区间且总和为 1 的概率分布，从而应用于分类问题的预测概率中。指数操作对于将输入数值的差距进一步扩大有很大的好处，也有利于在进行反向传播的参数更新时的导数计算。

（4） 损失函数

损失函数是对网络模型评估出的预测值和真实值之间差距的一种量化指标，其代表了网络相对于正确完成任务目标的差距。通常情况下，研究希望调整网络参数后能实现损失函数值的减小，从而使网络更接近期望。尽管损失函数能够评估网络的精度，使网络向最优化的方向调整，但不同的损失函数其关注的重点和效果也不同，因此选择适用于当前任务的损失函数十分重要。

均方误差（Mean Squared Error, MSE）函数是一种计算真实值与预测值之间差的平方的绝对值的损失函数，它的数学定义如下：

$$MSE\big(y, f(x)\big) = \frac{1}{m}\sum_{i=1}^{n}\big(y_i - f(x_i)\big)^2 \tag{2-5}$$

其中y为真实值，$f(x)$为预测值，n为样本总数。MSE 函数有较好的性质，有利于梯度下降法的收敛。但同时由于平方计算的性质，其受离群的极大极小点的影响较大。

交叉熵（Cross Entropy, CE）函数是从信息论中引入的概念，其衡量的是两个概率分布之间的差异，它的数学定义如下：

$$CE\big(y, f(x)\big) = -\sum_{i=1}^{n} y_i \log f(x_i) \tag{2-6}$$

其中y为真实值，$f(x)$为预测值，n为样本总数。交叉熵衡量了真实概率分布和预测概率分布之间的差异，并且交叉熵的值越小，说明预测概率分布越接近真实概率分布，也就说明了模型效果越好。在实际应用于服装图像分割这类多分类

问题时，交叉熵损失函数常与 Softmax 函数组合使用。

2.2 多尺度融合结构

像素级图像任务具备丰富的多尺度信息，不同语义区域拥有不同尺度的特征，这使得能够融合多尺度信息的技术至关重要。经过广泛的研究，目前的多尺度融合结构已经发展出了许多实用的方法，主要可分为并行多分支的多尺度融合、金字塔结构的多尺度融合和级联结构的多尺度融合三种方向。接下来将对这三种研究思路进行详细介绍。

2.2.1 并行多分支的多尺度融合

并行多分支结构是最常见的一种多尺度融合结构，其期望从特征图中使用不同感受野的子分支，来提取不同尺度的特征信息。典型的结构是 GoogLeNet[42]中的 Inception 模块，如图 2-12 所示，其将前一层得到的特征图并行用 1×1 卷积层、3×3 卷积层、5×5 卷积层和 3×3 池化层进行处理，来得到不同尺度的信息并将其融合。这种即插即用模块的效果很快得到了研究者们的认可，并衍生出了更多使用空洞卷积和其他池化来控制感受野的方法，成为了用并行多分支结构进行多尺度融合的标准做法。

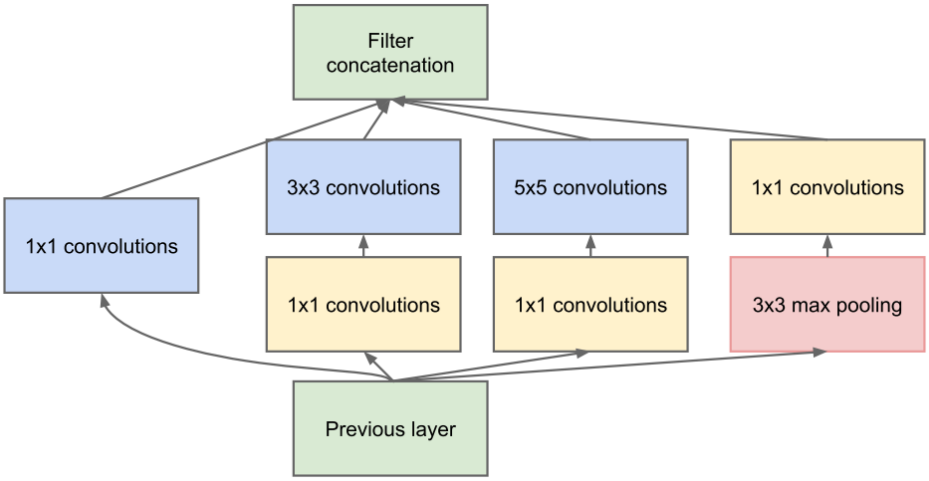

图 2-12 Inception 模块（来源于文献[42]）
Fig 2-12 Inception module (Origin from reference[42])

PSPNet[30]提出利用不同大小的池化层和卷积操作来生成不同尺度的特征信息，并通过上采样恢复出原大小的特征图并合并，得到综合多尺度信息的特征图，如图 2-13 所示。这种操作与 Inception 模块思路相近，通过不同核尺寸的池化或卷积来并行生成不同尺度的特征图，并融合得到多尺度融合结果。

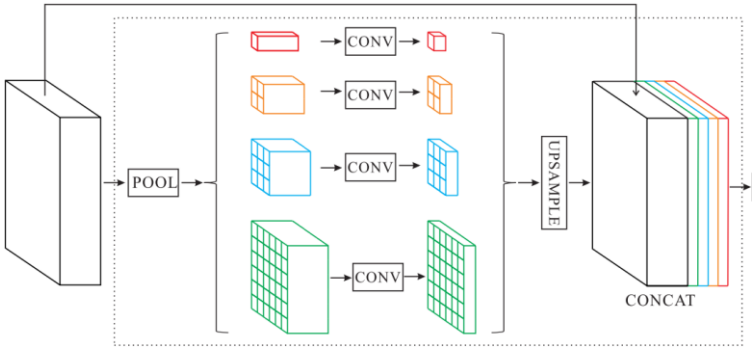

图 2-13 PSPNet 的金字塔池化模块（来源于文献[30]）
Fig 2-13 Pyramid pooling module of PSPNet (Origin from reference[30])

DeepLabv3+[51]中提出了一种基于空洞卷积的空间金字塔池化模块，如图 2-14 所示。正如之前的并行多分支结构一样，该模块使用一个 1×1 卷积、三个不同扩张率的空洞卷积以及一个全局池化进行五分支的多尺度提取，并进行拼接和融合。可以看到，基于并行多分支的多尺度融合结构使用不同分支来提取不同尺度的特征图，并对其进行融合，来获得更强的信息。这种做法拥有即插即用的优秀特性，能够轻松完成多尺度融合，但效果十分依赖输入特征图的质量，且大多模块从深层语义信息中提取特征，信息不够全面。

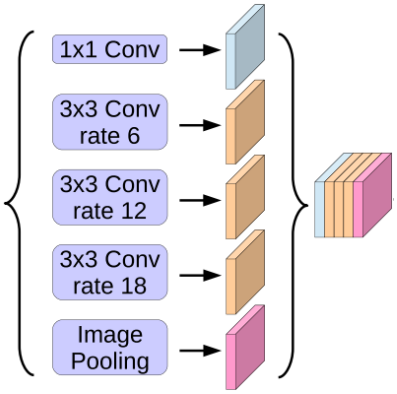

图 2-14 空洞空间金字塔池化模块（来源于文献[51]）
Fig 2-14 Atrous spatial pyramid pooling module (Origin from reference[51])

2.2.2 金字塔结构的多尺度融合

金字塔结构网络会构建一个特征图尺寸逐层递减的金字塔型结构，不同尺寸的特征图拥有不同尺度的信息，并在层间进行多尺度的融合。如图 15 所示，FPN[52]是最为经典的特征金字塔网络，其逐层生成特征和下采样得到不同尺度结果，并通过跳跃连接进行融合，提出了一种简单的金字塔结构多尺度融合范式。

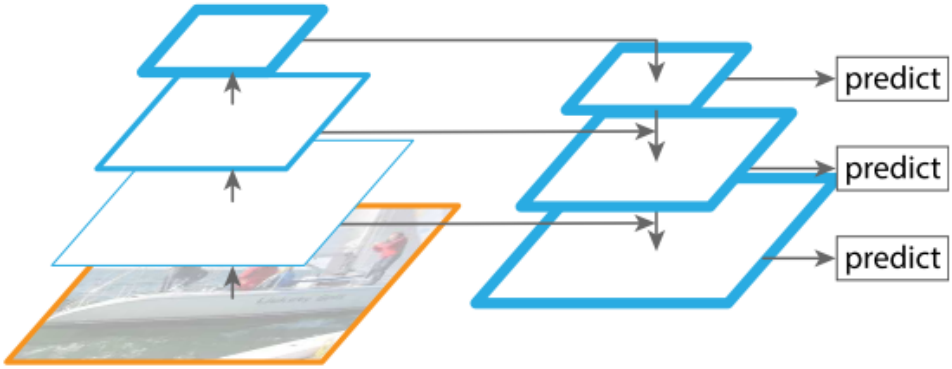

图 2-15 特征金字塔网络（来源于文献[52]）
Fig 2-15 Feature pyramid network (Origin from reference[52])

PANet[53]采用了路径聚合的方式，通过自下而上的路径增强来用底层信息增强整个特征层次结构，如图 2-16 所示。这种方式直接地弥补了原始 FPN 的不足，即底层和顶层特征图之间信息交流的欠缺，缩短了底层和顶层间的路径，更好地促进了多尺度信息的融合。这种做法使其在各任务中都表现出色，证明了特征金字塔研究方向的正确性。

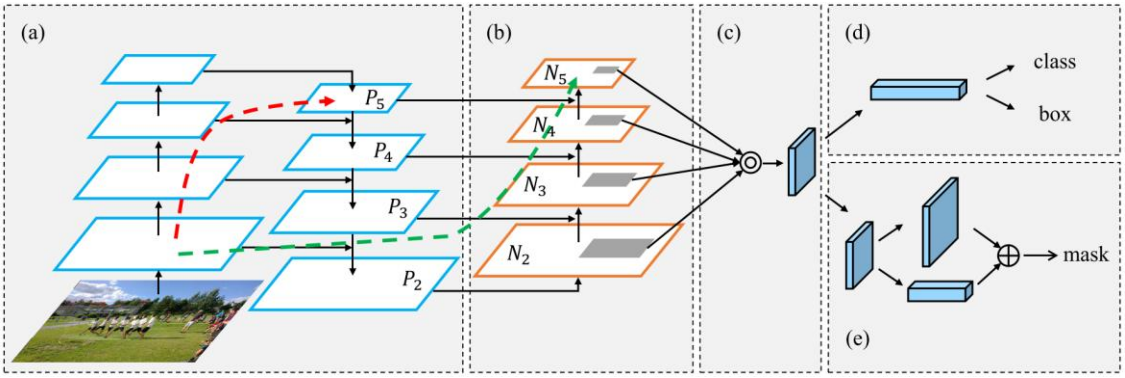

图 2-16 路径增强网络（来源于文献[53]）
Fig 2-16 Feature pyramid network (Origin from reference[53])

PAN[54]提出了使用两阶段的特征金字塔增强模块和三次跳跃连接的结构，如图 2-17 所示。他们使用的特征金字塔增强模块分为镜像的升尺度增强和降尺度增强两部分，这种对称的结构有利于跳跃连接时的对应拼接和特征融合。金字塔结构是一种直观的多尺度融合方法，其在特征学习阶段就生成了不同尺度的特征信息，这使得多尺度信息可以在信息传递过程中直接完成融合，在像素级任务中应用广泛。

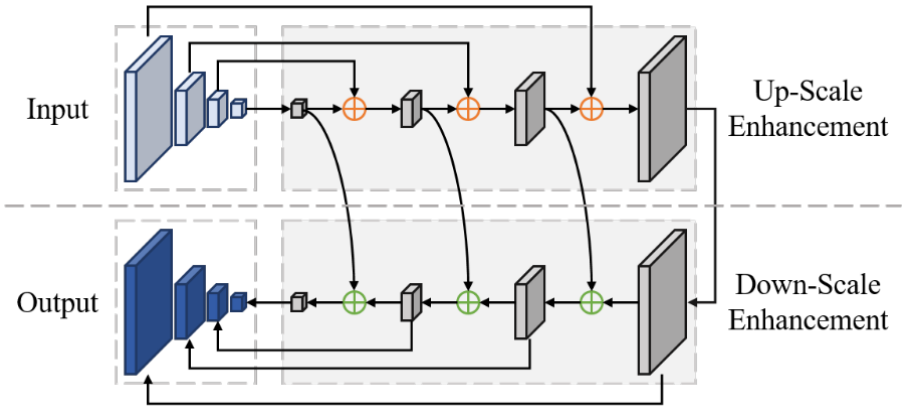

图 2-17 PAN 的特征金字塔增强模块（来源于文献[54]）
Fig 2-17 Feature pyramid enhance module of PAN (Origin from reference[54])

2.2.3 级联结构的多尺度融合

HRNet[21]使用了一种特殊的级联结构来实现多尺度融合，如图 2-18 所示。与之前大多数网络的低分辨率特征学习和高分辨率特征恢复的思路不同，HRNet 全程维持着高分辨率的特征，在每一阶段对全部尺度的特征进行融合交流并生成新一级分辨率的特征。这种方式使低级和高级的语义特征全程高度融合，拥有很强的语义一致性，并且网络可以重复从高分辨率特征中学习并改善参数，保证了特征的充分性。

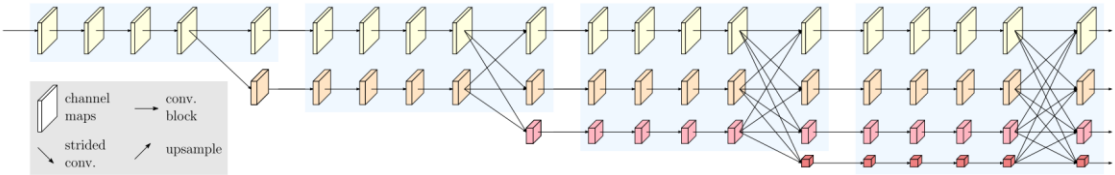

图 2-18 HRNet 结构（来源于文献[21]）
Fig 2-18 Structure of HRNet (Origin from reference[21])

HRNet 为语义分割的主干网络设计提供了一种新的思路，其区别于普遍的对称型金字塔编码器-解码器结构，采用了重型编码器加轻型解码器的高分辨率维持结构，这使其拥有了极强的特征提取能力。并且，由于特征融合操作的存在，HRNet 在每阶段每层常规卷积完成后对所有特征进行一次交流，用低分辨率特征图来提高高分辨率特征图的效果，用高分辨率特征图来丰富低分辨率特征图的表征表示，相当于完成对并行卷积的一次整理和归纳，最终使得网络对结果的预测更加精确，拥有很强的语义分割潜力。

HRFormer[55]将级联结构的多尺度融合与 Transformer 结构进行了结合，如图 2-19 所示。HRFormer 拥有和 HRNet 相似的结构，它在第一阶段保持卷积，并在其他阶段内部采用局部窗口自注意力机制来进行特征提取。为了在断开的局部窗口之间交换信息，在自注意力机制的前馈网络中添加了 3×3 深度卷积。通过使用并行的中低分辨率流来维护整个过程中的高分辨率流，高分辨率特征得到了显著的提高，并能够对多尺度变化进行建模，证明了级联结构的泛用性。

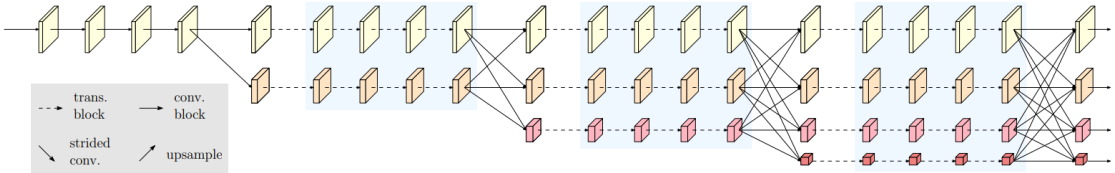

图 2-19 HRFormer 结构（来源于文献[55]）
Fig 2-19 Structure of HRFormer (Origin from reference[55])

2.3 隐式神经表示

隐式神经表示在三维重建任务中应用广泛，其对应一种将信息映射为目标的基于坐标的连续函数，并通过神经网络来实现这种映射。以符号距离函数（Signed Distance Function, SDF）为例，研究者在三维重建时将空间中的三维坐标映射为该坐标到物体表面的距离，来得到坐标相对于重建物体的内外关系，从而完成空间上连续的映射。通过连续映射的学习，网络能够拟合空间中任意一点坐标的值，就像一种隐式的插值操作，这使其非常适合连续生成的任务。

由于宽松的函数定义和直观的输出，隐式神经表示在三维任务中衍生出了各

种各样的实现形式。DeepSDF[56]使用 SDF 的形式，将自解码器和潜向量的概念和 SDF 的生成相结合，来从数据坐标的潜向量中生成 SDF 的估计，如图 2-20 所示。这种做法拥有很强的可解释性，因此得到了研究者的广泛关注。SAL[57]引入了符号不可知的方法，从原始无符号的几何数据里学习隐式的形状表示，来解决非定向点云表面重建的问题，取得了巨大的进展。然而，SDF 仅能表示坐标到重建物体表面的距离，这影响了重建细节的生成效果。

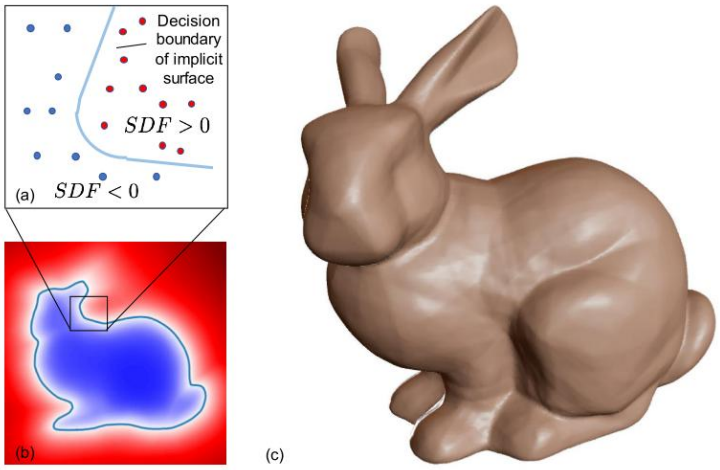

图 2-20 SDF 的示例图像（来源于文献[56]）
Fig 2-20 Example of SDF (Origin from reference[56])

通过空间的占用概率来描述三维物体是一种与体素法有诸多相似之处的方法。然而，基于隐式神经表示的方法使其与预测固定分辨率的体素化方法不同，其能够用一个神经网络在任意分辨率下求解占用函数，这使其具备了灵活的形式。Occupancy Network[58]首先提出了这种从各种输入形式，例如点云、图像或低分辨率体素，中推断出占用网络的方法，其隐式地将三维表面表示为深度神经网络分类器的连续决策边界，证明了隐式神经表示方法的可行性，如图 2-21 所示。IM-Net[59]提出了一种简洁的形式，并对隐式神经表示控制重建形状的插值过程进行了讨论，探索了更清晰的三维重建流程。

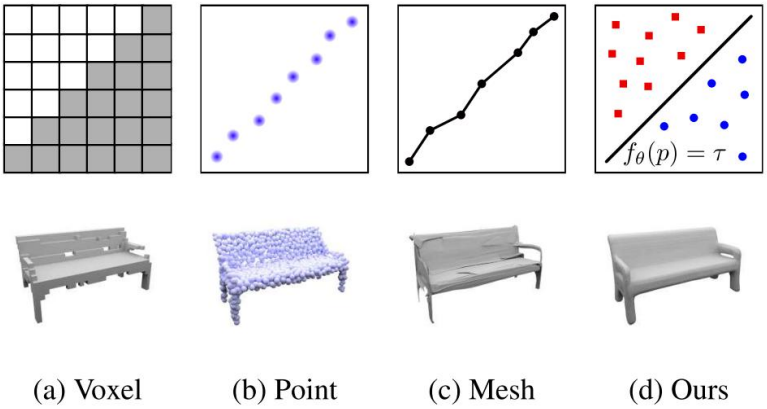

图 2-21 空间占用概率的示例图像（来源于文献[58]）
Fig 2-21 Example of occupancy probability (Origin from reference[58])

图 2-22 展示的神经辐射场（Neural Radiance Fields, NeRF）[60]则开创了一种新的三维重建流派，成为了近期备受关注的重建方法。其将输入坐标拓展为连续的五维坐标，包括三维空间位置和二维方向角，来得到经典的体渲染技术需要的参数。这种方式使三维重建能拥有比拟传统几何重建的效果，又不需要繁杂的处理流程，隐式地完成了三维模型搭建的过程。这种简单且高效的方法立即引起了研究人员对隐式神经表示方法的注意，并在后续推出了诸多研究。

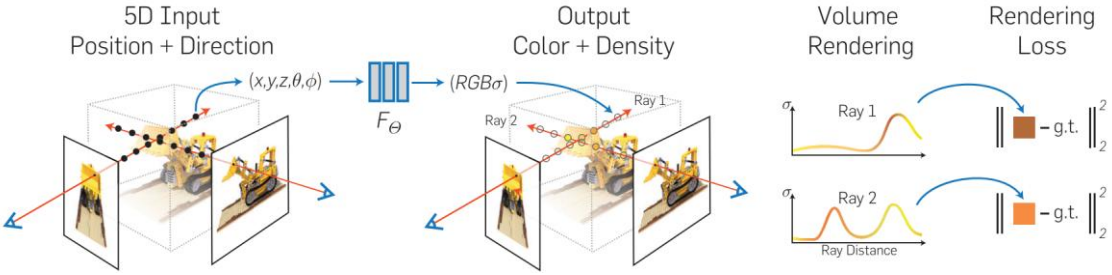

图 2-22 神经辐射场的示例图像（来源于文献[60]）
Fig 2-22 Example of NeRF (Origin from reference[60])

隐式神经表示在二维视觉任务中的应用前景仍在研究中，其基于坐标的连续形式被 LIIF[61]应用到了超分辨率图像生成任务中。图 2-23 展示了 LIIF 在超分辨率图像生成任务中的隐式神经表示流程。在数据准备阶段，它将高分辨率图像随机下采样为低分辨率图像，并逐像素采样高分辨率图像中的 RGB 值和坐标。在训

练阶段，LIIF 将低分辨率图像输入一个编码器得到特征，并通过隐式神经表示和高分辨率像素坐标来预测高分辨率结果，并用之前得到的 RGB 值进行监督，来学习从低分辨率特征拟合生成高分辨率图像的能力。

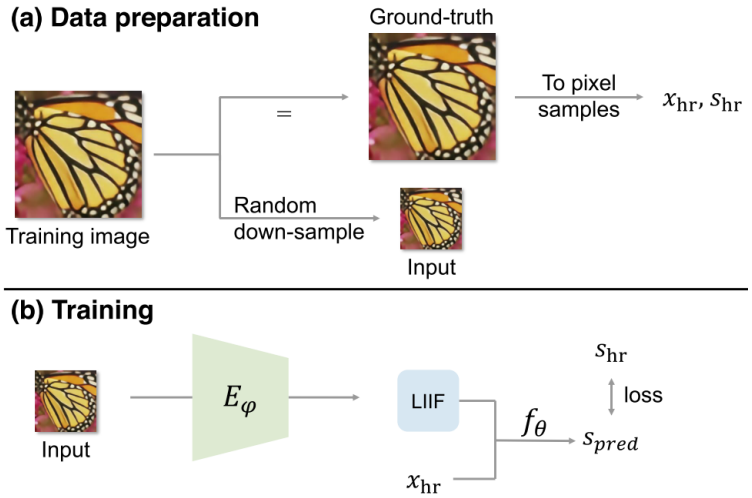

图 2-23 LIIF 结构（来源于文献[61]）
Fig 2-23 Structure of LIIF (Origin from reference[61])

由于应用场景相似，隐式神经表示方法顺利地在超分辨率任务中取得了较好的效果，并逐渐推广到了二维视觉任务中。IFA[62]将隐式神经表示的自由分辨率特性应用到了语义分割模型跳跃连接时的特征对齐，有效地用连续的形式生成了等分辨率的特征图。在此之前，PointRend[63]从点渲染的角度重新解读语义分割问题，以一种与隐式神经表示有近似思路的方法进行了预测。这些方法代表了隐式神经表示在视觉任务中的初步探索，但仍留有广阔的研究空间。

2.4 状态空间模型

在序列建模领域，传统的 Transformer 架构[64]因自注意力机制的二次复杂度$\mathcal{O}(N^2)$面临长序列处理的效率瓶颈。围绕这一点，研究人员展开了广泛的研究。2023 年提出的 Mamba 模型[65]通过结合状态空间模型（State Space Models, SSMs）与选择机制，实现了线性计算复杂度$\mathcal{O}(N)$下的高性能序列建模，为长上下文依赖问题提供了全新的解决方案。

状态空间模型源于经典的控制系统理论，对于状态h，输入x和输出y，其数学形式可表示为关于线性系统的状态空间表示方程：

$$\begin{aligned} h'(t) &= Ah(t) + Bx(t) \\ y(t) &= Ch'(t) + Dx(t) \end{aligned} \tag{2-7}$$

其中A为状态转移矩阵，B、C、D为投影参数。通过零阶保持的离散化（引入一个离散化参数Δ）后，SSM 可通过卷积形式高效处理离散序列。此时，状态空间模型可被解释为循环神经网络（Recurrent Neural Networks, RNNs）和 CNNs 的组合，可以非常有效地用递归形式或卷积形式完成计算。同时，一些早期的工作对这一思路进行了完善，例如 S4[66]通过 HiPPO 初始化策略优化参数矩阵，显著提升了模型对长距离依赖的捕捉能力。

Mamba 模型的核心创新在于引入选择机制，突破了传统 SSMs 的参数与输入无关的局限。通过动态生成与输入相关的B、C和Δ参数，模型具备了选择性，即上下文感知能力，可以将注意力集中于输入或者将输入过滤至状态。结合硬件算法对内存读写的加速，Mamba 模型形成了一个完善的基础模型体系，成为序列模型建模的又一奠基性工作，引发了后续的广泛研究。

VMamba[67]是将状态空间模型引入视觉任务的早期工作。如图 2-24 所示，它构建了一个金字塔型的堆叠结构，在每层的状态空间模块间添加了下采样，形成了尺寸逐层递减的框架。同时，根据视觉任务的特点，VMamba 对序列化过程中的扫描算法进行了改进，以四方向顺序进行序列化，成为了后续状态空间模型研究的范例。

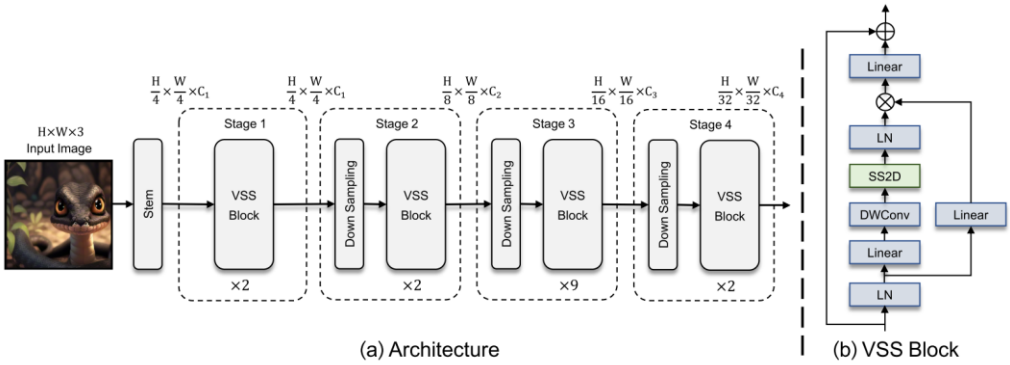

图 2-24 VMamba 模型的框架（来源于文献[67]）

Fig 2-24 Overall architecture of VMamba model (Origin from reference[67])

受到语义分割领域发展过程和 VMamba 模型的启发，Mamba-UNet[68]将 VMamba 的 VSS 模块堆叠为了 U 型结构，并使用了跳跃连接来提高不同层间语义信息的交互效果，如图 2-25 所示。此后，大量的研究围绕着状态空间模型的扫描机制和模型框架等方向进行，并在各种领域中展现出了出色的长距离依赖建模效果和无法忽视的研究潜力。该架构的提出标志着序列建模范式的方向转变，从基于注意力机制的全局交互逐渐转向基于状态空间的状态更新策略，同时也引发了对序列模型从状态空间模型角度的可解释性的持续关注。

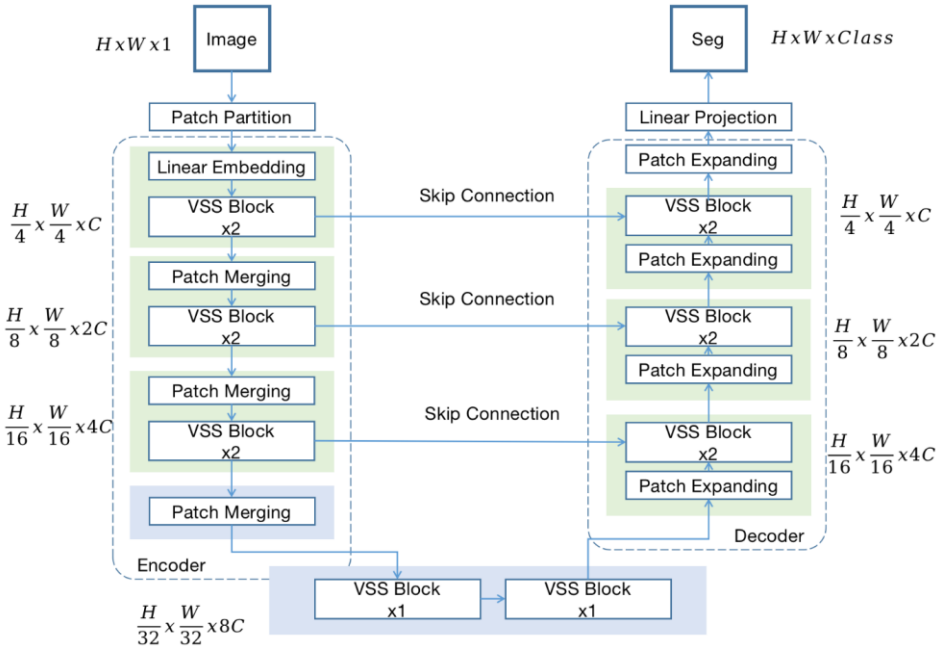

图 2-25 Mamba-UNet 模型的框架（来源于文献[68]）
Fig 2-25 Overall architecture of Mamba-UNet model (Origin from reference[67])

2.5 本章小结

本章主要研究了深度学习技术及其在语义分割领域的应用。首先对传统的卷积神经网络的发展过程进行了介绍，后续介绍了卷积神经网络的基本结构，然后分析了各基本结构中的重要组件。此外，本章还对语义分割中重要的多尺度融合技术进行了分类，对其中的并行多分支、金字塔结构和级联结构进行了举例和介绍，并对隐式神经表示和状态空间模型的研究现状进行了分析。

第三章　基于隐式神经表示的语义分割方法

语义物体的精确和准确预测对于语义分割任务至关重要，这对目前主流的编码器-解码器结构中的解码器部分有很高的要求。然而，现有的工作大多直接采用一个上采样解码器来逐渐恢复高分辨率，它们先从图像中提取全局和局部特征，再从特征中恢复出原分辨率的预测结果。这往往会影响类间边界的分割精度，使分割结果的边缘产生模糊。

针对以上问题，本章提出了一种基于隐式神经表示的分割模型，它用已知信息来查询解码结果，预测操作对应用一个基于坐标的连续函数将输入信息映射为解码结果的过程。通过隐式神经表示，解码器将直接查询高分辨率的结果，而非从低分辨率特征图中恢复出高分辨率结果。此外，为了增强输入的特征信息和位置信息的效果，本章还提出了可变形融合和小波位置编码两个子模块，来强化隐式神经表示在二维视觉任务中的效果。

3.1 多尺度融合的隐式神经表示解码器

隐式神经表示是一种由逐坐标的信息输入和预测输出定义的函数f_θ，其从整个数据集中学习并共享隐式参数θ，并由一个多层感知器（MultiLayer Perceptron, MLP）来实现。这个过程被定义为查询解码过程，与恢复特征的上采样解码过程不同，其能根据已知信息来得到预测结果。图 3-1 说明了上采样解码与查询解码之间的区别。

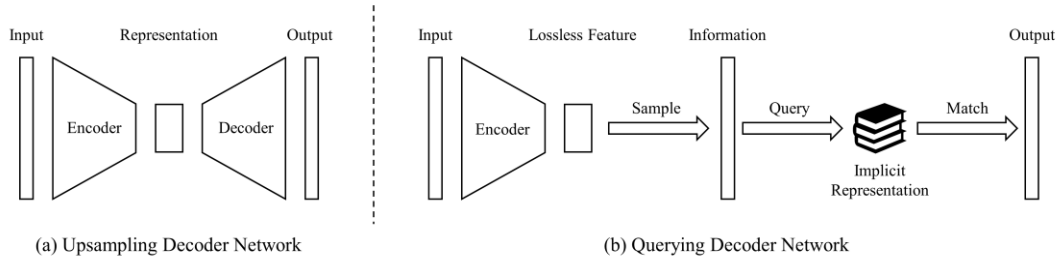

图 3-1 上采样解码网络和查询解码网络的对比

Fig 3-1 Comparison between upsampling decoder network and query decoder network

上采样解码器在高分辨率恢复过程中，从低分辨率表示中逐步上采样生成预测结果。然而，上采样方法的局限性严重影响了类间边界的分割精度，并导致了显著的边缘模糊。查询解码器的结构能有效解决这一问题。通过从无损的原始数据中逐坐标采样信息，解码成为了一种从信息中生成查询结果的过程。这使预测与高分辨率恢复无关，从而能从对齐的信息中得到更准确的结果。

原始的隐式神经表示使用二维坐标x和对应特征向量v预测语义标签l的过程如下：

$$l = f_\theta(v, x) \tag{3-1}$$

对于对应一张图像的特定特征向量v_0来说，公式（3-1）可被描述为$f_\theta(v_0(x), x)$，其表示一个将坐标映射为语义标签的连续函数。更进一步地说，通过从上下文中提取特征信息F和位置信息S来查询对应的语义标签L，公式（3-1）可改为如下形式：

$$L(x) = f_\theta\big(F(x), S(x)\big) \tag{3-2}$$

其中的F、S和L都是与坐标相关的，契合逐坐标函数的定义。至此，基于隐式神经表示的语义分割方法的基本结构已经确定。

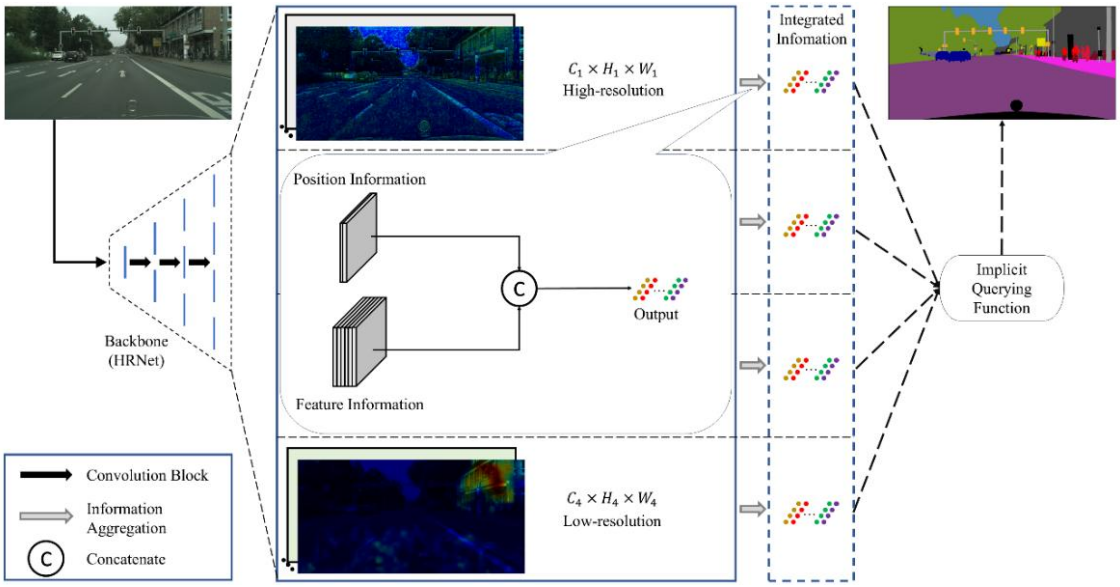

图 3-2 多尺度融合的隐式神经表示解码器的整体结构

Fig 3-2 Overall structure of the implicit neural representation decoder with multi-scale fusion

图 3-2 展示了多尺度融合的隐式神经表示解码器的整体结构。该解码器使用主干网络 HRNet[21]的四分支特征输入，分别表示了由低到高不同尺度的特征表示,其尺寸为$C_k \times H_k \times W_k$，其中$k \in \{1,2,3,4\}$表示层数，$C_k = 2^{k-1}C_1$是各层的通道数，$H_k = \frac{H_1}{2^{k-1}}$和$W_k = \frac{W_1}{2^{k-1}}$是各层的高和宽。之后，该解码器将从多尺度特征图中提取对应特征信息和位置信息，用于隐式神经表示的查询操作，并通过隐式查询函数即 MLP 层完成输出映射。

因此，隐式神经表示将被描述为一个关于特征和位置信息的基于坐标的函数，样本的特征向量被视作低维特征空间的特征，隐式表示被视为历史语义库。整个预测过程可以看作是一个查询操作，它在历史语义库中搜索与样本特征匹配的预测结果。然而，作为像素级任务，语义分割显然无法通过单像素的信息进行准确的推理预测，这需要对信息进一步强化。本文提出了适用于语义分割任务的隐式神经表示信息增强模块（Information Enhancement Module, IEM），其中包括了可变形融合（Deformable Fusion, DF）模块和小波位置编码（Position Encoding, PE）两部分，来获得强化的上下文特征信息和位置关注信息。

3.2 隐式神经表示的信息增强模块

3.2.1 信息增强模块的框架

信息增强模块主要由两部分组成，如图 3-3 所示，分为（a）部分的可变形融合模块和（b）部分的位置编码模块。前者利用逐通道的可变形核来提取每个坐标的上下文信息，生成精炼的特征向量和注意偏移量。后者是相对于位置信息的模块，其对二维位置信息进行编码，并利用位置编码核来生成增强的位置关注信息。这两个模块的输出将被拼接作为隐式查询函数的输入。

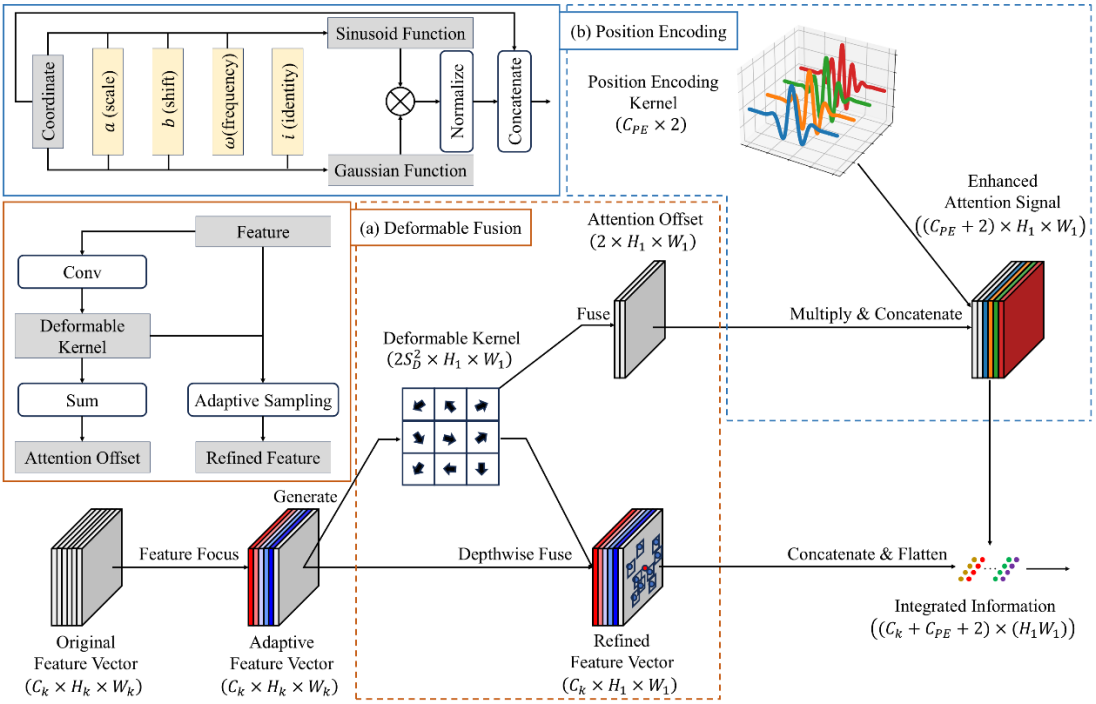

图 3-3 信息增强模块的结构

Fig 3-3 Structure of the information enhancement module

根据公式（3-2），隐式查询函数的输入仅包含由特征向量生成的上下文特征和位置信息。因此，提高特征向量的质量是提高隐式神经表示查询效果的主要挑战之一。对于原始特征向量，本文采用特征关注操作来自适应地加权特征，强化更有利于查询的特征，抑制相反特征。特征关注的范式为：

$$V_{ada} = f_{FF}(V_{ori})V_{ori} \tag{3-3}$$

其中$V_{ori}, V_{ada} \in \mathbb{R}^{C_k \times H_k \times W_k}$表示原始特征向量（输入）和自适应特征向量（输出），而$f_{FF}(\cdot)$表示只使用原始特征向量本身来更新权重的特征关注函数。通过特征关注操作，特征向量的每个通道根据整体受到了不同的关注，从而使后续的特征操作得到增强。

3.2.2 可变形融合模块

隐式神经表示的基于坐标的特征允许多尺度特征向量并行处理，这需要设计一种采样函数$\varphi(\cdot,\cdot)$其满足$\forall V \in \mathbb{R}^{C_k \times H_k \times W_k}, \forall X \in \mathbb{R}^{H_1 \times W_1} \Rightarrow \varphi(V, X) \in \mathbb{R}^{C_k \times H_1 \times W_1}$，

最直接的方法是从(H_k, W_k)的图中采样最近邻居的(H_1, W_1)点。之前的工作[61]提出在超分辨率任务中使用双线性插值来实现$\varphi(\cdot,\cdot)$，并将与最近邻居的相对位置作为隐式神经表示的位置信号输入。受此启发，本文改进了采样过程，使特征向量能够自适应地聚合上下文信息。

本文设计了可变形融合算法来实现采样函数$\varphi(\cdot,\cdot)$，该算法包括三个步骤：1）为(H_1, W_1)尺寸的坐标图生成可变形核；2）将可变形核的对应值与输入特征向量V_{ada}对应值融合，生成逐通道的采样值V_{ref}；3）将可变形核的偏移量融合为注意偏移信号S_{att}。

对于一个尺寸为S_D的可变形核D，其有可用的位置$(i,j) \in D$，此时可变形偏移$p_{i,j}$由核的固定偏移量$\delta_{i,j} = \{(i,j)\}$和生成偏移量$\Delta_{i,j} = f_{gen}(V_{ada}, x)_{i,j}$组成，即$p_{i,j} = \delta_{i,j} + \Delta_{i,j}$，其中$x \in X$且$f_{gen}(\cdot)$表示生成偏移量的生成函数。该可变形偏移表示该点$(i,j)$对各通道上下文的兴趣偏移，这构成了本文模型中位置信号的基础。根据可变形偏移，每个位置的特征向量更新如下：

$$V_{ref}^{x} = \sum_{(i,j)\in D} w_{i,j}^{x} \cdot f_{sam}\left(V_{ada}, x + p_{i,j}^{x}\right) \tag{3-4}$$

其中的上标x表示它是在点x处对应的可变形核参数，$w_{i,j}^{x}$表示位置(i,j)处对应的权重，$f_{sam}\left(V_{ada}, x + p_{i,j}^{x}\right)$表示在点$\left(x + p_{i,j}^{x}\right)$处从特征向量$V_{ada}$中采样的输出值。由于需要从低分辨率特征向量中采样高分辨率，模型将从V_{ada}中用双线性插值来填补低到高分辨率时的缺失值。

同时，根据可变形核生成每个点$x \in X$的注意偏移信号：

$$S_{att}^{x} = \sum_{(i,j)\in D} p_{i,j}^{x} \tag{3-5}$$

它代表了可变形核在各点上由上下文注意偏好引起的局部关注。一个点的注意偏移信号是一个二维的位置关注信息，其表示在隐式查询该点时影响注意力的上下文的相对位置。从数值的角度看，它也可以被看做一个矢量，其方向表示注意方向，大小表示注意程度。

通过这种方式，采样函数$\varphi(\cdot,\cdot)$可以表示为$\varphi(V_{ada}, X) = \left\{V_{ref}^{x}, S_{att}^{x} \mid x \in X\right\}$。至

此，模型生成了上下文特征和注意偏移信号，来提高特征信息和位置信息输入到隐式查询函数的质量。

3.2.3 小波位置编码模块

先前的研究[60, 69, 70]表明，神经网络在学习高频信号输入时表现不佳。这与实验结果一致，即当直接向神经网络提供二维坐标向量时，网络难以有效地拟合隐式查询函数。频谱偏差理论[71]表明，随着数据流形复杂度的增加，学习更高频的信号会更容易，为此本节引入了位置编码。对于注意偏移信号，使用位置编码函数f_{PE}来获得增强信号$S_{enh} = f_{PE}(S_{att})$。

与常规的正弦波函数编码不同，本节使用小波函数来对位置信息进行编码。实验表明，用多个小波拟合的非稳态信号相比稳态信号能让神经网络更好地拟合位置信息的特征。此外，为了使函数具有更广泛的微调空间和更合理的编码效果，参考前人的工作[72]，设计了以下形式的复 Morlet 小波核：

$$f_{PE}(s) = \frac{1}{\sqrt{a}} e^{2i\pi\omega s} e^{\frac{-4\ln(2)s^2}{h^2}} \tag{3-6}$$

其中$s = \frac{\hat{s}-b}{a}$，$\hat{s}$是S_{att}上的一个二维坐标，a是小波的缩放参数，b是小波的平移参数，ω是小波正弦部分的频率，h是半峰全宽，用来描述高斯部分的高斯宽度。简而言之，小波函数被表示为了特定频率的正弦函数和高斯函数的乘积，通过移动和缩放来扩大模拟信号位置的范围。

初始情况下，为了将二维的注意偏移映射为M维的增强信号，默认设置$\omega_j = \mu \log_{\mathrm{M}}(j)$，其中$j \in \{1, \dots, M\}$，$\mu$为频率的缩放因子，来获得范围为$[0, \mu]$的$M$维位置编码频率。所有参数的初始化分别为$M = 12$，$h = 1$，对应第$k$层的$\mu_k \in \{16,16,4,4\}$，$a = 1$和$b = 0$。对于小波函数的正弦部分，实验将采用同相和正交的$M$个频率的正弦函数来对两个坐标维度进行处理，从而获得$S_{enh} \in \mathbb{R}^{C_{PE} \times H_1 \times W_1}$ $(C_{PE} = 4M)$。结合原始输入S_{att}和函数输出S_{enh}，位置信号被从$\mathbb{R}^{2 \times H_1 \times W_1}$映射为$\mathbb{R}^{(C_{PE}+2) \times H_1 \times W_1}$，从而得到模拟的增强位置信号。

3.3 基于隐式神经表示的语义分割框架

基于多尺度融合的隐式神经表示解码器和信息增强模块，本章提出基于隐式神经表示的语义分割框架，称为隐式表示查询网络（Implicit Representation Querying Network, IRQNet），如图 3-4 所示。整个网络结构主要由主干网络、信息增强模块和隐式查询函数组成，主干网络负责提取出不同尺度的图像特征信息，信息增强用于从特征中得到隐式神经表示需要的特征信息和位置信息，隐式查询函数负责将特征信息和位置信息映射为目标的标签输出。

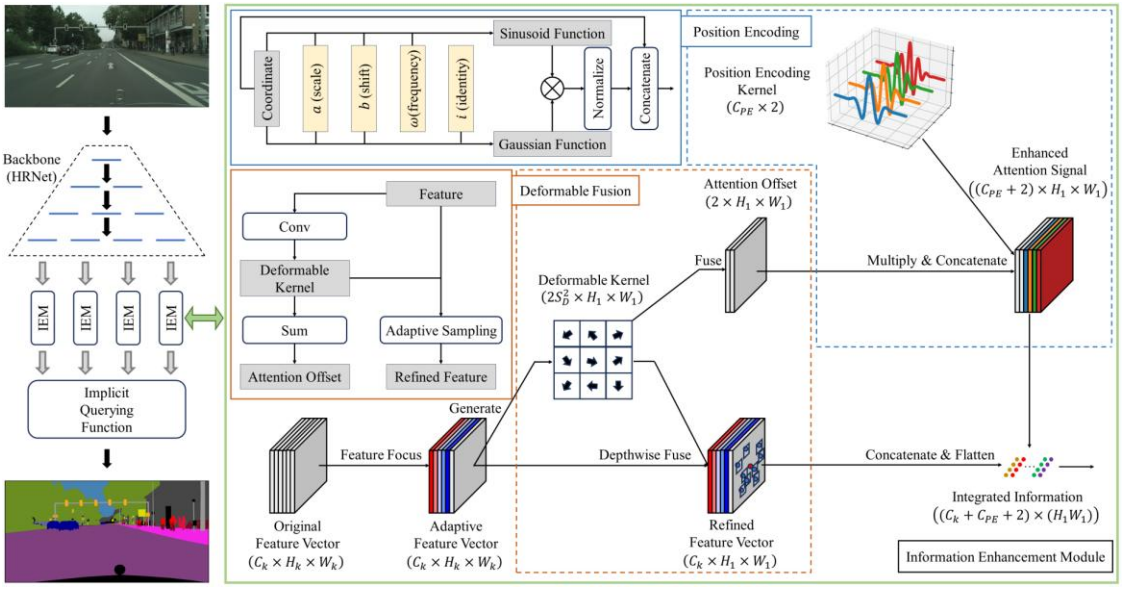

图 3-4 基于隐式神经表示的语义分割框架

Fig 3-4 Semantic segmentation framework based on implicit neural representation

整个网络的分割流程如下：

（1）将图像输入主干网络 HRNet 中，经过一系列特征提取操作后得到四个尺度的特征图，其中最高层的特征图尺寸为原图尺寸的1/4，尺寸逐层减少1/2，通道数逐层增加1/2。

（2）将每个尺度的特征图分别输入对应尺度的信息增强模块中，通过可变形融合和位置编码操作后，得到与最高层的特征图相同尺寸的特征信息和位置信息，用于隐式神经表示的函数拟合。

（3）将所有信息拼接后输入隐式查询函数中，通过 MLP 实现隐式神经表示的函数拟合，得到预测分割图，将分割图进行 4 倍上采样后得到原图大小的最终分割预测结果。

3.4 实验与分析

3.4.1 实验数据

本文采用 Cityscapes[73]数据集和 ADE20K[74]数据集进行实验，如图 3-5 所示，其中图 3-6(a)来自于 Cityscapes 数据集，图 3-6(b)来自于 ADE20K 数据集，第一行和第二行图片分别表示输入图像和对应的标签图。

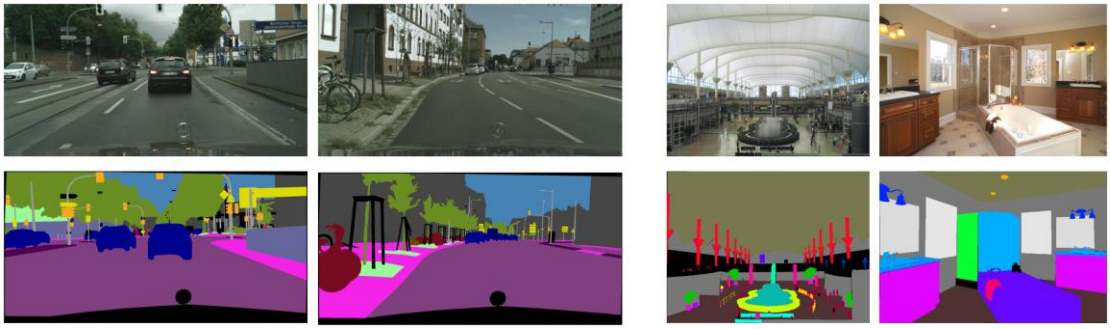

(a) Cityscapes 数据集样例　　(b) ADE20K 数据集样例

(a) Sample of Cityscapes dataset　　(b) Sample of ADE20K dataset

图 3-5 Cityscapes 数据集和 ADE20K 数据集样本示例

Fig 3-5 Samples of Cityscapes dataset and ADE20K dataset

3.4.2 评价指标

在深度学习中，为了对不同模型的性能进行比较，从而量化模型在应用于特定任务时的效果，通常会选择公认有效的评价指标作为衡量标准。由于不同评价指标在评价时的侧重点不同，不同任务对于模型预测的需求也不同，例如训练时间、参数量和准确率等因素，因此选择一个合适的评价指标至关重要。本文选定的评价指标为像素精度（Pixel Accuracy, PA）和平均交并比（mean Intersection over Union, mIoU），并以 mIoU 为主要评价指标。

在进行语义分割结果评价时，通常会将预测出的结果分为四个部分：真阳性

（True Positive, TP）、假阳性（False Positive, FP）、真阴性（True Negative, TN）和假阴性（False Negative, FN）。其中，阳性表示目标标签部分，阴性表示非目标标签部分。

PA 计算的是标记正确的像素占总像素的比例，这个比例等同于 TP、TN 之和比 TP、FP、TN、FN 之和，即表示为：

$$PA = \frac{TP + TN}{TP + FP + TN + FN} \tag{3-7}$$

IoU 计算的是真实值集合和预测值集合的交集和并集之比，这个比例等同于 TP 比 TP、FP、FN 之和，即表示为：

$$IoU = \frac{TP}{TP + FP + FN} \tag{3-8}$$

而 mIoU 则表示为在所有类上的 IoU 的平均值。

为了评价方法在分割结果边缘的效果，本章引入了额外的评价指标，边缘 F1 分数（Boundary F-Score, BF-Score）[75]。BF-Score 是一种基于轮廓的分割方法，它是对 mIoU 的一种补充，用于量化分割边缘附近的精度。对于二值化后的真实值分割图B_{gt}^{c}和预测分割图B_{ps}^{c}而言，在距离误差容忍度t下的第c类准确率P^{c}和召回率R^{c}分别为：

$$\begin{aligned} P^{c} &= \frac{1}{|B_{ps}|} \sum_{z \in B_{ps}^{c}} [\![d(z, B_{gt}^{c}) < t]\!] \\ R^{c} &= \frac{1}{|B_{gt}|} \sum_{z \in B_{gt}^{c}} [\![d(z, B_{ps}^{c}) < t]\!] \end{aligned} \tag{3-9}$$

其中$d(\cdot)$是欧氏距离，$[\![\cdot]\!]$是艾佛森括号。此时，第c类的 BF-Score 就被定义为：

$$F^{c} = \frac{2 \cdot P^{c} \cdot R^{c}}{P^{c} + R^{c}} \tag{3-10}$$

每张图像的 BF-Score 将由所有类别的F^{c}进行平均得到。简而言之，BF-Score 是每个类的真实轮廓和预测轮廓在一定距离误差容忍度下匹配像素的 F1 分数。

3.4.3 实验设置

本文使用的实验环境为 Ubuntu20.04 系统，编程语言为 Python 3.9，深度学习框架为 PyTorch 1.13.0，一共使用四张 NVIDIA GeForce RTX 3090 显卡，来完成

本文方法和对比方法的实现，分别都是 24G 的显存。本文用从 ImageNet[76]中初始化的HRNet[21]作为主干网络。对于训练时的最大迭代次数$iter_{max}$和当前迭代次数，使用因子为$1-\left(\frac{iter}{iter_{max}}\right)^{power}$的 Poly 学习率策略来动态调整学习率大小，并设置$power=0.9$。在训练期间，网络在末端使用一个交叉熵函数作为损失函数。在数据增强中，本文对训练图像施加随机缩放，随机裁剪，随机水平翻转和光度失真，对验证图像应用随机缩放，随机裁剪和随机水平翻转。

对于 Cityscapes 数据集，本文使用初始学习率为 0.01，动量为 0.9，权重衰减为 0.0005 的 SGD 优化器。设置批大小为 8，训练迭代次数为 80K，图像被随机裁剪至 512×1024 的尺寸。

对于 ADE20K 数据集，本文使用初始学习率为 0.02，动量为 0.9，权重衰减为 0.0001 的 SGD 优化器。设置批大小为 16，训练迭代次数为 160K，图像被随机裁剪至 512×512 的尺寸。

3.4.4 消融实验

为了验证各子模块的有效性，本文在 Cityscapes 数据集上进行了消融实验，分别对可变形融合模块和位置编码模块的使用效果进行对比，并根据实验结构探索了隐式查询函数和小波位置编码核的最优结构。

表 3-1 可变形融合模块和位置编码模块的消融实验

Table 3-1 Ablation study of deformable fusion module and position encoding module

方法	DF	PE	PA(%)	mIoU(%)
IRQNet			96.45	80.02
	√		96.48	80.45
		√	96.48	80.35
	√	√	**96.54**	**80.76**

表 3-1 展示了分别添加可变形融合模块和位置编码模块以及同时添加这两个模块后在 Cityscapes 数据集上的分割精度，可以看出可变形融合模块和位置编码模块均对分割效果的提升起到了不同程度的作用。从实验中可以看到，只添加可变形融合模块达到了 96.48%的 PA 和 80.45%的 mIoU，只添加位置编码模块达到

了 96.48%的 PA 和 80.35%的 mIoU，这两种情况下的分割精度均高于不添加任何模块时的情况，证明了可变形融合模块和位置编码模块的有效性。同时加入可变形融合模块和位置编码模块后分割精度则进一步来到了 96.54%的 PA 和 80.76%的 mIoU，证明了信息增强模块整体对隐式神经表示拟合的积极效果。

表 3-2 不同隐式查询函数结构的比较实验

Table 3-2 Comparison of different implicit querying function structures

MLP 层数	MLP 节点数	PA(%)	mIoU(%)
3	{512, 256, 256}	96.42	80.54
3	{1024, 512, 256}	**96.54**	**80.76**
4	{512, 256, 256, 256}	96.51	80.55
4	{512, 512, 256, 256}	96.49	80.55

为了评估不同的 MLP 隐藏层结构在解码器中拟合隐式查询函数的效果，表 3-2 比较了不同隐藏层设置下的模型表现。由于设置组合过多，该表选取了表现接近于最好结构的几个实验结果用于展示，其中效果最好的结构为 3 层的{1024, 512, 256}结构，过于复杂或过于简单的结构都会影响模型的效果，因此本文选择了该隐藏层结构作为最终结构。

表 3-3 不同小波位置编码核的比较实验

Table 3-3 Comparison of different wavelet position encoding kernels

h	μ	PA(%)	mIoU(%)
1	{2, 4, 8, 16}	96.22	79.54
1	{4, 4, 16, 16}	96.36	80.39
1	{16, 8, 4, 2}	96.31	79.54
1	{16, 16, 4, 4}	**96.54**	**80.76**
0.5	{16, 16, 4, 4}	96.47	80.52
2	{16, 16, 4, 4}	96.43	80.41
4	{16, 16, 4, 4}	96.15	79.30

表 3-3 比较了不同的小波位置编码核的结果。本文对公式 3-6 中小波位置编码核中的两个关键参数，半峰全宽h和正弦部分频率的缩放因子μ进行了研究。实验表明，在位置编码中，半峰全宽和正弦频率都存在局部最优，本文将其归因于不同层神经网络对位置信号的潜在偏好。根据实验结果，本文选择了$h = 1, \mu_k \in$

$\{16, 16, 4, 4\}$作为位置编码核的最终结构。

3.4.5 对比实验

为了进一步验证本章提出的网络 IRQNet 的有效性，本节将其性能与其他同类型模型进行比较，其中包括基于 CNN 的方法、上采样解码方法和隐式神经表示方法三类。

表 3-4 与基于 CNN 的方法的对比实验

Table 3-4 Comparison experiments with CNN-based methods

方法	主干网络	Cityscapes		ADE20K	
		PA(%)	mIoU(%)	PA(%)	mIoU(%)
HRNet	HRNet-w32	96.45	80.01	80.23	41.93
ResNeSt	ResNet-50	96.13	77.97	80.37	42.72
PIDNet	PIDNet-L	96.15	78.14	80.28	41.62
FADC	ResNet-50	96.47	80.63	80.99	43.56
IRQNet	HRNet-w32	**96.54**	**80.76**	**81.03**	**44.04**

表 3-4 显示了 IRQNet 与 HRNet[21]、ResNeSt[77]、PIDNet[78]和 FADC[79]方法在 Cityscapes 和 ADE20K 数据集上的性能比较。可以看到 IRQNet 在 Cityscapes 数据集上取得了 96.54%的 PA 和 80.76%的 mIoU，在 ADE20K 数据集上取得了 81.03%的 PA 和 44.04%的 mIoU，相对于基线模型 HRNet 在主要评价指标 mIoU 上分别提升了 0.75%和 2.11%。这说明本文的方法一定程度上提升了整体的分割精度，具备和先进 CNN 方法相近的效果。

表 3-5 与上采样解码方法的对比实验

Table 3-5 Comparison experiments with upsampling methods

方法	主干网络	Cityscapes		ADE20K	
		PA(%)	mIoU(%)	PA(%)	mIoU(%)
CARAFE	ResNet-50	95.91	77.27	79.62	40.75
CARAFE*	HRNet-w32	96.37	79.65	80.45	42.20
AlignSeg	ResNet-50	95.89	76.63	78.71	39.27
AlignSeg*	HRNet-w32	96.46	79.98	79.96	40.54
IRQNet	HRNet-w32	**96.54**	**80.76**	**81.03**	**44.04**

表 3-5 展示了 IRQNet 与上采样解码方法 CARAFE[80]和 AlignSeg[81]的性能比

较，其中带*号的方法表示本文使用 HRNet-w32 作为主干网络对其进行了改良，从而得到更好的分割效果。从实验数据中可以看到，本文的查询解码方法优于从上采样解码进行改良的各项方法。

表 3-6 与隐式神经表示方法的对比实验

Table 3-6 Comparison experiments with implicit neural representation methods

方法	主干网络	Cityscapes		ADE20K	
		PA(%)	mIoU(%)	PA(%)	mIoU(%)
PointRend	ResNet-50	95.94	75.82	77.93	37.98
PointRend*	HRNet-w32	96.49	80.73	80.33	42.13
IFA	ResNet-50	95.41	70.17	75.93	33.64
IFA*	HRNet-w32	96.50	79.76	80.40	41.87
IRQNet	HRNet-w32	**96.54**	**80.76**	**81.03**	**44.04**

表 3-6 显示了 IRQNet 与隐式神经表示方法 PointRend[63]和 IFA[62]的性能比较。其中，PointRend 的底层原理与隐式神经表示相一致，而 IFA 则直接使用了隐式神经表示用于特征图的对齐，二者是将隐式神经表示应用于语义分割任务的早期尝试。本文提出了一种将隐式神经表示应用于隐式神经表示的范式，对整体流程进行了细致的调整，因此拥有更好的效果。

表 3-7 对边缘分割的对比实验

Table 3-7 Comparison experiments of boundary segmentation results

距离误差容忍度	Cityscapes BF-Score(%)		ADE20K BF-Score(%)	
(px)	HRNet	IRQNet	HRNet	IRQNet
1	12.38	**12.71**	6.60	**6.98**
3	49.48	**49.97**	27.72	**29.66**
5	58.66	**58.94**	35.18	**37.37**

为了进一步证明本章提出的方法在分割结果边缘的改进效果，本文引入了 BF-Score 来对边缘预测效果进行评估。表 3-7 展示了 IRQNet 和基线模型 HRNet 的边缘分割效果对比。根据距离误差容忍度的定义，本文选取了不同的像素（pixel, px）误差，其中包括 1px、3px 和 5px 的情况。可以看到，在三种像素误差状况下，本文的方法均有更好的边缘表现，证明了方法在解决边缘模糊问题上的效果。

3.4.6 实验结果可视化

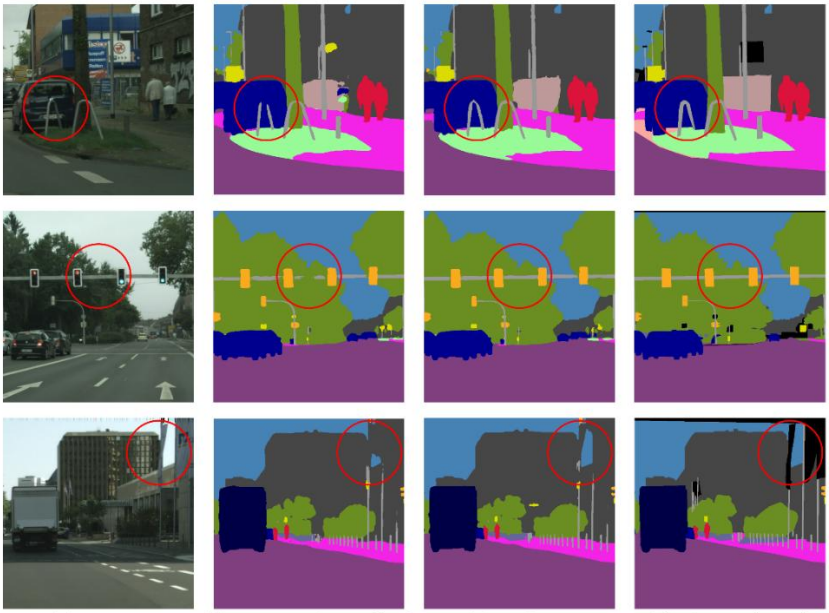

(a) Image (b) HRNet (Baseline) (c) IRQNet (d) Ground truth

图 3-6 不同方法在 Cityscapes 数据集上的可视化结果

Fig 3-6 Visualization results of different models on Cityscapes dataset

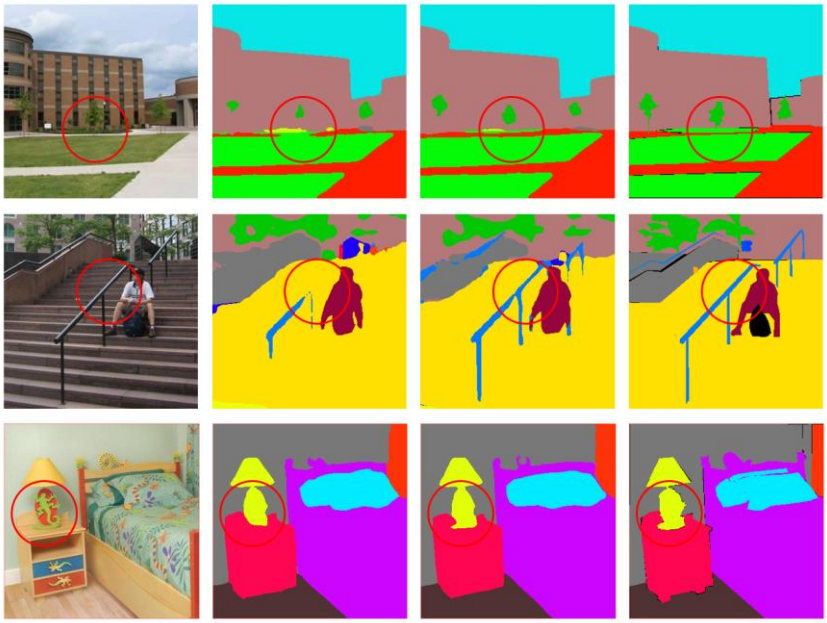

(a) Image (b) HRNet (Baseline) (c) IRQNet (d) Ground truth

图 3-7 不同方法在 ADE20K 数据集上的可视化结果

Fig 3-7 Visualization results of different models on ADE20K dataset

本节对 HRNet 和 IRQNet 的部分实验结果进行了可视化，以此来更直观地对比方法效果。Cityscapes 数据集和 ADE20K 数据集的可视化结果如图 3-6 和图 3-7 所示，从左到右依次为原图、HRNet、IRQNet 和真实值的分割图。本节使用红色圆圈来指出在语义分割中容易被误分类的挑战性区域。在 IRQNet 的分割结果中，小物体对象的类间边界更加清晰，如图 3-6 中第一行被“车”标签包围的“杆子”标签和第二行被“植物”标签包围的“杆子”标签，以及图 3-7 中第一行被“道路”标签包围的“草地”标签和第二行被“阶梯”标签包围的“栏杆”标签。同时，受周围大区域影响的小区域的分割边界也更加清晰，如图 3-6 中第三行的“天空”标签和“建筑物”标签，以及图 3-7 中第三行的“台灯”标签和“桌子”标签。这证实了查询方法相对于上采样方法更准确的类间边界预测能力，其显著增强了模型对目标区域的判别能力，提高了语义的一致性。

3.5 本章小结

本章针对语义分割过程中上采样解码对类间边界分割精度的影响问题，提出了一种基于隐式神经表示的语义分割方法，通过查询解码而非上采样的方式映射得到语义分割的结果。为了更好地结合隐式神经表示和语义分割任务的特性，本章提出了应用于语义分割任务的隐式神经表示范式，并设计了信息增强模块来提高输入信息的效果，其中可变形融合模块用于从特征图上下文中提取特征信息并融合得到上下文位置关注信息，小波位置编码模块用于进一步强化位置信息的效果。为了验证本章的方法在提升语义分割的精度和缓解边缘模糊问题方面的效果，分别在 Cityscapes 数据集和 ADE20K 数据集上进行了消融实验、对比实验，并对实验结果进行了可视化分析。

第四章　基于预热状态空间模型的语义分割方法

在上一章中，本文提出了多尺度融合的隐式神经表示解码器来解决上采样解码过程中存在的边缘模糊问题，同时提出了一个信息增强模块来提高隐式神经表示在语义分割任务中的效果。然而，在特征信息和位置信息生成的过程中，网络只使用了特征图的局部上下文，而没有考虑自然图像中丰富的全局关联信息，这一定程度上影响了在图像上复杂区域的分割效果和语义区域的一致性。在本章中，为了进一步利用图像中的全局信息，提取图像中的长距离依赖，提出了一种预热的状态空间模型，通过提取并预输入类与特征间关系的上下文，来实现状态空间模型的上下文信息聚合。除此之外，为了缓解重复输入导致的网络偏好，本章设计了一种信息补偿模块来提取并恢复丢失的部分信息。

4.1 预热状态空间模型

状态空间模型在长序列建模方面展现出了惊人的潜力。与近年来流行的 Transformer 模型的二次复杂度相比，状态空间模型方法以线性复杂度实现了有效的序列建模。与此同时，相对于线性注意力等效果较差的线性复杂度序列模型而言，状态空间模型方法还具备出色的效果。这使其成为了自然语言处理和计算机视觉领域备受关注的新型架构。

在计算机视觉领域中，序列模型通常会将图像或特征划分为等尺寸的块，来进行序列建模计算。在 Transformer 架构中，计算会逐元素地学习当前块与其他块之间的关系。而在状态空间模型中，计算会将逐步地更新模型中的隐状态，并使用隐状态来生成预测结果。这种状态更新的过程通常是单向的，因此许多方法会选择使用多个方向的序列化方法来保证序列语义的完整性，例如 VMamba[82]和 PlainMamba[83]。

目前的状态空间模型研究主要集中于在块序列中建模长距离依赖，却忽视了图像信息中丰富的上下文信息。为了解决这个问题，本节提出了一种预热机制，

将主干网络输出的粗分割图用于增强特征图中的语义信息，并在类上下文和特征之间建立一个关系矩阵。通过将经过粗分割辅助增强的特征提供给状态空间模型，来让其提前建立对重点上下文信息的关注。

图 4-1 展示了粗分割辅助特征图的生成流程。对于粗分割图M_c而言，首先通过缩放操作得到与特征图相同大小的粗分割图，然后通过线性层和 Softmax 操作得到像素属于某一类的概率，最后和特征图在像素维度进行矩阵乘法，来得到类与特征之间的关系矩阵M_r。接下来采用交叉注意力方法，先将关系矩阵与特征图进行对应投影和矩阵乘法，得到像素与类区域间的依赖关系，再进行缩放和 Softmax 操作，将该依赖关系注入类与特征的关系矩阵中，从而得到受到了粗分割图中像素和类关系信息辅助增强后的特征图R_{CSA}。

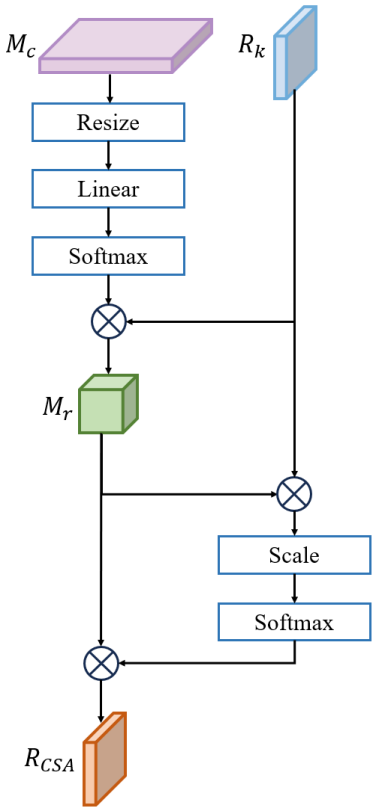

图 4-1 粗分割辅助特征图的生成流程

Fig 4-1 Generation process of coarse-segmentation-assistance feature map

生成的粗分割辅助特征图R_{CSA}在维持特征的同时拥有了重要的上下文信息，

被用于状态空间模型的预热中。之后，粗分割辅助特征图和原特征图将被依次输入到视觉状态空间（Visual State-Space, VSS）模型中，利用公式（2-7）中独立的参数A和D，以及依赖于输入的参数B、C和Δ来生成增强的输出特征R_{VSS}，如图 4-2 所示。值得注意的是，由于状态空间模型的四方向扫描策略和线性循环计算方法，这两个输入需要遵循相反的扫描序列顺序，来保证正确的长距离依赖建模。图 4-2 中的 Reverse 操作从输入中选择了相反的四组序列，其他操作则与纯 VSS 模型保持一致。

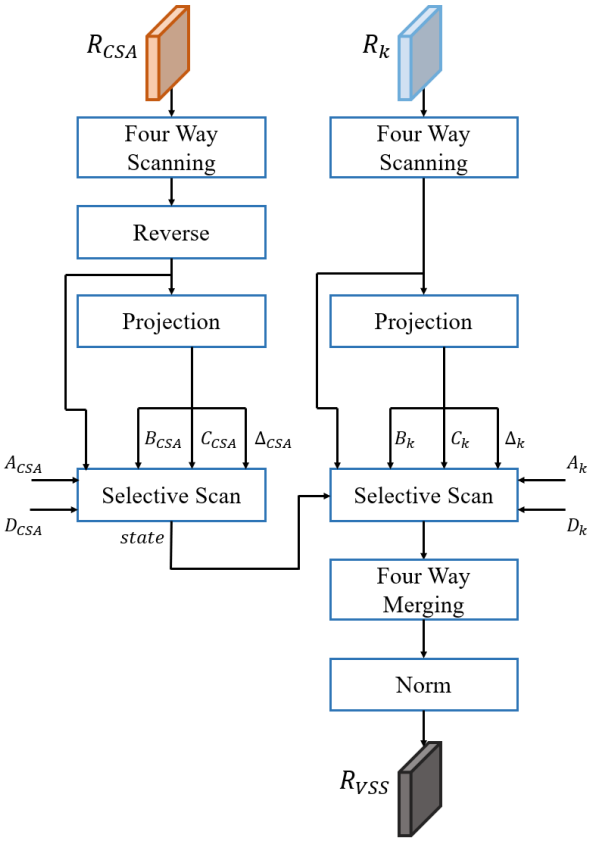

图 4-2 预热状态空间模型的流程

Fig 4-2 Process of preheating state space model

4.2 信息补偿模块

预热机制使状态空间模型能够提前适应当前数据，从而提高建模的效果。然而，由于预热过程和多方向扫描的多次重复输入，状态空间模型会产生对辅助信息的

偏好，从而不可避免地导致原特征中其他语义信息的丢失。为了解决这一问题，本节提出了信息补偿模块，其由局部补偿（Local Compensation, LC）模块和全局补偿（Global Compensation, GC）模块组成，来恢复特定的语义信息。每一个补偿模块均由对应的提取模块和相同的补偿模块构成。

4.2.1 局部提取模块

为了尽可能恢复局部丢失的信息，本节从原特征的多尺度局部信息出发，设计了一种简单有效的局部提取模块，如图 4-3 所示。其采用了 5×5、9×9 和 13×13 三种最大池化的多尺度结构，并将最大池化的结果和原特征拼接和映射，经过一个残差结构生成结果。通过多个池化核，该模块聚合了不同感受野的特征，有效地捕获了各种尺度的局部语义特征S_l。

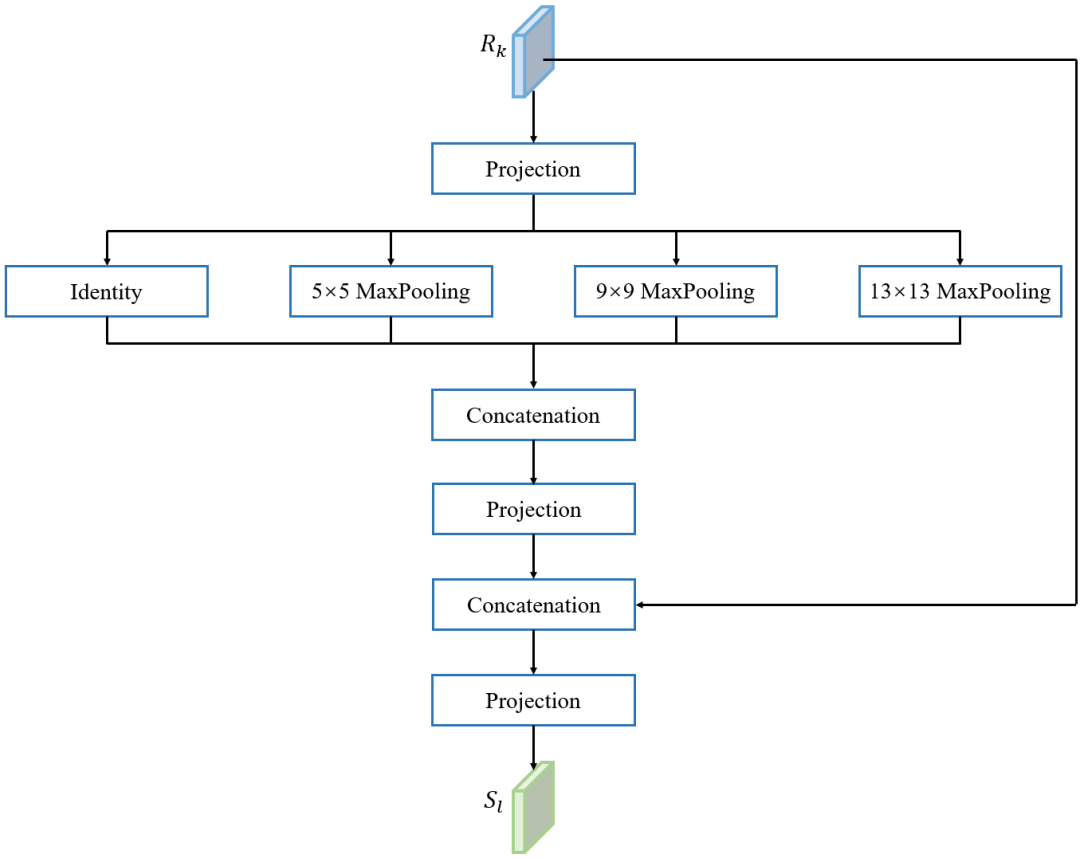

图 4-3 局部提取模块的流程
Fig 4-3 Process of local extraction module

4.2.2 全局提取模块

如图 4-4 所示，全局提取模块使用带相对位置编码的窗口注意力[84]来捕获全局上下文，并在窗口注意力后使用水平和垂直方向的条形卷积来捕捉邻近窗口之间的关系。对于本文设置的滑动窗口尺寸$ws = 8$，水平和垂直方向的条形卷积分别拥有$(ws, 1)$和$(1, ws)$尺寸的卷积核，以及$\left(\frac{ws}{2} - 1, 0\right)$和$\left(0, \frac{ws}{2} - 1\right)$的填充。这些水平和垂直方向的卷积结果之和描述了二维的窗口间长距离依赖，从而表示特征图的全局语义信息S_g。

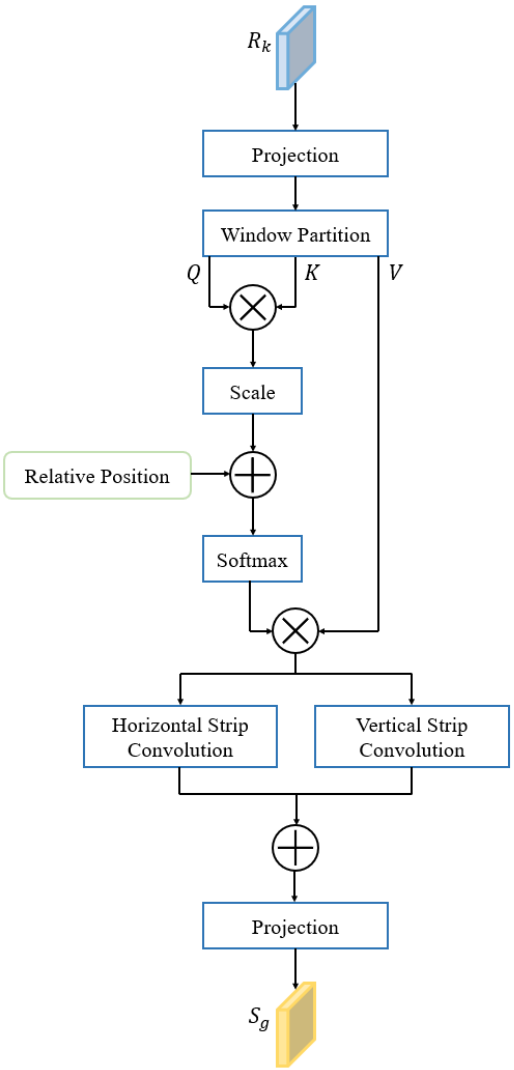

图 4-4 全局提取模块的流程

Fig 4-4 Process of global extraction module

4.2.3 补偿模块

预热状态空间模型生成的特征图保留了丰富的类与特征的关系细节，但会由于重复的输入丢失其他语义信息。同时，上述的提取模块从元特征图中单独提取了充足的局部和全局信息。本节设计了一个简单的多头交叉注意模块来进行语义信息的补偿，计算过程如图 4-5 所示。对于特定的局部语义信息S_l或全局语义信息S_g，模块通过关系矩阵的形式将其融入特征R_{VSS}中，从而得到对应的局部补偿特征R_{LC}或全局补偿特征R_{GC}。最后，局部和全局补偿的输出将被拼接和投影，然后输入到 IRQNet 的解码器部分来得到最终输出。

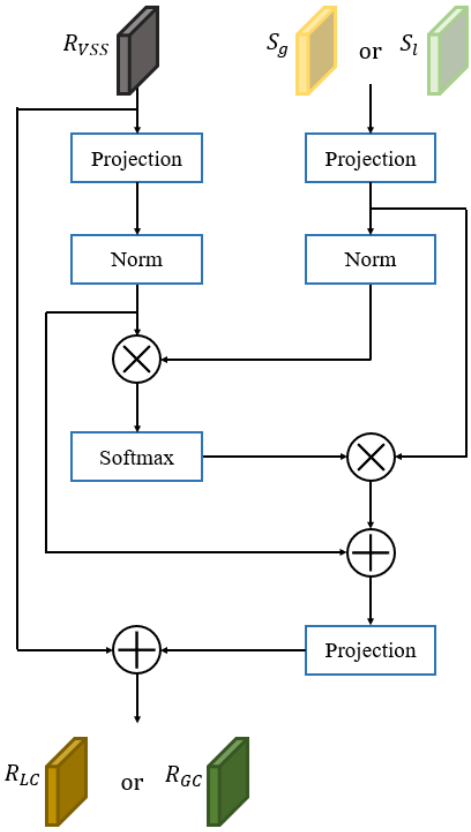

图 4-5 补偿模块的流程
Fig 4-5 Process of compensation module

4.3 基于预热状态空间模型的语义分割框架

基于预热的状态空间模型和信息补偿模块，本章提出基于预热状态空间模型

的语义分割框架 PH-Mamba。PH-Mamba 主要由主干网络、粗分割辅助模块、信息补偿模块和隐式查询解码器组成，网络结构如图 4-6 的左图所示。其中粗分割辅助模块和信息补偿模块构成了预热的视觉状态空间（PreHeating Visual State Space, PH-VSS）模块，如图 4-6 的右图所示。主干网络负责对图像特征进行逐层提取，并生成一个粗分割图用于上下文辅助；粗分割辅助模块从粗分割图和特征图中生成辅助特征图，并和原特征图先后输入预热状态空间模型中；信息补偿模块用于提取原特征图的局部和全局语义信息，并通过补偿模块将其恢复至输出特征图中；隐式查询解码器则根据第三章的内容进行信息增强和解码预测。

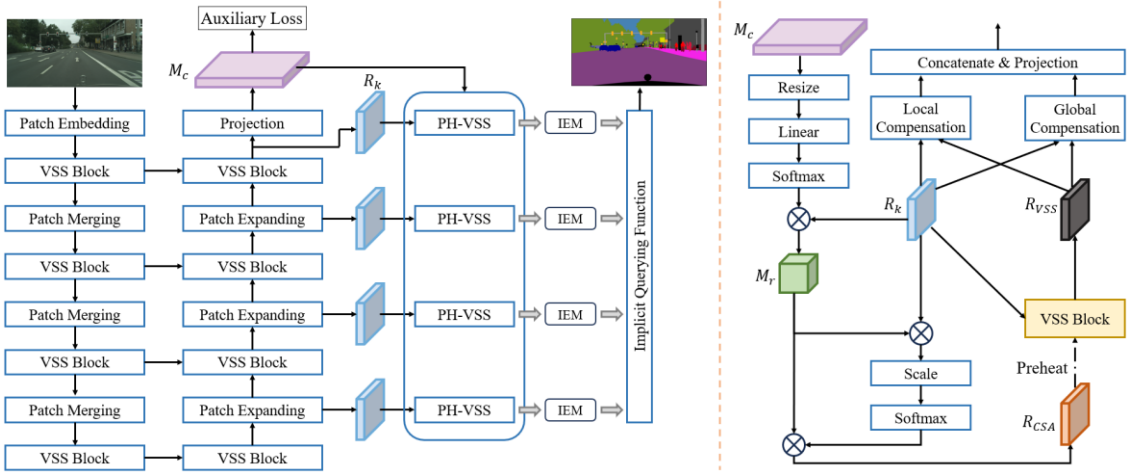

图 4-6 基于预热状态空间模型的语义分割框架

Fig 4-6 Semantic segmentation framework based on preheating state space model

整个网络的分割流程如下：

（1）将图像输入主干网络 Mamba-UNet 中，将图像映射为块进行序列建模操作，并通过块聚合和块拓展操作进行特征图尺度的调整，得到四阶段特征图，其中最高层的特征图尺寸为原图尺寸的$1/4$，尺寸逐层减少$1/2$，通道数逐层增加$1/2$。

（2）对主干网络的最终层输出映射得到粗分割图，并通过辅助损失函数进行监督，保证粗分割的精度。该粗分割图被投入每层的 PH-VSS 模块中，和特征图一同用于生成粗分割辅助特征图，并完成预热状态空间模型的算法流程。

（3）对原特征图进行局部和全局信息的提取和补偿，恢复因重复输入导致丢失的语义信息。

（4）各层的状态空间模型输出结果输入到隐式查询解码器的信息增强模块进行信息增强，并聚合输入到隐式查询函数得到分割图，对分割图进行 4 倍上采样得到最终分割预测结果。

4.4 实验与分析

4.4.1 实验设置

本节的实验环境和实验细节与第三章基本一致。为了实现更有效的粗分割，在训练阶段，除了最终预测时的交叉熵损失函数L_{pred}以外，本节还使用了一个辅助交叉熵损失函数L_{aux}来监督粗分割图的预测结果。此时，整个网络的总损失函数L为这两个子损失函数的加权和，表示为：

$$L = \lambda_1 L_{pred} + \lambda_2 L_{aux} \tag{4-1}$$

其中λ_1和λ_2是控制L_{pred}和L_{aux}两个损失函数之间平衡的权重。在实验中，我们设置这两个参数为$\lambda_1 = 1$和$\lambda_2 = 0.4$。

4.4.2 消融实验

为了验证信息提取和补偿操作的有效性，在 Cityscapes 数据集上，本节对局部补偿模块和全局补偿模块进行了消融实验，每一个模块由一个对应的提取模块和一个补偿模块构成。当不添加局部补偿模块和全局补偿模块时，网络的结构包含主干网络 Mamba-UNet、预热状态空间模型和隐式查询解码器三个部分。而当同时使用局部补偿模块和全局补偿模块时，二者的输出将被经过一次拼接和投影来得到最终的输出。

表 4-1 局部补偿模块和全局补偿模块的消融实验

Table 4-1 Ablation study of local compensation module and global compensation module

方法	LC	GC	PA(%)	mIoU(%)
PH-Mamba			96.59	81.22
	√		96.60	81.31
		√	96.62	81.40
	√	√	**96.67**	**81.79**

表 4-1 展示了分别添加局部补偿模块和全局补偿模块以及同时添加这两个模块后在 Cityscapes 数据集上的分割精度。从实验结果中可以看出，在预热状态空间模型的基础上，只添加局部补偿模块和只添加全局补偿模块带来的性能提升有限，分别为 0.01%的 PA 和 0.09%的 mIoU，以及 0.03%的 PA 和 0.18%的 mIoU。这一现象是可预测的，因为只对单一信息进行优化会导致不完全的信息补偿，从而影响分割的效果。而当同时添加局部补偿模块和全局补偿模块时，两项指标则分别来到了 96.67%的 PA 和 81.79%的 mIoU，提升了 0.08%的 PA 和 0.57%的 mIoU，证明了信息补偿模块组合对预热状态空间模型的积极效果。

表 4-2 不同预热状态空间模型结构的比较实验

Table 4-2 Comparison of different preheating state space model structures

辅助特征序列	参数A和D	PA(%)	mIoU(%)
顺序	共享	96.60	81.49
顺序	独立	96.64	81.57
逆序	共享	96.61	81.62
逆序	独立	**96.67**	**81.79**

表 4-2 显示了不同预热状态空间模型结构配置的分割精度比较。从数据中可以看出，当辅助特征序列被逆序输入时，模型能正确地建模序列内部的长距离依赖，从而产生更好的效果，在参数共享时提升了 0.01%的 PA 和 0.13%的 mIoU，在参数独立时提升了 0.03%的 PA 和 0.22%的 mIoU。同时，对两个特征序列采用独立的输入无关参数A和D也能提升一定的效果，在顺序输入辅助特征序列时提升了 0.04%的 PA 和 0.08%的 mIoU，在逆序输入时提升了 0.06%的 PA 和 0.17%的 mIoU。综合以上实验结果，本文采取逆序输入辅助特征序列和独立参数的配置进行实验。

4.4.3 对比实验

为了进一步验证本章提出的网络 PH-Mamba 的有效性，本节将其性能与其他方法进行了比较。

表 4-3 与其他方法的对比实验

Table 4-3 Comparison experiments with other methods

方法	主干网络	Cityscapes		ADE20K	
		PA(%)	mIoU(%)	PA(%)	mIoU(%)
FADC	ResNet-50	96.47	80.63	80.99	43.56
CARAFE	HRNet-w32	96.37	79.65	80.45	42.20
PointRend	HRNet-w32	96.49	80.73	80.33	42.13
PlainMamba	L1-UperNet	96.58	81.15	81.07	44.31
VMamba	VMamba-T	96.49	80.34	81.19	44.68
Mamba-UNet	VMamba-T	96.55	80.71	81.16	45.19
IRQNet	HRNet-w32	96.54	80.76	81.03	44.04
PH-Mamba	VMamba-T	**96.67**	**81.79**	**81.36**	**46.25**

表 4-3 显示了 PH-Mamba 与其他方法在 Cityscapes 和 ADE20K 数据集上的性能比较。数据显示 PH-Mamba 在 Cityscapes 数据集上取得了 96.67%的 PA 和 81.79%的 mIoU，在 ADE20K 数据集上取得了 81.36%的 PA 和 46.25%的 mIoU，相对于第三章提出的 IRQNet 表现有一定的提升，具备优秀的分割效果。在与 Mamba 相关方法的比较中，PH-Mamba 相对于其基线模型 Mamba-UNet，在两个数据集上主要评价指标 mIoU 分别提升了 1.08%和 1.06%，在所有方法中效果最好。这说明本章的方法一定程度上提升了分割精度，体现了在语义分割任务上的有效性。

4.4.4 实验结果可视化

本节对第三章的 IRQNet 和本章的 PH-Mamba 的部分实验结果进行了可视化，以此来更直观地对比方法效果。可视化结果如图 4-7 和图 4-8 所示，从左到右以此为原图、IRQNet、PH-Mamba 和真实值的分割图。从可视化结果中可以看出，PH-Mamba 具备更出色的语义一致性，对于复杂区域的分割效果更好，如图 4-7 中第一行内部变化丰富的“卡车”标签，第二行由于光照条件差而导致特征不足的“墙”标签，和第三行纹理特征不显著的“道路”标签，以及图 4-8 中第一行由于光照条件差而模糊的“草场”标签，第二行由于光照剧烈变化而导致特征变化的“墙壁”标签，和第三行特征相近的“建筑物”标签和“摩天大楼”标签。在这些区域中，模型需要通

过全局上下文对类特征进行关联，从而生成连续的区域。这体现了本章提取并利用类与特征关系上下文的效果，证实了预热机制能有效地将上下文信息融入状态空间模型，显著增强了语义区域的一致性。

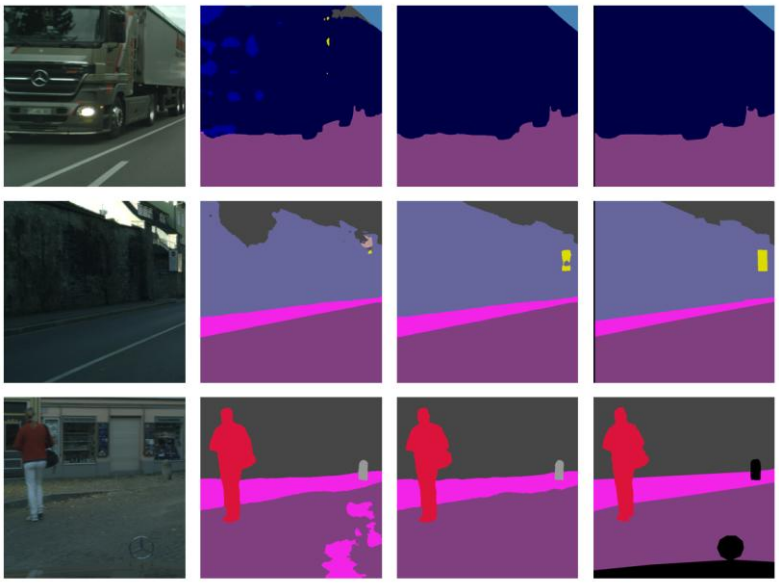

(a) Image (b) IRQNet (c) PH-Mamba (d) Ground truth

图 4-7 不同方法在 Cityscapes 数据集上的可视化结果

Fig 4-7 Visualization results of different models on Cityscapes dataset

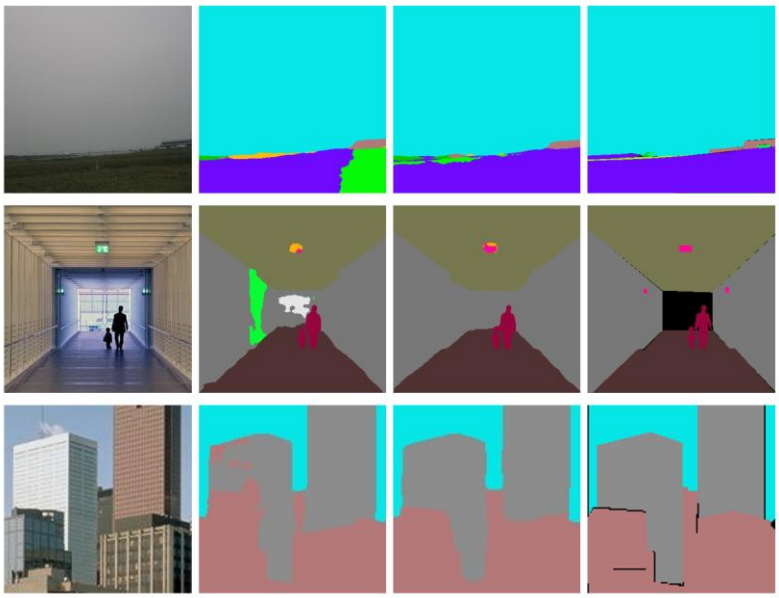

(a) Image (b) IRQNet (c) PH-Mamba (d) Ground truth

图 4-8 不同方法在 ADE20K 数据集上的可视化结果

Fig 4-8 Visualization results of different models on ADE20K dataset

4.5 本章小结

本章针对图像的复杂区域分割效果和语义区域的一致性问题，提出了一种基于状态空间模型的语义分割方法。提取并使用类与特征间关系的上下文，来对状态空间模型进行预热，从而融合图像的全局关联信息来提高分割效果。针对预热状态空间模型中的重复输入引发的模型偏好问题，本章提出了一种信息补偿模块，包括局部提取模块、全局提取模块和补偿模块，来提取并恢复预热过程中丢失的部分语义信息。为了验证本章的方法的有效性，分别在 Cityscapes 数据集和 ADE20K 数据集上进行了消融实验、对比实验，并对实验结果进行了可视化分析。

第五章　结论与展望

本文针对现有的语义分割方法中遇到的各项问题，首先提出了一种基于隐式神经表示的语义分割方法，用隐式神经表示的查询解码器代替上采样解码器，并设计了信息增强模块来提高隐式神经表示的效果。其次利用类与特征间关系上下文，提出了一种预热的状态空间模型方法，并通过信息补偿模块来提取并恢复部分语义信息。最后在 Cityscapes 数据集和 ADE20K 数据集上进行相应实验证明了本文提出的方法在语义分割任务中的有效性。

5.1 工作总结

本文的主要工作内容可总结如下：

（1）针对上采样解码引发的边缘模糊问题，将隐式神经表示方法引入语义分割任务中，提出了基于隐式神经表示的语义分割方法。根据逐坐标的隐式神经表示形式，提出根据特征信息和位置信息来查询最终的解码结果，形成查询形式的解码过程，来提高类间边界的分割精度。

（2）提出了基于特征信息和位置关注信息的信息增强模块，来对语义分割这一像素级任务进行更准确的预测。该模块中的可变形融合模块让特征向量能够自适应地聚合局部上下文信息，并逐像素生成对上下文的位置关注信息，该模块的小波位置编码则用小波函数对位置关注信息进行编码，提高网络的学习能力。本文在 Cityscapes 数据集和 ADE20K 数据集上进行了一系列实验，表明了方法提高语义分割预测效果和解决边缘模糊问题的有效性。

（3）为了进一步利用自然图像中丰富的全局关联信息，提高复杂区域的分割效果和语义区域的一致性，本文引入了状态空间模型，并提出了一种预热机制来聚合上下文信息。本文利用粗分割图进行辅助，提取了类与特征间关系的上下文，通过将粗分割辅助增强的特征预输入给状态空间模型，来提前建立对关键上下文的关注，有效利用了图像中的上下文信息。

（4）针对预热状态空间模型中重复输入导致对特定信息的偏好，从而引发的语义信息丢失问题，本文设计了一种信息补偿模块，来对丢失的信息进行对应的提取和补偿。该模块包含局部提取模块、全局提取模块和补偿模块，通过提取模块从原特征图中提取相应信息，并使用补偿模块将信息聚合至输出特征图。本文通过消融实验证明了信息补偿模块的有效性，并通过对比不同方法的分割精度和可视化结果，证明了该方法在提高复杂区域的语义一致性方面的效果。

5.2 课题展望

本文提出的基于隐式神经表示和预热状态空间模型的语义分割方法能从一定程度上改善语义分割的分割精度，但是仍存在一些不足，需要对其进行进一步优化。未来的改进方向可以分为以下几部分：

（1）在数据集中存在一定数量的难类别，即拥有相似外观的几个类别，例如“人”和“骑手”、“道路”和“人行道”等。这种情况在遮挡情况下尤为常见，而自然场景图像中存在大量的遮挡，很大程度地影响了分割的精度，却又难以从图像层面进行解决。未来可以研究多源数据（如 RGB-D、红外和文本描述）的语义分割方法，用多模态信息提升复杂场景下的分割精度，设计跨模态的特征对齐方法，解决单一模态信息不足的问题。

（2）在语义分割任务中，数据集的标注成本极高，需要消耗大量人力和财力，因此需要降低对像素级标注数据的依赖，研究利用弱标签（如图像级标签、草图标注）或少量样本进行高精度分割的方法。未来可以从自监督或弱监督方法着手，减少像素级标注数据的使用量，突破像素标注的应用瓶颈。

（3）在语义分割的下游任务，例如移动端、嵌入式设备或实时场景等应用场景下，需要参数量小、推理速度快且高精度的语义分割模型，但本文提出的方法具有较多的模型参数量和较大的计算开销。因此，未来可以探索知识蒸馏和模型量化等方法对模型进行压缩，得到一个计算更快，参数量更少，而分割精度相当的模型。

参 考 文 献

[1] Hofmarcher M, Unterthiner T, Arjona-Medina J, et al. Visual scene understanding for autonomous driving using semantic segmentation[J]. *Explainable AI: Interpreting, Explaining and Visualizing Deep Learning*, 2019: 285-296.

[2] 余鹰, 余家茂, 钱进, 等. 联合场景理解与多尺度特征融合的人群计数方法. 小型微型计算机系统, 2024, 45(11): 2673-2681.

[3] Bindhu V. Biomedical image analysis using semantic segmentation[J]. *Journal of Innovative Image Processing (JIIP)*, 2019, 1(02): 91-101.

[4] 李佳燨, 刘红英, 万亮 基于深度学习的医学图像分析域自适应研究. 计算机应用研究, 2024, 41(05): 1291-1300.

[5] Milan A, Pham T, Vijay K, et al. Semantic segmentation from limited training data[C]//2018 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2018: 1908-1915.

[6] 李亚宏, 周城旭, 段立娟, 等. 基于机器感知与学习的空气颗粒物智能检测、识别与预警方法研究综述. 北京工业大学学报, 2024, 50(02): 195-206.

[7] Patil P W, Dudhane A, Kulkarni A, et al. An unified recurrent video object segmentation framework for various surveillance environments[J]. *IEEE Transactions on Image Processing*, 2021, 30: 7889-7902.

[8] 刘云萍 基于神经网络的视频监控图像异常行为识别方法. 数字通信世界, 2023, (07): 71-73.

[9] Zhang H, Han B, Ip C Y, et al. Slimmer: Accelerating 3D semantic segmentation for mobile augmented reality[C]//2020 IEEE 17th International Conference on Mobile Ad Hoc and Sensor Systems (MASS). IEEE, 2020: 603-612.

[10] 卞贤掌, 费海平, 李世强 基于语义分割的增强现实图像配准技术. 电子技术与软件工程, 2018, (23): 79-82.

[11] Akbari M, Liang J, Han J. DSSLIC: Deep semantic segmentation-based layered image compression[C]//ICASSP 2019-2019 IEEE International Conference on

Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2019: 2042-2046.

[12] 吕超, 曹靖城, 周帅 基于深度学习的分形图像压缩编码模型设计. 信息技术, 2023, 47(01): 137-142.

[13] Otsu N. A threshold selection method from gray-level histograms[J]. *IEEE transactions on systems, man, and cybernetics*, 1979, 9(1): 62-66.

[14] Dhanachandra N, Manglem K, Chanu Y J. Image segmentation using K-means clustering algorithm and subtractive clustering algorithm[J]. *Procedia Computer Science*, 2015, 54: 764-771.

[15] Najman L, Schmitt M. Watershed of a continuous function[J]. *Signal Processing*, 1994, 38(1): 99-112.

[16] Kass M, Witkin A, Terzopoulos D. Snakes: Active contour models[J]. *International journal of computer vision*, 1988, 1(4): 321-331.

[17] Boykov Y, Veksler O, Zabih R. Fast approximate energy minimization via graph cuts[J]. *IEEE Transactions on pattern analysis and machine intelligence*, 2001, 23(11): 1222-1239.

[18] Plath N, Toussaint M, Nakajima S. Multi-class image segmentation using conditional random fields and global classification[C]//Proceedings of the 26th annual international conference on machine learning. 2009: 817-824.

[19] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 3431-3440.

[20] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.

[21] Sun K, Zhao Y, Jiang B r, et al. High-resolution representations for labeling pixels and regions[J]. *arXiv preprint arXiv:190404514*, 2019.

[22] 范九伦, 雷博 灰度图像最小误差阈值分割法的二维推广. 自动化学报, 2009, 35(04): 386-393.

[23] Sahoo P K, Arora G. A thresholding method based on two-dimensional Renyi's entropy[J]. *Pattern Recognition*, 2004, 37(6): 1149-1161.

[24] Wei W, Shen X, Qian Q. A local Threshold Segmentation method based on multi-direction grayscale wave[C]//2010 Fifth International Conference on Frontier of Computer Science and Technology. IEEE, 2010: 166-170.

[25] Marr D, Hildreth E. Theory of edge detection[J]. *Proceedings of the Royal Society of London Series B Biological Sciences*, 1980, 207(1167): 187-217.

[26] Couprie C, Grady L, Najman L, et al. Power watershed: A unifying graph-based optimization framework[J]. *IEEE transactions on pattern analysis and machine intelligence*, 2010, 33(7): 1384-1399.

[27] Mignotte M. Segmentation by fusion of histogram-based $ k $-means clusters in different color spaces[J]. *IEEE Transactions on image processing*, 2008, 17(5): 780-787.

[28] Rother C, Kolmogorov V, Blake A. " GrabCut" interactive foreground extraction using iterated graph cuts[J]. *ACM transactions on graphics (TOG)*, 2004, 23(3): 309-314.

[29] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. *Proceedings of the IEEE*, 1998, 86(11): 2278-2324.

[30] Zhao H, Shi J, Qi X, et al. Pyramid scene parsing network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2881-2890.

[31] Chen L-C, Papandreou G, Schroff F, et al. Rethinking atrous convolution for semantic image segmentation[J]. *arXiv preprint arXiv:170605587*, 2017.

[32] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.

[33] Fu J, Liu J, Tian H, et al. Dual attention network for scene segmentation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 3146-3154.

[34] Gu J, Wang Z, Kuen J, et al. Recent advances in convolutional neural networks[J]. *Pattern recognition*, 2018, 77: 354-377.

[35] Hubel D H, Wiesel T N. Receptive fields and functional architecture of monkey striate cortex[J]. *The Journal of physiology*, 1968, 195(1): 215-243.

[36] Fukushima K. Neocognitron: A self-organizing neural network model for a

mechanism of pattern recognition unaffected by shift in position[J]. *Biological cybernetics*, 1980, 36(4): 193-202.

[37] LeCun Y, Boser B, Denker J, et al. Handwritten digit recognition with a back-propagation network[J]. *Advances in neural information processing systems*, 1989, 2.

[38] Zhang W, Itoh K, Tanida J, et al. Parallel distributed processing model with local space-invariant interconnections and its optical architecture[J]. *Applied optics*, 1990, 29(32): 4790-4797.

[39] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. *Advances in neural information processing systems*, 2012, 25.

[40] Zeiler M D, Fergus R. Visualizing and understanding convolutional networks[C]//European conference on computer vision. Springer, 2014: 818-833.

[41] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. *arXiv preprint arXiv:14091556*, 2014.

[42] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 1-9.

[43] Yu F, Koltun V. Multi-scale context aggregation by dilated convolutions[J]. *arXiv preprint arXiv:151107122*, 2015.

[44] Dai J, Qi H, Xiong Y, et al. Deformable convolutional networks[C]//Proceedings of the IEEE international conference on computer vision. 2017: 764-773.

[45] Yu D, Wang H, Chen P, et al. Mixed pooling for convolutional neural networks[C]//Rough Sets and Knowledge Technology: 9th International Conference, RSKT 2014, Shanghai, China, October 24-26, 2014, Proceedings 9. Springer, 2014: 364-375.

[46] Zeiler M D, Fergus R. Stochastic pooling for regularization of deep convolutional neural networks[J]. *arXiv preprint arXiv:13013557*, 2013.

[47] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. *IEEE transactions on pattern analysis and machine intelligence*, 2015, 37(9): 1904-1916.

[48] Maas A L, Hannun A Y, Ng A Y. Rectifier nonlinearities improve neural network acoustic models[C]//Proc icml. Atlanta, GA, 2013: 3.

[49] He K, Zhang X, Ren S, et al. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1026-1034.

[50] Clevert D-A. Fast and accurate deep network learning by exponential linear units (elus)[J]. *arXiv preprint arXiv:151107289*, 2015.

[51] Chen L-C, Zhu Y, Papandreou G, et al. Encoder-decoder with atrous separable convolution for semantic image segmentation[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 801-818.

[52] Lin T-Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2117-2125.

[53] Liu S, Qi L, Qin H, et al. Path aggregation network for instance segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 8759-8768.

[54] Wang W, Xie E, Song X, et al. Efficient and accurate arbitrary-shaped text detection with pixel aggregation network[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 8440-8449.

[55] Yuan Y, Fu R, Huang L, et al. Hrformer: High-resolution vision transformer for dense predict[J]. *Advances in neural information processing systems*, 2021, 34: 7281-7293.

[56] Park J J, Florence P, Straub J, et al. Deepsdf: Learning continuous signed distance functions for shape representation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 165-174.

[57] Atzmon M, Lipman Y. Sal: Sign agnostic learning of shapes from raw data[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 2565-2574.

[58] Mescheder L, Oechsle M, Niemeyer M, et al. Occupancy networks: Learning 3d reconstruction in function space[C]//Proceedings of the IEEE/CVF conference on

computer vision and pattern recognition. 2019: 4460-4470.

[59] Chen Z, Zhang H. Learning implicit fields for generative shape modeling[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 5939-5948.

[60] Mildenhall B, Srinivasan P P, Tancik M, et al. Nerf: Representing scenes as neural radiance fields for view synthesis[J]. *Communications of the ACM*, 2021, 65(1): 99-106.

[61] Chen Y, Liu S, Wang X. Learning continuous image representation with local implicit image function[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 8628-8638.

[62] Hu H, Chen Y, Xu J, et al. Learning implicit feature alignment function for semantic segmentation[C]//Computer Vision–ECCV 2022: 17th European Conference, Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part XXIX. Springer, 2022: 487-505.

[63] Kirillov A, Wu Y, He K, et al. Pointrend: Image segmentation as rendering[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 9799-9808.

[64] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. *Advances in neural information processing systems*, 2017, 30.

[65] Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[J]. *arXiv preprint arXiv:231200752*, 2023.

[66] Gu A, Goel K, Ré C. Efficiently modeling long sequences with structured state spaces[J]. *arXiv preprint arXiv:211100396*, 2021.

[67] Liu Y, Tian Y, Zhao Y, et al. Vmamba: Visual state space model[J]. *arXiv preprint arXiv:240110166*, 2024.

[68] Wang Z, Zheng J-Q, Zhang Y, et al. Mamba-unet: Unet-like pure visual mamba for medical image segmentation[J]. *arXiv preprint arXiv:240205079*, 2024.

[69] Xu X, Wang Z, Shi H. Ultrasr: Spatial encoding is a missing key for implicit image function-based arbitrary-scale super-resolution[J]. *arXiv preprint arXiv:210312716*, 2021.

[70] Verbin D, Hedman P, Mildenhall B, et al. Ref-nerf: Structured view-dependent appearance for neural radiance fields[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2022: 5481-5490.

[71] Rahaman N, Baratin A, Arpit D, et al. On the spectral bias of neural networks[C]//International Conference on Machine Learning. PMLR, 2019: 5301-5310.

[72] Cohen M X. A better way to define and describe Morlet wavelets for time-frequency analysis[J]. *NeuroImage*, 2019, 199: 81-86.

[73] Cordts M, Omran M, Ramos S, et al. The cityscapes dataset for semantic urban scene understanding[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 3213-3223.

[74] Zhou B, Zhao H, Puig X, et al. Scene parsing through ade20k dataset[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 633-641.

[75] Csurka G, Larlus D, Perronnin F, et al. What is a good evaluation measure for semantic segmentation?[C]//Bmvc. Bristol, 2013: 10-5244.

[76] Deng J, Dong W, Socher R, et al. Imagenet: A large-scale hierarchical image database[C]//2009 IEEE conference on computer vision and pattern recognition. Ieee, 2009: 248-255.

[77] Zhang H, Wu C, Zhang Z, et al. Resnest: Split-attention networks[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 2736-2746.

[78] Xu J, Xiong Z, Bhattacharyya S P. PIDNet: A Real-Time Semantic Segmentation Network Inspired by PID Controllers[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 19529-19539.

[79] Chen L, Gu L, Zheng D, et al. Frequency-Adaptive Dilated Convolution for Semantic Segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 3414-3425.

[80] Wang J, Chen K, Xu R, et al. Carafe: Content-aware reassembly of features[C]//Proceedings of the IEEE/CVF international conference on computer

vision. 2019: 3007-3016.

[81] Huang Z, Wei Y, Wang X, et al. Alignseg: Feature-aligned segmentation networks[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2021, 44(1): 550-557.

[82] Liu Y, Tian Y, Zhao Y, et al. Vmamba: Visual state space model[J]. *Advances in neural information processing systems*, 2024, 37: 103031-103063.

[83] Yang C, Chen Z, Espinosa M, et al. PlainMamba: Improving Non-Hierarchical Mamba in Visual Recognition[J]. *arXiv preprint arXiv:240317695*, 2024.

[84] Liu Z, Lin Y t, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 10012-10022.

作者简历及在学期间所获得的学术成果

1. 作者简历

陈诺，男，2000 年 4 月 4 日生，于 2022 年 9 月 1 日考入东华大学计算机科学与技术学院计算机科学与技术专业，从事语义分割方向研究，完成学业并撰写了学位论文《基于隐式神经表示和预热状态空间模型的语义分割》。

2. 教育背景

2018 年 9 月~2022 年 6 月， 东华大学，本科，专业：软件工程

2022 年 9 月~2025 年 6 月， 东华大学，硕士研究生，专业：计算机科学与技术

3. 在学期间获得的学术成果

[1] Chen N, Wang S, Lu R, et al. PHMamba: Preheating State Space Models with Context-Augmented Features for Medical Image Segmentation[C]//ICASSP 2025-2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2025: 1-5. （**第一作者**，CCF-B，已发表）

[2] Chen N, Wang S, Lu R, et al. Clothing Parsing Based on Multi-Scale Fusion and Improved Self-Attention Mechanism[J]. Journal of Donghua University (English Edition), 2023, 40(6). （**第一作者**，已发表）

[3] Li W, Wang S, Chen N, et al. EDGRNet: An Error Detection and Guided Refinement Network for Skin Lesion Segmentation[C]//2025 International Joint Conference on Neural Networks (IJCNN). IEEE, 2025: 1-8. （第三作者，已录用）

[4] Li W, Wang S, Chen N, et al. Uncertainty-Guided Prototype Mixture Model for Skin Lesion Segmentation[C] //2025 International Joint Conference on Neural Networks (IJCNN). IEEE, 2025: 1-8. （第三作者，已录用）

[5] Ye S, Wang S, Chen N, et al. OMNet: Outfit Memory Net for clothing parsing[J].

International Journal of Clothing Science and Technology, 2023, 35(3): 493-505. （第三作者，已发表）

[6] Ding H, Wang S, Huang Z, et al. External attention augmented Swin-UNet network for semi-supervised cardiac image segmentation[C]//Third International Conference on Computer Vision and Pattern Analysis (ICCPA 2023). SPIE, 2023, 12754: 215-219. （第四作者，已发表）

[7] Teng Z, Wang S, Luo X, et al. WDSF-Mamba: Clothing Parsing via Wavelet Domain Spatial-Frequency Mamba[C]//2025 International Joint Conference on Neural Networks (IJCNN). IEEE, 2025: 1-7. （第五作者，已录用）

4. 在学期间参与科研项目情况

无

致　谢

行文至此，落笔为终。回首在东华的七年漫漫求学路，感慨万千。在此谨向所有给予我指导、帮助与支持的师长、亲友致以最诚挚的谢意。

首先，衷心感谢我的导师王绍宇老师。时光荏苒，转眼间拜入王老师门下已有三年，初见时的诚挚交谈却仿佛还在昨日。王老师不仅学识渊博，总能用丰富的经验为我指点一二，那严谨的治学态度、渊博的专业知识和精益求精的科研精神使我受益终身，而且平易近人，在学习和生活中亦师亦友。求学期间王老师给予的支持与鼓励，让我在迷茫时重拾信心，能更加坚定地继续向更高的层次迈进，这份师恩学生将永远铭记。

其次，感谢 721 实验室的同门们，感谢他们在学术交流中给予的科研启发，和在技术难题前提供的无私帮助。感谢 7021 的室友们，他们的陪伴和关怀为这段求学时光增添了温暖亮光。

最后，特别感谢我的家人们，感谢他们在我背后的关怀和陪伴，也感谢他们对我的理解和支持。在迷茫的时候，来自家人的鼓励总能让我重振旗鼓，坚定信念。今后，我将不辜负他们的期望，努力在学术上有所建树。

纸短情长，唯以勤勉回报所有善意。前路漫漫，吾将怀感恩之心继续求索。